Mô hình hồi quy tuyến tính · Mục 1

Từ bài toán dự đoán đến mô hình tuyến tính

Bài toán hồi quy được mô tả toán học thế nào?

Vì sao dùng hàm tuyến tính để xấp xỉ quan hệ?

Có vô số đường thẳng, làm sao chọn một đường tốt?

1.1 Bài toán hồi quy

Hồi quy dự đoán một con số

Hồi quy: "bao nhiêu?"

Giá nhà, nhiệt độ ngày mai, điểm thi. Đầu ra là một **số thực**.

Phân loại: "nhóm nào?"

Thư rác hay thư thường, đậu hay rớt. Đầu ra là một **nhãn** (bài Perceptron).

Dữ liệu: $\mathcal{D} = \{(x_1, y_1), \ldots, (x_n, y_n)\}$, với $y_i \in \mathbb{R}$

Mục tiêu: tìm quy tắc dự đoán ŷ gần y, cả trên dữ liệu mới.

1.1 Ví dụ xuyên suốt

Dự đoán giá nhà theo diện tích

Căn nhà	x (10 m^2)	y (tỷ đồng)	x_i
1	3	1,2	[1 3]
2	4	1,9	[1 4]
3	5	2,4	[1 5]
4	6	3,2	[1 6]
5	7	3,3	[1 7]

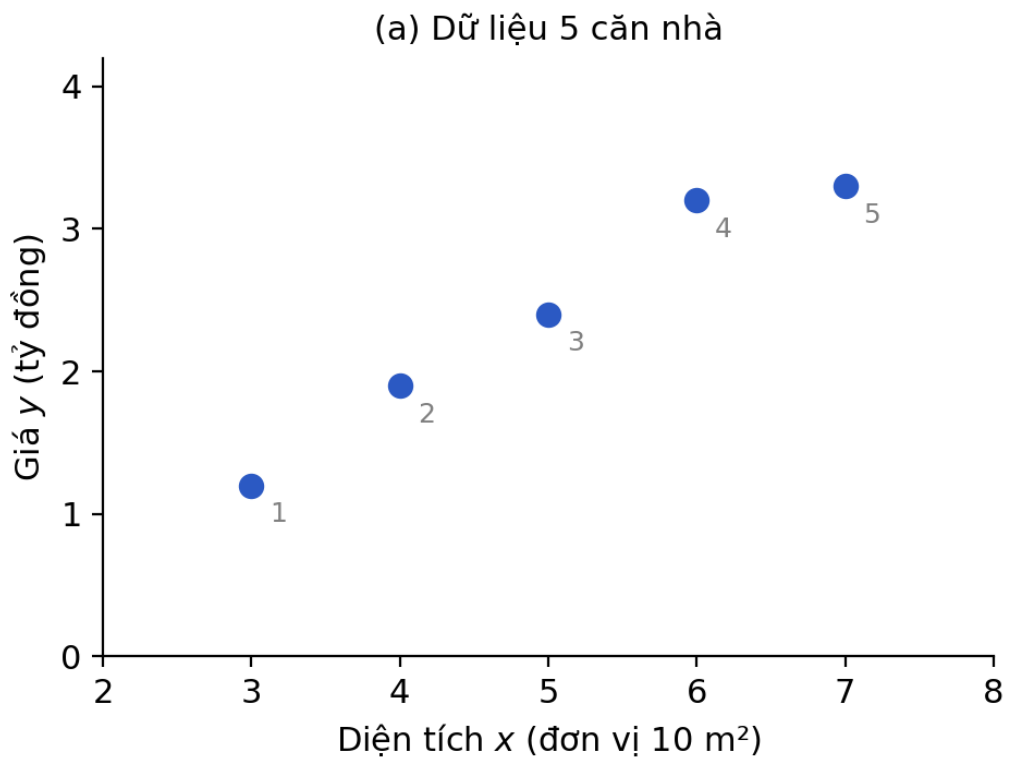
n = 5 mẫu, d = 1 đặc trưng

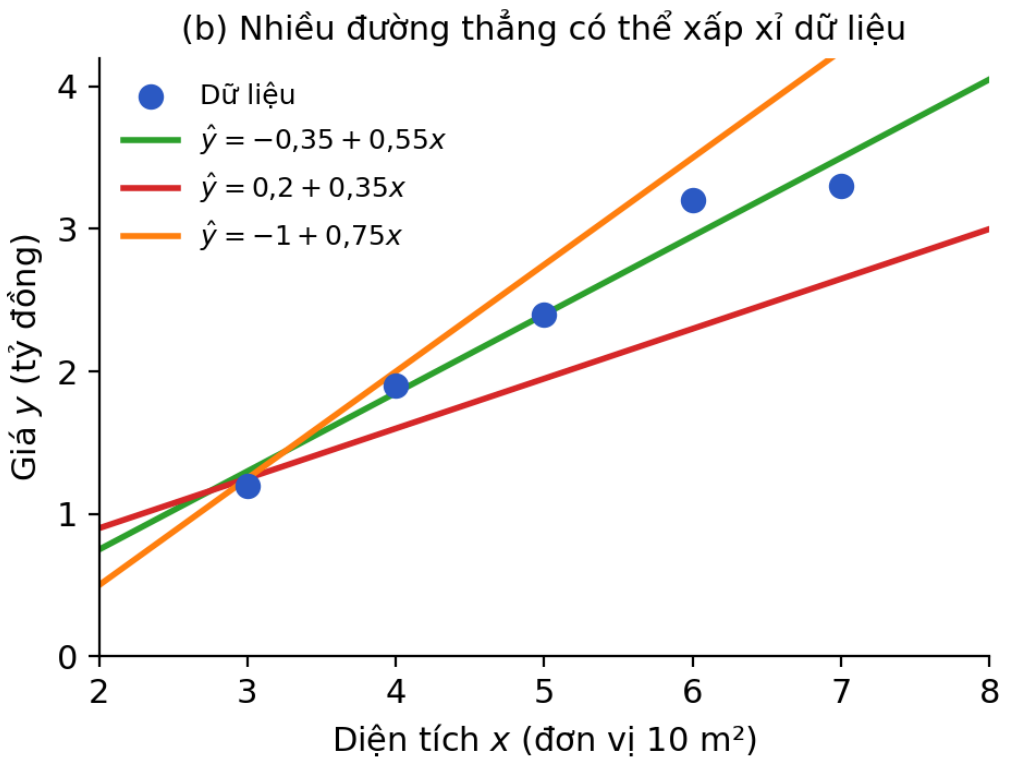
Thêm cột 1 vào đặc trưng, mỗi hàng của **X** là vector hàng x_i

X kích thước 5×2, **y** kích thước 5×1

1.2 Minh họa

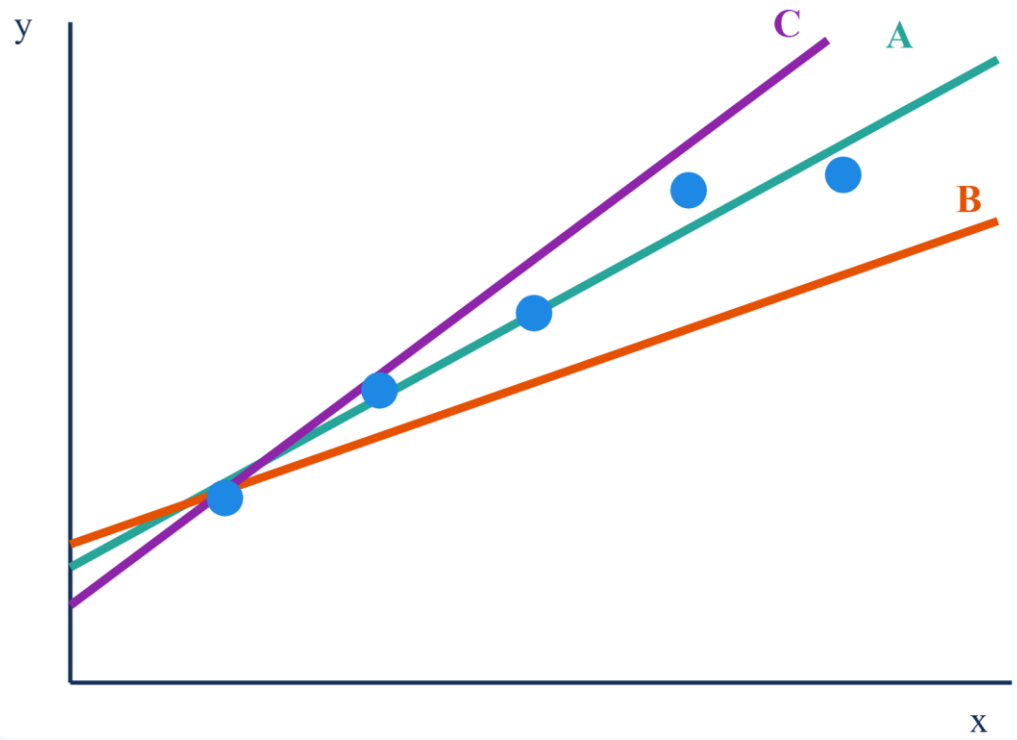
Hình 1. (a) Dữ liệu 5 căn nhà; (b) nhiều đường thẳng cùng xấp xỉ dữ liệu





1.2 Ý tưởng hồi quy tuyến tính

Xấp xỉ bằng đường thẳng $\hat{y} = w_0 + w_1 x$



Giá tăng gần đều theo diện tích, nên ta **giả định quan hệ tuyến tính**. Nhưng có vô số đường như vậy:

A: $\hat{y} = -0{,}35 + 0{,}55x$
Sai số TB bình phương = 0,023

C: $\hat{y} = -1 + 0{,}75x$
Sai số TB bình phương = 0,2255

B: $\hat{y} = 0{,}2 + 0{,}35x$
Sai số TB bình phương = 0,3055

1.2 Khung huấn luyện

Các tham số w lấy ở đâu?

Máy tính tự tìm w từ dữ liệu qua ba thành phần:

Mô hình

Dùng dạng hàm nào?

$\hat{y} = xw$

Mục 2

+

Hàm mất mát

Tham số hiện tại tốt hay kém?

MSE

Mục 3.2

+

Thuật toán tối ưu

Chỉnh tham số thế nào?

Gradient Descent

Mục 3.3 – 3.7

Mô hình + Hàm mất mát + Thuật toán tối ưu = Huấn luyện

Tóm tắt mục 1

Năm ý cần nhớ

- **Hồi quy** dự đoán số thực $y \in \mathbb{R}$, khác với phân loại dự đoán nhãn.
- Dữ liệu là ma trận **X** (mỗi hàng là vector hàng x_i, phần tử đầu bằng 1) và vector **y**.
- Ý tưởng: xấp xỉ bằng hàm tuyến tính $\hat{y} = w_0 + w_1x_1 + \ldots + w_dx_d$.
- Có vô số đường thẳng, nên cần **thước đo sai số** và quá trình **huấn luyện** để tìm **w**.
- Huấn luyện gồm ba thành phần: **mô hình, hàm mất mát, thuật toán tối ưu**.

Câu hỏi kiểm tra nhanh

Thử sức nào!

1. Viết x_3 và y_3 của 5 căn nhà. Ma trận **X** có kích thước bao nhiêu?

2. Hồi quy hay phân loại: (a) thư rác, (b) nhiệt độ ngày mai, (c) phút trễ của chuyến bay, (d) khách rời dịch vụ?

3. Đường B: $\hat{y} = 0{,}2 + 0{,}35x$. Dự đoán nhà 50 m^2 ($x = 5$) lệch bao nhiêu so với $y_3 = 2{,}4$?

4. $n = 100$ mẫu, $d = 3$ đặc trưng: kích thước của x_i, **X** và **w**?

5. Vì sao cần thước đo sai số thay vì chọn đường bằng cách nhìn đồ thị?

Bài giảng hồi quy tuyến tính · Mục 2

Mô hình hồi quy tuyến tính

Tổng có trọng số · Vector và ma trận · Hình học

Tổng có trọng số
2.1

Vector và ma trận
2.2

Hình học
2.3

Mở đầu

Ba câu hỏi của mục 2

Mô hình nhận đầu vào và tính giá trị dự đoán như thế nào? Các tham số có ý nghĩa gì?

Mô hình được viết gọn bằng vector và ma trận ra sao? Sai số dự đoán tính thế nào?

Về hình học, mô hình tạo ra đường (mặt) nào? Tham số điều khiển nó ra sao?

Quy ước ký hiệu

Thống nhất ký hiệu cho cả bài

Đối tượng	Ký hiệu	Kích thước
Vector đặc trưng (hàng) của mẫu i	$\mathbf{x_i} = [1\ x_{i1} \dots x_{id}]$	$1 \times (d+1)$
Ma trận đặc trưng	$\mathbf{X}$ (hàng i là $\mathbf{x}_i$)	$n \times (d+1)$
Vector tham số (cột)	$\mathbf{w} = [w_0\ w_1 \dots w_d]^T$	$(d+1) \times 1$
Vector giá trị thực (cột)	$\mathbf{y}$	$n \times 1$
Dự đoán và sai số	$\hat{y}_i$, $\hat{\mathbf{y}}$; e_i, $\mathbf{e}$	vô hướng; $n \times 1$

Chữ thường in đậm: vector. Chữ hoa in đậm: ma trận.

2.1 Tổng có trọng số

Một “máy dự đoán” hai bước

Bước 1: Nhận đặc trưng

$x_1, x_2, \ldots, x_d$ của một mẫu

→

Bước 2: Tổng có trọng số

Nhân mỗi đặc trưng với trọng số, cộng lại, cộng hằng số điều chỉnh

→

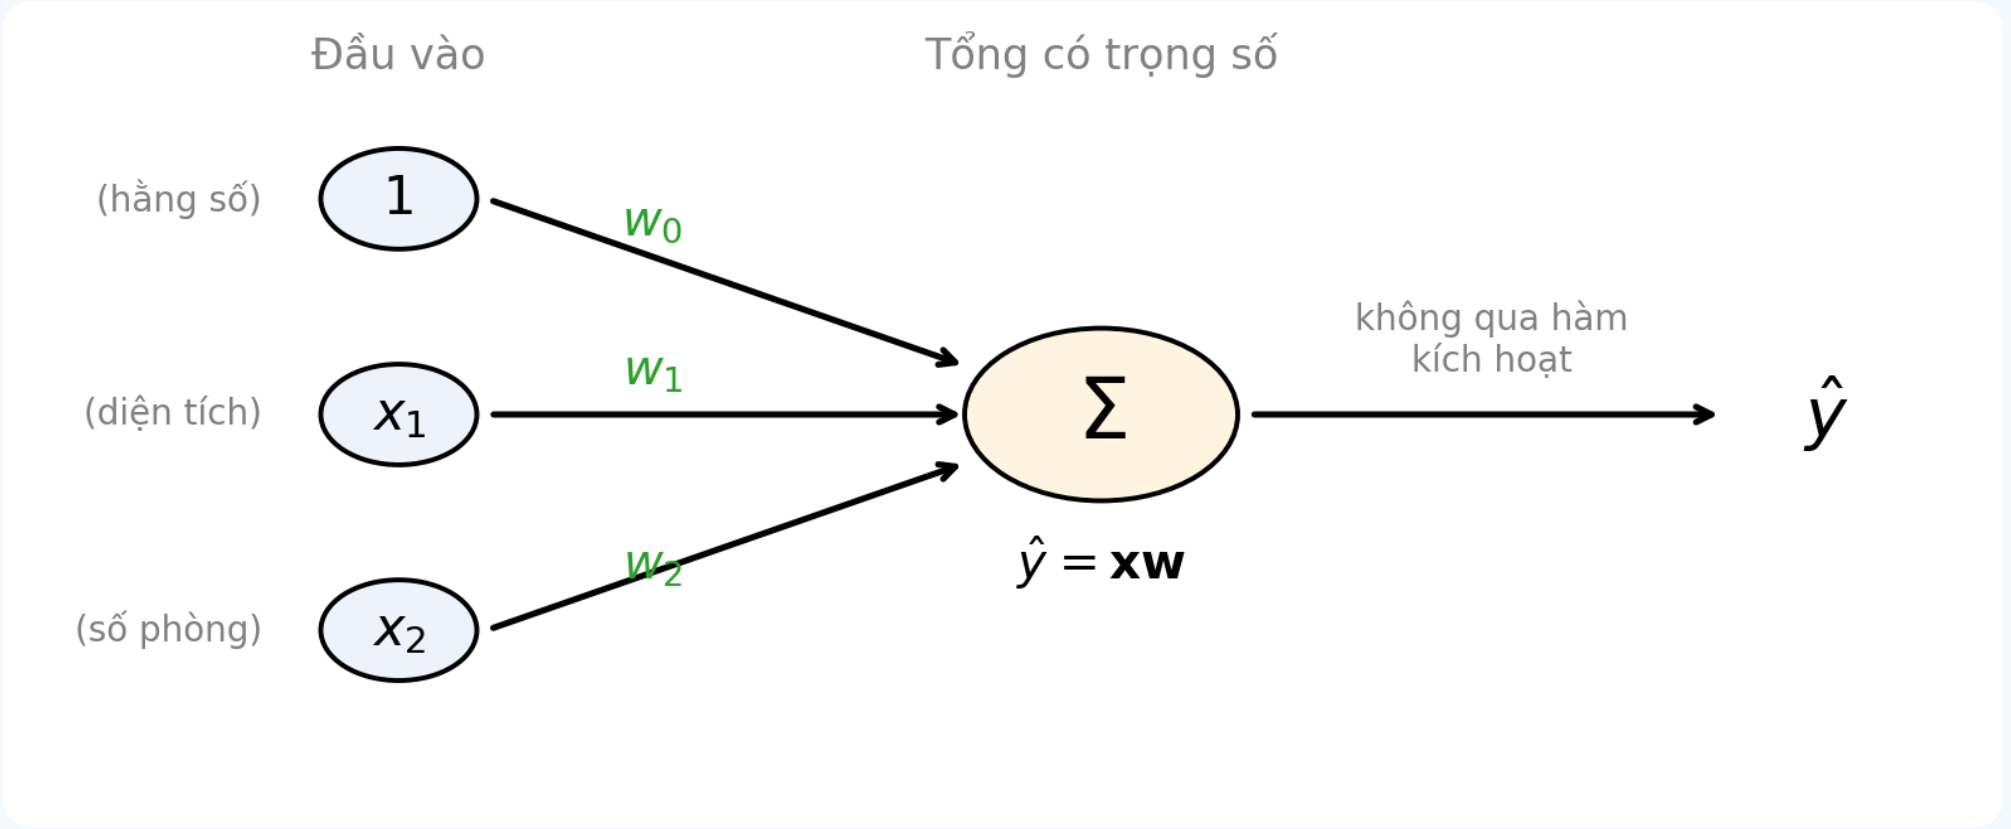
Kết quả

Giá trị dự đoán ŷ, dùng trực tiếp làm đầu ra

Không có hàm kích hoạt (Perceptron sẽ thêm hàm dấu)

2.1 Minh họa

Hình 2. Cấu trúc mô hình hồi quy tuyến tính với hai đặc trưng



2.1 Tổng có trọng số

Công thức dự đoán

$$\hat{y} = w_0 + w_1x_1 + w_2x_2 + \ldots + w_dx_d = w_0 + \sum_j w_jx_j$$

$w_1, \ldots, w_d$: trọng số

Mức độ ảnh hưởng của từng đặc trưng lên ŷ

w_0: hệ số chệch (bias)

Giá trị dự đoán khi mọi đặc trưng bằng 0, “mức khởi điểm”

2.1 Tổng có trọng số

Ý nghĩa của trọng số w_j

x_j tăng 1 đơn vị, các đặc trưng khác giữ nguyên ⇒ ŷ thay đổi w_j đơn vị

$w_j > 0$

x_j tăng làm ŷ **tăng**

$w_j < 0$

x_j tăng làm ŷ **giảm**

$w_j = 0$

Đặc trưng x_j **không ảnh hưởng** đến dự đoán

2.1 Tổng có trọng số

Hệ số chệch w_0

Ý nghĩa

w_0 là giá trị dự đoán khi mọi đặc trưng bằng 0. Hình học: **tung độ gốc** của đường thẳng.

Ví dụ 5 căn nhà

Đường A: $\hat{y} = -0{,}35 + 0{,}55x$
có $w_0 = -0{,}35$: khi $x = 0$, $\hat{y} = -0{,}35$ (giá âm, vô nghĩa)

Mô hình chỉ đáng tin trong khoảng dữ liệu đã quan sát (30 đến 70 m^2)

2.1 Ví dụ

Hai đặc trưng: diện tích và khoảng cách

$$\hat{y} = 0{,}8 + 0{,}045 \cdot x_1 - 0{,}08 \cdot x_2$$

Dữ liệu vào

$x_1 = 70\ m^2$ (diện tích)

$x_2 = 5$ km (đến trung tâm)

Tính toán

$\hat{y} = 0{,}8 + 0{,}045 \cdot 70 - 0{,}08 \cdot 5$

$= 0{,}8 + 3{,}15 - 0{,}4$

Kết quả

$\hat{y} =$ **3,55 tỷ đồng**

2.1 Ví dụ

Đọc các hệ số

$w_1 = 0{,}045$

Mỗi m^2 tăng thêm (giữ nguyên khoảng cách) làm giá dự đoán tăng 0,045 tỷ đồng, tức **45 triệu**

$w_2 = -0{,}08$

Mỗi km xa trung tâm hơn (giữ nguyên diện tích) làm giá dự đoán giảm 0,08 tỷ đồng, tức **80 triệu**

2.1

Hai lưu ý khi diễn giải tham số

Lưu ý 1. Không dùng độ lớn $|w_j|$ để so sánh mức quan trọng nếu các đặc trưng khác thang đo. Ví dụ trước có $|w_2| > |w_1|$, nhưng một đặc trưng tính bằng km, đặc trưng kia bằng m^2.

Lưu ý 2. w_0 chỉ có ý nghĩa thực tế khi giá trị 0 của các đặc trưng nằm trong phạm vi dữ liệu.

2.1 Dạng vector

Thêm số 1 để gộp hệ số chệch

Vector đặc trưng (hàng)

$\mathbf{x} = [1\ x_1 \dots x_d]$

Vector tham số (cột)

$\mathbf{w} = [w_0\ w_1 \dots w_d]^T$

$$\hat{y} = \mathbf{x}\,\mathbf{w} = w_0 \cdot 1 + w_1 x_1 + \dots + w_d x_d$$

Số 1 được nhân với w_0, nên hệ số chệch nằm cùng một phép nhân với các trọng số.

Một mẫu: tích hàng và cột

$$\hat{y}_i = \mathbf{x}_i\mathbf{w} = w_0 + w_1x_{i1} + \ldots + w_dx_{id}$$

$\mathbf{x}_i$
$1 \times (d+1)$
vector hàng

$\times$

$\mathbf{w}$
$(d+1) \times 1$
vector cột

$=$

$\hat{\mathbf{y}}_i$
1×1
một số

2.2 Vector và ma trận

Toàn bộ n mẫu cùng lúc

$$\hat{\mathbf{y}} = [\hat{y}_1; \hat{y}_2; \ldots; \hat{y}_n] = [\mathbf{x}_1\mathbf{w}; \mathbf{x}_2\mathbf{w}; \ldots; \mathbf{x}_n\mathbf{w}] = \mathbf{X}\,\mathbf{w}$$

$\mathbf{X}$	×	$\mathbf{w}$	=	$\hat{\mathbf{y}}$
$n \times (d+1)$		$(d+1) \times 1$		$n \times 1$

Một phép nhân ma trận cho toàn bộ dự đoán, không cần vòng lặp.

2.2 Sai số dự đoán

Sai số = dự đoán trừ thực tế

$$e_i = \hat{y}_i - y_i, \mathbf{e = \hat{y} - y = X w - y}$$

$e_i > 0$

Dự đoán **cao hơn** thực tế

$e_i < 0$

Dự đoán **thấp hơn** thực tế

$e_i = 0$

Dự đoán **chính xác**

2.2 Ví dụ số

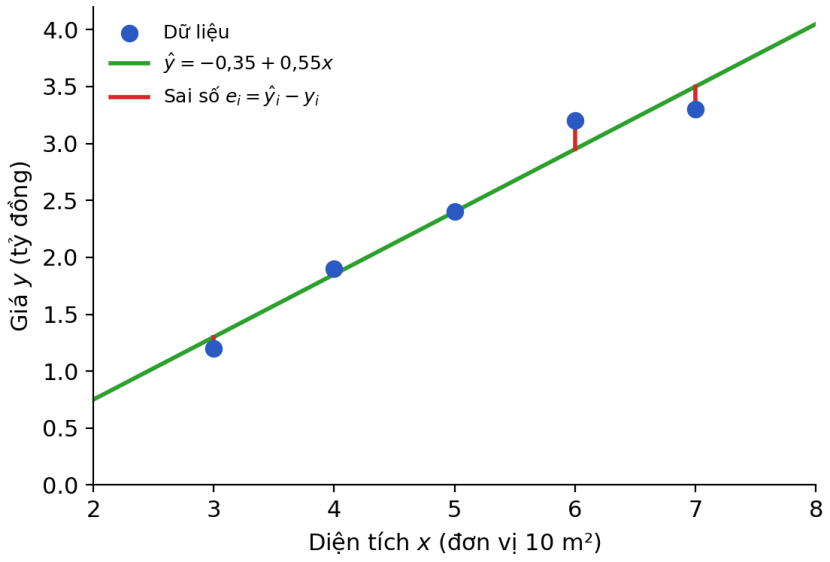
Đường A: $w = [-0{,}35;\ 0{,}55]^T$

Căn nhà	$\mathbf{x_i}$	y_i	$\hat{\mathbf{y}}_i = \mathbf{x}_i\mathbf{w}$	e_i
1	[1 3]	1,2	1,30	0,10
2	[1 4]	1,9	1,85	−0,05
3	[1 5]	2,4	2,40	0
4	[1 6]	3,2	2,95	−0,25
5	[1 7]	3,3	3,50	0,20

Sai số nhỏ, có dương có âm: đường A bám sát dữ liệu.

2.3 Hình học

Sai số đo theo phương thẳng đứng



Đoạn đỏ là sai số e_i: khoảng cách **theo trục y** từ điểm dữ liệu đến đường hồi quy.

Đây **không** phải khoảng cách vuông góc tới đường thẳng.

Ta quan tâm ŷ sai bao nhiêu khi đã biết x.

2.3 Hình học

Đường, mặt phẳng, siêu phẳng

d = 1

Một **đường thẳng** trong mặt phẳng (x, y)

d = 2

Một **mặt phẳng** trong không gian (x_1, x_2, y)

d > 2

Một **siêu phẳng** trong không gian d+1 chiều (không vẽ được)

Tập các điểm (x, ŷ) thỏa ŷ = x w

2.3 So sánh

Cùng biểu thức xw, ý nghĩa hình học khác

Hồi quy tuyến tính

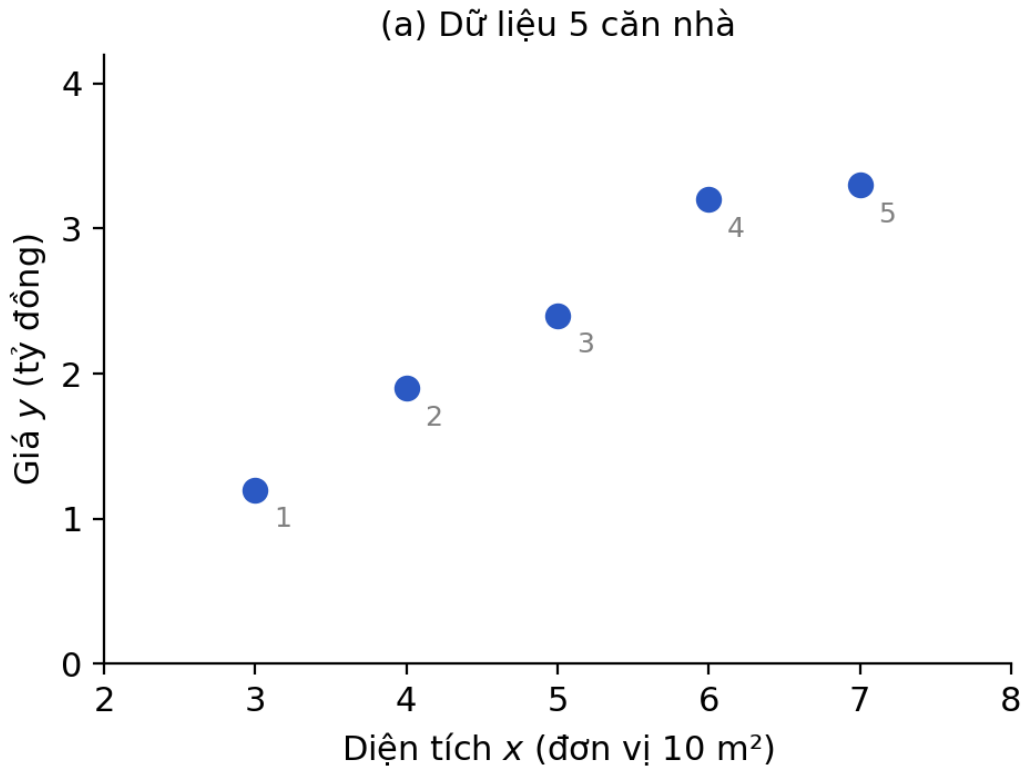
Siêu phẳng y = **x w** nằm trong không gian đặc trưng **cộng trục đầu ra**. Đó là **bề mặt dự đoán** đi xuyên qua đám dữ liệu.

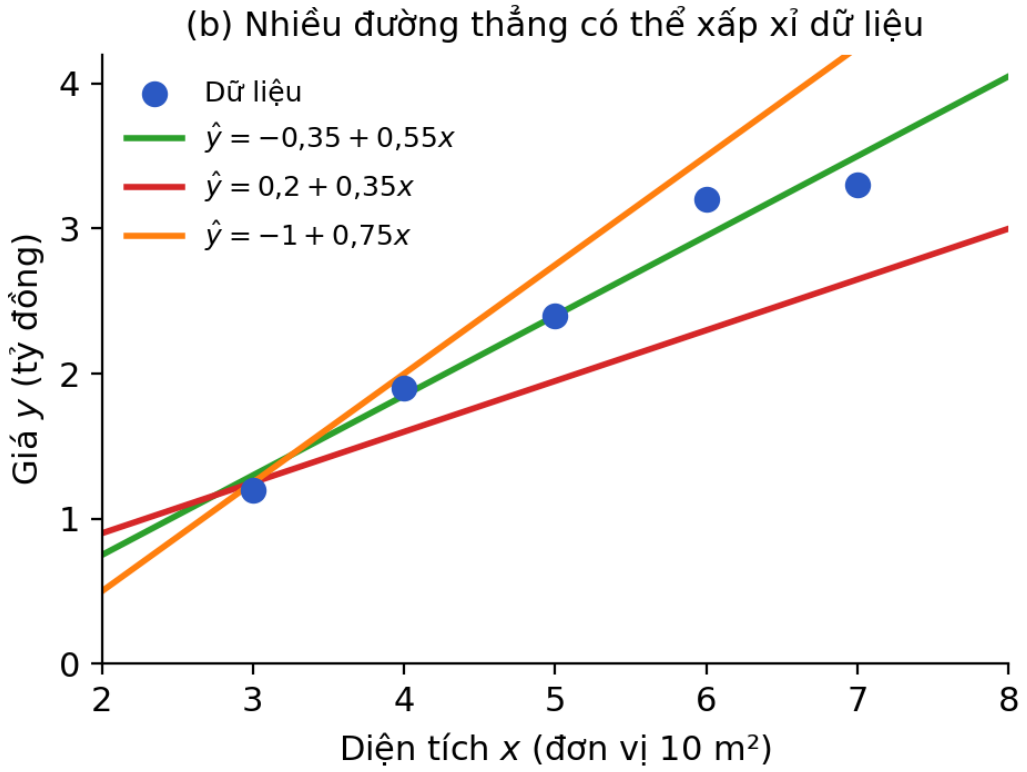
Perceptron (bài sau)

Siêu phẳng **x w** = 0 nằm **trong không gian đặc trưng**. Đó là **đường biên** chia hai lớp.

2.3 Minh họa

Hình 1. Ba đường thẳng có w_0, w_1 khác nhau trên cùng dữ liệu





2.3 Hình học

Vai trò của w_0 và w_1 (d = 1)

w_0: tung độ gốc

Đổi w_0 làm đường thẳng **tịnh tiến lên xuống**, không đổi hướng.

w_1: hệ số góc

Đổi w_1 làm đường thẳng **xoay**. Với đường A, w_1 = 0,55: thêm 10 m^2 thì giá tăng 0,55 tỷ.

Đường B (w_1 = 0,35) thoải hơn dữ liệu. Đường C (w_1 = 0,75) dốc hơn dữ liệu.

2.3 Điểm then chốt

Tuyến tính theo tham số

Nhân đôi mọi tham số ⇒ dự đoán nhân đôi

Tính chất này (không phải tính tuyến tính theo đặc trưng) làm việc huấn luyện ở mục 3 đơn giản. Mục 4 sẽ khai thác sự khác biệt này.

Tóm tắt mục 2

Năm ý cần nhớ

- $\hat{y} = w_0 + w_1x_1 + \ldots + w_dx_d = \mathbf{x}\,\mathbf{w}$: tổng có trọng số cộng hệ số chệch.
- w_j là mức thay đổi của $\hat{y}$ khi x_j tăng 1 đơn vị. Không so sánh $|w_j|$ giữa các đặc trưng khác thang đo.
- Toàn bộ dữ liệu: $\hat{\mathbf{y}} = \mathbf{X}\,\mathbf{w}$, sai số $\mathbf{e} = \mathbf{X}\,\mathbf{w} - \mathbf{y}$ (dương: dự đoán cao hơn).
- Hình học: đường thẳng ($d = 1$), mặt phẳng ($d = 2$), siêu phẳng ($d > 2$). w_0 tịnh tiến, các trọng số làm xoay.
- Mô hình **tuyến tính theo tham số w**.

Câu hỏi kiểm tra nhanh (1/2)

Thử sức nào!

1. Với $\mathbf{w} = [0{,}8;\ 0{,}045;\ -0{,}08]^T$ và $\mathbf{x} = [1\ 90\ 3]$, tính ŷ.

2. Giải thích ý nghĩa của $w_2 = -0{,}08$ ở câu 1.

3. Với đường A ($w_0 = -0{,}35$; $w_1 = 0{,}55$), tính ŷ cho nhà 45 m^2 ($x = 4{,}5$).

Câu hỏi kiểm tra nhanh (2/2)

Thử sức nào!

4. Ba mẫu $\mathbf{x}_1 = [1\ 2]$, $\mathbf{x}_2 = [1\ 4]$, $\mathbf{x}_3 = [1\ 6]$, $\mathbf{y} = [2{,}5;\ 3;\ 3{,}5]^T$, $\mathbf{w} = [1;\ 0{,}5]^T$. Tính $\hat{\mathbf{y}}$ và $\mathbf{e}$.

5. Vì sao không nên diễn giải $w_0 = -0{,}35$ của đường A là "giá nhà có diện tích bằng 0"?

Bài giảng hồi quy tuyến tính · Mục 3

Huấn luyện mô hình hồi quy tuyến tính

Hàm mất mát · Gradient Descent · Phương trình chuẩn

Đo sai

Hàm mất mát MSE

Chỉnh hướng nào

Gradient và quy tắc cập nhật

Lặp và dừng

Thuật toán, tốc độ học, nghiệm đóng

Mở đầu

Ba câu hỏi của mục 3

Làm thế nào để **đo mức độ sai** của một bộ tham số? (hàm mất mát)

Với tham số hiện tại, nên chỉnh **w theo hướng nào** để sai số giảm? (gradient)

Lặp lại ra sao, **khi nào dừng**, và có cách **giải trực tiếp** không? (thuật toán)

3.1 Mục tiêu huấn luyện

Tìm w làm hàm mất mát nhỏ nhất

$$\mathbf{w}^* = \text{argmin } J(\mathbf{w})$$

Quá trình học là một vòng lặp:

w
tham số hiện tại

→

ŷ, J
dự đoán, mất mát

→

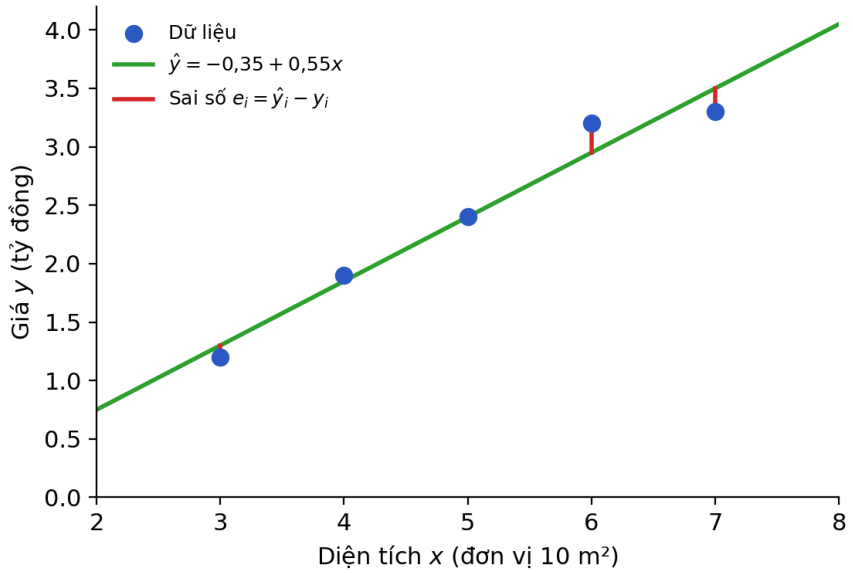
∇J
hướng chỉnh

→

w mới
tham số tốt hơn

3.2 Hàm mất mát MSE

Từ sai số từng mẫu đến mất mát toàn bộ



Một mẫu: $\ell_i(\mathbf{w}) = e_i^2 = (\hat{y}_i - y_i)^2$

Toàn bộ: $\mathbf{J}(\mathbf{w}) = (1/n)\ \Sigma_i\ \ell_i(\mathbf{w})$

Đây là **MSE** (Mean Squared Error). J càng nhỏ, dự đoán càng sát thực tế.

3.2 Hàm mất mát MSE

Vì sao bình phương sai số?

Không triệt tiêu

Tổng e_i của đường A bằng 0 dù mô hình chưa hoàn hảo

Phạt mạnh sai lớn

Sai gấp 5 lần thì bị phạt gấp 25 lần

Hàm trơn

e_i^2 khả vi mọi nơi, tính gradient thuận tiện

3.2 Hàm mất mát MSE

Dạng ma trận và bài toán huấn luyện

$$J(\mathbf{w}) = (1/n)\,\|\mathbf{X}\,\mathbf{w} - \mathbf{y}\|^2 = (1/n)\,\mathbf{e}^{\mathsf{T}}\mathbf{e}$$

$$\mathbf{w}^* = \operatorname{argmin}\,(1/n)\,\|\mathbf{X}\,\mathbf{w} - \mathbf{y}\|^2$$

J là hàm bậc hai của **w**: đồ thị hình "cái bát" có **đúng một điểm thấp nhất**, nên mọi thuật toán đi xuống đều tới cùng một đáp án.

3.2 Ví dụ số

J của các đường trên 5 căn nhà

Bộ tham số w	J(w)	Nhận xét
$[-0{,}35;\ 0{,}55]^T$ (đường A)	0,023	Rất nhỏ, bám sát dữ liệu
$[-1;\ 0{,}75]^T$ (đường C)	0,2255	Dốc hơn dữ liệu
$[0{,}2;\ 0{,}35]^T$ (đường B)	0,3055	Thoải hơn dữ liệu
$[0;\ 0]^T$	6,388	Rất tệ: điểm khởi đầu ở 3.5

Đường A: $J = (0{,}10^2 + 0{,}05^2 + 0 + 0{,}25^2 + 0{,}20^2)/5 = 0{,}115/5 =$ **0,023**

3.3 Gradient

Gradient chỉ hướng đi xuống

$$\nabla J(\mathbf{w}) = [\partial J/\partial w_0; \partial J/\partial w_1; \ldots; \partial J/\partial w_d]$$

∇J

chỉ về hướng J **tăng nhanh nhất**

$-\nabla J$

chỉ về hướng J **giảm nhanh nhất**

Đây là cơ sở của **Gradient Descent** (hạ gradient).

3.3 Gradient

Bước 1: gradient của một mẫu

$$\ell_i = (\mathbf{x_i w} - y_i)^2 \Rightarrow \nabla \ell_i = 2\, e_i\, \mathbf{x_i}^T$$

Thành phần w_0

$\partial \ell_i / \partial w_0 = 2\, e_i$

Thành phần w_j

$\partial \ell_i / \partial w_j = 2\, e_i\, x_{ij}$

$\mathbf{x}_i^T$ là vector cột để gradient cùng kích thước $(d+1) \times 1$ với $\mathbf{w}$.

3.3 Gradient

Bước 2: gradient của MSE

$$\nabla J(\mathbf{w}) = (1/n)\,\Sigma_i\, 2e_i\mathbf{x}_i^T = (2/n)\,\mathbf{X}^T\mathbf{e} = (2/n)\,\mathbf{X}^T(\mathbf{X}\,\mathbf{w} - \mathbf{y})$$

Theo w_0

$(2/n)\,\Sigma_i\, e_i$

Theo w_j

$(2/n)\,\Sigma_i\, e_i\, x_{ij}$

$\mathbf{X}^T$ có các cột là $\mathbf{x}_i^T$ nên $\mathbf{X}^T\mathbf{e} = \Sigma\, e_i\mathbf{x}_i^T$. Kích thước: (d+1) × n nhân n × 1 = (d+1) × 1.

3.3 Quy tắc cập nhật

Đi một bước theo hướng $-\nabla J$

$$\mathbf{w} \leftarrow \mathbf{w} - \eta \nabla J = \mathbf{w} - \eta\,(2/n)\,\mathbf{X}^T(\mathbf{X}\,\mathbf{w} - \mathbf{y})$$

$\eta > 0$: tốc độ học

Quyết định độ dài bước đi

$e_i > 0$ (dự đoán cao)

Trừ một phần $\mathbf{x}_i^T$ khỏi $\mathbf{w}$ để dự đoán giảm

$e_i < 0$ (dự đoán thấp)

Cộng một phần $\mathbf{x}_i^T$ vào $\mathbf{w}$ để dự đoán tăng

3.3 Kiểm tra

Vì sao quy tắc này hợp lý?

Chỉ cập nhật theo mẫu i: $\mathbf{w}' = \mathbf{w} - 2\eta\, e_i \mathbf{x}_i^T$. Khi đó

$$e_i' = e_i\,(1 - 2\eta\,\|\mathbf{x}_i\|^2)$$

$0 < \eta < 1/\|\mathbf{x}_i\|^2$

$|e_i'| < |e_i|$: sai số của mẫu **giảm**

η quá lớn

Thừa số nhỏ hơn −1: sai số **tăng**, mầm mống phân kỳ

3.3 Nhìn trước

So sánh với Perceptron (bài sau)

Tiêu chí	Hồi quy tuyến tính (MSE)	Perceptron
Mẫu nào đóng góp	Mọi mẫu	Chỉ mẫu phân loại sai
Mức đóng góp	Tỉ lệ sai số liên tục e_i	Luôn là $\pm \eta x_i^T$
Cách duyệt	Thường dùng toàn bộ dữ liệu	Cập nhật ngay sau mỗi mẫu

3.4 Gradient Descent

Thuật toán từng bước

1. **Khởi tạo $\mathbf{w} = \mathbf{0}$** (hoặc giá trị nhỏ).

2. **Tính** dự đoán $\hat{\mathbf{y}} = \mathbf{X}\,\mathbf{w}$ và sai số $\mathbf{e} = \hat{\mathbf{y}} - \mathbf{y}$.

3. **Tính** mất mát $J = (1/n)\,\mathbf{e}^{\mathsf{T}}\mathbf{e}$ và gradient $\nabla J = (2/n)\,\mathbf{X}^{\mathsf{T}}\mathbf{e}$.

4. **Cập nhật $\mathbf{w} \leftarrow \mathbf{w} - \eta\,\nabla J$**.

5. **Lặp** bước 2 đến 4 cho tới khi thỏa điều kiện dừng.

3.4 Gradient Descent

Điều kiện dừng

J gần như không giảm

$|J_{t+1} - J_t| < \varepsilon$

Gradient gần bằng 0

$\|\nabla J\| < \varepsilon$: đã gần cực tiểu

Hết số lần lặp

$t = T_{max}$: "van an toàn" khi η chọn không phù hợp

3.4 Gradient Descent

Batch, SGD và Mini-batch

Biến thể	Số mẫu mỗi lần cập nhật	Cập nhật
Batch GD	Toàn bộ n mẫu	$\mathbf{w} \leftarrow \mathbf{w} - \eta\,(2/n)\,\mathbf{X}^T\mathbf{e}$
SGD	1 mẫu	$\mathbf{w} \leftarrow \mathbf{w} - \eta\,2e_i\mathbf{x}_i^T$
Mini-batch	b mẫu (1 < b < n)	$\mathbf{w} \leftarrow \mathbf{w} - \eta\,(2/b)\,\Sigma_{\{i\in B\}}\, e_i\mathbf{x}_i^T$

SGD và Mini-batch rẻ hơn mỗi bước nhưng gradient “nhiễu” hơn. Bài này dùng Batch cho dễ tính tay.

3.5 Ví dụ tính tay

Lần lặp 1 (η = 0,02, w = 0)

Sai số

$\hat{\mathbf{y}} = \mathbf{0}$ nên $\mathbf{e} = -\mathbf{y} = [-1{,}2;\ -1{,}9;\ -2{,}4;\ -3{,}2;\ -3{,}3]^T$

X^Te

$[\Sigma e_i;\ \Sigma x_i e_i] = [-12;\ -65{,}5]^T$

Gradient

$\nabla J = (2/5)[-12;\ -65{,}5]^T = [-4{,}8;\ -26{,}2]^T$

Cập nhật

$\mathbf{w}^{(1)} = \mathbf{0} - 0{,}02 \cdot [-4{,}8;\ -26{,}2]^T = [0{,}096;\ 0{,}524]^T$

J giảm từ 6,388 xuống 0,1242

3.5 Ví dụ tính tay

Lần lặp 2 và các lần sau

Sai số

$\mathbf{e} = [0{,}468;\ 0{,}292;\ 0{,}316;\ 0{,}040;\ 0{,}464]^T$

$\mathbf{X}^T\mathbf{e} = [1{,}58;\ 7{,}64]^T$

Cập nhật

$\nabla J = [0{,}632;\ 3{,}056]^T$

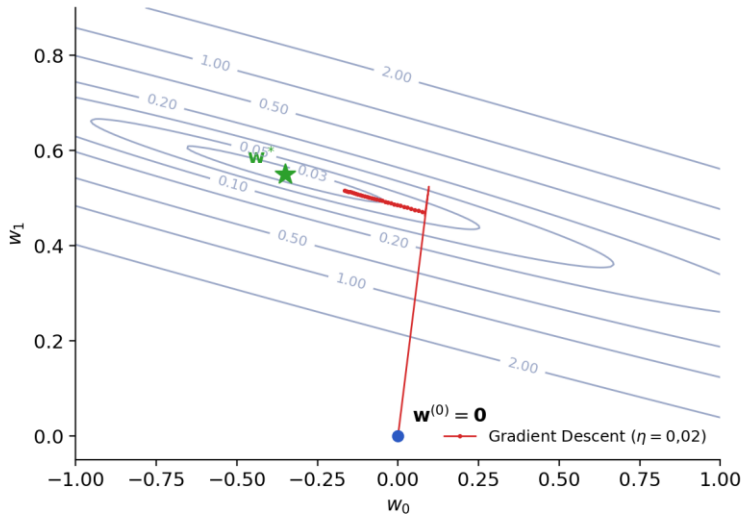
$\mathbf{w}^{(2)} = [0{,}08336;\ 0{,}46288]^T$, $J = 0{,}0382$

t	0	1	2	3	10	50	200	1000
J	6,388	0,1242	0,0382	0,0369	0,0364	0,0336	0,0275	0,0230

J giảm rất nhanh lúc đầu, rồi chậm lại đáng kể.

3.5 Nhận xét

Vì sao chậm? Thung lũng hẹp



Các đường mức là elip rất **dài và hẹp**, tạo thành "thung lũng".

Bước đầu xuống nhanh tới đáy, sau đó phải **bò dọc đáy** với bước rất nhỏ.

Nguyên nhân: x có giá trị lớn (3 đến 7) so với cột toàn số 1, nên J nhạy với w_1 hơn w_0 rất nhiều.

3.5 Cách khắc phục

Chuẩn hóa đặc trưng

$$z = (x - \bar{x})/\sigma,\ \bar{x} = 5,\ \sigma = \sqrt{2}$$

Kết quả

Với $\eta = 0{,}3$ chỉ cần **khoảng 17 lần lặp**

$\mathbf{w}' = [2{,}4;\ 0{,}7778]^T$

Quy về thang gốc

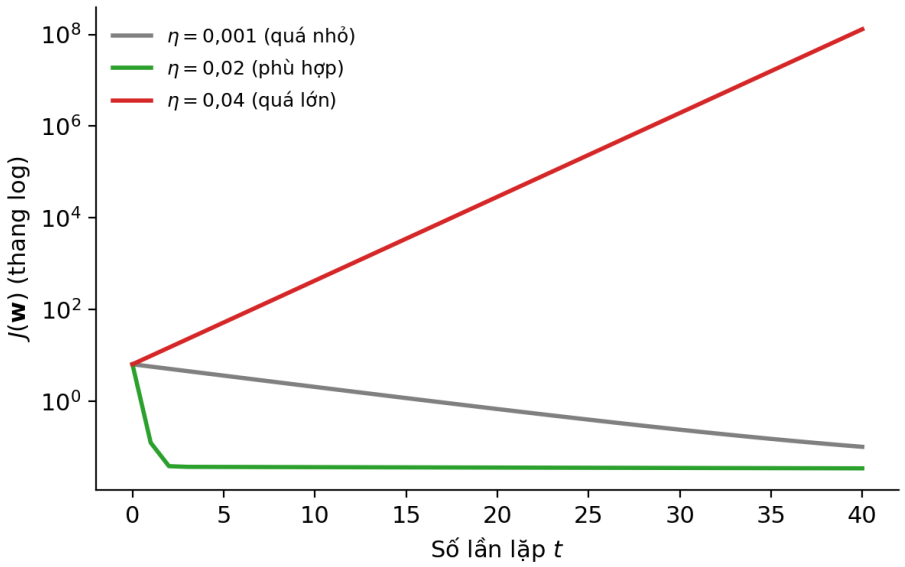
$w_1 = 0{,}7778/\sqrt{2} = 0{,}55$

$w_0 = 2{,}4 - 0{,}7778 \cdot 5/\sqrt{2} = -0{,}35$

$w_0' = 2{,}4$ chính là $\bar{y}$. Tham số chuẩn hóa chỉ ước lượng trên **tập huấn luyện**.

3.6 Tốc độ học

η quyết định độ dài mỗi bước



η = 0,001 (quá nhỏ): hội tụ rất chậm, sau 40 lần lặp J vẫn 0,1009.

η = 0,02 (phù hợp): J giảm mạnh rồi vào vùng cực tiểu.

η = 0,04 (quá lớn): vượt qua cực tiểu, J tăng: 6,388 → 9,712 → …, **phân kỳ**.

3.6 Đọc thêm

Ngưỡng ổn định của η

$$0 < \eta < 2 / L$$

L là giá trị riêng lớn nhất của $(2/n)\mathbf{X}^{T}\mathbf{X}$. Dữ liệu nhà: L ≈ 55,86 nên ngưỡng ≈ 0,0358. Vậy η = 0,02 ổn định, η = 0,04 phân kỳ. Sau chuẩn hóa ngưỡng tăng lên 1, nên dùng được η = 0,3.

3.7 Giải trực tiếp

Phương trình chuẩn

Tại cực tiểu, gradient bằng 0:

$$(2/n)\, \mathbf{X}^{\mathsf{T}}(\mathbf{X}\,\mathbf{w} - \mathbf{y}) = \mathbf{0} \Rightarrow \mathbf{X}^{\mathsf{T}}\mathbf{X}\,\mathbf{w} = \mathbf{X}^{\mathsf{T}}\mathbf{y}$$

$$\mathbf{w}^{*} = (\mathbf{X}^{\mathsf{T}}\mathbf{X})^{-1}\,\mathbf{X}^{\mathsf{T}}\mathbf{y}$$

Cần $\mathbf{X}^{\mathsf{T}}\mathbf{X}$ khả nghịch: n ≥ d+1 và không có đặc trưng nào là tổ hợp tuyến tính của các đặc trưng khác.

3.7 Ví dụ số

Giải phương trình chuẩn cho 5 căn nhà

X^TX

[5 25; 25 135], định thức = 50

X^Ty

$[12; 65{,}5]^T$

$$\mathbf{w^* = } (1/50)[135\ -25;\ -25\ 5]\cdot[12;\ 65{,}5] = [-0{,}35;\ 0{,}55]^T$$

Đúng đường A, J = 0,023. Tại nghiệm, $\mathbf{X^Te = 0}$: $\Sigma e_i = 0$ và $\Sigma x_i e_i = 0{,}3 - 0{,}2 - 1{,}5 + 1{,}4 = 0$.

3.7 So sánh

Gradient Descent hay phương trình chuẩn?

Tiêu chí	Gradient Descent	Phương trình chuẩn
Cách tìm w*	Lặp, tiến dần	Giải hệ một lần
Siêu tham số	Cần η, T_max, ε	Không cần
Khi d lớn	~ n·d mỗi lần lặp	~ $n \cdot d^2 + d^3$
Hàm mất mát khác	Có (MAE, Lasso, …)	Chỉ MSE (và Ridge)
Chuẩn hóa	Nên có	Không bắt buộc

Điểm then chốt

Ba thành phần khác nhau

Hồi quy tuyến tính không phải là Gradient Descent

Mô hình

ŷ = **x w** (hồi quy tuyến tính)

Hàm mất mát

MSE

Tối ưu

Gradient Descent hoặc phương trình chuẩn

Tóm tắt mục 3

Năm ý cần nhớ

Huấn luyện: $\mathbf{w}^* = \arg\min J(\mathbf{w})$. **MSE**: $J = (1/n)\|\mathbf{X}\,\mathbf{w} - \mathbf{y}\|^2$, hàm hình cái bát, một cực tiểu duy nhất.

Gradient: $\nabla J = (2/n)\mathbf{X}^\top(\mathbf{X}\,\mathbf{w} - \mathbf{y})$. **Gradient Descent**: $\mathbf{w} \leftarrow \mathbf{w} - \eta\nabla J$.

η quá nhỏ thì chậm, quá lớn thì phân kỳ. **Chuẩn hóa đặc trưng** giúp hội tụ nhanh.

Phương trình chuẩn $\mathbf{w}^* = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y}$; tại nghiệm $\mathbf{X}^\top\mathbf{e} = \mathbf{0}$.

Mô hình + Hàm mất mát + Thuật toán tối ưu = Huấn luyện.

Câu hỏi kiểm tra nhanh (1/2)

Thử sức nào!

1. Tính MSE của đường B ($\mathbf{w} = [0{,}2;\ 0{,}35]^T$) biết $\hat{\mathbf{y}} = [1{,}25;\ 1{,}60;\ 1{,}95;\ 2{,}30;\ 2{,}65]^T$.

2. Ba mẫu $\mathbf{x}_1 = [1\ 2]$, $\mathbf{x}_2 = [1\ 4]$, $\mathbf{x}_3 = [1\ 6]$, $\mathbf{y} = [2{,}5;\ 3;\ 3{,}5]^T$, $\mathbf{w} = [1;\ 0{,}5]^T$. Tính J, ∇J và $\mathbf{w}$ sau một lần cập nhật với $\eta = 0{,}1$.

3. Dùng phương trình chuẩn tìm $\mathbf{w}^*$ cho ba mẫu ở câu 2. $J(\mathbf{w}^*)$ bằng bao nhiêu?

Câu hỏi kiểm tra nhanh (2/2)

Thử sức nào!

4. Vì sao $\eta = 0{,}04$ làm Gradient Descent phân kỳ trên dữ liệu nhà còn $\eta = 0{,}02$ thì không?

5. Vì sao nói "hồi quy tuyến tính không phải là Gradient Descent"? Chuẩn hóa đặc trưng giúp ích gì?

Bài giảng hồi quy tuyến tính · Mục 4

Mở rộng mô hình bằng biến đổi đặc trưng

Từ đường thẳng đến đường cong, và nguy cơ quá khớp

Biến đổi đặc trưng

φ(x): tạo đặc trưng mới

Ma trận Φ

Thay X bằng Φ

Quá khớp

Mô hình quá phức tạp

Mở đầu

Ba câu hỏi của mục 4

Khi quan hệ giữa x và y **không phải đường thẳng**, mô hình tuyến tính còn dùng được không?

Biến đổi đặc trưng là gì, và công thức huấn luyện ở mục 3 thay đổi thế nào?

Tăng độ phức tạp của mô hình có **luôn làm mô hình tốt hơn** không?

4.1 Giới hạn của đường thẳng

Nhiều quan hệ là cong

Mô hình hiện tại

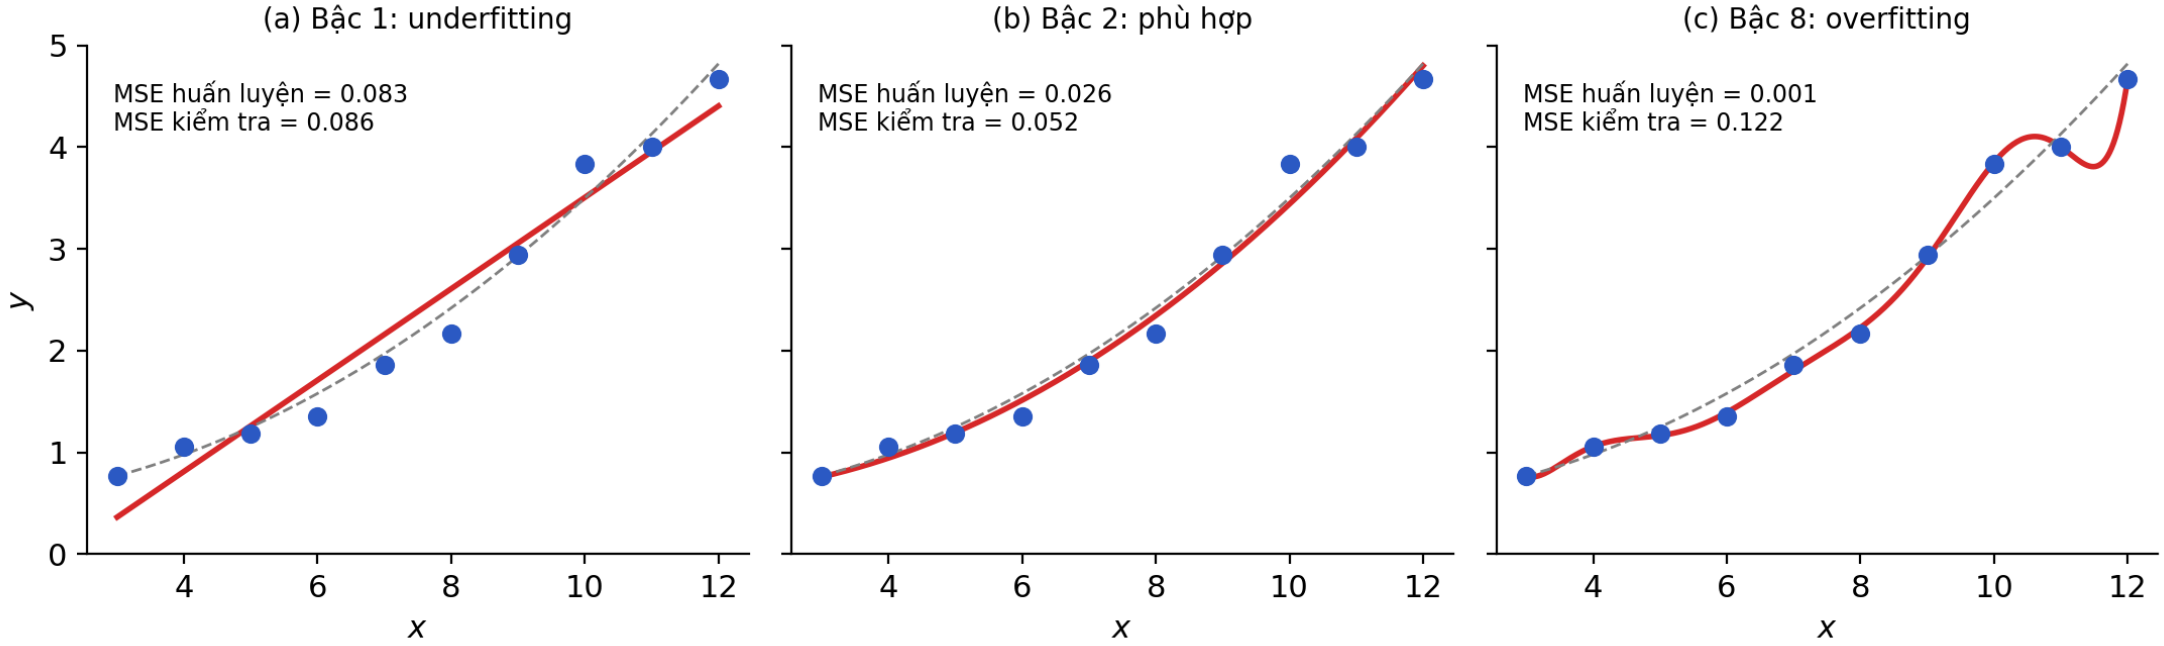
ŷ = **x w** chỉ là **tổ hợp tuyến tính** của các đặc trưng gốc: đường thẳng hoặc mặt phẳng.

Thực tế

Nhà lớn có giá mỗi m^2 cao hơn, nên giá tăng **nhanh hơn** khi diện tích tăng: quan hệ dạng cong.

Làm sao biểu diễn đường cong mà không đổi cơ chế huấn luyện?

Đường thẳng bám dữ liệu cong rất kém



Hình (a): bậc 1 bỏ lỡ độ cong. Hiện tượng này gọi là **underfitting** (dưới khớp): mô hình **quá đơn giản**.

4.2 Ý tưởng

Biến đổi đặc trưng

Tạo thêm đặc trưng mới từ x, rồi vẫn dùng mô hình tuyến tính

Đường cong trong không gian x trở thành “mặt phẳng” trong không gian đặc trưng mới.

4.2 Ý tưởng

Phép biến đổi φ

$$\varphi(x) = [1\ \varphi_1(x)\ \varphi_2(x)\ \dots\ \varphi_m(x)]$$

$$\hat{y} = \varphi(x)\, w = w_0 + \Sigma_j\, w_j\, \varphi_j(x),\ w = [w_0\ \dots\ w_m]^T$$

Mỗi φ_j là hàm của đặc trưng đầu vào: đa thức, lượng giác, mũ, logarit, hoặc thiết kế theo kiến thức chuyên ngành. Phần tử đầu vẫn bằng 1 để giữ hệ số chệch.

4.2 Điểm then chốt

Phi tuyến theo x, tuyến tính theo w

Phi tuyến theo đặc trưng

$\varphi_j(\mathbf{x})$ có thể cong: x^2, sin x, log x, …

Tuyến tính theo tham số

ŷ là tổng có trọng số của $\varphi_j(\mathbf{x})$ với các **w**

Vì vậy vẫn gọi là hồi quy tuyến tính và dùng được mọi công cụ ở mục 3

4.2 Ví dụ một đặc trưng

Đa thức bậc 3

$$\varphi(x) = [1 \; x \; x^2 \; x^3]$$

$$\hat{y} = w_0 + w_1 x + w_2 x^2 + w_3 x^3$$

Dữ liệu 1 chiều trở thành **3 đặc trưng** (chưa tính số 1). Không có thông tin mới, chỉ là cách biểu diễn khác.

4.2 Ví dụ hai đặc trưng

Thêm bậc hai và tương tác

$$\varphi = [1\ x_1\ x_2\ x_1^2\ x_1x_2\ x_2^2]$$

$$\hat{y} = w_0 + w_1x_1 + w_2x_2 + w_3x_1^2 + w_4x_1x_2 + w_5x_2^2$$

x_1^2, x_2^2

Cong theo từng đặc trưng

x_1x_2

Tác động kết hợp giữa hai đặc trưng

4.2 Ví dụ hai đặc trưng

Ý nghĩa của thành phần tương tác x_1x_2

x_1: diện tích

Tác động của diện tích lên giá

x_2: khoảng cách đến trung tâm

Vị trí của căn nhà

Tác động của diện tích có thể khác nhau tùy vị trí: x_1x_2 giúp mô hình biểu diễn một phần sự tương tác đó

4.2 Các hàm thường gặp

Chọn φ theo đặc điểm dữ liệu

Nhóm	Ví dụ	Biểu diễn được
Đa thức	x, x^2, x^3	Quan hệ cong
Tương tác	x_1x_2	Tác động kết hợp
Lượng giác	sin x, cos x	Quan hệ tuần hoàn
Logarit	log(1 + x)	Tăng chậm, bão hòa
Hàm mũ	e^x	Tăng hoặc giảm theo hàm mũ
Cơ sở xuyên tâm	e^(−γ(x−c)²)	Quan hệ cục bộ quanh c

4.2 Dạng ma trận

Ma trận đặc trưng mới Φ

$$\Phi = [\varphi(x_1); \varphi(x_2); \ldots; \varphi(x_n)], \text{ kích thước } n \times (m+1)$$

Hàng i của Φ

Là $\boldsymbol{\varphi}(\mathbf{x}_i)$, tương tự hàng i của $\mathbf{X}$ là $\mathbf{x}_i$

Cột đầu

Toàn số 1 để có hệ số chệch w_0

4.2 Ví dụ số

5 căn nhà với φ(x) = [1 x x^2]

x	1	x	x^2
3	1	3	9
4	1	4	16
5	1	5	25
6	1	6	36
7	1	7	49



4.2 Dạng ma trận

Chỉ cần thay X bằng Φ

Đại lượng	Công thức
Dự đoán	$\hat{\mathbf{y}} = \boldsymbol{\Phi}\,\mathbf{w}$
Sai số	$\mathbf{e} = \boldsymbol{\Phi}\,\mathbf{w} - \mathbf{y}$
MSE	$J = (1/n)\,\|\|\boldsymbol{\Phi}\,\mathbf{w} - \mathbf{y}\|\|^2$
Gradient	$\nabla J = (2/n)\,\boldsymbol{\Phi}^T(\boldsymbol{\Phi}\,\mathbf{w} - \mathbf{y})$
Cập nhật	$\mathbf{w} \leftarrow w - \eta\,(2/n)\,\boldsymbol{\Phi}^T(\boldsymbol{\Phi}\,\mathbf{w} - \mathbf{y})$
Phương trình chuẩn	$\mathbf{w}^* = (\boldsymbol{\Phi}^T\boldsymbol{\Phi})^{-1}\,\boldsymbol{\Phi}^T\mathbf{y}$

4.2 Lưu ý thực hành

Chuẩn hóa các cột của Φ

Vấn đề

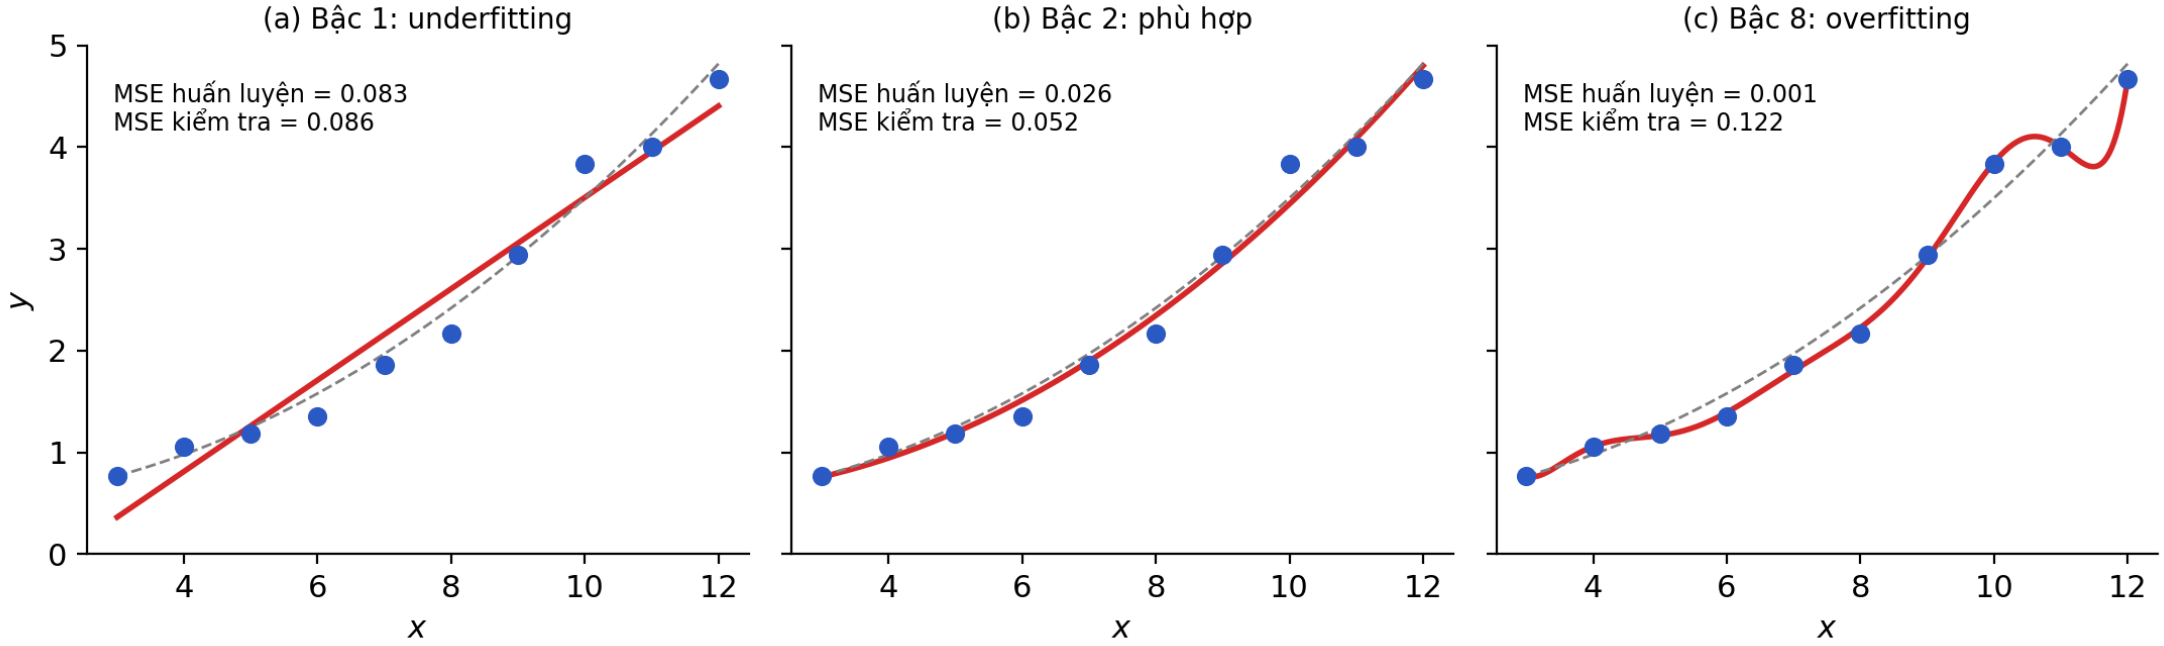
x, x^2, x^3 có thang đo rất khác nhau và tương quan mạnh: Gradient Descent hội tụ chậm, nghiệm kém ổn định

Cách làm

Chuẩn hóa các cột (trừ cột 1). Tham số chuẩn hóa chỉ ước lượng trên **tập huấn luyện**

4.3 Quá khớp

Ba mô hình trên cùng dữ liệu cong



10 điểm huấn luyện (nhiễu độ lệch chuẩn 0,25) và 200 điểm kiểm tra chưa từng thấy. Đường nét đứt xám là quan hệ thật.

4.3 Quá khớp

So sánh sai số huấn luyện và kiểm tra

Mô hình	Số tham số	MSE huấn luyện	MSE kiểm tra	Độ lớn trọng số
Bậc 1	2	0,0829	0,0861	1,29
Bậc 2	3	0,0256	0,0521	1,45
Bậc 8	9	0,0009	0,1221	182 752

Mức nhiễu của dữ liệu: $0{,}25^2 = 0{,}0625$. Bậc 2 đạt gần mức này.

4.3 Quá khớp

Ba trường hợp

Bậc 1: underfitting

Sai số lớn trên **cả** tập huấn luyện và kiểm tra: mô hình quá đơn giản

Bậc 2: phù hợp

Sai số kiểm tra **thấp nhất**: cùng dạng với quan hệ thật

Bậc 8: overfitting

Sai số huấn luyện ≈ 0 nhưng kiểm tra **tăng vọt**: học cả nhiễu

4.3 Dấu hiệu nhận biết

Overfitting

Trọng số khổng lồ: ||w|| ≈ 182 752

Các trọng số hàng trăm nghìn triệt tiêu lẫn nhau để tạo dao động mạnh, giúp đường cong đi qua từng điểm huấn luyện: mô hình quá phức tạp so với lượng dữ liệu, ghi nhớ nhiễu thay vì học quy luật.

4.3 Quá khớp

Vì sao phải đo trên dữ liệu chưa thấy?

Sai số huấn luyện đánh lừa

Thêm đặc trưng chỉ làm J huấn luyện giảm hoặc giữ nguyên, nên ta luôn chọn mô hình phức tạp nhất

Điều ta quan tâm

Khả năng tổng quát hóa: dự đoán tốt trên dữ liệu mới. Luôn dành ra **tập kiểm tra** không dùng khi huấn luyện

4.3 Giới hạn

Tăng số đặc trưng không phải lúc nào cũng tốt

Số đặc trưng bùng nổ

$C(d+p, p) - 1$

$d = 10, p = 3$: 285

$d = 100, p = 3$: 176 850

Đặc trưng tương quan

x, x^2, x^3 tương quan mạnh: $\mathbf{\Phi^T\Phi}$ gần suy biến, nghiệm không ổn định

Dễ quá khớp

Khi số đặc trưng m gần hoặc vượt số mẫu n

4.3 Cách kiểm soát

Ba công cụ

Chuẩn hóa đặc trưng

Giúp tối ưu ổn định

Chọn bậc bằng dữ liệu kiểm chứng

Chọn mô hình có sai số kiểm tra nhỏ

Điều chuẩn

Ridge, Lasso: nội dung mục 5

Kết luận mục 4

Cầu nối đến mô hình phi tuyến

Mở rộng cách biểu diễn dữ liệu, giữ nguyên khung huấn luyện

Dự đoán, tính mất mát, tính gradient, cập nhật tham số và đánh giá khả năng tổng quát hóa. Mô hình **phi tuyến theo đặc trưng** nhưng **tuyến tính theo tham số**.

Tóm tắt mục 4

Năm ý cần nhớ

- Đường thẳng chỉ biểu diễn được quan hệ tuyến tính; quan hệ cong gây **underfitting**.
- **Biến đổi đặc trưng $\mathbf{x} \mapsto \boldsymbol{\varphi}(\mathbf{x})$** (đa thức, tương tác, sin, log, …) cho phép biểu diễn phi tuyến.
- Mô hình vẫn **tuyến tính theo tham số**; mọi công thức mục 3 giữ nguyên khi **thay $\mathbf{X}$ bằng $\boldsymbol{\Phi}$**.
- Mô hình quá phức tạp bị **overfitting**: sai số huấn luyện nhỏ, sai số kiểm tra lớn, trọng số rất lớn.
- Số đặc trưng đa thức tăng rất nhanh; cần chuẩn hóa, chọn bậc bằng dữ liệu kiểm chứng và điều chuẩn.

Câu hỏi kiểm tra nhanh (1/2)

Thử sức nào!

1. Với $\boldsymbol{\varphi}(x) = [1\ x\ x^2]$, $\mathbf{w} = [1; 0{,}5; 0{,}1]^T$, tính ŷ tại $x = 4$.

2. Với $\boldsymbol{\varphi} = [1\ x_1\ x_2\ x_1x_2]$, $\mathbf{w} = [1; 2; 3; -1]^T$, tính ŷ tại $\mathbf{x} = [2\ 3]$.

3. Mô hình $\hat{y} = w_0 + w_1 \sin x$ có phải hồi quy tuyến tính không? Vì sao?

Câu hỏi kiểm tra nhanh (2/2)

Thử sức nào!

4. Viết $\mathbf{\Phi}$ cho x = 1, 2, 3 với $\boldsymbol{\varphi}$ = [1 x x^2]. Vì sao số mẫu bằng số tham số là cảnh báo quá khớp?

5. Bậc 8: MSE huấn luyện 0,0009, kiểm tra 0,1221. Bậc 2: 0,0256 và 0,0521. Mô hình nào tốt hơn? Hiện tượng của bậc 8 là gì?

6. Có bao nhiêu đặc trưng đa thức (không tính hằng số) khi d = 10 và bậc p = 3?

Bài giảng hồi quy tuyến tính · Mục 5

Mở rộng hàm mất mát và điều chuẩn

MAE · Ridge · Lasso

Ngoại lệ

MSE nhạy, MAE bền hơn

Điều chuẩn

Kiểm soát độ phức tạp

Ridge và Lasso

Co nhỏ và chọn đặc trưng

Mở đầu

Ba câu hỏi của mục 5

Làm thế nào để mô hình **bớt nhạy với ngoại lệ**? (MAE)

Làm thế nào **kiểm soát độ phức tạp** của mô hình? (Ridge, Lasso)

Hàm mục tiêu, **gradient** và cách huấn luyện của từng trường hợp là gì?

Đặt vấn đề

MSE cố định chưa đủ

Ngoại lệ

Một quan sát bất thường làm lệch cả đường hồi quy, vì MSE phạt rất mạnh sai số lớn

Quá khớp

Mô hình phức tạp có trọng số rất lớn (mục 4.3: $\|w\| \approx 182\,752$)

Chọn hàm mất mát là chọn điều ta muốn mô hình ưu tiên

5.1 Từ MSE đến MAE

MSE phạt sai số lớn rất mạnh

$e_1 = 2$

Mức phạt $2^2 = 4$

$e_2 = 10$

Gấp 5 lần, nhưng mức phạt $10^2 = 100$: gấp **25 lần**

Ưu điểm: tránh sai số lớn. Hạn chế: ngoại lệ chi phối quá trình huấn luyện

5.1 Từ MSE đến MAE

MAE: dùng giá trị tuyệt đối

$$J_{MAE}(\mathbf{w}) = (1/n)\,\Sigma_i\,|e_i| = (1/n)\,\|\mathbf{X}\,\mathbf{w} - \mathbf{y}\|_1$$

Sai số 2 và 10

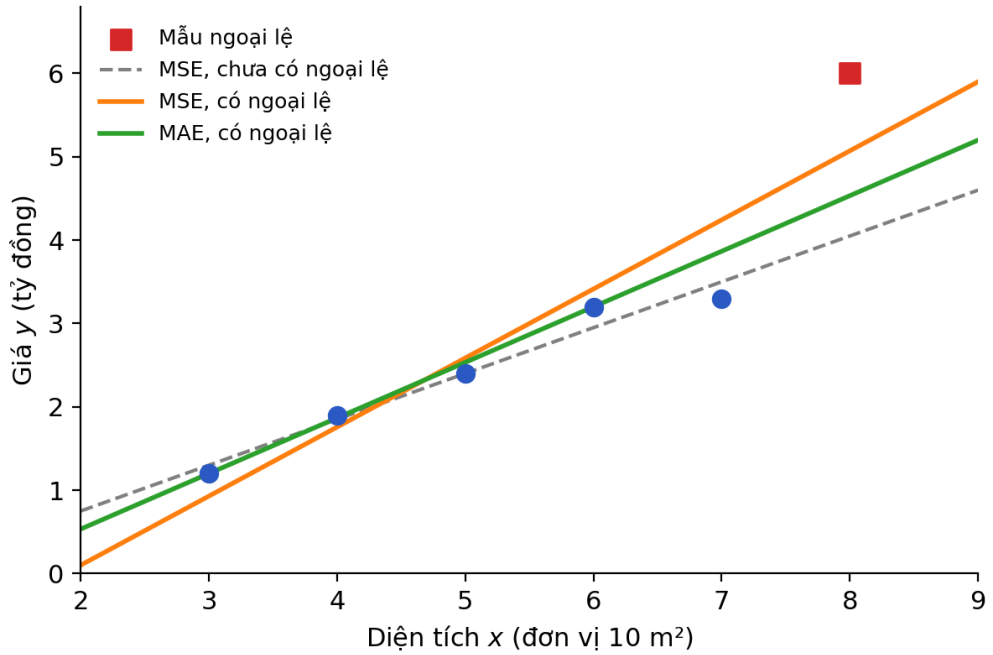
Mức phạt 2 và 10

Tăng tuyến tính

Không tăng vọt theo bình phương

5.1 Ví dụ ngoại lệ

Thêm căn nhà x = 8, y = 6,0 tỷ



- Ô vuông đỏ là **ngoại lệ** (có thể nhập sai số liệu).
- Đường **MSE** (cam) bị kéo lệch nhiều.
- Đường **MAE** (xanh lá) vẫn bám nhóm nhà bình thường.
- Nét đứt xám: đường MSE khi chưa có ngoại lệ.

5.1 Ví dụ ngoại lệ

Số liệu so sánh

Cách huấn luyện	w_0	w_1	MAE trên 5 nhà bình thường
MSE, chưa có ngoại lệ	−0,35	0,55	0,1200
MSE, có ngoại lệ	−1,557	0,829	0,3515
MAE, có ngoại lệ	−0,80	0,667	0,1467

MSE: hệ số góc tăng 51% và sai số trên nhà bình thường **gần gấp ba**. MAE vẫn sát nhóm bình thường.

5.1 Gradient của MAE

Dưới đạo hàm (subgradient)

Vấn đề

|e| không khả vi tại e = 0

Giải pháp

d|e|/de = sign(e), chọn sign(0) = 0

$$\partial J_{MAE} = (1/n)\, \mathbf{X}^T \operatorname{sign}(\mathbf{X}\,\mathbf{w} - \mathbf{y})$$

5.1 Gradient của MAE

Độ lớn hay chỉ dấu?

Hàm mất mát	Gradient	Mẫu có e = 10 đóng góp
MSE	(2/n) $\mathbf{X}^T\mathbf{e}$: dùng độ lớn	2·10 = 20
MAE	(1/n) $\mathbf{X}^T$ sign(**e**): chỉ dùng dấu	1

Đó là lý do ngoại lệ chi phối MSE nhưng không chi phối MAE

5.1 Tổng kết

So sánh MSE và MAE

Đặc điểm	MSE	MAE
Sai số dùng	e^2	$\|e\|$
Ảnh hưởng sai số lớn	Rất mạnh	Nhẹ hơn
Nhạy với ngoại lệ	Cao	Thấp
Độ trơn	Khả vi mọi nơi	Không khả vi tại e = 0
Nghiệm đóng	Có (phương trình chuẩn)	Không đơn giản

5.2 Điều chuẩn

Thêm “chi phí” cho sự phức tạp

$$J_{reg}(\mathbf{w}) = J_{MSE}(\mathbf{w}) + \lambda\, R(\mathbf{w})$$

$R(\mathbf{w})$ đo độ lớn các trọng số, $\lambda \geq 0$ điều khiển mức điều chuẩn. Mô hình phải vừa dự đoán tốt, vừa không quá phức tạp.

5.2 Điều chuẩn

Không điều chuẩn hệ số chệch w_0

$$\mathbf{P} = \text{diag}(0, 1, 1, \ldots, 1)$$

$\mathbf{w}^T\mathbf{P}\,\mathbf{w}$

$= \sum_{j=1}^{d} w_j^2$

$\|\mathbf{P}\,\mathbf{w}\|_1$

$= \sum_{j=1}^{d} |w_j|$

w_0 chỉ đặt mức giá cơ sở, không làm mô hình “cong” hơn, nên bỏ ra khỏi penalty.

5.2 Ridge (L2)

Phạt bình phương trọng số

$$J_{Ridge} = (1/n)\|\mathbf{X}\,\mathbf{w} - \mathbf{y}\|^2 + \lambda\,\mathbf{w}^T\mathbf{P}\,\mathbf{w}$$

$$\nabla J_{Ridge} = (2/n)\,\mathbf{X}^T(\mathbf{X}\mathbf{w} - \mathbf{y}) + 2\lambda\,\mathbf{P}\mathbf{w}$$

Gradient của hàm mục tiêu là tổng gradient của MSE và gradient của penalty.

5.2 Ridge (L2)

Weight decay: trọng số bị co nhỏ

$$\mathbf{w} \leftarrow (\mathbf{I} - 2\eta\lambda\mathbf{P})\,\mathbf{w} - \eta\,(2/n)\,\mathbf{X}^{\mathsf{T}}\mathbf{e}$$

Mỗi bước

Mọi w_j ($j \geq 1$) nhân với hệ số **$1 - 2\eta\lambda < 1$**

Ví dụ

$\eta = 0{,}1$; $\lambda = 0{,}5$: hệ số 0,9, trọng số co còn 90%

5.2 Ridge (L2)

Nghiệm đóng luôn tồn tại

$$(X^TX + n\lambda P)\, w^* = X^Ty$$

λ > 0: ma trận trong ngoặc luôn khả nghịch

Kể cả khi các đặc trưng tương quan mạnh hoặc n < d + 1. Đây là lý do Ridge ổn định hơn phương trình chuẩn thông thường (mục 3.7).

5.2 Ridge (L2)

Kết quả trên đa thức bậc 8

Không điều chuẩn

$\|\mathbf{w}\|$ = 182 752

MSE kiểm tra = 0,1221

Ridge, λ = 0,01

$\|\mathbf{w}\|$ = 0,92

MSE kiểm tra = **0,0543**

Trọng số nhỏ hơn: mô hình đơn giản và ổn định hơn

5.2 Lasso (L1)

Phạt tổng giá trị tuyệt đối

$$J_{Lasso} = (1/n)\|\mathbf{X}\,\mathbf{w} - \mathbf{y}\|^2 + \lambda\,\|\mathbf{P}\mathbf{w}\|_1$$

w_j	Dưới đạo hàm của $\lvert w_j \rvert$
$w_j > 0$	{ 1 }
$w_j = 0$	cả đoạn [−1, 1]
$w_j < 0$	{ −1 }

$\partial J_{Lasso} = (2/n)\mathbf{X}^T(\mathbf{X}\,\mathbf{w} - \mathbf{y}) + \lambda\,\mathbf{P}\,\mathrm{sign}(\mathbf{w})$

5.2 Lasso (L1)

Đưa trọng số về đúng 0

Chọn đặc trưng

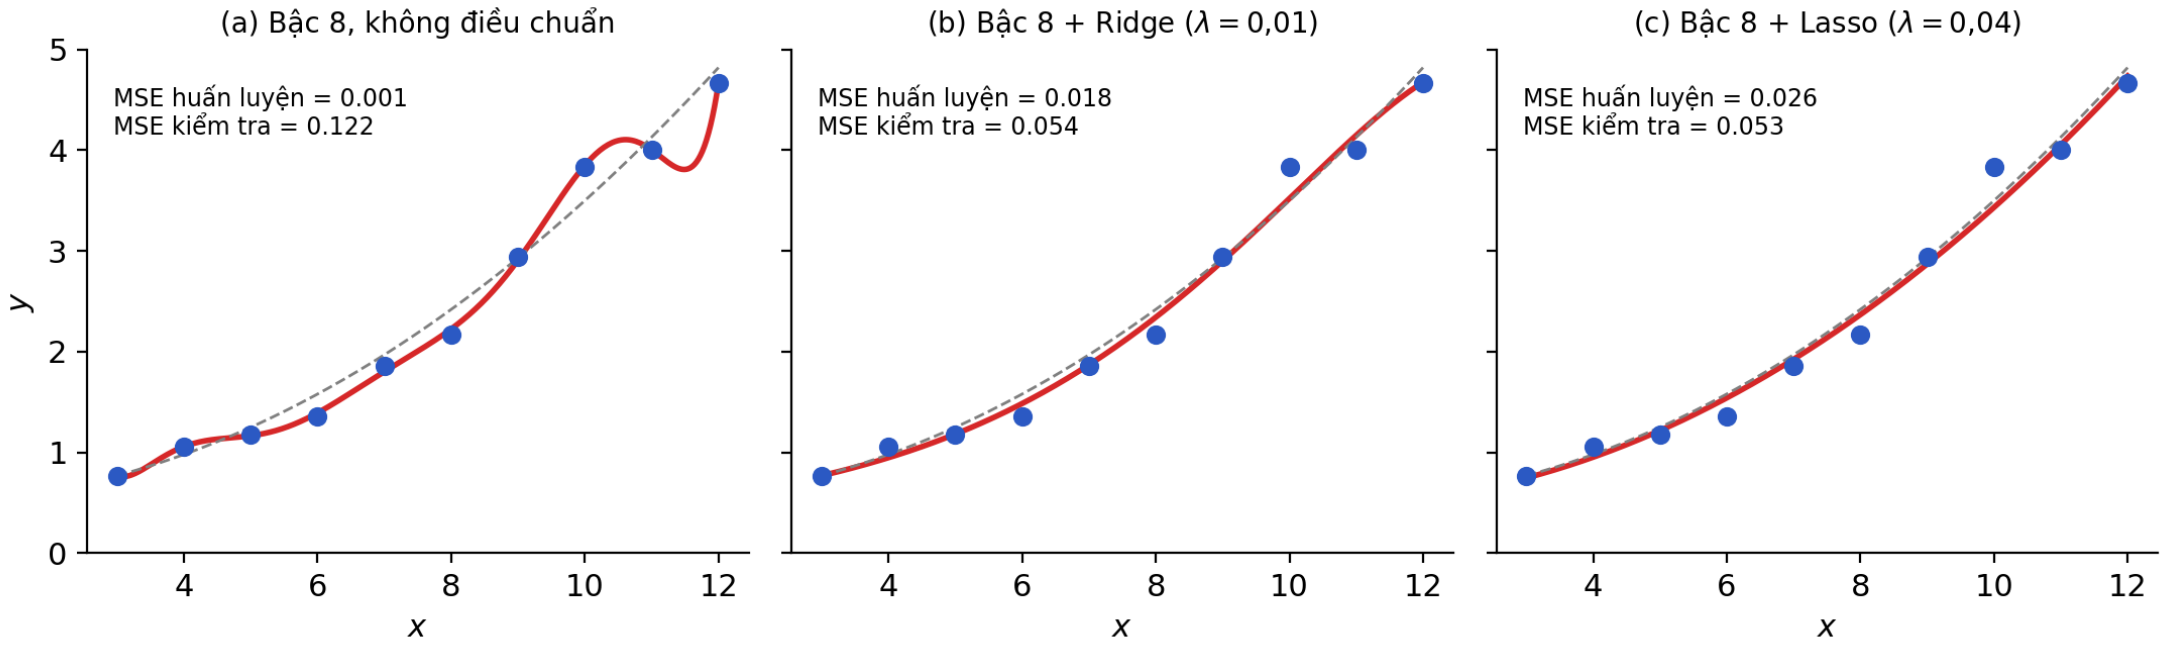
$w_j = 0$ nghĩa là đặc trưng x_j không còn đóng góp vào dự đoán

Trên dữ liệu bậc 8

$\lambda = 0{,}04$ giữ **2 trong 8** đặc trưng (chủ yếu x^2), 6 trọng số về 0. MSE kiểm tra = **0,0527**

5.2 Minh họa

Điều chuẩn loại bỏ dao động quá khớp



(a) Không điều chuẩn: dao động mạnh. (b) Ridge. (c) Lasso. Hai cách điều chuẩn cho đường cong mượt gần quan hệ thật.

5.2 So sánh

Vì sao L1 cho 0 còn L2 chỉ co nhỏ?

Ridge: lực kéo $2\lambda w_j$

Yếu dần khi w_j nhỏ: w_j nhỏ đi nhưng hiếm khi chạm đúng 0

Lasso: lực kéo $\lambda \cdot \text{sign}(w_j)$

Độ lớn không đổi: có thể kéo thẳng w_j về đúng 0 nếu dữ liệu không đủ mạnh chống lại

5.2 Huấn luyện Lasso

Cần thuật toán khác

Vấn đề

Dưới đạo hàm không liên tục tại 0, Gradient Descent thông thường không phù hợp

Thường dùng

Coordinate Descent (tối ưu từng trọng số) hoặc **Proximal Gradient**

Đổi hàm mục tiêu có thể buộc đổi cả thuật toán tối ưu

5.2 Siêu tham số λ

Chọn mức điều chuẩn

λ = 0

Không điều chuẩn, quay về MSE

λ nhỏ

Điều chuẩn yếu, vẫn có thể quá khớp

λ lớn

$w_j \to 0$ ($j \geq 1$), mô hình luôn đoán $\bar{y}$: **underfitting**

λ là **siêu tham số** chọn bằng tập kiểm chứng hoặc kiểm chứng chéo, khác với w được học từ dữ liệu.

5.2 Lưu ý

Luôn chuẩn hóa trước khi điều chuẩn

Penalty phụ thuộc độ lớn w_j, mà độ lớn này phụ thuộc thang đo của đặc trưng

Nếu không chuẩn hóa, đặc trưng đo bằng đơn vị nhỏ sẽ bị phạt bất công so với đặc trưng đo bằng đơn vị lớn.

5.3 Tổng hợp

Bốn hàm mục tiêu

Mô hình	Gradient / dưới đạo hàm	Tối ưu
MSE	$(2/n)\mathbf{X}^{\mathsf{T}}\mathbf{e}$	GD, phương trình chuẩn
MAE	$(1/n)\mathbf{X}^{\mathsf{T}}\,\mathrm{sign}(\mathbf{e})$	Subgradient descent
Ridge	$(2/n)\mathbf{X}^{\mathsf{T}}\mathbf{e} + 2\lambda\mathbf{P}\,\mathbf{w}$	GD, nghiệm đóng
Lasso	$(2/n)\mathbf{X}^{\mathsf{T}}\mathbf{e} + \lambda\mathbf{P}\,\mathrm{sign}(\mathbf{w})$	Coordinate Descent, Proximal

5.3 Bộ khung

Ba câu hỏi cho mọi mô hình

1. Dạng mô hình

$\hat{y} = \mathbf{x}\,\mathbf{w}$

2. Hàm mục tiêu

MSE, MAE, Ridge, Lasso

3. Thuật toán tối ưu

GD, phương trình chuẩn, Coordinate Descent

Hàm mục tiêu = Loss dữ liệu + Penalty độ phức tạp

Tóm tắt mục 5

Năm ý cần nhớ

MSE phạt sai lớn rất mạnh nên nhạy với ngoại lệ; **MAE** phạt tuyến tính nên bền hơn. MSE dùng độ lớn, MAE chỉ dùng dấu.

Điều chuẩn: $J = J_{MSE} + \lambda R(\mathbf{w})$, với $\mathbf{P} = \text{diag}(0, 1, \ldots, 1)$ để không phạt w_0.

Ridge: $\lambda \mathbf{w}^T \mathbf{P}\, \mathbf{w}$, co nhỏ trọng số, nghiệm đóng $(\mathbf{X}^T\mathbf{X} + n\lambda\mathbf{P})\mathbf{w} = \mathbf{X}^T\mathbf{y}$.

Lasso: $\lambda \|\mathbf{P}\, \mathbf{w}\|_1$, đưa trọng số về đúng 0 (chọn đặc trưng).

λ là siêu tham số chọn bằng dữ liệu kiểm chứng; luôn chuẩn hóa đặc trưng trước.

Câu hỏi kiểm tra nhanh (1/2)

Thử sức nào!

1. $\mathbf{e} = [1; -2; 4]^T$. Tính MSE và MAE. Nếu sai số thứ ba đổi từ 4 thành 40 thì chúng thay đổi thế nào?

2. Tính sign($\mathbf{e}$) cho $\mathbf{e} = [0{,}5; -2; 0; 3]^T$ (sign(0) = 0).

3. $\mathbf{w} = [2; 3; -1]^T$, $\lambda = 0{,}1$, $\mathbf{P} = \text{diag}(0, 1, 1)$. Tính $2\lambda\mathbf{P}\,\mathbf{w}$.

Câu hỏi kiểm tra nhanh (2/2)

Thử sức nào!

4. Hệ số co $1 - 2\eta\lambda$ của Ridge bằng bao nhiêu khi $\eta = 0{,}1$ và $\lambda = 0{,}5$? Vì sao khi $\lambda \to \infty$ mô hình chỉ đoán $\bar{y}$?

5. Ridge hay Lasso có thể đưa trọng số về đúng 0? Vì sao?

6. Vì sao không điều chuẩn w_0, và vì sao phải chuẩn hóa đặc trưng trước khi dùng Ridge hoặc Lasso?

Bài giảng hồi quy tuyến tính · Mục 6

Cài đặt và đánh giá mô hình

Python từ đầu · Tập kiểm tra · scikit-learn

Cài đặt từ đầu

NumPy, phép nhân ma trận

Đánh giá

MSE, RMSE, MAE, R^2

scikit-learn

So sánh bốn mô hình

Mở đầu

Ba việc của mục 6

Cài đặt hồi quy tuyến tính **từ đầu** bằng Python (chỉ NumPy) và kiểm tra khớp với ví dụ tính tay ở mục 3.

Huấn luyện trên dữ liệu lớn hơn, **chia tập huấn luyện/kiểm tra**, đánh giá bằng MSE, RMSE, MAE, R^2.

So sánh với **LinearRegression, Ridge, Lasso, SGDRegressor** của scikit-learn.

6.0 Từ toán sang mã

Mỗi công thức là một dòng mã

Ký hiệu toán	Trong Python
Ma trận đặc trưng X (cột đầu bằng 1)	Xb = them_bias(X)
Dự đoán $\hat{y} = X w$	Xb @ w
Sai số $e = X w - y$	Xb @ w - y
MSE: $J = (1/n)\|e\|^2$	np.mean(e ** 2)
Gradient $(2/n) X^T e$	(2 / n) * Xb.T @ e
Cập nhật $w \leftarrow w - \eta \nabla J$	w = w - eta * grad
Phương trình chuẩn	np.linalg.solve(Xb.T @ Xb, Xb.T @ y)

6.1 Cài đặt từ đầu

Bước 1: thêm cột 1

```
import numpy as np

def them_bias(X):
    # (n, d) -> (n, d+1)
    return np.hstack([np.ones((X.shape[0], 1)), X])
```

Cột toàn số 1 ở đầu để gộp hệ số chệch w_0 vào cùng phép nhân ma trận.

Bước 2: dự đoán, MSE, gradient

```
def du_doan(Xb, w):
    return Xb @ w                       # y_hat = Xw

def mse(Xb, y, w):
    e = Xb @ w - y
    return np.mean(e ** 2)              # (1/n)||e||^2

def gradient(Xb, y, w):
    n = len(y)
    return (2 / n) * Xb.T @ (Xb @ w - y)
```

Toàn bộ là phép nhân ma trận, **không cần vòng lặp qua từng mẫu**.

6.1 Cài đặt từ đầu

Bước 3: Gradient Descent

```
def huan_luyen_gd(Xb, y, eta=0.02, t_max=1000, eps=1e-12):
    w = np.zeros(Xb.shape[1])            # khởi tạo w = 0
    lich_su = [mse(Xb, y, w)]
    for t in range(t_max):
        w = w - eta * gradient(Xb, y, w) # cập nhật
        lich_su.append(mse(Xb, y, w))
        if abs(lich_su[-2] - lich_su[-1]) < eps:
            break                        # điều kiện dừng
    return w, lich_su
```

6.1 Cài đặt từ đầu

Bước 4: phương trình chuẩn

```
def phuong_trinh_chuan(Xb, y):
    return np.linalg.solve(Xb.T @ Xb, Xb.T @ y)
```

Nên dùng solve

Giải trực tiếp hệ phương trình: **chính xác và nhanh hơn**

Tránh inv

Tính nghịch đảo tường minh tốn kém và dễ sai số khi X^TX gần suy biến

6.1 Kiểm tra

Chạy trên đúng 5 căn nhà ở mục 1.1

```
X_nha = np.array([[3], [4], [5], [6], [7]], dtype=float)
y_nha = np.array([1.2, 1.9, 2.4, 3.2, 3.3])
Xb_nha = them_bias(X_nha)

w_pt = phuong_trinh_chuan(Xb_nha, y_nha)
w_gd, J = huan_luyen_gd(Xb_nha, y_nha, eta=0.02, t_max=3, eps=0)
```

Cách tốt nhất để biết cài đặt đúng: so với kết quả đã tính tay.

6.1 Kiểm tra

Kết quả khớp hoàn toàn với tính tay

```
Phuong trinh chuan: w = [-0.35  0.55] | J = 0.023
GD sau 3 lan lap  : w = [0.08345 0.4703 ]
J qua cac lan lap : [6.388  0.1242 0.0382 0.0369]
GD sau 1000 lan   : w = [-0.3252  0.5454] | J = 0.023
```

Phương trình chuẩn

$w^* = [-0{,}35;\ 0{,}55]^T$, $J = 0{,}023$

Gradient Descent

6,388 → 0,1242 → 0,0382, trùng hai lần lặp ở mục 3.5

6.1 Kiểm tra

Chuẩn hóa giúp hội tụ nhanh

```
Sau chuan hoa: w = [2.4    0.7778] | so lan lap = 17 | J = 0.023
Quy ve thang do goc: w = [-0.35  0.55]
```

Không chuẩn hóa

Sau 1000 lần lặp vẫn chưa tới w*

Có chuẩn hóa (η = 0,3)

Chỉ 17 lần lặp, quy về thang gốc đúng w*

6.2 Dữ liệu lớn hơn

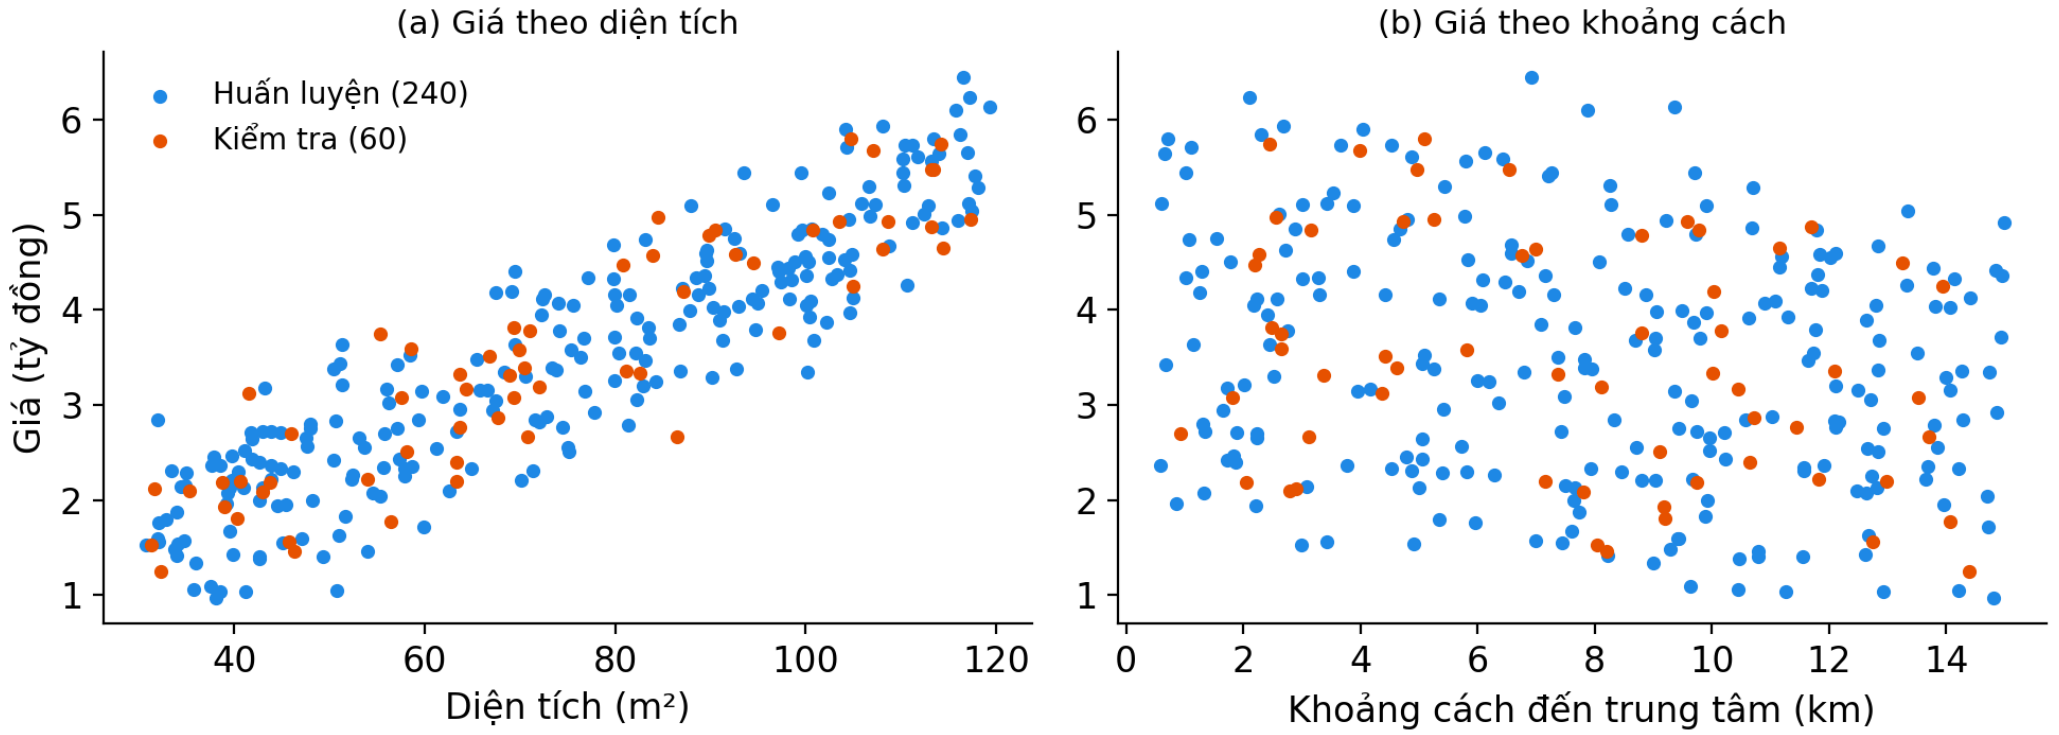
Mô phỏng 300 căn nhà

```
rng = np.random.default_rng(42)
n = 300
dien_tich = rng.uniform(30, 120, n)
khoang_cach = rng.uniform(0.5, 15, n)
gia = (0.8 + 0.045*dien_tich
       - 0.08*khoang_cach
       + rng.normal(0, 0.4, n))
```

Quan hệ thật: $y = 0{,}8 + 0{,}045x_1 - 0{,}08x_2$ + nhiễu (độ lệch chuẩn 0,4).

6.2 Dữ liệu lớn hơn

Hai đặc trưng, hai tập dữ liệu



Giá tăng theo diện tích và giảm theo khoảng cách. Chấm xanh: 240 mẫu huấn luyện; chấm cam: 60 mẫu kiểm tra.

6.2 Chia dữ liệu

Tập huấn luyện và tập kiểm tra

```
idx = rng.permutation(n)
n_tr = int(0.8 * n)
tr, te = idx[:n_tr], idx[n_tr:]
X_tr, y_tr, X_te, y_te = X[tr], gia[tr], X[te], gia[te]
```

80%: huấn luyện

240 mẫu, dùng để học w

20%: kiểm tra

60 mẫu, “dữ liệu mới”: mô hình không được nhìn khi học

6.2 Chuẩn hóa đúng cách

Tránh “rò rỉ” thông tin

```
tb, sd = X_tr.mean(axis=0), X_tr.std(axis=0)  # chỉ tập huấn luyện
Xs_tr = them_bias((X_tr - tb) / sd)
Xs_te = them_bias((X_te - tb) / sd)
```

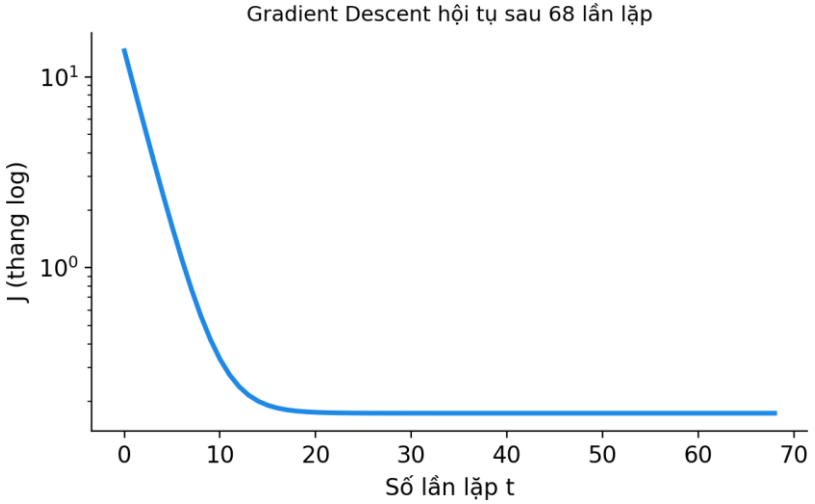
Trung bình và độ lệch chuẩn chỉ ước lượng trên tập huấn luyện, rồi áp dụng cho cả hai tập

6.2 Huấn luyện

Hai cách, cùng một nghiệm

```
GD: so lan lap = 68
  w = [ 3.4679  1.1855 -0.3627]
PT chuan
  w = [ 3.4679  1.1855 -0.3627]
Sai khac toi da: 8.92e-07
```

Sai khác dưới 10^{-6}: hai cách cho **cùng nghiệm**.



6.2 Diễn giải

Quy về thang đo gốc

Mô hình học được

$\hat{y} = 0{,}8157 + 0{,}0452 \cdot x_1 - 0{,}0871 \cdot x_2$

Quan hệ thật

$y = 0{,}8 + 0{,}045 \cdot x_1 - 0{,}08 \cdot x_2$

Mô hình tìm lại được cấu trúc của dữ liệu từ các mẫu có nhiễu

Ở thang chuẩn hóa, $w_0 = 3{,}4679$ chính là $\bar{y}$ của tập huấn luyện.

6.2 Đánh giá

Bốn thước đo

Thước đo	Công thức	Đặc điểm
MSE	$(1/n)\ \Sigma\ e_i^2$	Nhạy với sai số lớn
RMSE	$\sqrt{MSE}$	Cùng đơn vị với y
MAE	$(1/n)\ \Sigma\ \lvert e_i \rvert$	Sai số trung bình, cùng đơn vị y
R^2	$1 - \Sigma e_i^2 / \Sigma(y_i - \bar{y})^2$	Tỉ lệ phương sai được giải thích

6.2 Đánh giá

Ý nghĩa của R^2

$R^2 = 1$

Dự đoán hoàn hảo

$R^2 = 0$

Không tốt hơn việc luôn đoán $\bar{y}$

$R^2 < 0$

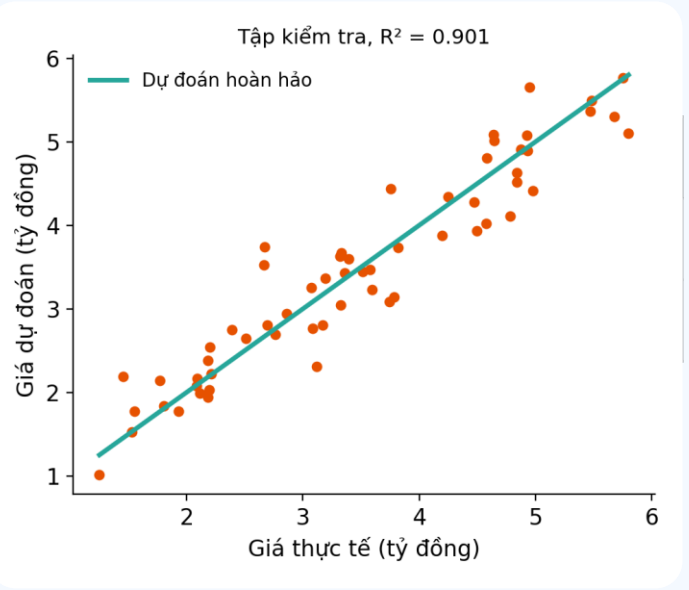
Còn **tệ hơn** việc đoán $\bar{y}$

6.2 Đánh giá

Kết quả trên tập kiểm tra

Tập	MSE	RMSE	MAE
Huấn luyện	0,1732	0,4162	0,3340
Kiểm tra	0,1526	0,3907	0,2995

Mô hình “đoán trung bình”: $R^2 \approx 0$ trên tập kiểm tra.



6.2 Nhận xét

Ba kết luận

MAE ≈ 0,30 tỷ đồng và **R^2 ≈ 0,90**: mô hình giải thích khoảng 90% biến thiên giá nhà, so với ≈ 0 của mô hình đoán trung bình.

Sai số huấn luyện và kiểm tra **gần nhau**: không quá khớp (3 tham số, 240 mẫu). Kiểm tra thấp hơn chút là do ngẫu nhiên của 60 mẫu.

RMSE 0,39 ≈ độ lệch chuẩn của nhiễu (0,4): mô hình đã đạt gần **mức sai số tối thiểu**, vì nhiễu không thể dự đoán.

6.2 Ridge cài từ đầu

Nghiệm đóng $(X^TX + n\lambda P)w = X^Ty$

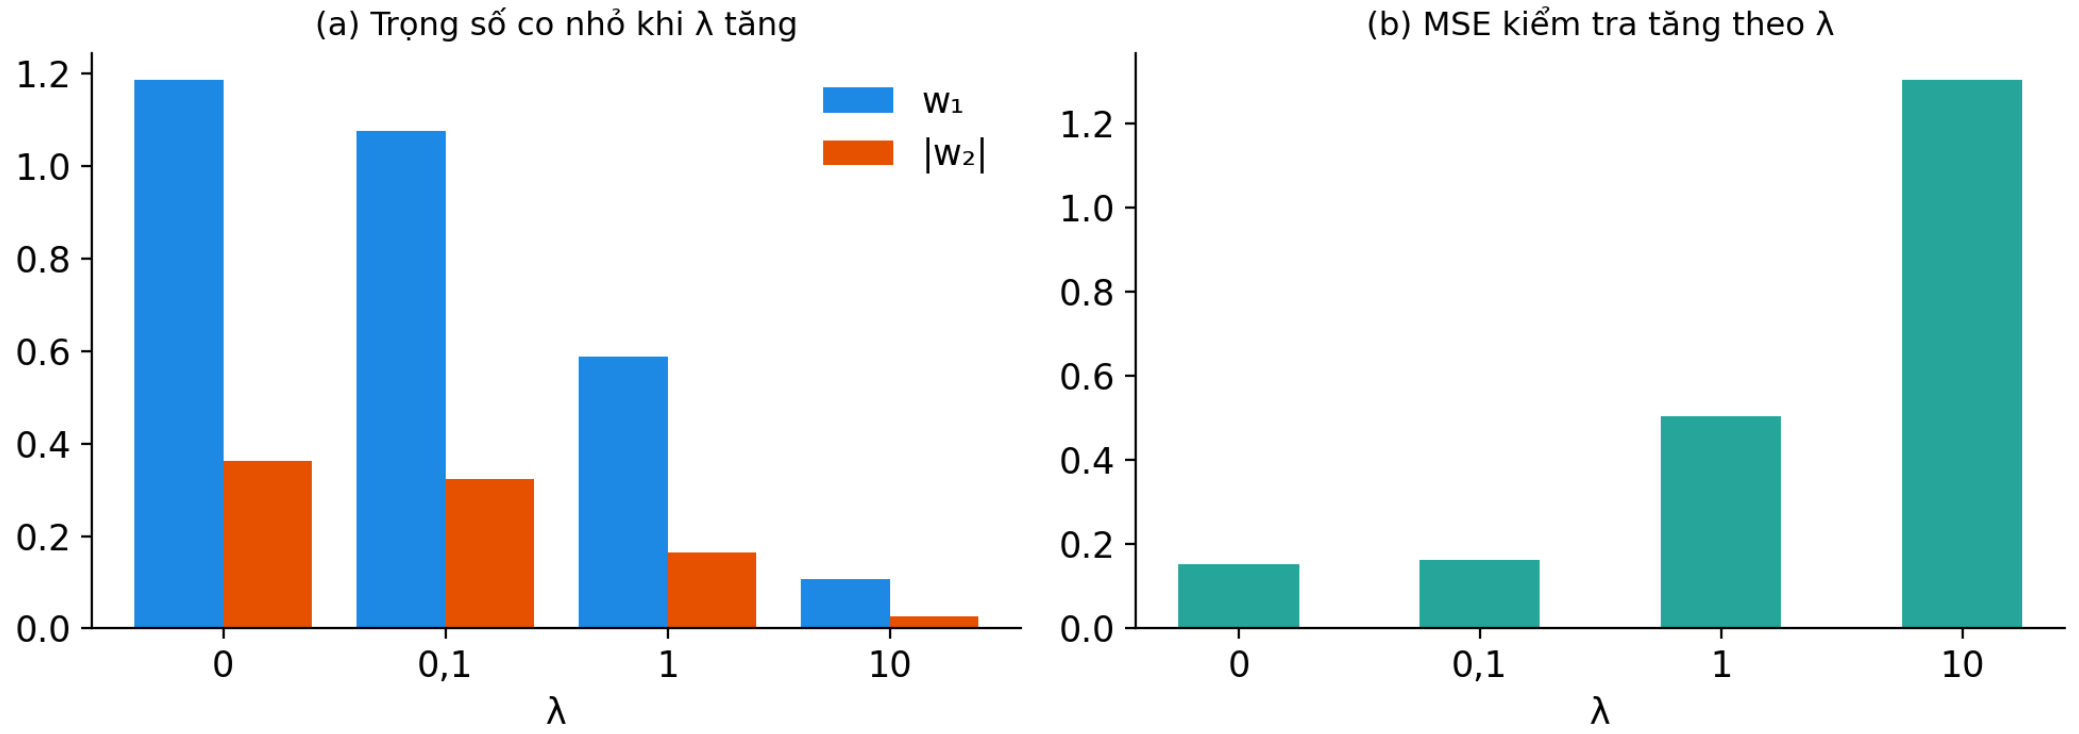
```
def ridge(Xb, y, lam):
    n_, d1 = Xb.shape
    P = np.eye(d1); P[0, 0] = 0        # không điều chuẩn w0
    return np.linalg.solve(Xb.T @ Xb + n_ * lam * P, Xb.T @ y)

for lam in [0, 0.1, 1, 10]:
    w_r = ridge(Xs_tr, y_tr, lam)
```

Thử bốn giá trị λ rồi so sánh trọng số và MSE kiểm tra.

6.2 Ridge cài từ đầu

Trọng số co nhỏ khi λ tăng



λ = 0; 0,1; 1; 10: w_1 = 1,186; 1,076; 0,587; 0,106. w_0 = ȳ không đổi. MSE kiểm tra: 0,1526; 0,1625; 0,5034; 1,3018.

6.2 Nhận xét

Vì sao MSE kiểm tra lại tăng theo λ?

Không có quá khớp để chữa

240 mẫu cho 3 tham số, mô hình đúng dạng

Điều chuẩn làm dưới khớp

λ càng lớn càng kéo trọng số về 0

Điều chuẩn có ích khi mô hình phức tạp so với dữ liệu (Hình bậc 8, mục 5). Chọn λ bằng dữ liệu kiểm chứng

6.3 scikit-learn

Bốn mô hình trên cùng dữ liệu

```
lam = 0.1
mo_hinh = {
  "LinearRegression": LinearRegression(),
  "Ridge": Ridge(alpha=n_tr * lam),    # alpha = n * lambda
  "Lasso": Lasso(alpha=lam / 2),       # alpha = lambda / 2
  "SGDRegressor": SGDRegressor(penalty=None, eta0=0.01,
        learning_rate="constant", max_iter=2000, random_state=0),
}
for ten, m in mo_hinh.items():
    pipe = make_pipeline(StandardScaler(), m).fit(X_tr, y_tr)
```

Pipeline có StandardScaler: chuẩn hóa ước lượng trên tập huấn luyện đúng như đã làm.

6.3 scikit-learn

Kết quả trên tập kiểm tra

Mô hình	b	w (chuẩn hóa)	MSE	MAE	R^2
LinearRegression	3,468	[1,186; −0,363]	0,1526	0,2995	0,9008
Ridge (λ = 0,1)	3,468	[1,076; −0,324]	0,1625	0,3157	0,8944
Lasso (λ = 0,1)	3,468	[1,133; −0,310]	0,1587	0,3096	0,8968
SGDRegressor	3,484	[1,215; −0,378]	0,1539	0,3027	0,8999

Cả bốn có chất lượng xấp xỉ nhau (R^2 từ 0,894 đến 0,901): bài toán đơn giản, không quá khớp.

6.3 Lưu ý

Quy ước tham số điều chuẩn

Mô hình	scikit-learn tối thiểu hóa	Đổi từ λ của bài giảng
Ridge	$\|y - Xw\|^2 + \alpha\|w\|^2$	$\alpha = n\lambda$
Lasso	$(1/2n)\|y - Xw\|^2 + \alpha\|w\|_1$	$\alpha = \lambda/2$

Với cách đổi này, Ridge cho w = [1,076; −0,324], trùng kết quả tự cài đặt

6.3 Những điểm cần biết

LinearRegression, Lasso, SGD

LinearRegression

Trùng nghiệm phương trình chuẩn. Hệ số chệch lưu trong intercept_, trọng số trong coef_

Lasso

Huấn luyện bằng Coordinate Descent; λ = 0,1 chưa có trọng số bằng 0 vì cả hai đặc trưng đều hữu ích

SGDRegressor

Dùng SGD nên gần nhưng không trùng nghiệm (b = 3,484 so với 3,468)

Tóm tắt mục 6

Năm ý cần nhớ

- Mọi công thức cài bằng **phép nhân ma trận**: Xb @ w, (2/n)·Xb.T @ e, np.linalg.solve.
- Gradient Descent và phương trình chuẩn cho **cùng nghiệm**; chuẩn hóa giúp GD hội tụ nhanh và nghiệm quy về được thang gốc.
- Luôn **chia tập huấn luyện/kiểm tra**; ước lượng tham số chuẩn hóa chỉ trên tập huấn luyện.
- Thước đo: **MSE, RMSE, MAE** (nhỏ là tốt) và **R^2** (gần 1 là tốt, ≈ 0 là không hơn việc đoán trung bình).
- scikit-learn: α (Ridge) = nλ, α (Lasso) = λ/2.

Câu hỏi kiểm tra nhanh (1/2)

Thử sức nào!

1. $R^2 = 0$ trên tập kiểm tra nghĩa là gì? $R^2 < 0$ nghĩa là gì?

2. Vì sao tham số chuẩn hóa phải ước lượng trên tập huấn luyện chứ không phải toàn bộ dữ liệu?

3. RMSE = 0,39 và MAE = 0,30 (tỷ đồng) trên tập kiểm tra: diễn giải hai số này. Vì sao RMSE lớn hơn MAE?

Câu hỏi kiểm tra nhanh (2/2)

Thử sức nào!

4. Muốn dùng $\lambda = 0{,}02$ với $n = 240$ mẫu, cần đặt alpha bằng bao nhiêu cho Ridge và Lasso của scikit-learn?

5. Vì sao nên dùng np.linalg.solve(Xb.T @ Xb, Xb.T @ y) thay vì np.linalg.inv(Xb.T @ Xb) @ Xb.T @ y?