MÔ HÌNH LOGISTIC REGRESSION · MỤC 1

Từ Perceptron đến bài toán phân loại bằng xác suất

Từ nhãn cứng ±1 đến độ tin cậy $p \in (0, 1)$

Ba câu hỏi của mục 1

Câu 1

Perceptron còn hạn chế gì khi phân loại?

Câu 2

Bài toán nhị phân được mô tả lại thế thế nào khi dự đoán xác suất?

Câu 3

Ý tưởng nào biến điểm số tuyến tính thành xác suất hợp lý?

Đích đến: Logistic Regression, mô hình tuyến tính cho ra xác suất.

Quy ước ký hiệu

Đối tượng	Ký hiệu	Kích thước và ý nghĩa
Số mẫu, số đặc trưng	n, d	n quan sát, mỗi mẫu có d đặc trưng
Vector đặc trưng (hàng)	x_i	$1 \times (d+1)$, phần tử đầu bằng 1
Ma trận đặc trưng	X	$n \times (d+1)$, hàng thứ i là x_i
Vector tham số (cột)	w	$(d+1) \times 1$: hệ số chệch w_0 và $w_1 \dots w_d$
Nhãn thực	y	$n \times 1$, $y_i \in \{0, 1\}$
Điểm số	s_i, s	$s_i = x_i w$ và $s = Xw$
Xác suất dự đoán	p_i, p	Xác suất mẫu i thuộc lớp dương
Nhãn dự đoán	$\hat{y}_i, \hat{y}$	$\hat{y}_i \in \{0, 1\}$

Thay đổi quan trọng: nhãn {0, 1}

Ý nghĩa	Bài Perceptron ($y^{\pm}$)	Bài này (y)
Lớp dương (đậu)	$+1$	1
Lớp âm (rớt)	-1	0
Công thức chuyển	$y^{\pm} = 2y - 1$	$y = (y^{\pm} + 1) / 2$

Với nhãn {0, 1}: $E[y \mid x] = 1 \cdot p + 0 \cdot (1 - p) = p(x)$.

Hạn chế 1: chỉ có nhãn cứng

Vấn đề

Perceptron trả về $y = \pm 1$. Hai mẫu cách xa đường biên rất khác nhau vẫn nhận cùng một nhãn.

Nhu cầu thực tế

Nhà trường muốn cảnh báo học vụ sớm cho mọi sinh viên có khả năng rớt trên 30%, kể cả khi mô hình vẫn nghiêng về “đậu”.

Nhãn cứng không làm được điều này.

Cùng nhãn “đậu”, độ chắc chắn rất khác

Sinh viên A

Học 9 giờ, vắng 0 buổi

s = 6,5

Perceptron: **đậu**

Logistic: **p = 0,998**

Sinh viên B

Học 5 giờ, vắng 2 buổi

s = 0,5

Perceptron: **đậu**

Logistic: **p ≈ 0,622**

Sinh viên B chỉ cần học ít hơn 1 giờ hoặc vắng thêm 1 buổi là chuyển sang rớt.

Hạn chế 2: ngưỡng cố định

Perceptron

Ngưỡng luôn ở s = 0. Điểm số s không có đơn vị rõ ràng nên không thể "hạ ngưỡng" có ý nghĩa.

Mô hình xác suất

Có thể nói rõ: "dự đoán dương khi xác suất vượt 20%".

Ví dụ tầm soát bệnh: ưu tiên không bỏ sót ca dương, nên cần hạ ngưỡng.

Hạn chế 3: không học êm khi dữ liệu chồng lấn

Số mẫu sai dao động

25 đến hơn 100 trên 280 mẫu qua các epoch.

Nguyên nhân

Mất mát $\max(0, -m)$ chỉ quan tâm mẫu sai; bước cập nhật cố định $\pm\eta x_i^T$.

Luôn còn mẫu sai thì w không bao giờ yên, phải dùng thêm thuật toán túi.

Hạn chế 4: không mượt

Mẫu sát biên bị bỏ qua

Mẫu có margin m = 0,01 và m = 5 đều có mất mát 0. Mô hình không có động lực đẩy mẫu sát biên ra xa.

Hàm dấu vô dụng cho GD

Đạo hàm bằng 0 hầu như mọi nơi, nên không dùng Gradient Descent trên đầu ra và không ghép được mạng nhiều lớp.

Cần hàm kích hoạt khả vi và hàm mất mát trơn.

Hạn chế và điều ta mong muốn

Hạn chế của Perceptron	Điều ta mong muốn
Chỉ cho nhãn cứng ±1	Đầu ra là xác suất thể hiện độ tin cậy
Ngưỡng cố định	Chọn ngưỡng theo bài toán (ví dụ cảnh báo khi P > 30%)
Dao động khi dữ liệu chồng lấn	Hàm mất mát trơn để Gradient Descent hoạt động êm
Mẫu đúng nhưng sát biên không được quan tâm	Hàm mất mát vẫn phạt nhẹ mẫu chưa đủ chắc chắn
Hàm dấu không có đạo hàm hữu ích	Hàm kích hoạt khả vi

Một thay đổi giải quyết cả năm: thay hàm dấu bằng hàm cho ra xác suất.

Dự đoán xác suất thay vì nhãn

$p(x) = P(y = 1 \mid x)$

Nhãn mới: $y = 1$ (đậu), $y = 0$ (rớt)

$E[y \mid x] = p(x)$

Nhãn dự đoán: $y = 1$ nếu $p \geq 0{,}5$

Giờ học	Số SV	Đậu	Tỉ lệ đậu
[0, 2)	39	0	0%
[2, 4)	68	2	2,9%
[4, 6)	96	33	34,4%
[6, 8)	93	69	74,2%
[8, 10)	79	71	89,9%
≥ 10	25	25	100%

Ví dụ xuyên suốt: 6 sinh viên

Sinh viên	x_1 (giờ tự học)	x_2 (buổi vắng)	y (kết quả)
1	2	4	0 (rớt)
2	3	3	0 (rớt)
3	4	5	0 (rớt)
4	6	1	1 (đậu)
5	8	2	1 (đậu)
6	9	0	1 (đậu)

n = 6, d = 2. So với bài Perceptron, ma trận X không đổi, chỉ nhãn y đổi từ ±1 sang 0/1.

Hồi quy tuyến tính cho “ xác suất” ngoài [0, 1]

Hồi quy tuyến tính trên nhãn 0/1: $p = -0{,}222 + 0{,}122 \cdot x_1$

$x_1 = 0$ giờ

$p = -0{,}222 < 0$

$x_1 = 12$ giờ

$p \approx 1{,}244 > 1$

Cần một hàm “nén” điểm số về (0, 1), có dạng chữ S và trơn.

Hình 1. Xác suất đậu theo số giờ tự học



Đường thẳng (hồi quy tuyến tính) vượt ra ngoài [0, 1]; đường cong chữ S bám sát tỉ lệ đậu thực tế.

Ý tưởng: tách làm hai bước

Bước 1: điểm số tuyến tính

$s = xw$, có thể là mọi số thực. s lớn dương: rất có khả năng đậu; s rất âm: rất có khả năng rớt.

Bước 2: hàm nén σ

$p = \sigma(s) \in (0, 1)$.

σ cần: tăng theo s; $\to 0$ khi $s \to -\infty$; $\to 1$ khi $s \to +\infty$; $\sigma(0) = 0{,}5$; khả vi.

Odds và log-odds

Odds

p / (1 − p): tỉ lệ khả năng xảy ra so với không xảy ra. p = 0,8 nghĩa là odds = 4.

Log-odds (logit)

ln(p / (1 − p)) nhận mọi giá trị trong (−∞, +∞), đúng bằng miền của điểm số.

p	0,1	0,2	0,5	0,8	0,9
Odds	0,111	0,25	1	4	9
Log-odds	−2,197	−1,386	0	1,386	2,197

Giả thiết và suy ra sigmoid

Giả thiết: $\ln(p / (1 - p)) = xw = s$

$p / (1 - p) = e^s$

$p = e^s (1 - p) \Rightarrow p (1 + e^s) = e^s$

$p = e^s / (1 + e^s) = 1 / (1 + e^{-s}) = \sigma(s)$

Mô hình: $p = P(y = 1 \mid x) = \sigma(xw)$

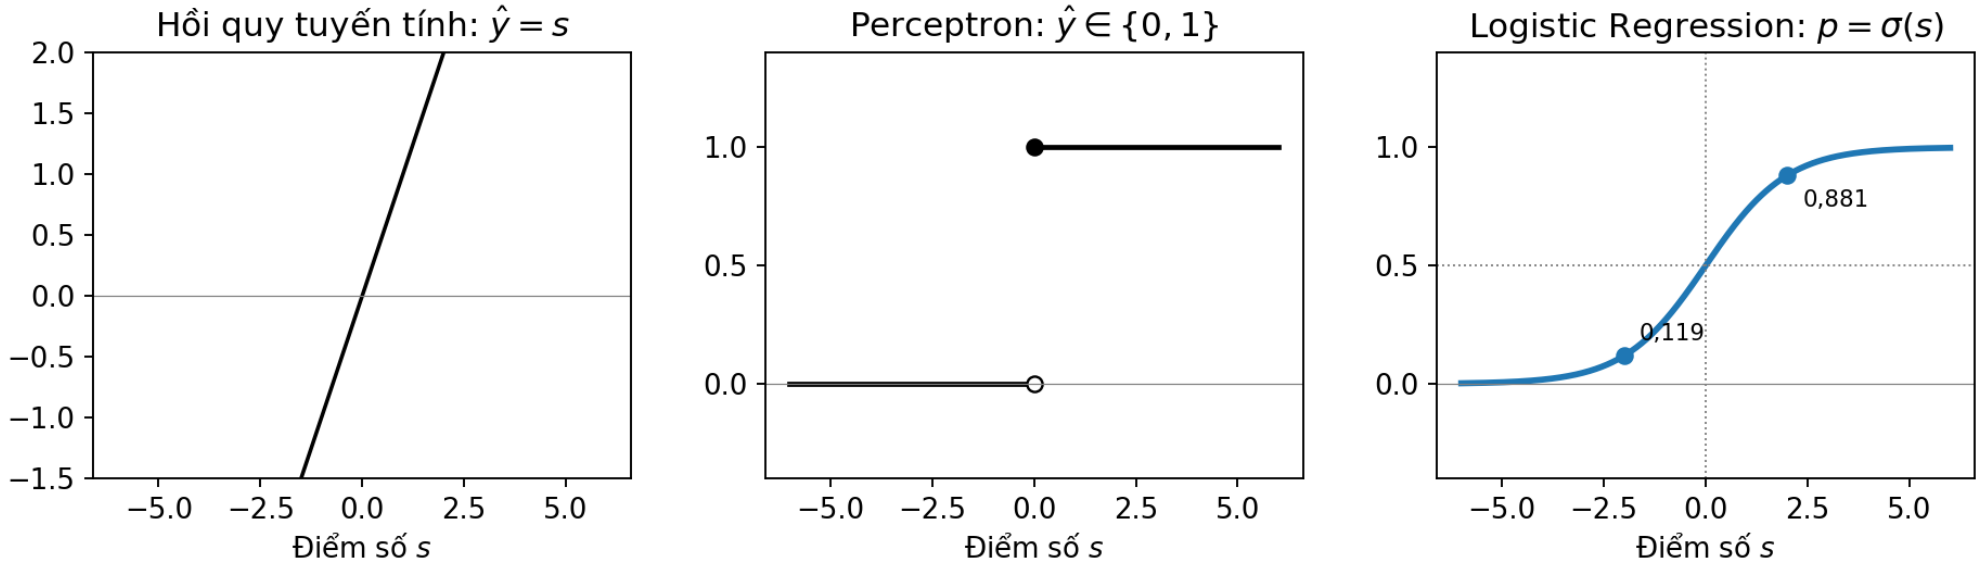
Một số giá trị sigmoid nên nhớ

s	−4	−2	−1	0	0,5	1	2	4
σ(s)	0,018	0,119	0,269	0,5	0,622	0,731	0,881	0,982

Đối xứng: σ(−s) = 1 − σ(s), ví dụ σ(2) = 0,881 và σ(−2) = 0,119.

Logistic Regression = hồi quy tuyến tính + hàm sigmoid

Hình 2. Ba cách xử lý cùng một điểm số s = xw



Hồi quy tuyến tính giữ nguyên s, Perceptron nhảy đột ngột tại s = 0, Logistic Regression chuyển mượt trong (0, 1).

Từ điểm số tuyến tính đến xác suất

Odds

$p / (1 - p)$

Miền $(0, +\infty)$

$p = 0{,}8 \rightarrow$ odds $= 4$

Log-odds

$\ln(p / (1 - p)) = s = xw$

Miền $(-\infty, +\infty)$

Sigmoid

$p = \sigma(s) = 1 / (1 + e^{-s})$

Miền $(0, 1)$

Giả thiết: log-odds là hàm tuyến tính của đặc trưng.

Tính xác suất cho 6 sinh viên

Sinh viên	x_1 (giờ tự học)	x_2 (buổi vắng)	y (kết quả)	$s = xw$	$p = \sigma(s)$	Nhãn ŷ (ngưỡng 0,5)
1	2	4	0 (rớt)	−4,5	0,011	0
2	3	3	0 (rớt)	−2,5	0,076	0
3	4	5	0 (rớt)	−3,5	0,029	0
4	6	1	1 (đậu)	2,5	0,924	1
5	8	2	1 (đậu)	3,5	0,971	1
6	9	0	1 (đậu)	6,5	0,998	1

Với $w = (-2{,}5;\ 1;\ -1)^T$. Nhãn trùng Perceptron, nhưng có thêm cột xác suất.

So với Perceptron: giữ lại và thay đổi

Giữ lại

Điểm số $s = xw$ và đường biên $xw = 0$. Vì σ tăng và $\sigma(0) = 0{,}5$ nên $p \geq 0{,}5 \Leftrightarrow s \geq 0$.

Thay đổi

Đầu ra là xác suất, nên hàm mất mát phải đổi: không dùng $\max(0, -m)$, cũng không nên dùng MSE.

Mọi hiểu biết hình học (vector pháp tuyến, khoảng cách $|s| / \|w\|$) vẫn đúng.

Độ lớn của w bây giờ có ý nghĩa

Tham số (sinh viên B, s = 0,5)	Điểm số s	Xác suất σ(s)
0,5w	0,25	0,562
w	0,5	0,622
2w	1	0,731

Hệ số lớn

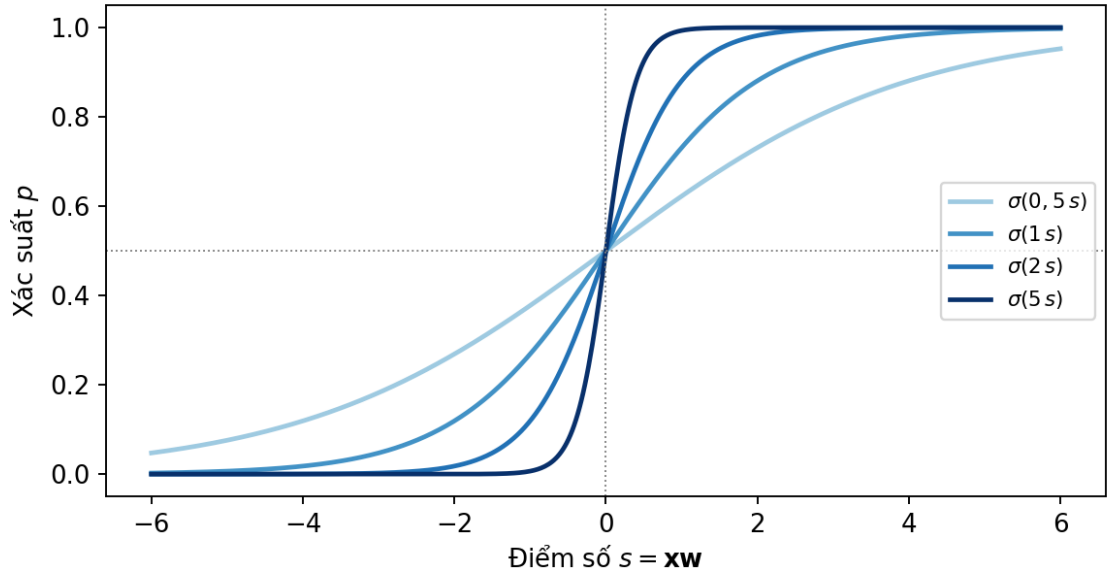
Sigmoid dốc hơn: mô hình quả quyết hơn.

Hệ số nhỏ

Sigmoid thoải hơn: mô hình dè dặt hơn.

Đường biên không đổi, nhưng độ tự tin thay đổi. Lưu ý: xác suất chỉ đáng tin khi giả thiết log-odds tuyến tính phù hợp.

Hình 3. Đồ thị σ(c·s) với các hệ số c khác nhau



Mọi đường đều đi qua (0; 0,5) nên đường biên không đổi; c càng lớn thì xác suất chuyển càng nhanh từ 0 lên 1. từ 0 lên 1.

Tóm tắt mục 1

Bốn hạn chế của Perceptron

Nhãn cứng, ngưỡng cố định, dao động khi chồng lấn, không mượt.

Bài toán theo xác suất

$p(x) = P(y = 1 \mid x)$, $y \in \{0, 1\}$, $E[y \mid x] = p(x)$, ngưỡng 0,5.

Hồi quy tuyến tính trên nhãn 0/1 thất bại

Cho giá trị ngoài [0, 1] và không bám đường cong chữ S.

Log-odds tuyến tính, $p = \sigma(xw)$

Đường biên vẫn là $xw = 0$, độ lớn của w điều khiển độ tự tin.

Bước tiếp theo

Hàm mất mát phù hợp xác suất: nguyên lý hợp lý cực đại (mục 3).

Câu hỏi kiểm tra nhanh (1/2)

1. Với $w = (-2{,}5;\ 1;\ -1)^T$ và sinh viên $x = (1, 6, 3)$, tính s, $p = \sigma(s)$ và nhãn $\hat{y}$.

2. Cho $p = 0{,}75$, tính odds và log-odds. Làm tương tự với $p = 0{,}25$ và nhận xét.

3. Nếu log-odds của một sinh viên là -2 thì xác suất đậu bằng bao nhiêu?

Câu hỏi kiểm tra nhanh (2/2)

4. Giải thích vì sao thay hàm dấu bằng sigmoid không làm đổi đường biên quyết định.

5. So sánh xác suất cho mẫu có $s = 0{,}5$ khi dùng w và $2w$. Điều này nói gì về vai trò độ lớn của w?

6. Chuyển $y_{\pm} = (-1, -1, -1, +1, +1, +1)^T$ sang nhãn $\{0, 1\}$ bằng $y = (y_{\pm} + 1) / 2$.

Gợi ý đáp án

1. $s = -2{,}5 + 6 - 3 = 0{,}5$; $p \approx 0{,}622$; $p \geq 0{,}5$ nên $\hat{y} = 1$ (đậu).

2. $p = 0{,}75$: odds = 3, log-odds $\approx 1{,}099$. $p = 0{,}25$: odds = 1/3, log-odds $\approx -1{,}099$. Trái dấu, cùng độ lớn.

3. $p = \sigma(-2) = 1 / (1 + e^2) \approx 0{,}119$.

4. σ tăng và $\sigma(0) = 0{,}5$ nên $\sigma(s) \geq 0{,}5 \Leftrightarrow s \geq 0$, cùng phân chia với dấu của s.

5. w: $p \approx 0{,}622$; $2w$: $p \approx 0{,}731$. Độ lớn của w điều khiển độ tự tin.

6. $y = (0, 0, 0, 1, 1, 1)^T$.

Bốn hạn chế của Perceptron

1. Chỉ có nhãn cứng

Không cho biết mô hình chắc chắn đến đâu.

2. Ngưỡng cố định

Luôn cắt ở s = 0, không chọn được theo hậu quả của sai sót.

3. Dao động

Dữ liệu chồng lấn: số mẫu sai nhảy từ 25 đến hơn 100 trên 280 mẫu.

4. Không mượt

Mẫu sát biên không được quan tâm; hàm dấu có đạo hàm bằng 0.

MÔ HÌNH LOGISTIC REGRESSION · MỤC 2

Mô hình Logistic Regression

Điểm số, sigmoid, đường biên và ý nghĩa của trọng số

Ba câu hỏi của mục 2

Câu 1

Mô hình nhận đầu vào, xử lý và đưa ra xác suất như thế nào?

Câu 2

Mô hình viết gọn bằng vector và ma trận ra sao?

Câu 3

Đường biên ở đâu, và trọng số w_j có ý nghĩa gì?

Dù tên là “hồi quy”, đây là mô hình phân loại: hồi quy ra xác suất rồi suy ra nhãn.

Máy ước lượng khả năng: bốn bước

1. Nhận đặc trưng

$x_1, x_2, \ldots, x_d$ của một mẫu.

2. Tính điểm số

$s = xw$: một số thực bất kỳ, chính là log-odds.

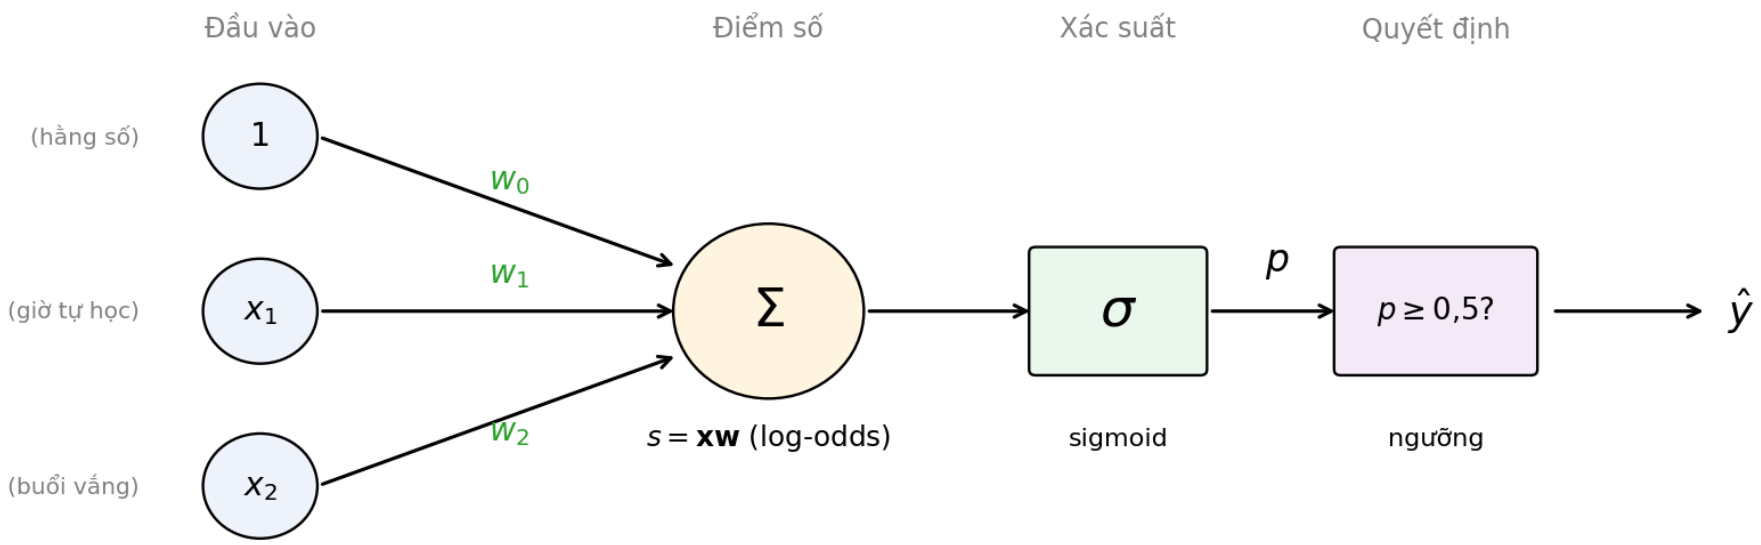
3. Tính xác suất

$p = \sigma(s) \in (0, 1)$.

4. Ra quyết định

So p với ngưỡng (mặc định 0,5) để được $\hat{y} \in \{0, 1\}$.

Hình 4. Cấu trúc Logistic Regression với hai đặc trưng



Đầu vào nhân trọng số, cộng thành điểm số s (log-odds); sigmoid cho xác suất p; so với ngưỡng cho nhãn ŷ.

Điểm số là log-odds

$$s = w_0 + w_1 x_1 + \ldots + w_d x_d = xw = \ln\left(\frac{p}{1-p}\right)$$

Hệ số chệch w_0

Log-odds khi mọi đặc trưng bằng 0. $\sigma(w_0)$ là xác suất nền. Với $w_0 = -2{,}5$: $\sigma(-2{,}5) \approx 0{,}076$, tức 7,6%.

Trọng số w_j

x_j tăng 1 đơn vị thì log-odds tăng w_j. $w_j > 0$ làm tăng khả năng lớp dương, $w_j < 0$ làm giảm, $w_j = 0$ không ảnh hưởng.

Cộng vào log-odds, nhân vào odds

$$\text{odds} = p / (1 - p) = e^{s} = e^{w_0} \cdot e^{(w_1 x_1)} \cdot e^{(w_2 x_2)} \cdots e^{(w_d x_d)}$$

Ví dụ: $w = (-2{,}5;\ 1;\ -1)^T$

$s = -2{,}5 + 1 \cdot x_1 - 1 \cdot x_2$

Cách đọc

Mô hình khởi đầu ở log-odds −2,5 (xác suất 7,6%). Mỗi giờ học làm log-odds tăng 1, mỗi buổi vắng làm giảm 1.

Sinh viên phải tích lũy đủ giờ học thì xác suất đậu mới vượt 50%.

Hàm sigmoid $\sigma(s) = 1 / (1 + e^{-s})$

Tính chất	Biểu thức	Giải thích
Miền giá trị	$0 < \sigma(s) < 1$	$e^{-s} > 0$ nên mẫu số > 1
Giá trị tại 0	$\sigma(0) = 0{,}5$	$e^0 = 1$ nên $\sigma(0) = 1/2$
Giới hạn	$\sigma \to 1$ khi $s \to +\infty$; $\sigma \to 0$ khi $s \to -\infty$	$e^{-s} \to 0$ hoặc $e^{-s} \to +\infty$
Đơn điệu tăng	$\sigma'(s) > 0$	Chứng minh ở slide sau
Đối xứng	$\sigma(-s) = 1 - \sigma(s)$	Chứng minh ở slide sau
Hàm ngược	$\sigma^{-1}(p) = \ln(p / (1 - p))$	Chính là logit

Hai chứng minh ngắn

Đối xứng

$\sigma(-s) = 1/(1 + e^{s}) = e^{-s}/(e^{-s} + 1) = 1 - 1/(1 + e^{-s}) = 1 - \sigma(s)$.

Đạo hàm

$\sigma'(s) = e^{-s}/(1 + e^{-s})^2 = \sigma(s) \cdot e^{-s}/(1 + e^{-s}) = \sigma(s)(1 - \sigma(s))$.

$\sigma'(s) = \sigma(s)(1 - \sigma(s)) > 0$, và công thức gọn này dùng liên tục ở mục 3.

Sigmoid nhạy nhất quanh đường biên

$\sigma'(0) = 0{,}25$

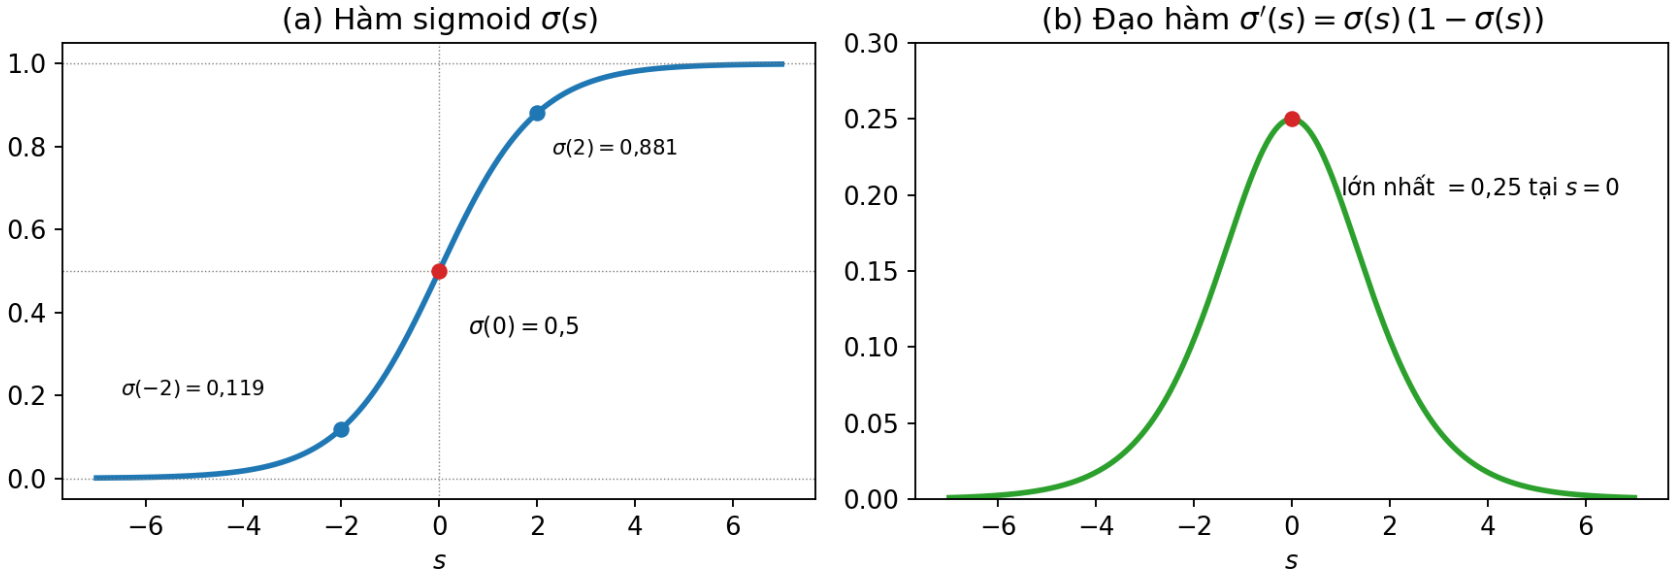
Lớn nhất, vì $\sigma(1 - \sigma)$ đạt cực đại khi $\sigma = 0{,}5$.

$\sigma'(2) \approx 0{,}105$

$0{,}881 \times 0{,}119$. Nhỏ hơn nhiều khi mẫu đã xa biên.

Mẫu xa đường biên ($|s|$ lớn): xác suất gần như không đổi dù điểm số đổi thêm.

Hình 5. Hàm sigmoid và đạo hàm của nó



(a) σ(s) đi qua (0; 0,5) và bão hòa về 0, 1. (b) σ′(s) lớn nhất tại s = 0 và tiến về 0 khi |s| lớn.

Xác suất của cả hai lớp

Hai lớp

$P(y=1 \mid x) = \sigma(xw)$

$P(y=0 \mid x) = 1 - \sigma(xw) = \sigma(-xw)$

Một công thức duy nhất

$P(y \mid x) = p^y (1 - p)^{1-y}$, với $p = \sigma(xw)$

$y = 1$ cho $p^1(1 - p)^0 = p$; $y = 0$ cho $p^0(1 - p)^1 = 1 - p$. Đây là phân phối Bernoulli, nền tảng của hàm mất mát ở mục 3.

Quy tắc dự đoán nhãn

$\hat{y} = 1 \Leftrightarrow p \geq 0{,}5 \Leftrightarrow s = xw \geq 0$ (điểm nằm đúng trên biên gán nhãn 1)

Sinh viên ($w = (-2{,}5; 1;$	s	$p = \sigma(s)$	$\hat{y}$
7 giờ, vắng 3 buổi: $x = (1, 7, 3)$	1,5	0,818	1
3 giờ, vắng 4 buổi: $x = (1, 3, 4)$	−3,5	0,029	0
4,5 giờ, vắng 2 buổi: $x = (1, 4{,}5, 2)$	0	0,5	1

Ngưỡng quyết định tùy chọn τ

$$\hat{y} = 1 \Leftrightarrow p \geq \tau \Leftrightarrow s \geq \ln(\tau / (1 - \tau))$$

Ngưỡng τ	0,2	0,3	0,5	0,7	0,8
Điểm số tối thiểu	−1,386	−0,847	0	0,847	1,386

Cảnh báo học vụ khi P(rớt) > 30%, tức p < 0,7, tương đương s < 0,847.

Cảnh báo học vụ với ngưỡng 0,7

Sinh viên	p (đậu)	ŷ (ngưỡng 0,5)	Cảnh báo? (p < 0,7)
1	0,011	0	Có
2	0,076	0	Có
3	0,029	0	Có
4	0,924	1	Không
5	0,971	1	Không
6	0,998	1	Không
B (s = 0,5)	0,622	1	Có

Sinh viên B được dự đoán "đậu" nhưng vẫn bị cảnh báo. Perceptron không làm được điều này.

Biểu diễn vector và ma trận

Một mẫu

$s_i = x_i w$ ($1\times(d+1)$ nhân $(d+1)\times 1$ là một số), $p_i = \sigma(s_i)$, $\hat{y}_i = 1$ nếu $p_i \geq 0{,}5$.

Cả n mẫu

$s = Xw$, $p = \sigma(Xw)$: sigmoid áp dụng lên từng phần tử.

Đại lượng	Biểu thức	Kích thước
Ma trận đặc trưng	X	$n \times (d+1)$
Vector tham số	w	$(d+1)\times 1$
Điểm số (log-odds)	$s = Xw$	$n \times 1$
Xác suất	$p = \sigma(s)$	$n \times 1$
Nhãn dự đoán, nhãn thực	$\hat{y}$, y	$n \times 1$

Ví dụ số với 6 sinh viên

$$s = Xw = (-4{,}5;\ -2{,}5;\ -3{,}5;\ 2{,}5;\ 3{,}5;\ 6{,}5)^T$$

$$p = \sigma(s) \approx (0{,}011;\ 0{,}076;\ 0{,}029;\ 0{,}924;\ 0{,}971;\ 0{,}998)^T$$

$$\hat{y} = (0,\ 0,\ 0,\ 1,\ 1,\ 1)^T = y$$

Nhãn dự đoán trùng nhãn thật ở cả 6 mẫu, và ta có thêm vector xác suất p.

Xác suất mô hình gán cho nhãn thật

Định nghĩa

$q_i = P(y_i \mid x_i) = p_i^{y_i} (1 - p_i)^{(1 - y_i)}$: $y_i = 1$ thì $q_i = p_i$, $y_i = 0$ thì $q_i = 1 - p_i$.

Ví dụ

$q \approx (0{,}989; 0{,}924; 0{,}971; 0{,}924; 0{,}971; 0{,}998)^T$

Tích $\prod q_i \approx 0{,}795$. Chọn w để tích này lớn nhất: nguyên lý hợp lý cực đại (mục 3).

Đường biên quyết định

$$\{ x : xw = 0 \} \Leftrightarrow w_o + w_1 x_1 + \ldots + w_d\, x_d = 0$$

Giống hệt Perceptron

Siêu phẳng (đường thẳng khi d = 2); w là vector pháp tuyến chỉ về phía xác suất tăng; w_o tịnh tiến, các trọng số xoay đường biên.

Ví dụ

$w = (-2{,}5;\ 1;\ -1)^T$ cho đường biên $x_2 = x_1 - 2{,}5$. Vẫn là bộ phân loại tuyến tính, không giải được XOR.

Các đường đồng mức xác suất

$\sigma(xw) = c \Leftrightarrow xw = \ln(c / (1 - c))$: siêu phẳng song song với đường biên

$p = 0{,}9$

$s = \ln 9 \approx 2{,}197$

$p = 0{,}1$

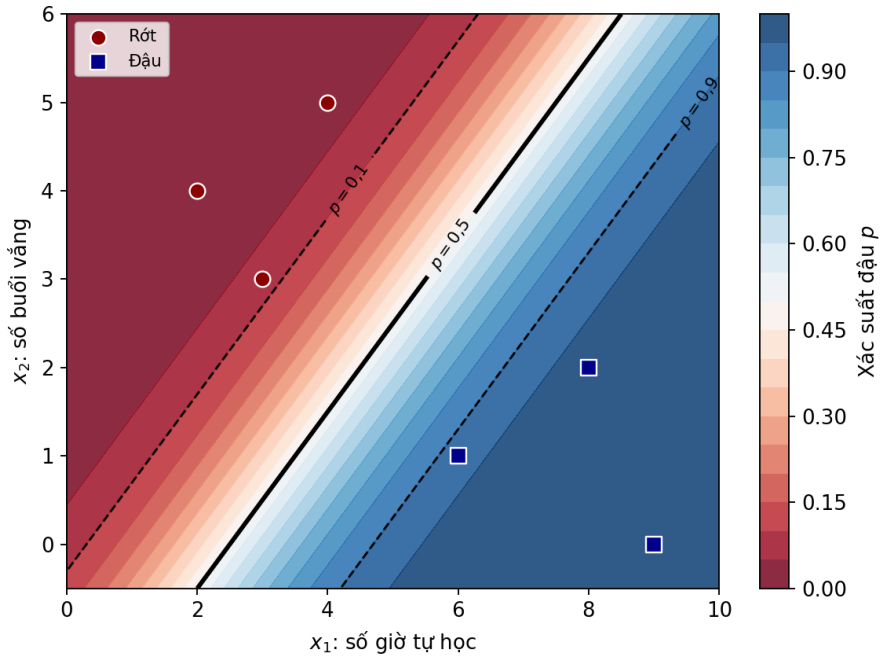
$s = -2{,}197$

Khoảng cách

$|s| / \|w\| = 2{,}197 / \sqrt{2} \approx 1{,}55$

$\|w\|$ lớn: đường đồng mức sát nhau, mô hình quả quyết. $\|w\|$ nhỏ: thưa, mô hình dè dặt.

Hình 6. Bản đồ xác suất đậu trên mặt phẳng đặc trưng



Đường liền

p = 0,5: đường biên xw = 0.

Hai đường đứt

p = 0,1 và p = 0,9, song song với đường biên.

Chuyển mượt

Từ vùng rớt (đỏ) sang vùng đậu (xanh), nhanh nhất quanh đường biên.

Ý nghĩa trọng số: odds ratio

x_j tăng 1 đơn vị ⇒ odds sau / odds trước = $e^{(s + w_j)} / e^s = e^{w_j}$

Quy tắc đọc

$w_j > 0$: odds tăng e^{w_j} lần. $w_j < 0$: odds giảm. $w_j = 0$: không đổi.

Ví dụ $w = (-2{,}5;\ 1;\ -1)^T$

Mỗi giờ học thêm: odds × $e^1 \approx 2{,}718$. Mỗi buổi vắng thêm: odds × $e^{-1} \approx 0{,}368$ (giảm khoảng 63%).

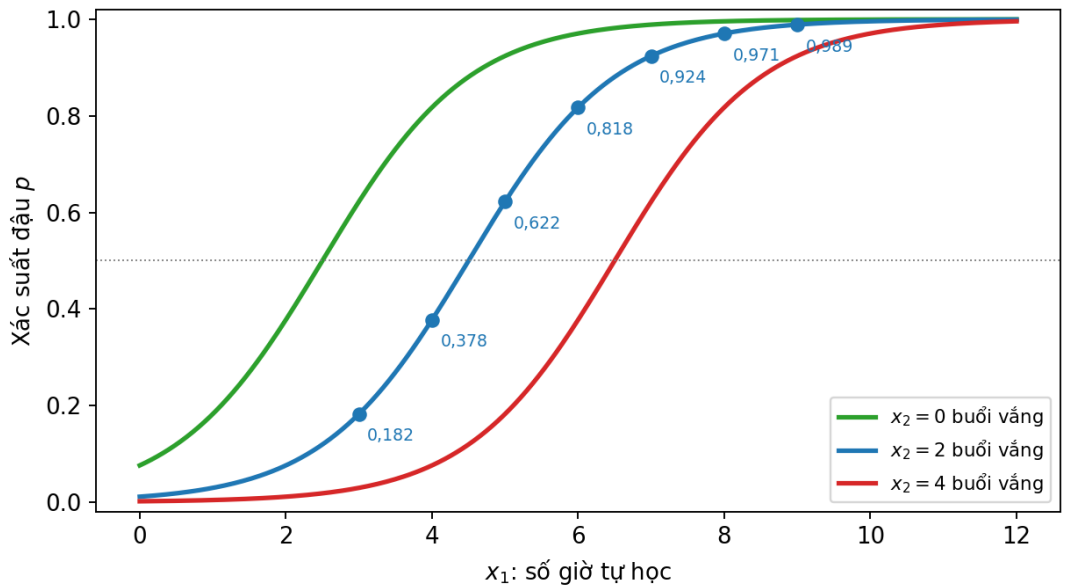
Sinh viên B ($s = 0{,}5$, odds ≈ 1,649): học thêm 1 giờ cho $p \approx 0{,}818$; vắng thêm 1 buổi cho $p \approx 0{,}378$.

Odds nhân đều, xác suất thì không

x_1	3	4	5	6	7	8	9
$s = x_1 - 4{,}5$	−1,5	−0,5	0,5	1,5	2,5	3,5	4,5
Odds = e^s	0,223	0,607	1,649	4,482	12,18	33,12	90,02
Xác suất p	0,182	0,378	0,622	0,818	0,924	0,971	0,989
Tăng của p		+ 0,196	+ 0,244	+ 0,196	+ 0,106	+ 0,047	+ 0,018

Một giờ học thêm rất hữu ích với sinh viên ở mức trung bình, gần như vô ích với sinh viên đã chắc chắn đậu.

Hình 7. Xác suất đậu theo số giờ tự học



Ba đường x_2 = 0, 2, 4 là cùng một đường sigmoid tịnh tiến theo x_1; các số trên đường x_2 = 2 là xác suất tại từng giá trị nguyên của x_1.

Giải thích bằng đạo hàm

$$\partial p/\partial x_j = \sigma'(s) \cdot w_j = p(1-p)\, w_j$$

Lớn nhất

Khi p = 0,5 mức tăng là $w_j/4$. Với $w_1 = 1$: tối đa khoảng 0,25, sát +0,244 trong bảng.

Gần bằng 0

Khi p tiến sát 0 hoặc 1, xác suất gần như không đổi.

Lưu ý khi diễn giải trọng số

Dấu và độ lớn

Dấu của w_j cho hướng ảnh hưởng, độ lớn cho cường độ qua e^{w_j}. Perceptron không có lợi thế này.

Thang đo

Đơn vị của w_j gắn với đơn vị của x_j, nên chỉ so sánh công bằng khi các đặc trưng cùng thang đo (ví dụ sau khi chuẩn hóa, mục 4.2).

Nhân đôi w

Đường biên không đổi nhưng odds ratio từ e^{w_j} thành $e^{(2w_j)}$: tác động mạnh hơn.

So sánh nhanh với Perceptron

	Perceptron	Logistic Regression
Điểm số	$s = xw$	$s = xw$ (là log-odds)
Hàm kích hoạt	Hàm dấu / hàm bước	Sigmoid $\sigma(s)$
Đầu ra	Nhãn cứng	Xác suất $p \in (0, 1)$, suy ra nhãn
Đường biên	$xw = 0$	$xw = 0$ ($p = 0{,}5$) và các đường đồng mức song song
Độ lớn của w	Không ảnh hưởng	Điều khiển độ tự tin
Ý nghĩa w_j	Hướng ảnh hưởng	Hướng và cường độ: e^{w_j} là odds ratio
Đạo hàm kích hoạt	0 hầu như mọi nơi	$\sigma(1 - \sigma) > 0$ ở mọi nơi

Tóm tắt mục 2

Mô hình

$s = xw$ là log-odds, $p = \sigma(xw) = 1/(1 + e^{-xw})$; $\hat{y} = 1 \Leftrightarrow p \geq 0{,}5 \Leftrightarrow xw \geq 0$.

Sigmoid

$\sigma(0) = 0{,}5$; $\sigma(-s) = 1 - \sigma(s)$; $\sigma' = \sigma(1 - \sigma)$. $P(y \mid x) = p^y(1 - p)^{1-y}$.

Ngưỡng và ma trận

$\hat{y} = 1 \Leftrightarrow xw \geq \ln(\tau/(1 - \tau))$; $p = \sigma(Xw)$, σ áp dụng từng phần tử.

Hình học

Đường biên $xw = 0$ như Perceptron; đường đồng mức xác suất song song với nó.

Trọng số

e^w_j là hệ số nhân của odds; mức đổi của p là $p(1 - p)w_j$, lớn nhất quanh $p = 0{,}5$.

Câu hỏi kiểm tra nhanh (1/2)

1. Với $w = (-2{,}5;\ 1;\ -1)^T$ và $x = (1,\ 7,\ 3)$, tính s, p, ŷ và odds.

2. Tính $\sigma'(0)$ và $\sigma'(2)$. Giá trị nào lớn hơn, điều đó nói gì về ảnh hưởng của điểm số lên xác suất?

3. Ngưỡng $\tau = 0{,}7$, sinh viên $x = (1,\ 6,\ 3)$: nhãn dự đoán với ngưỡng 0,5 và 0,7?

4. Sinh viên có $s = 0{,}5$ (odds $\approx 1{,}649$) vắng thêm một buổi: tính odds, p mới và kiểm tra bằng e^{w_2}.

Câu hỏi kiểm tra nhanh (2/2)

5. Một mô hình có $w_1 = 0,7$ cho "số giờ học". Tính odds ratio khi học thêm 1 giờ và 2 giờ.

6. Hai sinh viên cùng bị dự đoán $\hat{y} = 1$, một người $p = 0,55$, một người $p = 0,99$. Perceptron có phân biệt được không? Logistic Regression thì sao?

7. Với sinh viên 2 ($y_2 = 0$, $p_2 \approx 0,076$), xác suất mô hình gán cho nhãn thật là bao nhiêu?

Gợi ý đáp án (1/2)

1. $s = -2{,}5 + 7 - 3 = 1{,}5$; $p \approx 0{,}818$; $\hat{y} = 1$; odds $= e^{1{,}5} \approx 4{,}482$ (kiểm tra: $0{,}818/0{,}182 \approx 4{,}49$).

2. $\sigma'(0) = 0{,}25$; $\sigma'(2) \approx 0{,}881 \times 0{,}119 \approx 0{,}105$. Giá trị tại 0 lớn hơn: xác suất nhạy nhất khi mẫu sát đường biên.

3. $s = -2{,}5 + 6 - 3 = 0{,}5$, $p \approx 0{,}622$. Ngưỡng 0,5: $\hat{y} = 1$. Ngưỡng 0,7: $\hat{y} = 0$ (cần $s \geq 0{,}847$).

4. $s = -0{,}5$, odds $= e^{-0{,}5} \approx 0{,}607$, $p \approx 0{,}378$. Theo odds ratio: $1{,}649 \times 0{,}368 \approx 0{,}607$, khớp.

Gợi ý đáp án (2/2)

5. Học thêm 1 giờ: $e^{0,7} \approx 2,014$. Học thêm 2 giờ: $e^{1,4} \approx 4,055 = 2,014^2$, vì các tác động nhân lên nhau.

6. Perceptron không phân biệt (cả hai chỉ nhận +1). Logistic Regression cho 0,55 (rất không chắc chắn) và 0,99 (gần như chắc chắn).

7. $q_2 = 1 - p_2 \approx 1 - 0,076 = 0,924$, vì nhãn thật là 0 nên xác suất của nhãn thật là $1 - p$.

MÔ HÌNH LOGISTIC REGRESSION · MỤC 3

Huấn luyện mô hình Logistic Regression

Cross-entropy, gradient và Gradient Descent

Khung huấn luyện và ba câu hỏi

Mô hình + Hàm mất mát + Thuật toán tối ưu = Huấn luyện

Câu 1

Hàm mất mát nào đo tốt sự phù hợp giữa xác suất dự đoán và nhãn thật?

Câu 2

Gradient của nó là gì, và quy tắc cập nhật w trông thế nào?

Câu 3

Thuật toán chạy ra sao; tốc độ học và cách chia dữ liệu ảnh hưởng gì?

Vì sao cần hàm mất mát mới?

Mất mát Perceptron

max(0, −m) chỉ phạt mẫu sai, bằng 0 ngay khi mẫu đúng. Không có ý nghĩa xác suất.

Điều ta muốn

Mẫu thực sự đậu mà mô hình gán p = 0,51 là “đúng nhưng chưa chắc”: vẫn phải đẩy p lên cao hơn.

Còn MSE, hợp lý về hình thức, thì gặp một vấn đề nghiêm trọng khi kết hợp với sigmoid.

MSE kết hợp sigmoid: gradient tắt

$$J_MSE(w) = (1/n)\ \Sigma_i\ (y_i - \sigma(s_i))^2$$

Mẫu có y = 1

$\partial l/\partial s = -2(1 - p) \cdot \sigma'(s) = -2(1 - p) \cdot p(1 - p)$

Hệ quả

Thừa số $p(1 - p) \to 0$ khi $p \to 0$ hoặc 1: mô hình sai chắc chắn thì gradient lại cực nhỏ.

MSE kết hợp sigmoid còn không lồi theo w, có vùng phẳng khiến Gradient Descent bị kẹt.

Ví dụ số: y = 1 nhưng s = −6

p ≈ 0,0025

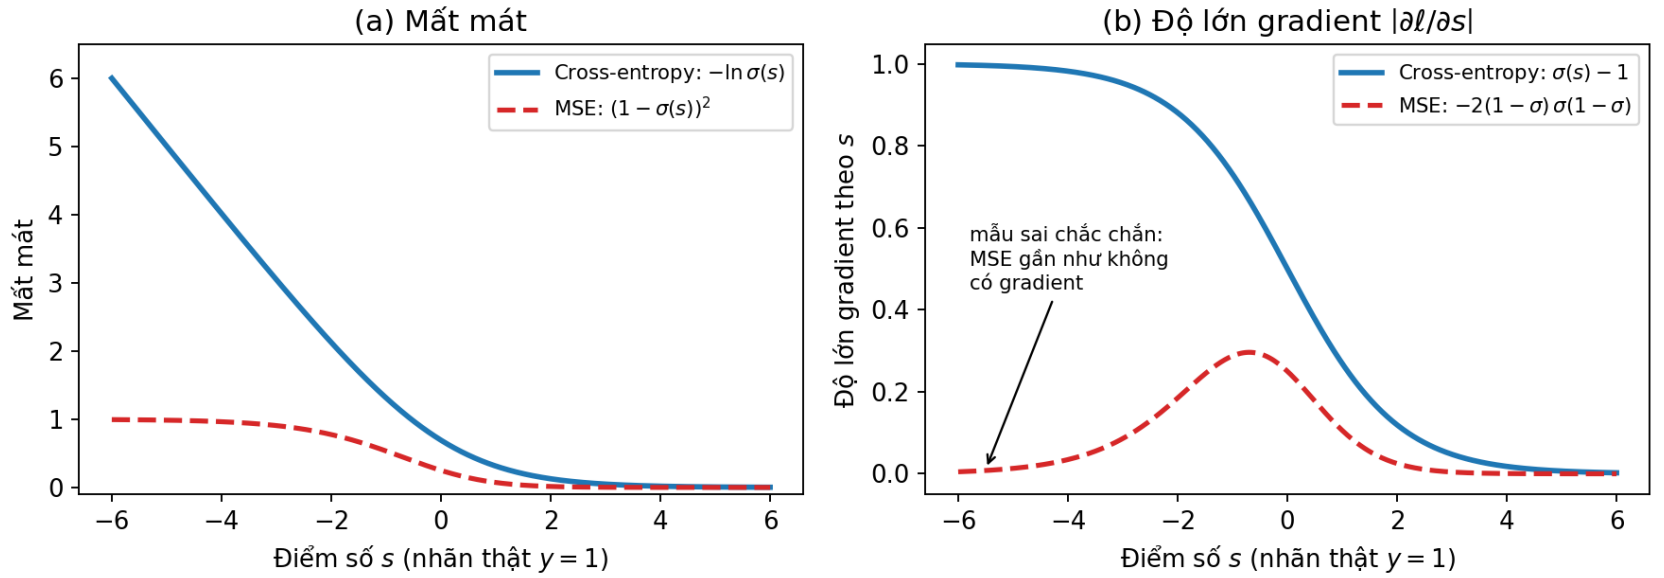
Mô hình tin chắc là rớt, trong khi thực tế đậu.

≈ 0,005

Gradient theo s của MSE: 2 · 0,9975 · 0,0025 · 0,9975, gần như bằng 0.

Thuật toán gần như không học từ chính những mẫu mà nó sai nặng nhất.

Hình 8. Cross-entropy so với MSE (y = 1)



(a) Cross-entropy phạt rất nặng khi s rất âm, MSE bị chặn ở 1. (b) Gradient MSE → 0 đúng ở vùng sai nặng.

Hàm mất mát cần có gì?

Yêu cầu	Lý do
Phạt nặng khi sai chắc chắn	Gán xác suất thấp cho điều đã xảy ra phải bị phạt rất nặng
Gradient lớn khi sai nặng	Học nhanh từ những mẫu sai nhất, không "tắt" như MSE
Trơn (khả vi)	Để dùng được Gradient Descent
Lồi	Chỉ có một nghiệm tối ưu, không kẹt cực tiểu địa phương
Có cơ sở xác suất	Việc chọn hàm mất mát không tùy tiện

Hàm thỏa mãn tất cả: cross-entropy, xuất phát từ nguyên lý hợp lý cực đại.

Hợp lý cực đại: chọn w để dữ liệu "dễ xảy ra nhất"

Câu hỏi

Với mô hình w, xác suất thu được đúng bộ nhãn $y_1, \ldots, y_n$ đã quan sát là bao nhiêu? Chọn w làm xác suất này lớn nhất.

Xác suất cho một mẫu

$q_i = P(y_i \mid x_i) = p_i^{y_i} (1 - p_i)^{(1 - y_i)}$

Các mẫu độc lập ⇒ hàm hợp lý $L(w) = \Pi_i p_i^{y_i} (1 - p_i)^{(1 - y_i)}$, $p_i = \sigma(x_i w)$

So sánh vài bộ tham số trên 6 sinh viên

Bộ tham số w	L(w)	ln L(w)
$(0, 0, 0)^T$ (mọi $p_i = 0{,}5$)	$0{,}5^6 \approx 0{,}0156$	$-4{,}159$
$(-2{,}5; 1; 0)^T$ (bỏ qua số buổi vắng)	$\approx 0{,}0414$	$-3{,}185$
$(-2{,}5; 0; -1)^T$ (bỏ qua số giờ học)	$\approx 0{,}00002$	$-10{,}626$
$(-2{,}5; 1; -1)^T$	$\approx 0{,}795$	$-0{,}230$

Bộ cuối cho dữ liệu "dễ xảy ra" nhất. Bộ thứ ba nghiêng về "rớt" cho cả ba sinh viên đậu nên L gần 0.

Từ hợp lý cực đại đến cross-entropy

Tích nhiều số nhỏ hơn 1 rất nhỏ, dễ tràn số. Lấy logarit: $\ln L(w) = \Sigma_i \, [\, y_i \ln p_i + (1 - y_i) \ln(1 - p_i) \,]$

Muốn cực tiểu hóa nên đổi dấu và lấy trung bình: $J(w) = -(1/n) \, \Sigma_i \, [\, y_i \ln p_i + (1 - y_i) \ln(1 - p_i) \,]$

$\max L \Leftrightarrow \max \ln L \Leftrightarrow \min J$. Đây là cross-entropy nhị phân (log-loss).

Mất mát một mẫu: −ln q

Hai nhánh

$l_i = -\ln p_i$ nếu $y_i = 1$; $l_i = -\ln(1 - p_i)$ nếu $y_i = 0$. Cả hai là $-\ln q_i$.

Mức “ngạc nhiên”

q_i là xác suất gán cho điều đã xảy ra: càng ít ngờ tới thì bị phạt càng nặng.

q	0,99	0,9	0,5	0,1	0,01
−ln q	0,010	0,105	0,693	2,303	4,605

q → 0: mất mát → +∞. q → 1: mất mát → 0.

Tính J trên dữ liệu sinh viên

Bộ tham số w	J(w)
$(0, 0, 0)^T$	0,693
$(-2{,}5; 1; 0)^T$	0,531
$(-2{,}5; 0; -1)^T$	1,771
$(-2{,}5; 1; -1)^T$	0,038

J(0) = ln 2 ≈ 0,693

Với w = 0 mọi $p_i = 0{,}5$, mỗi mẫu bị phạt $-\ln 0{,}5 = \ln 2$, với mọi bộ dữ liệu. Dùng để kiểm tra cài đặt.

Dạng margin

$l_i = \ln(1 + e^{(-m_i)})$ với $y_\pm = 2y - 1$, $m = y_\pm s$: trùng mất mát logistic ở bài Perceptron.

Gradient của mất mát một mẫu

Bước 1

$\partial l/\partial p = -y/p + (1 - y)/(1 - p)$

Bước 2

$\partial p/\partial s = \sigma'(s) = p(1 - p)$

Bước 3

$\partial s/\partial w = x^T$ (vì $s = xw$)

Chuỗi đạo hàm: w → s → p → l

Thừa số p(1 – p) triệt tiêu

$$\partial l/\partial s = -[\, y/p - (1-y)/(1-p) \,] \cdot p(1-p) = -y(1-p) + (1-y)p = p - y$$

$\nabla l_i(w) = (p_i - y_i)\, x_i^T$

Gradient là sai số giữa xác suất dự đoán và nhãn thật.

–0,9975 so với –0,005

Mẫu y = 1, s = −6: cross-entropy cho gradient gần lớn nhất, MSE gần 0.

Gradient của hàm mất mát tổng

$$\nabla J(w) = (1/n)\ \Sigma_i\ (p_i - y_i)\ x_i^T = (1/n)\ X^T(p - y),\ p = \sigma(Xw)$$

Kiểm tra kích thước

X^T: (d+1)×n; (p − y): n×1; tích: (d+1)×1, khớp với w.

Từng thành phần

$\partial J/\partial w_o = (1/n)\ \Sigma\ (p_i - y_i)$

$\partial J/\partial w_j = (1/n)\ \Sigma\ (p_i - y_i)\ x_{ij}$

Quy tắc cập nhật

$$w \leftarrow w - \eta \nabla J(w) = w - (\eta/n)\, X^T(p - y) = w + (\eta/n)\, X^T(y - p)$$

$y_i = 1$, p_i nhỏ

$y_i - p_i > 0$ lớn: cộng x_i^T vào w, tăng p_i.

$y_i = 0$, p_i lớn

$y_i - p_i < 0$: trừ x_i^T, giảm p_i.

$p_i \approx y_i$

Gần như không đóng góp.

$\eta > 0$ là tốc độ học (learning rate).

Ba quy tắc cập nhật cùng một khung

Mô hình	Quy tắc theo toàn bộ dữ liệu
Hồi quy tuyến tính	$w \leftarrow w - (2\eta/n)\, X^T(Xw - y)$
Logistic Regression	$w \leftarrow w - (\eta/n)\, X^T(\sigma(Xw) - y)$
Perceptron (nhãn ± 1, từng mẫu)	$w \leftarrow w + \eta \cdot 1[m \le 0] \cdot y_i x_i^T$

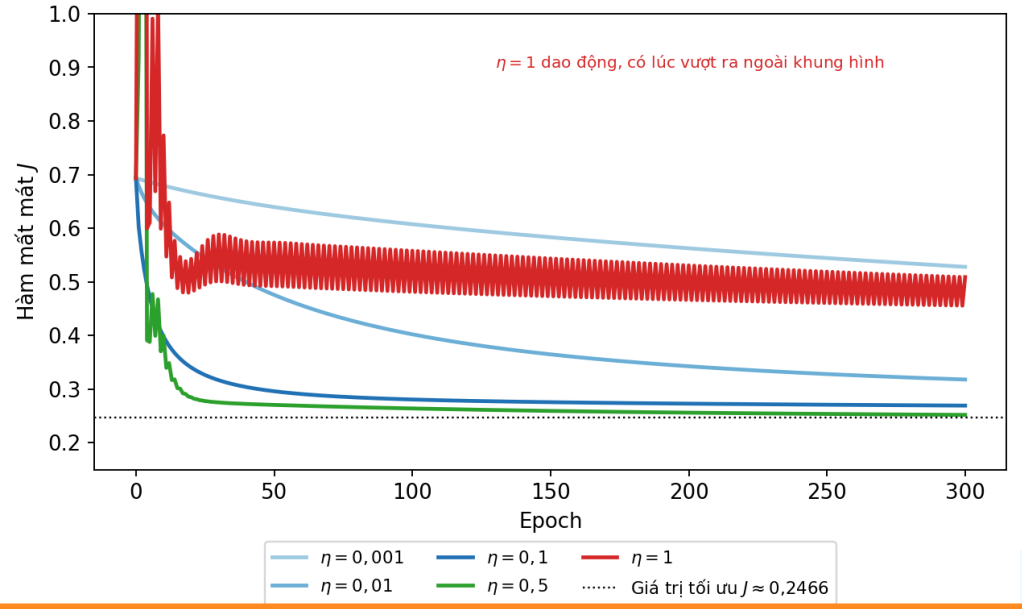
Logistic và Perceptron: Perceptron dùng trọng số cứng $1[m \le 0]$, Logistic dùng trọng số mềm $\sigma(-m)$.

Tốc độ học η

η	10 epoch	100 epoch	500 epoch	2000 epoch
0,001	0,679	0,607	0,476	0,343
0,01	0,607	0,402	0,297	0,273
0,05	0,473	0,296	0,271	0,256
0,1	0,398	0,281	0,264	0,250
0,2	0,336	0,273	0,256	0,247
0,5	0,400	0,264	0,248	0,2466
1	0,773	0,558	0,479	0,443

Giá trị J nhỏ nhất đạt được trên 280 mẫu này là ≈ 0,2466. Khác Perceptron, Logistic rất nhạy với η.

Hình 9. Hàm mất mát J theo epoch với các η khác nhau



η quá nhỏ: chậm. η vừa (0,1 đến 0,5): hội tụ về ≈ 0,2466. η = 1: vọt qua tối ưu và dao động.

Chọn η như thế nào?

η quá nhỏ (0,001)

J giảm rất chậm; sau 2000 epoch vẫn xa mức tối ưu.

η vừa phải (0,1 đến 0,5)

Hội tụ về ≈ 0,2466. η = 0,5 nhanh nhất nhưng J có lúc vọt lên ≈ 2,7: sát giới hạn an toàn.

η quá lớn (1)

w vọt qua tối ưu; J lên tới ≈ 5,4 và vẫn dao động quanh 0,45 đến 0,55.

Vẽ J theo epoch: J tăng hoặc dao động mạnh thì giảm η; J giảm đều nhưng chậm thì tăng η. Chuẩn hóa đặc trưng giúp chọn η dễ hơn.

Batch, SGD và mini-batch

Biến thể	Số mẫu mỗi lần	Số cập nhật mỗi epoch	Quy tắc
Batch GD	n (toàn bộ)	1	$w \leftarrow w - (\eta/n)\, X^T(p - y)$
SGD	1	n	$w \leftarrow w - \eta(p_i - y_i)\, x_i^T$
Mini-batch	b ($1 < b < n$)	$\lceil n/b \rceil$	$w \leftarrow w - (\eta/b)\, X_B^T(p_B - y_B)$

Một epoch là một lượt duyệt qua toàn bộ n mẫu, bất kể biến thể nào.

Thuật toán Gradient Descent

Đầu vào: X $(n\times(d+1))$, $y \in \{0,1\}^n$, $\eta > 0$, kích thước batch b, số epoch tối đa T_{max}, ngưỡng ε.

Khởi tạo $w = 0$.

Lặp mỗi epoch: xáo trộn mẫu, chia mini-batch; với mỗi batch B tính $p_B = \sigma(X_B w)$, $g = (1/b)\, X_B^T(p_B - y_B)$, $w \leftarrow w - \eta g$.

Dừng khi $\|\nabla J\| < \varepsilon$, hoặc $|J_t - J_{(t-1)}| < tol$, hoặc đạt T_{max}. Trả về w.

Logistic thường không đạt gradient đúng bằng 0 trong hữu hạn bước, nên cần điều kiện dừng và T_{max} làm "van an toàn".

Tính tay: bước 1 ($w_0 = 0$, $\eta = 0{,}1$)

Xác suất và mất mát

$s = 0$ nên $p_i = 0{,}5$. $p - y = (0{,}5; 0{,}5; 0{,}5; -0{,}5; -0{,}5; -0{,}5)^T$.
$J(w_0) = \ln 2 \approx 0{,}6931$.

Gradient

$X^T(p - y) = (0; -7; 4{,}5)^T$, nên $\nabla J(w_0) \approx (0; -1{,}1667; 0{,}75)^T$.

$w_1 = w_0 - 0{,}1 \cdot \nabla J = (0; 0{,}1167; -0{,}075)^T$. Giờ học tăng, số buổi vắng giảm: đúng hướng.

Bước 2 và bảng các bước

Từ w_1

$p \approx (0{,}483; 0{,}531; 0{,}523; 0{,}651; 0{,}686; 0{,}741)^T$; $J(w_1) \approx 0{,}5438 < 0{,}6931$.

Cập nhật

$w_2 \approx (-0{,}0103; 0{,}1547; -0{,}1611)^T$; $J(w_2) \approx 0{,}4603$.

Bước t	0	1	2	3	4	5
$J(w_t)$	0,6931	0,5438	0,4603	0,3974	0,3491	0,3111

J giảm đều. Mỗi bước giảm một chút, cả 6 mẫu đều đóng góp. Dữ liệu này phân tách được nên J giảm mãi về 0 (xem mục 4.4).

Mã Python: các hàm cơ bản

```
def them_bias(X): return np.hstack([np.ones((X.shape[0], 1)), X])
def sigmoid(s): return 0.5 * (1.0 + np.tanh(0.5 * s))
def mat_mat(Xb, y, w):
p = np.clip(sigmoid(Xb @ w), 1e-12, 1 - 1e-12)
return -np.mean(y * np.log(p) + (1 - y) * np.log(1 - p))
def gradient(Xb, y, w):
return Xb.T @ (sigmoid(Xb @ w) - y) / len(y)
```

Dùng σ(s) = ½(1 + tanh(s/2)) để không tràn số; np.clip giữ p cách xa 0 và 1 để ln p không thành –∞. thành –∞.

Mã Python: hàm huấn luyện

```
def huan_luyen(Xb, y, eta=0.1, so_epoch=1000, kich_thuoc_batch=None, seed=0):
n, d1 = Xb.shape
b = n if kich_thuoc_batch is None else kich_thuoc_batch
rng = np.random.default_rng(seed)
w = np.zeros(d1)
lich_su = [mat_mat(Xb, y, w)]
for epoch in range(so_epoch):
idx = rng.permutation(n) if b < n else np.arange(n)
for k in range(0, n, b):
lo = idx[k:k + b]
w = w - eta * gradient(Xb[lo], y[lo], w)
lich_su.append(mat_mat(Xb, y, w))
return w, lich_su
```

Kiểm tra cài đặt

Khớp với tính tay

Sau 1, 2, 5 bước: w = (0; 0,1167; −0,075), (−0,0103; 0,1547; 0,1547; −0,1611), (−0,0344; 0,2414; −0,3585); J = 0,5438; 0,5438; 0,4603; 0,3111.

Đạo hàm số

$\partial J/\partial w_j \approx [J(w + \varepsilon e_j) - J(w - \varepsilon e_j)] / 2\varepsilon$. Với 280 mẫu huấn huấn luyện: gradient giải tích và gradient số đều (0,0351; (0,0351; −0,1825; 0,3466).

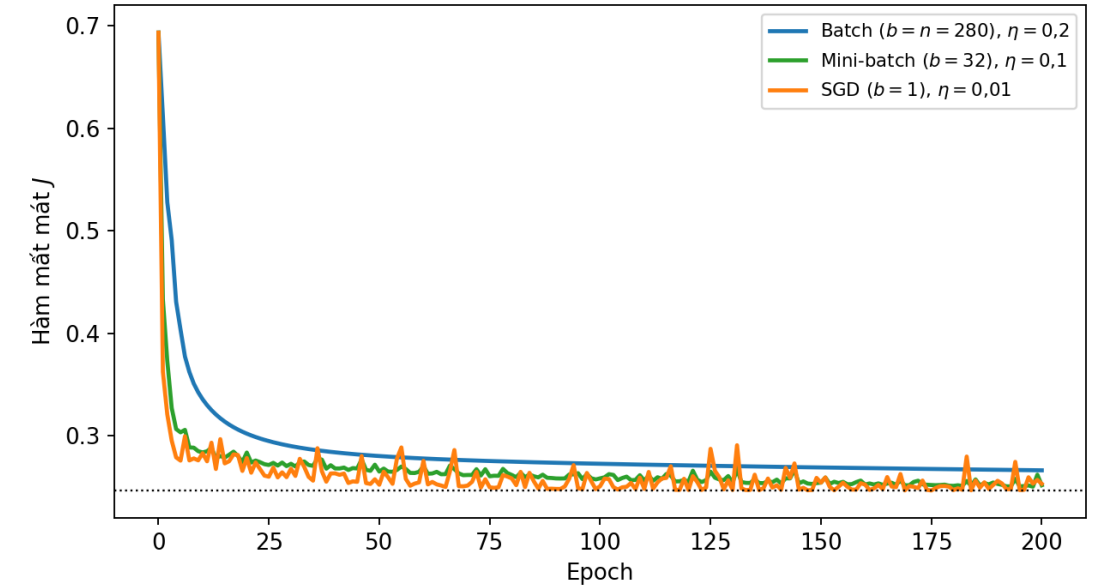
Hai kết quả trùng đến 4 chữ số thập phân: công thức $\nabla J = (1/n)X^T(p - y)$ đúng. Ngoài ra J ban đầu = ln 2 = đầu = ln 2 = 0,6931.

Huấn luyện bằng ba cách (200 epoch)

Cách	η	J	Độ chính xác train	Độ chính xác test
Batch (b = 280)	0,2	0,2664	0,8786	0,8500
Mini-batch (b = 32)	0,1	0,2518	0,8929	0,8917
SGD (b = 1)	0,01	0,2533	0,8821	0,8917

Mini-batch và SGD thực hiện nhiều bước hơn mỗi epoch nên giảm J nhanh hơn. Batch chưa hội tụ sau 200 epoch (không phải do kém hơn). Cả ba về cùng nghiệm tối ưu.

Hình 10. Hàm mất mát J theo epoch của ba biến thể



Mini-batch và SGD giảm nhanh nhưng dao động; batch mượt nhưng chậm. Đường chấm là J tối ưu ≈ 0,2466.

Tóm tắt mục 3

Vì sao không dùng Perceptron loss hay MSE

MSE kết hợp sigmoid gây gradient tắt và không lồi.

Hợp lý cực đại, cross-entropy

$J(w) = -(1/n)\,\Sigma\,[y \ln p + (1 - y)\ln(1 - p)]$; $l_i = -\ln q_i$; $J(0) = \ln 2$.

Gradient và cập nhật

$\nabla J = (1/n)X^T(p - y)$; $w \leftarrow w - (\eta/n)X^T(p - y)$, cùng dạng hồi quy tuyến tính.

Tốc độ học và biến thể

η quá nhỏ thì chậm, quá lớn thì dao động. Batch chính xác, SGD nhanh nhưng nhiễu, mini-batch dung hòa.

Cài đặt

NumPy khớp tính tay; kiểm tra gradient bằng đạo hàm số.

Câu hỏi kiểm tra nhanh (1/2)

1. Tính cross-entropy một mẫu cho $(y = 1, p = 0{,}9)$, $(y = 1, p = 0{,}1)$, $(y = 0, p = 0{,}9)$. Nhận xét.

2. Mẫu $x = (1, 2, 3)$, $y = 1$, $w = 0$. Tính p, gradient $(p - y)x^T$, cập nhật w với $\eta = 0{,}1$ và xác suất mới.

3. Với $y = 1$, $s = -6$: so sánh gradient theo s của cross-entropy và MSE.

4. Hai mẫu độc lập có $q_1 = 0{,}8$ và $q_2 = 0{,}5$. Tính L và J.

Câu hỏi kiểm tra nhanh (2/2)

5. Khi huấn luyện, J tăng dần qua các epoch. Nguyên nhân có thể là gì và cần làm gì?

6. n = 1000, mini-batch b = 50: mỗi epoch có bao nhiêu lần cập nhật với batch, SGD, mini-batch?

7. Với y = 0, s = 1: kiểm tra $-\ln(1 - \sigma(s))$ và $\ln(1 + e^{(-m)})$ ($m = y_{\pm} s$, $y_{\pm} = 2y - 1$) cho cùng giá trị.

Gợi ý đáp án (1/2)

1. 0,105; 2,303; 2,303. Đúng thì phạt nhẹ, sai chắc chắn thì phạt gấp hơn 20 lần.

2. $s = 0$, $p = 0{,}5$. Gradient $(-0{,}5)(1, 2, 3) = (-0{,}5; -1; -1{,}5)$. $w = (0{,}05; 0{,}1; 0{,}15)^T$. s mới $= 0{,}7$, $p \approx 0{,}668$: tăng từ 0,5.

3. $p \approx 0{,}0025$. Cross-entropy: $p - y \approx -0{,}9975$. MSE: $-2(1 - p)p(1 - p) \approx -0{,}005$. MSE gần như không sửa được lỗi này.

4. $L = 0{,}8 \cdot 0{,}5 = 0{,}4$. $J = -\frac{1}{2} \ln 0{,}4 \approx 0{,}458$.

Gợi ý đáp án (2/2)

5. Thường do η quá lớn nên bước nhảy vọt qua tối ưu. Giảm η (chia 2 hoặc 10), kiểm tra gradient bằng đạo hàm số và thang đo đặc trưng (nên chuẩn hóa).

6. Batch: 1. SGD: 1000. Mini-batch: $\lceil 1000/50 \rceil = 20$.

7. $\sigma(1) \approx 0{,}731$ nên $-\ln(1 - 0{,}731) = -\ln 0{,}269 \approx 1{,}313$. $y = 0$ nên $m = -s = -1$: $\ln(1 + e^{1}) = \ln 3{,}718 \approx 1{,}313$. Bằng nhau.

MÔ HÌNH LOGISTIC REGRESSION · MỤC 4

Phân tích cơ chế học của Logistic Regression

Mẫu sai, chuẩn hóa, tính lồi, dữ liệu phân tách và XOR

Bốn câu hỏi của mục 4

Câu 1

Một mẫu sai (hoặc chưa chắc) kéo tham số mạnh đến đâu?

Câu 2

Khởi tạo, tốc độ học, thang đo đặc trưng ảnh hưởng ra sao?

Câu 3

Thuật toán có hội tụ không, và về nghiệm nào?

Câu 4

Chuyện gì xảy ra với dữ liệu phân tách hoàn hảo và dữ liệu phi tuyến?

Mức đóng góp của một mẫu vào gradient

$$\|\nabla \ell_i(w)\| = |p_i - y_i| \cdot \|x_i\|$$

$|p_i - y_i| \in [0, 1)$

Mức sai của xác suất. Bằng 0 khi gán xác suất 1 cho nhãn thật, tiến tới 1 khi gán xác suất tiến tới 0.

$\|x_i\|$

Độ lớn của vector đặc trưng: mẫu đặc trưng lớn kéo mạnh hơn.

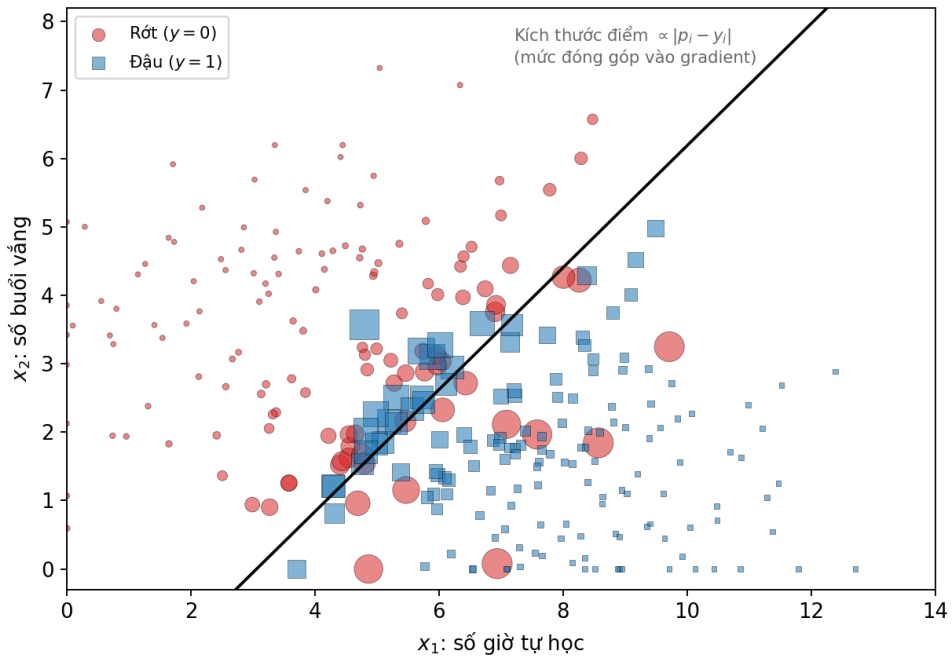
Thừa số đầu liên tục theo mức sai (khác Perceptron).

Sáu mẫu điển hình tại nghiệm tối ưu

Mẫu $(x_1; x_2)$	y	s	p	$\lvert p - y \rvert$	$\lVert x \rVert$	$\lVert \nabla \ell \rVert$	Tình trạng
2; 5	0	−7,673	0,0005	0,0005	5,48	0,003	Đúng, rất chắc chắn
9; 0,5	1	6,191	0,998	0,002	9,07	0,019	Đúng, rất chắc chắn
6; 3	0	−0,488	0,380	0,380	6,78	2,58	Đúng nhưng sát biên
6; 3	1	−0,488	0,380	0,620	6,78	4,20	Sai nhẹ, sát biên
4; 4	1	−4,080	0,017	0,983	5,75	5,65	Sai nặng
12; 0	0	10,289	≈ 1	≈ 1,000	12,04	12,04	Sai nặng và ở xa

$w^* \approx (-3{,}520;\ 1{,}151;\ -1{,}291)^T$, nghiệm tối ưu trên 280 mẫu huấn luyện của mục 3.7.

Hình 11. Đóng góp của từng mẫu vào gradient



Đúng và chắc chắn

Gần như không đóng góp (gradient ≈ 0).

Sát đường biên

Đóng góp vừa phải.

Sai nặng

Đóng góp lớn nhất. Kích thước điểm tỉ lệ với $|p_i - y_i|$.

Mềm hơn Perceptron

Perceptron

Mẫu đúng không đóng góp; mẫu sai kéo bằng bước $\pm \eta x_i^T$ có độ lớn không phụ thuộc mức sai.

Logistic Regression

Mức kéo đổi liên tục theo mức sai. Mẫu đúng nhưng chưa chắc ($p = 0{,}38$ cho nhãn 0) vẫn được đẩy thêm một chút.

Mô hình không dừng ở đường biên sát mẫu mà tiếp tục đẩy các mẫu ra xa đường biên.

Một bước cập nhật theo một mẫu

$$w' = w - \eta(p_i - y_i)x_i^T \Rightarrow s_i' = s_i + \eta(y_i - p_i)\|x_i\|^2$$

Ý nghĩa

Điểm số luôn dịch về phía đúng (tăng nếu y = 1, giảm nếu y = 0), độ dịch tỉ lệ với |y − p|. Phiên bản mềm của $m' = m + \eta\|x\|^2$ ở Perceptron.

Ví dụ: mẫu (4; 4), y = 1

$s = -4{,}080$, $p = 0{,}0166$, $\|x\|^2 = 33$. Với $\eta = 0{,}1$: $s' \approx -0{,}835$, $p' \approx 0{,}303$.

Xác suất đúng tăng từ 0,017 lên 0,303 chỉ sau một bước. Nếu $\eta\|x_i\|^2$ quá lớn, bước có thể vọt qua phía đúng.

Mẫu sai nặng ở xa

(12; 0), y = 0

|p − y| ≈ 1 và ‖x‖ = 12,04: cả hai thừa số cùng lớn.

Gấp 3 đến 5 lần

gradient so với các mẫu sát biên.

Thường là nhãn nhiễu hoặc trường hợp đặc biệt, nhưng kéo đường biên mạnh hơn hẳn. Cần quan tâm nhãn nhiễu, ngoại lai và điều chuẩn hóa (mục 4.4).

Chuẩn hóa đặc trưng

Vấn đề

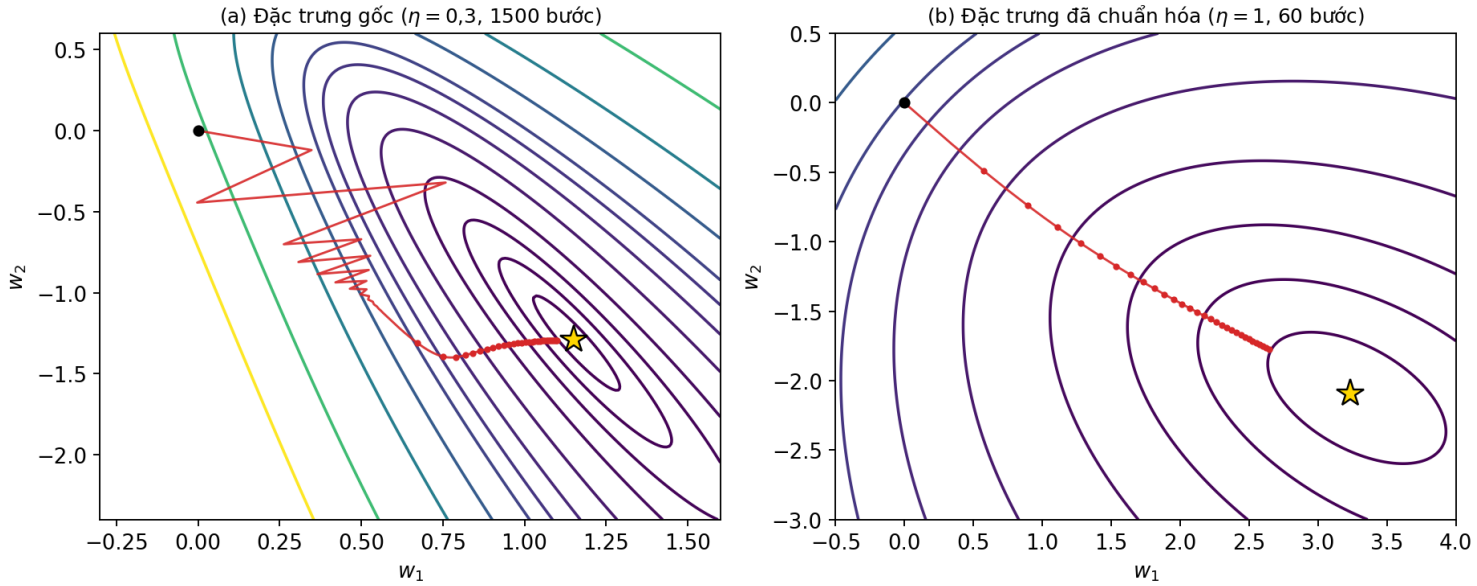
$x_1 \in [0, 14]$, $x_2 \in [0, 8]$: thang đo khác nhau làm J có dạng thung lũng dài hẹp, GD dích dắc và tiến chậm.

Cách khắc phục

$z_{ij} = (x_{ij} - \mu_j) / s_j$, μ_j là trung bình và s_j là độ lệch chuẩn của cột j.

μ_j, s_j chỉ tính từ tập huấn luyện, rồi dùng chính chúng cho tập kiểm tra. Tính trên cả tập kiểm tra sẽ làm thông tin "rò rỉ".

Hình 12. Đường đồng mức của J và đường đi của GD



(a) Đặc trưng gốc: thung lũng dài hẹp, đường đi dích dắc và chậm. (b) Đã chuẩn hóa: đường đồng mức gần tròn, đường đi thẳng.

Số epoch để J cách J* không quá 0,001

Tốc độ học η	Đặc trưng gốc	Đặc trưng đã chuẩn hóa
0,05	> 5000	1976
0,1	3119	987
0,2	1559	493
0,5	622	196
0,8	không hội tụ (dao động)	122
1	không hội tụ (dao động)	97
2	không hội tụ (dao động)	48
5	không hội tụ (dao động)	16

J* = 0,24656. Sau chuẩn hóa: nhanh hơn nhiều lần và chịu được η lớn hơn rất nhiều (η = 10 vẫn hội tụ).

Chuyển ngược tham số và đọc trọng số

Về thang gốc

Vì điểm số không đổi: $w_j = w_j'/s_j$ và $w_0 = w_0' - \Sigma_j w_j'\mu_j/s_j$. Ví dụ $w' = (0{,}243;\ 3{,}235;\ -2{,}092)$ cho $w = (-3{,}520;\ 1{,}151;\ -1{,}291)$, trùng nghiệm trực tiếp.

Odds ratio dễ so sánh

Tăng 1 độ lệch chuẩn số giờ học (≈ 2,81 giờ): odds × $e^{3{,}235} \approx 25{,}4$. Tăng 1 độ lệch chuẩn số buổi vắng: odds × $e^{-2{,}092} \approx 0{,}123$.

Chuẩn hóa chỉ đổi cách đi đến nghiệm, không đổi nghiệm. Số giờ học là yếu tố ảnh hưởng mạnh hơn.

Khởi tạo không ảnh hưởng nghiệm cuối

Khởi tạo w_0	w sau 300 epoch	J
$(0, 0, 0)^T$	$(0{,}2430; 3{,}2351; -2{,}0918)^T$	0,246559
$(5, -3, 2)^T$	$(0{,}2430; 3{,}2351; -2{,}0918)^T$	0,246559
$(-8, 4, 4)^T$	$(0{,}2430; 3{,}2351; -2{,}0918)^T$	0,246559
$(2, -6, -6)^T$	$(0{,}2430; 3{,}2351; -2{,}0918)^T$	0,246559

Đặc trưng chuẩn hóa, η = 5. Khác Perceptron (nhiều nghiệm), Logistic cho cùng một nghiệm: khởi tạo chỉ ảnh hưởng số bước. Lý do: J lồi.

Ma trận Hessian và tính lồi

$$H(w) = (1/n)\,\Sigma_i\, p_i(1-p_i)\, x_i^T x_i = (1/n)\, X^T S X,\ S = \mathrm{diag}(p_i(1-p_i))$$

Kích thước

$x_i^T x_i$: (d+1)×(d+1) (tích ngoài); S: n×n đường chéo gồm các số dương; H: (d+1)×(d+1).

Với mọi z

$z^T H z = (1/n)\,\Sigma_i\, p_i(1-p_i)(x_i z)^2 \geq 0$: H nửa xác định dương tại mọi w, nên J là hàm lồi.

Số dương nhân bình phương thì không âm.

Hệ quả của tính lồi

Không bị kẹt

Mọi cực tiểu địa phương đều là cực tiểu toàn cục.

Hội tụ từ mọi khởi tạo

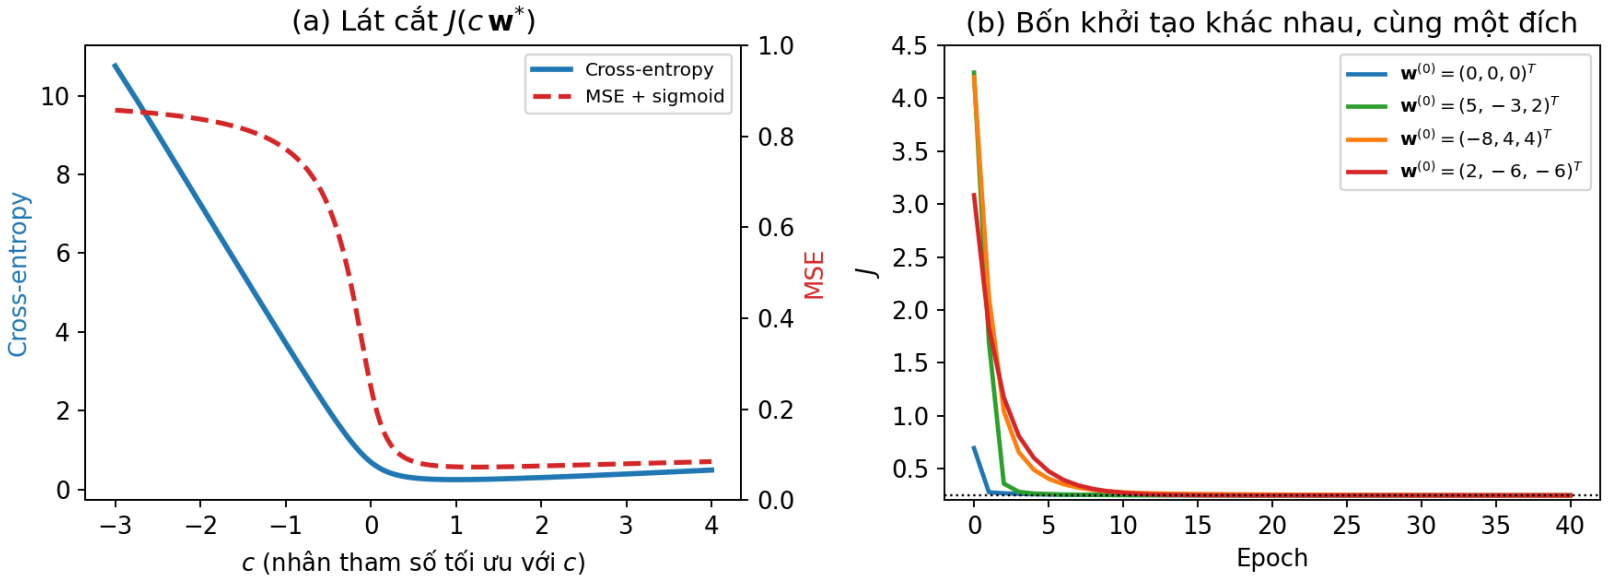
GD với η phù hợp hội tụ về cực tiểu toàn cục.

Nghiệm duy nhất

Nếu các cột của X độc lập tuyến tính thì H xác định dương. Dữ liệu sinh viên: trị riêng 0,0046; 0,0688; 3,502, đều dương.

MSE kết hợp sigmoid thì không lồi (dạng chữ S): lý do thứ hai để chọn cross-entropy.

Hình 13. Tính lồi và hội tụ từ nhiều khởi tạo



(a) Cross-entropy lồi, MSE kết hợp sigmoid có dạng chữ S. (b) GD từ bốn khởi tạo rất khác nhau đều về cùng một giá trị J.

Điều kiện tối ưu có ý nghĩa gì?

$$X^T(p - y) = 0 \Leftrightarrow \Sigma_i(p_i - y_i) = 0 \text{ và } \Sigma_i(p_i - y_i)x_{ij} = 0$$

Dòng đầu (cột 1)

$(1/n)\ \Sigma\ p_i = (1/n)\ \Sigma\ y_i$: trung bình xác suất dự đoán bằng tỉ lệ lớp dương. Thực tế: 149/280 = 0,5321, trung bình dự đoán cũng là 0,5321.

Các dòng còn lại

Sai số $p_i - y_i$ không tương quan với bất kỳ đặc trưng nào: mô hình đã khai thác hết thông tin tuyến tính.

Độ cong quyết định tốc độ và độ ổn định

GD ổn định ⇔ $|1 - \eta\lambda| < 1$ với mọi trị riêng λ của H ⇔ $\eta < 2 / \lambda_{max}$

	Đặc trưng gốc	Đặc trưng chuẩn hóa
λ_{max}	3,502	0,0775
λ_{min}	0,0046	0,0135
Số điều kiện $\kappa = \lambda_{max} / \lambda_{min}$	≈ 765	≈ 5,75
Ngưỡng ổn định $2 / \lambda_{max}$	≈ 0,57	≈ 25,8

η = 0,5 hội tụ, η = 0,8 và 1 dao động (đặc trưng gốc). Chuẩn hóa đưa κ từ 765 xuống 5,75.

Perceptron so với Logistic Regression

	Perceptron	Logistic Regression
Hàm mất mát	Không trơn, chỉ quan tâm mẫu sai	Trơn và lồi
Dữ liệu chồng lấn	Không hội tụ, w dao động (cần thuật toán túi)	Hội tụ êm về nghiệm duy nhất
Phụ thuộc khởi tạo, thứ tự	Có (nhiều nghiệm)	Không (một nghiệm duy nhất)
Điều kiện dừng	Một epoch không còn mẫu sai	Gradient nhỏ, J không giảm nữa, hoặc T_max

scikit-learn dùng L-BFGS hoặc Newton (có dùng H); nhờ tính lồi, chúng hội tụ nhanh về cùng nghiệm.

Dữ liệu phân tách hoàn hảo

Nếu có w^* với mọi margin $m_i > 0$: $J(cw^*) = (1/n)\,\Sigma_i \ln(1 + e^{(-c \cdot m_i)}) \to 0$ khi $c \to \infty$

Không có cực tiểu hữu hạn

J nhỏ tùy ý nhưng không bao giờ bằng 0, vì ln(1 + e^(−cm)) > 0. Muốn J nhỏ hơn thì w phải lớn hơn.

Với Perceptron

Phân tách được là thuận lợi (thuật toán dừng). Với Logistic, đáy thung lũng nằm ở vô cực.

Dữ liệu 6 sinh viên của mục 1 chính là trường hợp này.

‖w‖ tăng mãi, J giảm nhưng không về 0

Số bước t	10	100	1000	10^4	10^5	10^6
‖w‖	1,62	2,68	4,07	5,56	7,06	8,56
J	$3{,}9\cdot10^{-2}$	$7{,}1\cdot10^{-3}$	$8{,}3\cdot10^{-4}$	$8{,}5\cdot10^{-5}$	$8{,}5\cdot10^{-6}$	$8{,}6\cdot10^{-7}$

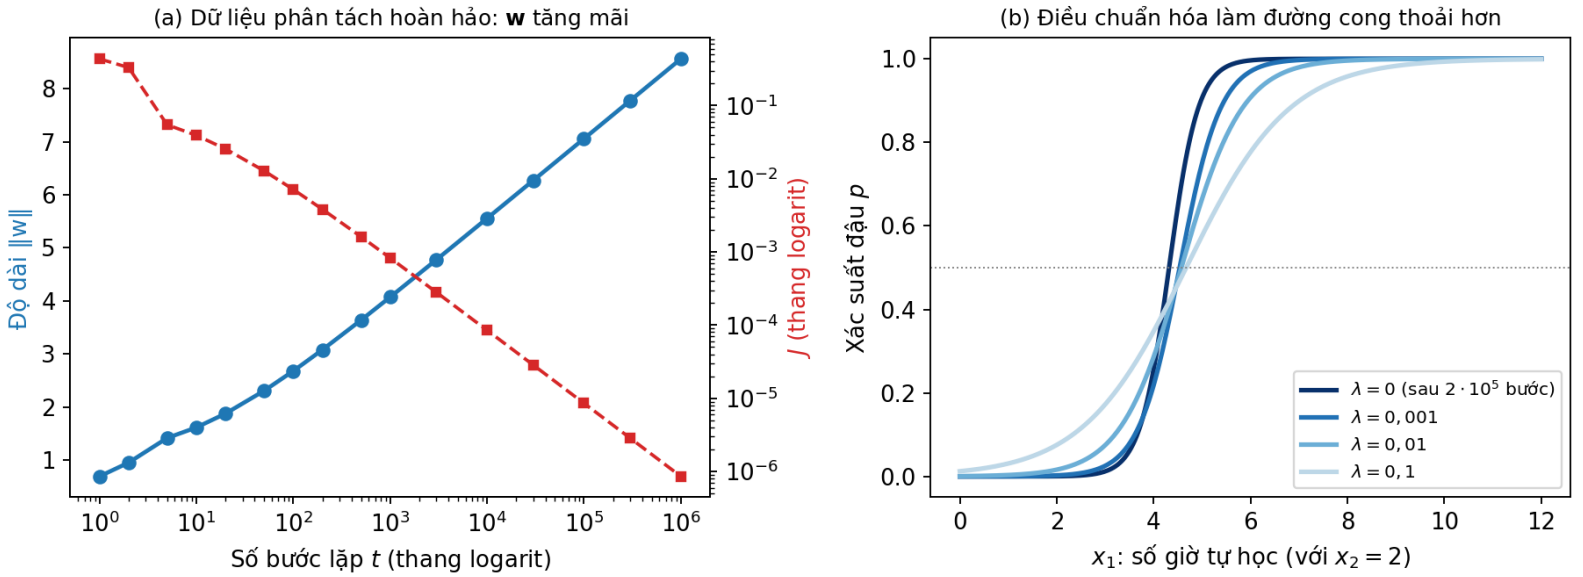
Tăng cỡ logarit

‖w‖ tăng khoảng 1,5 mỗi khi số bước tăng 10 lần; J giảm cỡ 1/t.

Hướng của w

Cosin với hướng (−1; 2; −4) tăng từ 0,9925 (bước 10) lên 0,9980 (bước 10^6): tiến dần tới đường biên có margin lớn nhất (SVM).

Hình 14. w tăng không giới hạn và điều chuẩn hóa L2



(a) ‖w‖ tăng mãi trong khi J giảm về 0 mà không đạt. (b) Điều chuẩn hóa L2 giữ w hữu hạn: λ càng lớn, đường cong xác suất càng thoải.

Hệ quả khi w quá lớn

Quá tự tin

Sigmoid rất dốc: mẫu sát biên cũng gán xác suất gần 0 hoặc 1. Sinh viên B có p = 0,907 sau $2 \cdot 10^5$ bước.

Không có điểm dừng tự nhiên

Chỉ dừng vì T_max hoặc ε ta đặt. Dừng sớm vô hình trung là điều chuẩn hóa.

Phụ thuộc bộ giải

Không có nghiệm duy nhất để các phương pháp cùng hướng tới.

Không hiếm: nhất là khi số đặc trưng lớn so với số mẫu.

Điều chuẩn hóa L2

$$J_\lambda(w) = J(w) + (\lambda/2)\,\Sigma_j\, w_j^2 = J(w) + (\lambda/2)\, w^T D_0 w,\ D_0 = \mathrm{diag}(0, 1, \ldots, 1)$$

Gradient và cập nhật

$\nabla J_\lambda = (1/n)X^T(p - y) + \lambda D_0 w$; $w \leftarrow w - \eta \nabla J_\lambda$. Số hạng $\lambda D_0 w$ kéo w về 0.

Không phạt w_0

w_0 chỉ chỉnh xác suất nền, không phải độ nhạy với đặc trưng.

J_λ vẫn lồi và có cực tiểu hữu hạn duy nhất, kể cả khi dữ liệu phân tách hoàn hảo.

Hiệu ứng của λ trên 6 sinh viên

λ	w	‖w̃‖	p (sinh viên B)
0	(−1,1577; 3,3382; −6,6285)	7,422 (còn tăng)	0,907
0,001	(−6,9733; 2,3751; −1,9000)	3,042	0,751
0,01	(−4,7420; 1,5997; −1,2854)	2,052	0,665
0,1	(−2,9394; 0,9385; −0,7219)	1,184	0,577

λ > 0: w hữu hạn, ổn định; λ càng lớn w càng nhỏ, xác suất càng gần 0,5.

Đánh đổi và liên hệ với scikit-learn

λ quá lớn

Mô hình bị "bó": khớp kém, độ chính xác giảm, xác suất bị kéo về 0,5.

λ quá nhỏ

Không chống được hiện tượng w tăng vô hạn.

scikit-learn

Mặc định dùng L2; hàm mục tiêu $C \cdot \Sigma \ell_i + \frac{1}{2}\|w\|^2$, tương đương $\lambda = 1/(C \cdot n)$. C nhỏ thì điều chuẩn hóa mạnh.

Chọn λ bằng tập kiểm định riêng (mục 5). Perceptron dừng ngay khi có đường biên phân tách; Logistic "không bao giờ hài lòng", nên luôn đi kèm điều chuẩn hóa.

Logistic Regression không giải được XOR

Vẫn là siêu phẳng

$p = 0{,}5 \Leftrightarrow xw = 0$, nên không phân loại được dữ liệu không phân tách tuyến tính.

Gradient tại w = 0

$\nabla J(0) = (1/4)X^T(0{,}5 \cdot 1 - y) = (0, 0, 0)^T$. J lồi nên w = 0 là cực tiểu toàn cục duy nhất.

GD từ $w_0 = (2, -3, 1)^T$ hội tụ êm về $w \approx 0$: p = 0,5 cho cả 4 mẫu, $J = \ln 2 \approx 0{,}693$. Khác Perceptron quay vòng mãi: mô hình trung thực "không biết".

Thêm đặc trưng đa thức cho XOR

$x' = (1, x_1, x_2, x_1x_2)$: dữ liệu phân tách được, nên cần điều chuẩn hóa L2 ($\lambda = 0$ thì $\|w\| \approx 37$ sau 10^5 bước và vẫn tăng)

λ	w	p cho (0,0), (0,1), (1,0), (1,1)
0,001	(−2,389; 5,076; 5,076; −10,856)	0,084; 0,936; 0,936; 0,043
0,01	(−0,735; 1,827; 1,827; −4,450)	0,324; 0,749; 0,749; 0,178

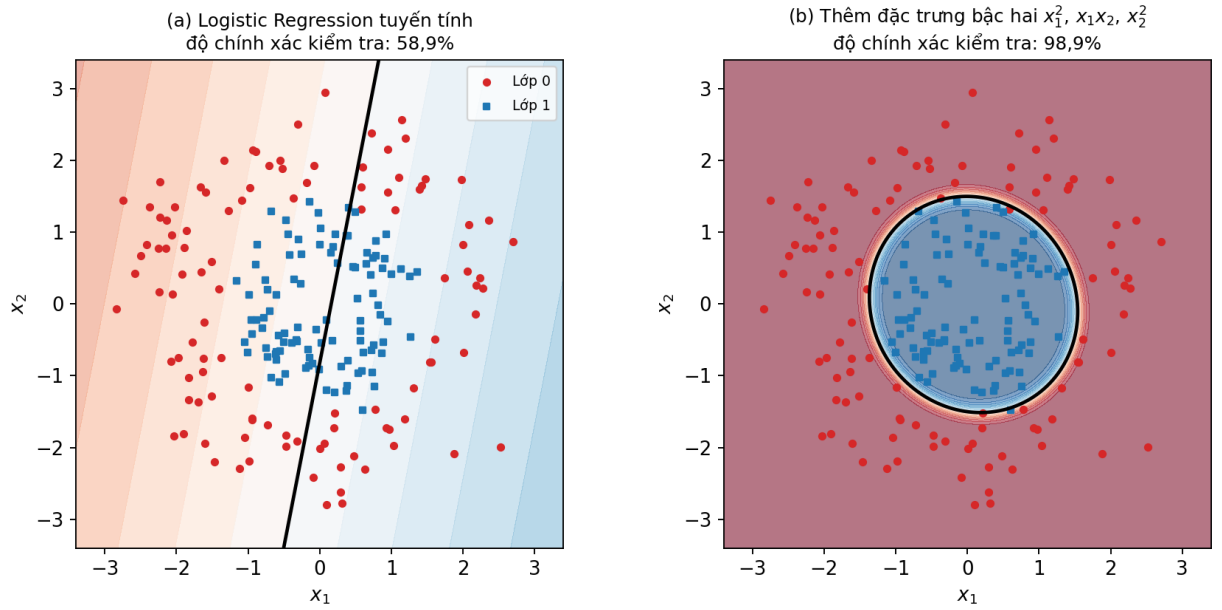
Ngưỡng 0,5 cho nhãn $(0, 1, 1, 0)^T = y$: đúng XOR. λ nhỏ cho xác suất quyết liệt hơn.

Dữ liệu hình vòng tròn

Mô hình	Số tham số	Accuracy huấn luyện	Accuracy kiểm tra
Tuyến tính $x = (1, x_1, x_2)$	3	51,0%	58,9%
Bậc hai $x' = (1, x_1, x_2, x_1^2, x_1x_2, x_2^2)$	6	99,0%	98,9%

Đường biên $w_0 + w_1x_1 + w_2x_2 + w_3x_1^2 + w_4x_1x_2 + w_5x_2^2 = 0$ là một đường conic (ở đây là đường tròn), dù mô hình vẫn tuyến tính theo các đặc trưng mới.

Hình 15. Dữ liệu hình vòng tròn



(a) Mô hình tuyến tính chỉ vẽ được đường thẳng nên gần như đoán mò. (b) Đặc trưng bậc hai cho đường biên tròn, phân loại gần như hoàn hảo.

Cái giá của đặc trưng đa thức

Số đặc trưng (không kể hệ số chệch) = C(d + k, k) − 1

d = 2, k = 2

C(4, 2) − 1 = 5 đặc trưng.

d = 10, k = 3

C(13, 3) − 1 = 285 đặc trưng.

Nhiều đặc trưng dễ học thuộc và dễ phân tách hoàn hảo, nên cần L2 và chuẩn hóa. Phải tự đoán dạng đặc trưng; hướng tổng quát hơn là để mô hình tự học đặc trưng: mạng nơ-ron (mục 6).

Tóm tắt mục 4

Đóng góp của mẫu

$\|\nabla \ell\| = |p - y|\|x\|$; $s' = s + \eta(y - p)\|x\|^2$: mẫu sai nặng kéo mạnh nhất.

Chuẩn hóa và khởi tạo

Chuẩn hóa giảm κ từ ≈ 765 xuống $\approx 5{,}75$; khởi tạo không đổi nghiệm.

Tính lồi

$H = (1/n)X^{\top}SX$ nửa xác định dương: nghiệm duy nhất; GD ổn định khi $\eta < 2/\lambda_max$.

Dữ liệu phân tách hoàn hảo

$\|w\|$ tăng mãi, xác suất quá tự tin; điều chuẩn hóa L2 cho nghiệm hữu hạn.

Giới hạn tuyến tính

XOR: hội tụ êm về $w = 0$ ($p = 0{,}5$). Đặc trưng đa thức cho biên cong nhưng số đặc trưng tăng rất nhanh.

Câu hỏi kiểm tra nhanh (1/2)

1. $y = 1$, $p = 0{,}2$, $\|x\|^2 = 10$. Tính $|p - y|$, s' sau một bước SGD ($\eta = 0{,}05$) và p mới.

2. So sánh gradient theo điểm số của hai mẫu $y = 1$ với $p = 0{,}05$ và $p = 0{,}45$: mẫu nào kéo mạnh hơn, gấp mấy lần?

3. $\mu = 6{,}093$, $s = 2{,}811$ (từ tập huấn luyện). Chuẩn hóa sinh viên học 9 giờ và 3 giờ. Dấu của z nghĩa là gì?

4. Vì sao khởi tạo không ảnh hưởng nghiệm Logistic nhưng ảnh hưởng nghiệm Perceptron?

Câu hỏi kiểm tra nhanh (2/2)

5. Chứng minh gradient của XOR tại w = 0 bằng 0 và nêu kết luận.

6. Hai mẫu margin m = 1 và m = 2. Tính J(cw*) = ½[ln(1 + e^(−c)) + ln(1 + e^(−2c))] với c = 1, 5, 10.

7. Viết gradient của J_λ và giải thích vì sao không phạt w_0.

8. d = 4 đặc trưng gốc, bậc tối đa k = 3: có bao nhiêu đặc trưng đa thức (không kể hệ số chệch)?

Gợi ý đáp án (1/2)

1. $|p - y| = 0{,}8$; $s = \ln(0{,}2/0{,}8) \approx -1{,}386$; $s' = -1{,}386 + 0{,}05 \cdot 0{,}8 \cdot 10 = -0{,}986$; $p' \approx 0{,}272$.

2. $|p - y| = 0{,}95$ và $0{,}55$; mẫu $p = 0{,}05$ kéo mạnh hơn, gấp $0{,}95/0{,}55 \approx 1{,}73$ lần.

3. $z_9 \approx 1{,}034$; $z_3 \approx -1{,}100$. Dương: học nhiều hơn trung bình; âm: ít hơn; độ lớn là số độ lệch chuẩn.

4. Logistic: J lồi, nghiệm duy nhất. Perceptron: vô số nghiệm đúng, dừng ở nghiệm đầu tiên gặp nên khởi tạo và thứ tự mẫu quyết định.

Gợi ý đáp án (2/2)

5. $X^T(0{,}5 \cdot 1 - y) = X^T(0{,}5; -0{,}5; -0{,}5; 0{,}5)^T$: cột 1: 0,5 − 0,5 − 0,5 + 0,5 = 0; cột x_1: −0,5 + 0,5 = 0; cột x_2: −0,5 + 0,5 = 0. J lồi nên w = 0 là cực tiểu toàn cục: p = 0,5 cho mọi mẫu.

6. c = 1: ½(0,3133 + 0,1269) ≈ 0,2201. c = 5: ≈ 0,00338. c = 10: ≈ 0,0000227. Giảm rất nhanh nhưng luôn dương: không có cực tiểu hữu hạn.

7. $\nabla J_\lambda = (1/n)X^T(p - y) + \lambda D_0 w$. Phạt w_0 sẽ ép xác suất trung bình lệch tỉ lệ lớp thực tế mà không giảm độ phức tạp.

8. C(7, 3) − 1 = 35 − 1 = 34 đặc trưng.

MÔ HÌNH LOGISTIC REGRESSION · MỤC 5

Đánh giá và trực quan hóa mô hình Logistic Regression

Mô hình tốt đến đâu, và xác suất đáng tin đến mức nào?

Năm phần của mục 5

5.1 Quá trình học

Đường cong học và bản đồ xác suất.

5.2 Huấn luyện và kiểm tra

Tập kiểm tra và hiện tượng học thuộc (overfitting).

5.3 Chỉ số và ngưỡng

Accuracy, ma trận nhầm lẫn, precision, recall, F1, chọn ngưỡng.

5.4 Chất lượng xác suất

Log-loss, ROC, AUC, biểu đồ hiệu chuẩn.

5.5 scikit-learn

So sánh với thư viện và chọn siêu tham số bằng kiểm định chéo.

Dữ liệu và mô hình dùng xuyên suốt

Dữ liệu

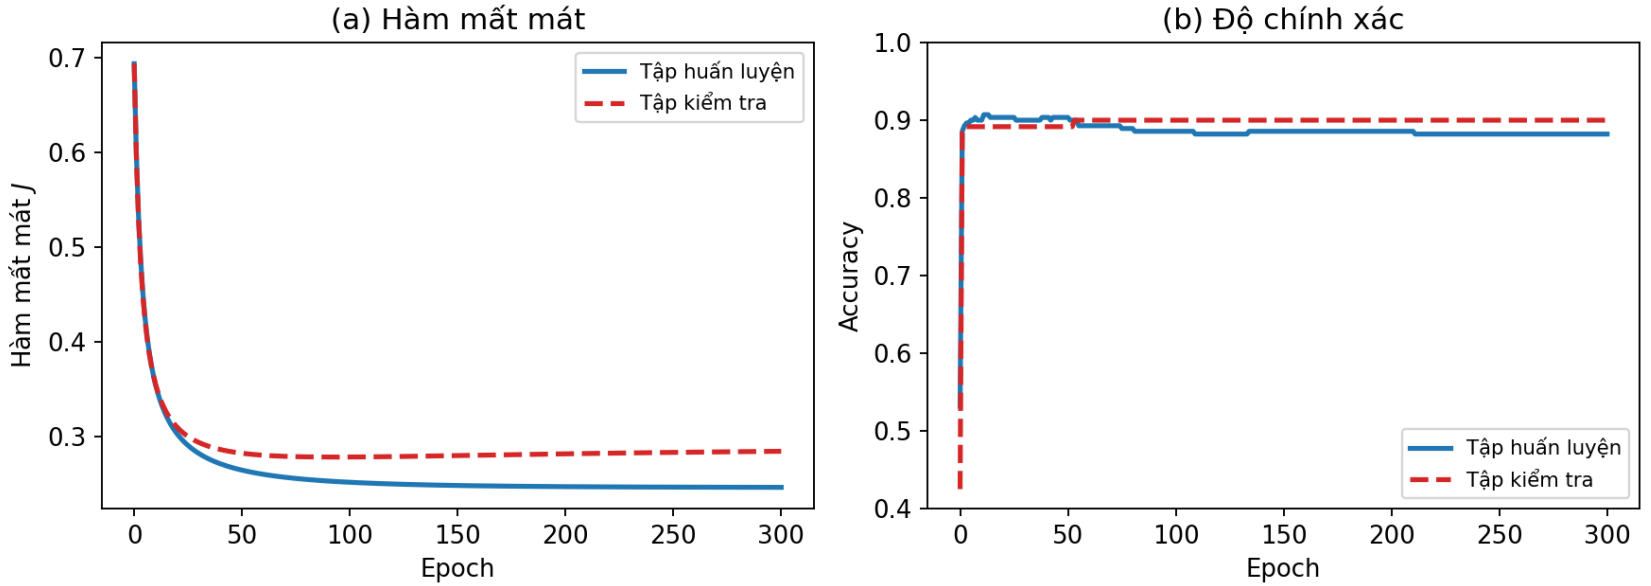
400 sinh viên mô phỏng (mục 3.7): 280 mẫu huấn luyện, 120 mẫu kiểm tra. x_1 là số giờ tự học, x_2 là số buổi vắng; lớp dương là “đậu” ($y = 1$).

Mô hình (mục 4.2)

$w = (-3{,}520;\ 1{,}151;\ -1{,}291)^T$ trên đặc trưng gốc, tương đương $w' = (0{,}243;\ 3{,}235;\ -2{,}092)^T$ trên đặc trưng chuẩn hóa.

Câu hỏi: mô hình tốt đến đâu, và ta tin vào xác suất của nó đến mức nào?

Hình 16. Đường cong học



(a) J trên tập huấn luyện và kiểm tra giảm rồi ổn định. (b) Accuracy tăng vọt trong ~10 epoch đầu rồi gần như không đổi dù J còn giảm.

Số liệu đường cong học

Epoch	J huấn luyện	J kiểm tra	Acc. huấn luyện	Acc. kiểm tra
0	0,6931	0,6931	53,2%	42,5%
10	0,3540	0,3548	90,0%	89,2%
50	0,2649	0,2827	90,4%	89,2%
300	0,2468	0,2848	88,2%	90,0%

Epoch 0

w = 0 nên J = ln 2 và accuracy bằng tỉ lệ lớp dương (53,2% và 42,5%).

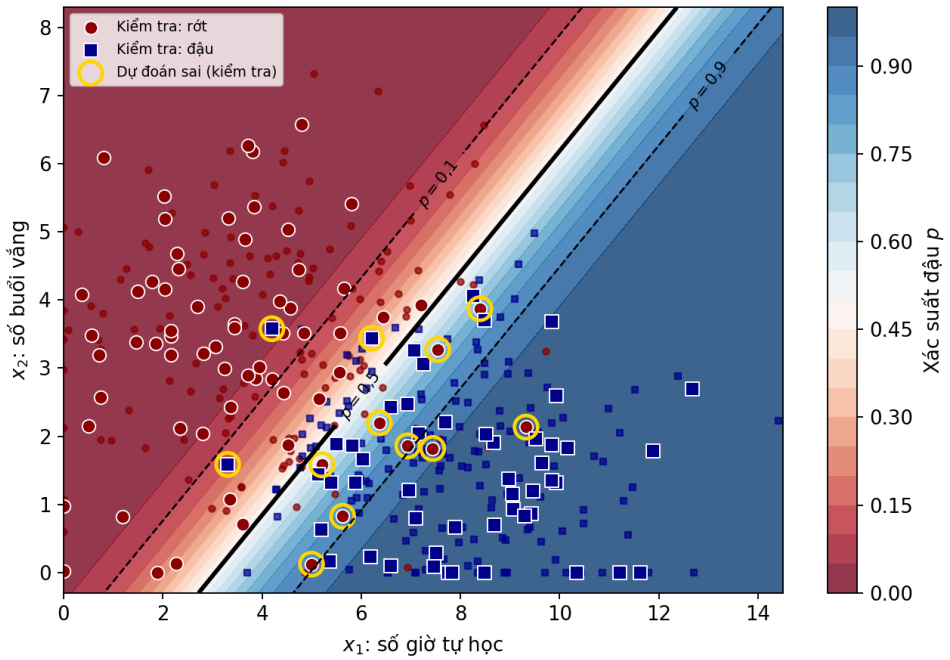
Chênh lệch nhỏ

J kiểm tra cao hơn J huấn luyện một chút (0,285 so với 0,247): bình thường.

Accuracy bão hòa sớm

J còn giảm: mất mát phản ánh chi tiết hơn, vì chất lượng xác suất vẫn cải thiện.

Hình 17. Bản đồ xác suất đậu



Nền màu

Xác suất p tại mọi điểm. Đường liền: p = 0,5; đường đứt: p = 0,1 và 0,9.

Điểm to

120 mẫu kiểm tra (viền trắng).

Vòng vàng

12 mẫu kiểm tra bị dự đoán sai.

Dải “chưa chắc chắn” và các lỗi sai chắc chắn

Độ rộng dải

ln 9 / ‖w‖ = 2,197 / 1,729 ≈ 1,27 mỗi bên, nên dải 0,1 < p < 0,9 rộng khoảng 2,5 đơn vị.

9 trong 12 lỗi nằm trong dải

p từ 0,147 đến 0,888: sai “có cảnh báo”, mô hình đã tỏ ra không chắc chắn.

3 lỗi sai chắc chắn

p = 0,035 (thực tế đậu), 0,937 và 0,989 (thực tế rớt). Mất mát: 3,34; 2,76; 4,47.

Ba mẫu này chỉ chiếm 2,5% số mẫu nhưng đóng góp khoảng 31% tổng mất mát kiểm tra: cross-entropy phạt rất nặng việc sai chắc chắn.

Đánh giá trên tập huấn luyện và tập kiểm tra

Nguyên tắc

Tập kiểm tra bị giấu trong suốt quá trình huấn luyện, chỉ dùng ở cuối. Hai tập có 53,2% và 42,5% sinh viên đậu do chia ngẫu nhiên; scikit-learn thường chia phân tầng.

Accuracy kiểm tra cao hơn?

SE ≈ $\sqrt{(0{,}9 \cdot 0{,}1/120)} \approx 0{,}027$ (±2,7 điểm phần trăm). Chênh 1,8 điểm nằm trong sai số nên không có ý nghĩa thống kê.

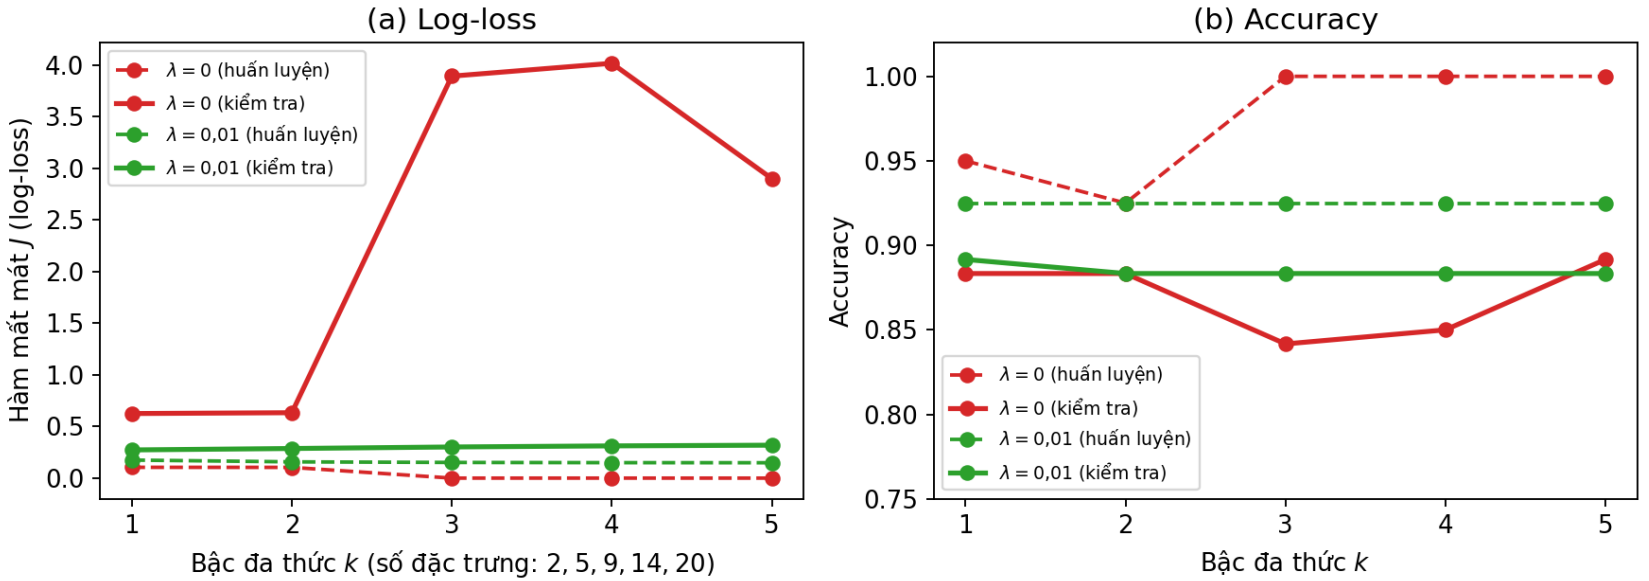
Chỉ số	Huấn luyện (n = 280)	Kiểm tra (n = 120)
Log-loss J	0,2466	0,2877
Accuracy	88,2%	90,0%
AUC (mục 5.4)	0,962	0,953

Học thuộc (overfitting): thí nghiệm 40 mẫu

Chỉ 40 mẫu huấn luyện, đặc trưng đa thức bậc k = 1…5 (2, 5, 9, 14, 20 đặc trưng), L-BFGS; so λ = 0 với λ = 0,01.

Bậc k	λ	J huấn luyện	J kiểm tra	Acc. huấn luyện	Acc. kiểm tra
1	0	0,105	0,625	95,0%	88,3%
1	0,01	0,175	0,273	92,5%	89,2%
3	0	0,000	3,893	100%	84,2%
3	0,01	0,152	0,302	92,5%	88,3%
5	0	0,000	2,901	100%	89,2%
5	0,01	0,149	0,319	92,5%	88,3%

Hình 18. Log-loss và accuracy theo bậc đa thức



Nét đứt: huấn luyện; nét liền: kiểm tra. Không điều chuẩn hóa (đỏ): log-loss kiểm tra tăng vọt. Có điều chuẩn hóa L2 (xanh): ổn định ở mọi bậc.

Rút ra từ thí nghiệm

Học thuộc

k ≥ 3, λ = 0: accuracy huấn luyện 100%, J huấn luyện 0 nhưng J kiểm tra tăng vọt lên 3,9 và 2,9, gấp 9 đến 13 lần so với có điều chuẩn hóa (0,30 và 0,32).

Log-loss nhạy hơn accuracy

k = 5, λ = 0: accuracy kiểm tra 89,2% không thua bản điều chuẩn hóa (88,3%), nhưng log-loss 2,90 so với 0,32 lộ ra việc quá tự tin.

L2 giữ ổn định

Log-loss kiểm tra 0,27 đến 0,32 ở mọi bậc, đánh đổi log-loss huấn luyện cao hơn một chút.

Ở đây dùng tập kiểm tra chỉ để minh họa. Thực tế phải dùng tập kiểm định hoặc kiểm định chéo (mục 5.5).

Ma trận nhầm lẫn và các chỉ số

Ma trận C (hàng: thực, cột: dự đoán)

C = [[TN, FP], [FN, TP]]. FN (bỏ sót): đậu bị đoán rớt. FP (báo nhầm): rớt bị đoán đậu. Kiểm tra ($\tau = 0{,}5$): [[60, 9], [3, 48]]; huấn luyện: [[118, 13], [20, 129]].

Các chỉ số trên tập kiểm tra

Accuracy = (48 + 60)/120 = 0,900

Precision = 48/57 ≈ 0,842

Recall = 48/51 ≈ 0,941

Độ đặc hiệu = 60/69 ≈ 0,870

F1 = 96/108 ≈ 0,889

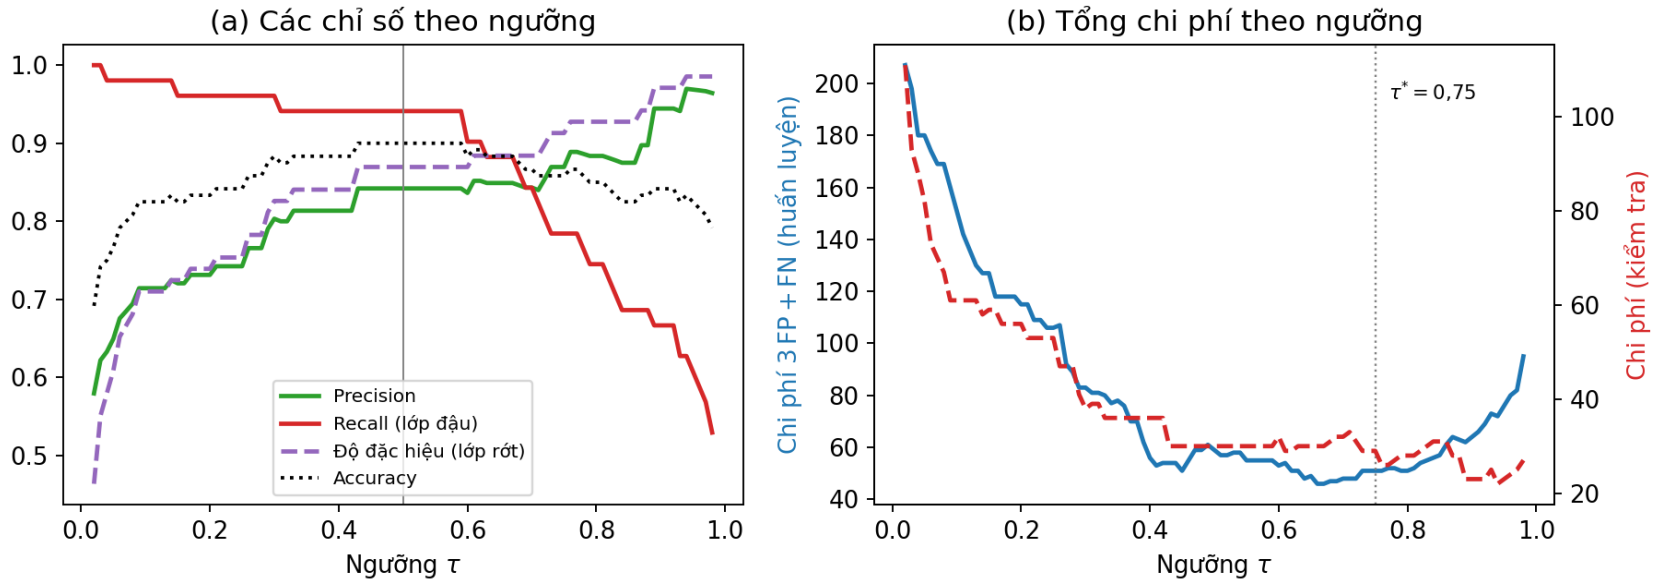
Perceptron túi trên cùng tập kiểm tra chỉ sai nhiều hơn 1 mẫu (một báo nhầm). Khác biệt thật sự là xác suất và khả năng đổi ngưỡng.

Đổi ngưỡng quyết định τ

τ	TP	FP	FN	TN	Acc.	Precision	Recall	Đặc hiệu	F1
0,1	50	20	1	49	0,825	0,714	0,980	0,710	0,826
0,3	49	12	2	57	0,883	0,803	0,961	0,826	0,875
0,5	48	9	3	60	0,900	0,842	0,941	0,870	0,889
0,7	43	8	8	61	0,867	0,843	0,843	0,884	0,843
0,75	40	6	11	63	0,858	0,870	0,784	0,913	0,825
0,8	38	5	13	64	0,850	0,884	0,745	0,928	0,809
0,9	34	2	17	67	0,842	0,944	0,667	0,971	0,782

τ tăng: precision và độ đặc hiệu tăng, recall giảm. Accuracy cao nhất gần τ = 0,5, chỉ đúng khi hai loại sai quan trọng như nhau.

Hình 19. Chỉ số và chi phí theo ngưỡng τ



(a) Precision, recall, độ đặc hiệu, accuracy theo τ. (b) Tổng chi phí 3FP + FN: ngưỡng lý thuyết τ* = 0,75.

Chọn ngưỡng theo chi phí

Dự đoán $y = 1 \Leftrightarrow (1 - p) \cdot c_{FP} \leq p \cdot c_{FN} \Leftrightarrow p \geq \tau^* = c_{FP} / (c_{FP} + c_{FN})$

Ví dụ: $c_{FP} = 3$, $c_{FN} = 1$

$\tau^* = 3/(3 + 1) = 0{,}75$. Chỉ kết luận "đậu" khi $p \geq 75\%$. Chi phí $3FP + FN$ trên tập kiểm tra theo $\tau = 0{,}1; 0{,}3; 0{,}5; 0{,}7; 0{,}75; 0{,}8; 0{,}9$: 61; 38; 30; 32; 29; 28; 23.

Đọc thận trọng

Từ 0,5 đến 0,8 chi phí dao động 28 đến 32: không đáng kể. Trên tập huấn luyện, chi phí nhỏ nhất ở $\tau \approx 0{,}66$. τ^* chỉ đúng khi xác suất hiệu chuẩn tốt. Chọn τ theo tập kiểm tra là vi phạm quy tắc vàng.

$c_{FP} = c_{FN} \Rightarrow \tau^* = 0{,}5$.

Log-loss và điểm Brier

0,2877

Log-loss của mô hình trên tập kiểm tra.

0,693 và 0,705

Mô hình đoán p = 0,5 (ln 2) và mô hình hằng p = 0,532.

Diễn giải

e^(−0,2877) ≈ 0,750: trung bình nhân của xác suất gán cho nhãn thật là khoảng 0,75, so với 0,5 nếu đoán mò.

Điểm Brier

$(1/n)\ \Sigma\ (p_i - y_i)^2$: 0,0868 so với 0,2559 của mô hình hằng (càng nhỏ càng tốt).

Đường ROC

TPR = TP/(TP + FN) = recall; FPR = FP/(FP + TN) = 1 − độ đặc hiệu

Ngưỡng τ	FPR	TPR
0,3	12/69 ≈ 0,174	49/51 ≈ 0,961
0,5	9/69 ≈ 0,130	48/51 ≈ 0,941
0,7	8/69 ≈ 0,116	43/51 ≈ 0,843

ROC nối các điểm (FPR, TPR) khi τ chạy từ 1 xuống 0. Lý tưởng: góc trên bên trái; đoán ngẫu nhiên: đường chéo.

AUC: diện tích dưới đường ROC

AUC = 0,953

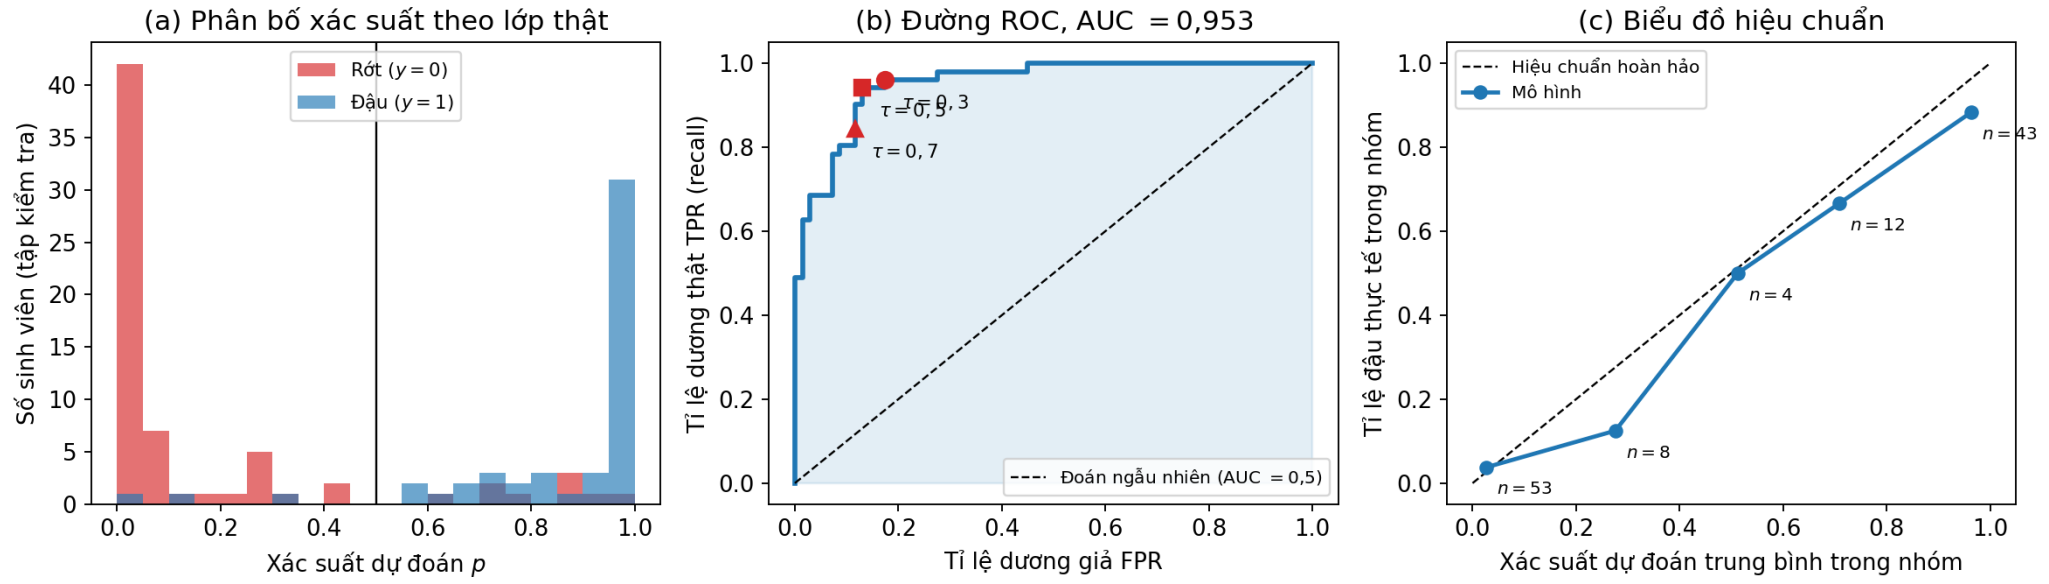
Từ 0,5 (đoán ngẫu nhiên) đến 1 (hoàn hảo).

3519 cặp

51 × 69 cặp (dương, âm): đếm tay và sklearn đều cho 0,9534.

AUC = P(mẫu dương ngẫu nhiên có p cao hơn mẫu âm ngẫu nhiên) = $(1/n_+n_-)\ \Sigma\ [1(p_i > p_j) + ½\cdot 1(p_i = p_j)]$. AUC chỉ phụ thuộc thứ tự, không phụ thuộc ngưỡng.

Hình 20. Phân bố xác suất, ROC và hiệu chuẩn



(a) Phân bố p theo lớp thật. (b) ROC, AUC = 0,953. (c) Biểu đồ hiệu chuẩn.

Biểu đồ hiệu chuẩn

Nhóm theo p	Số mẫu	p dự đoán trung bình	Tỉ lệ đậu thực tế
[0; 0,2)	53	0,026	0,038
[0,2; 0,4)	8	0,276	0,125
[0,4; 0,6)	4	0,512	0,500
[0,6; 0,8)	12	0,709	0,667
[0,8; 1]	43	0,964	0,884

Hiệu chuẩn tương đối tốt, nhưng hơi quá tự tin ở nhóm cao nhất (0,964 so với 0,884). Các nhóm giữa chỉ có 4, 8, 12 mẫu nên rất nhiễu; L2 có thể giảm bớt.

Khi nào dùng chỉ số nào?

Câu hỏi	Chỉ số phù hợp
Tỉ lệ nhãn đúng (hai loại sai như nhau, lớp cân bằng)	Accuracy
Hai loại sai có hậu quả khác nhau, hoặc lớp lệch	Ma trận nhầm lẫn, precision, recall, F1
Khả năng xếp hạng, không phụ thuộc ngưỡng	ROC, AUC
Chất lượng của chính xác suất	Log-loss, điểm Brier, biểu đồ hiệu chuẩn
So sánh cấu hình trong lúc huấn luyện	Log-loss (nhạy hơn accuracy)

LogisticRegression của scikit-learn

Tham số cần nhớ

C: nghịch đảo độ mạnh L2, mục tiêu $C \cdot \Sigma \ell_i + \frac{1}{2}\|w\|^2$, $\lambda = 1/(C \cdot n)$, mặc định C = 1.
intercept_ là w_0, coef_ là $w_1 \ldots w_d$.
predict_proba cho P(y = 0), P(y = 1);
decision_function cho s.

Khớp với tự cài đặt ($C = 10^{10}$)

Thư viện: (−3,5251; 1,1519; −1,2917). Tự cài: (−3,520; 1,1508; −1,2909). Xác suất lệch tối đa 0,0005, do ta dừng sau 300 epoch.

Lệch rất nhỏ vì bộ giải lbfgs chạy đến dung sai chặt hơn.

So sánh các mô hình tuyến tính

Mô hình	Acc. huấn luyện	Acc. kiểm tra	Log-loss	AUC
Logistic, tự cài đặt	88,2%	90,0%	0,2877	0,9534
Logistic, sklearn C = 10^{10}	88,2%	90,0%	0,2878	0,9534
Logistic, sklearn mặc định (C = 1)	88,6%	90,0%	0,2842	0,9531
Perceptron, sklearn	—	89,2%	không có	0,9523
Hồi quy tuyến tính + ngưỡng 0,5	—	89,2%	không có	0,9531

Mọi mô hình tuyến tính gần như bằng nhau. Lợi thế của Logistic: xác suất (log-loss, hiệu chuẩn, đổi ngưỡng), ổn định, và nền tảng mở rộng sang mạng nơ-ron.

Chọn C bằng kiểm định chéo 5 lần

CV = (1/K) Σ_k điểm số_k, trên tập huấn luyện; StandardScaler nằm bên trong pipeline để tránh rò rỉ

C	0,001	0,01	0,1	1	10	100	1000
CV accuracy	0,689	0,889	0,900	0,886	0,882	0,882	0,882
CV log-loss	0,650	0,480	0,306	0,256	0,253	0,253	0,253

C = 0,001: underfit. Từ C ≈ 1: gần như không đổi. Log-loss nhỏ nhất ở C = 10 (0,2528), nên chọn C = 10; accuracy ±1,8 điểm không phân biệt được. Sau đó mới huấn luyện lại và đánh giá một lần: accuracy 0,9, log-loss 0,286.

Lời khuyên thực hành

1. Chuẩn hóa đặc trưng bên trong pipeline.

2. Chọn siêu tham số như C bằng kiểm định chéo trên tập huấn luyện.

3. Báo cáo một lần trên tập kiểm tra: ma trận nhầm lẫn, log-loss và AUC, không chỉ accuracy.

4. Nếu hậu quả hai loại sai khác nhau, chọn ngưỡng $\tau^* = c_{FP}/(c_{FP} + c_{FN})$ trên tập kiểm định.

Tóm tắt mục 5

Quá trình học

J giảm trên cả hai tập; accuracy bão hòa sớm; phần lớn lỗi nằm trong dải $0,1 < p < 0,9$.

Overfitting

Khoảng cách J kiểm tra − J huấn luyện lớn; log-loss nhạy hơn accuracy; L2 giữ ổn định.

Chỉ số và ngưỡng

Từ ma trận nhầm lẫn: accuracy, precision, recall, F1. $\tau^* = c_{FP}/(c_{FP} + c_{FN})$.

Chất lượng xác suất

Log-loss, Brier, ROC/AUC (xếp hạng), hiệu chuẩn.

scikit-learn

Trùng khớp khi C lớn; chọn C bằng kiểm định chéo; tập kiểm tra chỉ dùng một lần.

Câu hỏi kiểm tra nhanh (1/2)

1. Vì sao ở epoch 0 (w = 0) accuracy huấn luyện bằng đúng tỉ lệ lớp dương 0,532?

2. C = [[70, 10], [5, 15]]. Tính accuracy, precision, recall, độ đặc hiệu, F1 cho lớp dương.

3. Accuracy kiểm tra 91% nhưng log-loss 2,5: gợi ý hiện tượng gì? Vì sao accuracy không phát hiện?

4. Bỏ sót bệnh nhân (FN) tốn gấp 9 lần cảnh báo thừa (FP). τ^* là bao nhiêu, cao hay thấp hơn 0,5?

Câu hỏi kiểm tra nhanh (2/2)

5. 10 mẫu dương, 20 mẫu âm; mô hình xếp đúng 190 trong 200 cặp, hòa 0 cặp. Tính và diễn giải AUC.

6. Vì sao AUC không phụ thuộc ngưỡng? AUC có phản ánh độ hiệu chuẩn không?

7. Vì sao phải đặt StandardScaler bên trong pipeline khi kiểm định chéo?

8. Vì sao chọn C bằng kiểm định chéo trên tập huấn luyện chứ không dùng tập kiểm tra?

Gợi ý đáp án (1/2)

1. $w = 0$ nên mọi $p = 0{,}5$; theo quy ước $p \geq 0{,}5 \Rightarrow y = 1$, mô hình đoán 1 cho mọi mẫu, nên accuracy = 149/280 = 0,532.

2. TN = 70, FP = 10, FN = 5, TP = 15, $n = 100$. Accuracy 0,85; precision 15/25 = 0,60; recall 15/20 = 0,75; độ đặc hiệu 70/80 = 0,875; F1 = 30/45 ≈ 0,667.

3. Mô hình quá tự tin (overfitting): đúng ở hầu hết mẫu nhưng gán xác suất cực đoan cho nhãn sai ($-\ln 0{,}01 \approx 4{,}6$). Accuracy không phân biệt sai nhẹ và sai chắc chắn.

4. $c_{FN} = 9$, $c_{FP} = 1$: $\tau^* = 1/(1 + 9) = 0{,}1$, thấp hơn nhiều so với 0,5, vì bỏ sót nguy hiểm hơn nên sẵn sàng đoán “bệnh” từ xác suất 10%.

Gợi ý đáp án (2/2)

5. $10 \cdot 20 = 200$ cặp, đúng 190 nên AUC = 0,95: xác suất mẫu dương ngẫu nhiên được xếp cao hơn mẫu âm ngẫu nhiên là 95%.

6. AUC tính từ thứ tự các xác suất nên tổng hợp mọi ngưỡng. Không phản ánh hiệu chuẩn: thay p bằng p^2 (giữ thứ tự) thì AUC không đổi dù xác suất méo.

7. Nếu chuẩn hóa trước, μ và s tính cả từ các mẫu sẽ làm tập kiểm định: thông tin rò rỉ, điểm CV lạc quan. Trong pipeline, mỗi lần chia tự tính lại từ phần huấn luyện.

8. Chọn C theo tập kiểm tra thì tập này không còn “chưa thấy”, điểm cuối quá lạc quan. CV trên tập huấn luyện giữ tập kiểm tra nguyên vẹn để đánh giá một lần.

MÔ HÌNH LOGISTIC REGRESSION · MỤC 6

Tổng kết và mở rộng

Ưu và nhược điểm, Perceptron, Softmax và mạng nơ-ron

Nội dung mục 6

Nhìn lại

Năm bước của bài giảng và ba ý tưởng cốt lõi.

6.1 Ưu và hạn chế

Kể cả đa cộng tuyến và điều chuẩn hóa L1.

6.2 Perceptron

Phiên bản “cứng” của Logistic Regression.

6.3 Mở rộng

Softmax Regression và mạng nơ-ron.

6.4 Bài tập

Tính tay, lập trình, mở rộng.

Nhìn lại: năm bước, năm câu hỏi

Mục	Câu hỏi	Kết quả chính
1	Perceptron còn thiếu gì? Làm sao có xác suất?	Log-odds tuyến tính $\ln(p/(1-p)) = xw$ $\Rightarrow p = \sigma(xw)$; $y \in \{0, 1\}$
2	Mô hình là gì?	$p = \sigma(Xw)$; biên $xw = 0$; đường đồng mức song song; e^{w_j} là odds ratio
3	Huấn luyện thế nào?	Hợp lý cực đại $\Rightarrow$ cross-entropy; gradient $(1/n)X^T(p - y)$
4	Hội tụ ra sao? Khi nào bất thường?	J lồi, nghiệm duy nhất; dữ liệu phân tách $\Rightarrow$ cần L2; biên vẫn phẳng
5	Tốt đến đâu?	Train/test, ngưỡng τ^*, log-loss, ROC/AUC, hiệu chuẩn, kiểm định chéo

Ba ý tưởng cốt lõi

1. Xác suất và hợp lý cực đại

Cross-entropy không tùy tiện: nó là −(1/n)·ln của xác suất mô hình gán cho dữ liệu quan sát được.

2. Gradient dạng X^T(dự đoán − thực tế)

Xuất hiện ở hồi quy tuyến tính, Logistic, Softmax và cả lớp cuối của mạng nơ-ron.

3. Giới hạn của mô hình tuyến tính

Đường biên phẳng; phát triển sau này là vượt giới hạn mà vẫn giữ: mô hình, mất mát, tối ưu.

Ưu điểm của Logistic Regression

- Cho ra xác suất: chọn ngưỡng theo hậu quả, đánh giá bằng log-loss, AUC, hiệu chuẩn.
- Dễ diễn giải: hướng và cường độ qua odds ratio e^{w_j}.
- Bài toán tối ưu dễ chịu: J lồi, nghiệm duy nhất, mọi khởi tạo cho cùng kết quả.
- Học êm khi dữ liệu nhiễu hoặc chồng lấn, ít bị ảnh hưởng bởi mẫu “rất đúng” ở xa.
- Nhanh, mở rộng được: chi phí mỗi epoch cỡ $n \cdot d$; SGD, mini-batch, học trực tuyến.
- Dễ kết hợp điều chuẩn hóa; là baseline tốt và là nền tảng của Softmax và mạng nơ-ron.

Hạn chế, nguyên nhân và hướng khắc phục

Hạn chế	Nguyên nhân	Hướng khắc phục
Biên phẳng: không giải được XOR, vòng tròn	Log-odds tuyến tính theo đặc trưng	Đặc trưng phi tuyến; mạng nơ-ron
Phân tách hoàn hảo: w tăng vô hạn	Không có cực tiểu hữu hạn	Điều chuẩn hóa L2 hoặc L1
Nhạy với thang đo	Số điều kiện Hessian lớn	Chuẩn hóa đặc trưng
Mẫu sai nặng ở xa kéo mạnh biên	Gradient $\lvert p_i - y_i \rvert \cdot \lVert x_i \rVert$	Làm sạch dữ liệu, điều chuẩn hóa
Đa cộng tuyến: trọng số bất ổn	Hessian gần suy biến	Điều chuẩn hóa, bỏ bớt đặc trưng
Lớp mất cân bằng: accuracy gây hiểu lầm	Mô hình thiên về lớp đông	Precision, recall, AUC; đổi ngưỡng; class_weight
Chỉ hai lớp	Một đầu ra xác suất	Softmax Regression

Đa cộng tuyến: trọng số không còn diễn giải được

Thêm $x_1' = x_1 + \varepsilon$ (ε có độ lệch chuẩn 0,05): x_1 và x_1' có tương quan 0,9999

Cấu hình	w_0	w_1, w_1', w_2	$w_1 + w_1'$	Acc. kiểm tra
Chỉ x_1, x_2, không điều chuẩn hóa	−3,520	1,151; −1,291		90,0%
Thêm bản sao, không điều chuẩn hóa	−3,540	−3,112; 4,272; −1,310	1,161	90,0%
Thêm bản sao, L2 (C = 1)	−3,471	0,478; 0,640; −1,233	1,118	90,0%

Dự đoán không đổi, diễn giải thì vô lý

Odds ratio riêng lẻ

e^(−3,112) ≈ 0,045 (“thêm giờ học làm giảm odds”) và e^(4,272) ≈ 71 (“tăng 71 lần”) cho cùng một đại lượng.

Chỉ diễn giải được tổng

Hai trọng số dấu ngược nhau, độ lớn lớn, gần triệt tiêu: tổng 1,161 ≈ 1,151 ban đầu.

Điều chuẩn hóa L2 chia đều trọng số cho hai bản sao (0,478 và 0,640).

Điều chuẩn hóa L1

$$J_{\lambda}^{L1}(w) = J(w) + \lambda \sum_j |w_j|$$

L2

Chỉ làm trọng số nhỏ đi; vẫn dùng được Gradient Descent.

L1

Đưa nhiều trọng số về đúng 0: tự chọn đặc trưng (mô hình thưa). $|w_j|$ không khả vi tại 0 nên cần bộ giải chuyên dụng.

Bài tập C1 so sánh L1 và L2 trên dữ liệu ung thư vú.

Perceptron so với Logistic Regression (1/2)

	Perceptron	Logistic Regression
Điểm số	s = xw	s = xw (là log-odds)
Hàm kích hoạt	Hàm dấu, hàm bước	Sigmoid σ(s)
Đầu ra	Nhãn cứng	Xác suất p ∈ (0, 1), suy ra nhãn
Mất mát theo margin m = y±s	max(0, −m)	ln(1 + e^(−m))
Trọng số mẫu khi cập nhật	Cứng: 1[m ≤ 0]	Mềm: σ(−m)
Mẫu nào ảnh hưởng	Chỉ mẫu sai	Mọi mẫu, mạnh nhất là mẫu sai nặng

Perceptron so với Logistic Regression (2/2)

	Perceptron	Logistic Regression
Dữ liệu phân tách được	Dừng sau hữu hạn bước ($k \le R^2/\gamma^2$)	w tăng mãi, cần điều chuẩn hóa
Dữ liệu chồng lấn	Không hội tụ, w dao động	Hội tụ êm về nghiệm duy nhất
Khởi tạo, thứ tự	Ảnh hưởng (nhiều nghiệm)	Không ảnh hưởng (J lồi)
Độ lớn của w	Không ảnh hưởng bộ phân loại	Điều khiển độ tự tin
Đổi ngưỡng, ROC, log-loss	Không	Có
Đạo hàm hàm kích hoạt	0 hầu như mọi nơi	$\sigma(1-\sigma) > 0$ ở mọi nơi

Perceptron là giới hạn “cứng” của Logistic Regression

$$\lim_{c \to \infty} \frac{1}{c} \cdot \ln(1 + e^{-c \cdot m}) = \max(0, -m)$$

Chứng minh ngắn

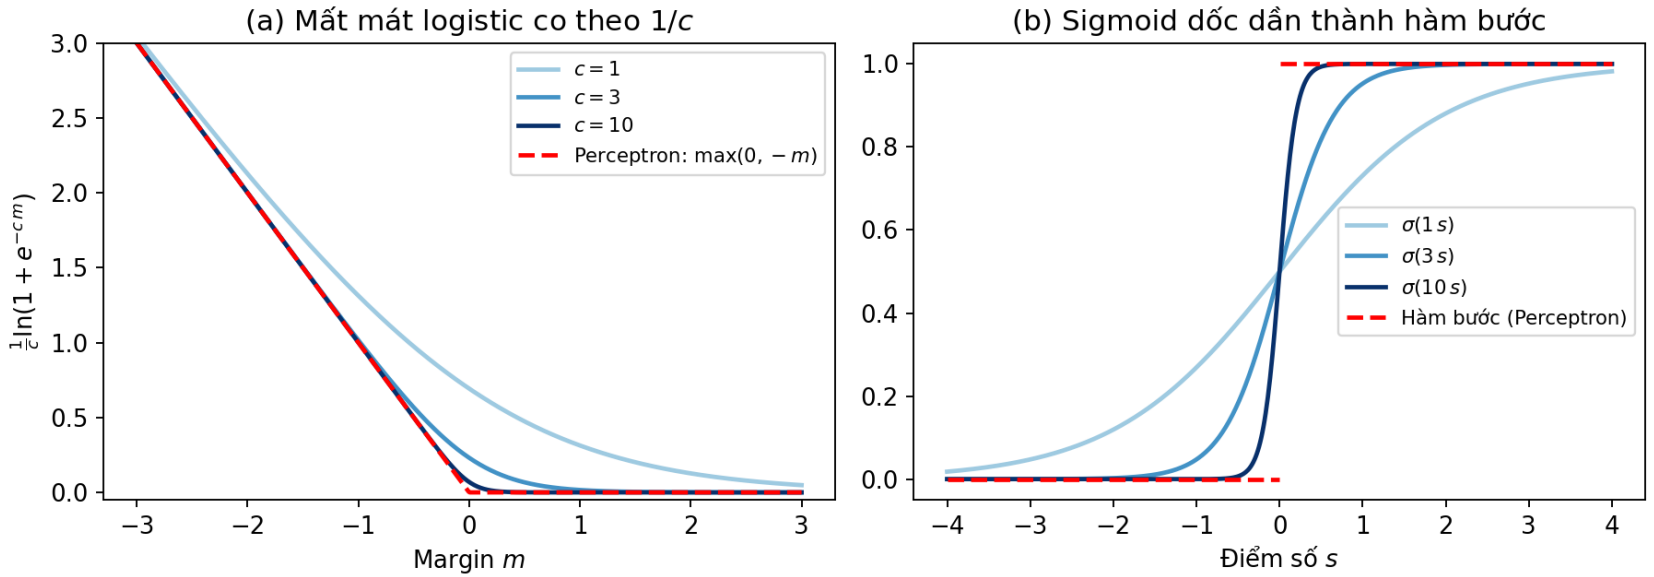
$m > 0$: $0 < \frac{1}{c}\ln(1 + e^{-cm}) \le e^{-cm}/c \to 0$. $m < 0$: $\frac{1}{c}\ln(1 + e^{-cm}) = -m + \frac{1}{c}\ln(1 + e^{cm}) \to -m$.

Kiểm chứng số

$m = -2$: 2,1269 ($c = 1$), 2,000009 ($c = 5$), 2,0000 ($c \ge 20$).
$m = 0{,}5$: 0,4741; 0,0158; 0,000002; 0,0000, tiến về 0.

Perceptron = giới hạn của Logistic Regression với $c \cdot w$ khi $c \to \infty$. Logistic là phiên bản mềm, khả vi của Perceptron.

Hình 21. Từ Logistic đến Perceptron khi c tăng



(a) Mất mát logistic chia cho c tiến tới mất mát Perceptron. (b) σ(c·s) tiến tới hàm bước.

So sánh bằng thực nghiệm: thành thật về accuracy

Mô hình	Acc. kiểm tra, dữ liệu gốc	Acc. kiểm tra, thêm 15 mẫu ngoại lai đúng
Perceptron (thuật toán túi)	86,5% ± 2,8	86,5% ± 2,7
Logistic Regression	87,3% ± 2,8	87,3% ± 2,8

Ngang nhau về accuracy

Chênh lệch nhỏ hơn độ lệch chuẩn giữa các lần chạy; mục 5.5: 89,2% và 90,0%, AUC 0,952 và 0,953.

Lợi thế nằm ở

Xác suất (ngưỡng, log-loss, hiệu chuẩn, ROC); học ổn định; khả năng mở rộng sang Softmax và nhiều tầng.

Perceptron vẫn có chỗ: mô hình đơn giản nhất, học trực tuyến chi phí cực thấp.

Softmax Regression: nhiều hơn hai lớp

$p_{ik} = e^{s_{ik}} / \Sigma_j e^{s_{ij}}$, $P = \text{softmax}(XW)$, W: $(d+1)\times K$

Ý tưởng

Mỗi lớp một cột trọng số; softmax thay sigmoid, áp dụng theo từng hàng. Các p_{ik} dương, cộng lại bằng 1; lớp dự đoán là argmax.

Ví dụ s = (0,5; 1,5; 2,5)

e^s = 1,6487; 4,4817; 12,1825, tổng 18,3129 ⇒ p ≈ (0,090; 0,245; 0,665).

Trừ giá trị lớn nhất của hàng trước khi lấy mũ để tránh tràn số: softmax không đổi khi cộng cùng một hằng số.

Softmax là sigmoid mở rộng, kèm cross-entropy nhiều lớp

K = 2 trở về Logistic

$p_1 = e^{(s_1)}/(e^{(s_0)} + e^{(s_1)}) = 1/(1 + e^{(-(s_1 - s_0))}) = \sigma(x(w_1 - w_0))$.

Mất mát với nhãn one-hot

$J(W) = -(1/n) \Sigma_i \Sigma_k y_{ik} \cdot \ln p_{ik}$. Với K = 2 là cross-entropy nhị phân; W = 0 cho J = ln K.

Mẫu thuộc lớp c: $\ell = -\ln p_{ic}$, đạo hàm theo s_{ik} là $p_{ik} - 1[k = c]$. Ví dụ nhãn lớp 2: $\ell = -\ln 0{,}245 \approx 1{,}408$, gradient (0,090; −0,755; 0,665).

Gradient và cập nhật của Softmax

$$\nabla_W J = (1/n)\, X^T(P - Y),\ W \leftarrow W - \eta \nabla_W J$$

Kiểm tra kích thước

X^T: (d+1)×n; P − Y: n×K; tích: (d+1)×K, khớp với W.

Cùng dạng với nhị phân

Mã chỉ khác Logistic ở hai chỗ: sigmoid thành softmax, vector thành ma trận.

Cùng một khung: X^T(dự đoán − thực tế).

Softmax trên bộ dữ liệu Iris

1,0986 → 0,0634

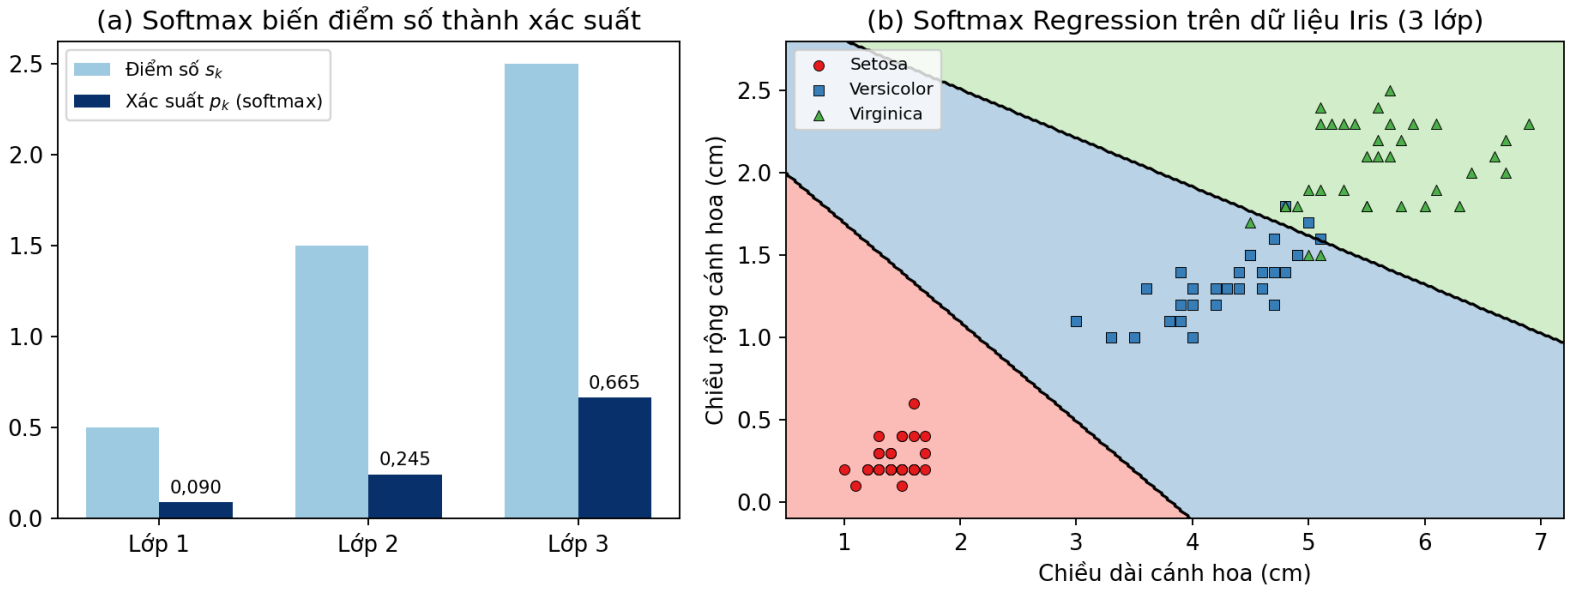
J ban đầu = ln 3 (W = 0) và J sau 2000 epoch, η = 0,5.

97,1% và 100%

Accuracy huấn luyện và kiểm tra (45 mẫu, ma trận nhầm lẫn 3×3 chéo hoàn toàn).

150 mẫu, 4 đặc trưng, 3 loài, chia phân tầng 70/30, đã chuẩn hóa. Gradient giải tích và số sai khác cỡ 10^{-10}. Setosa tách hoàn toàn nên nghiệm không duy nhất: scikit-learn trùng nhãn 100% nhưng xác suất lệch tới 0,25 ở một số mẫu.

Hình 22. Softmax và Iris



(a) Softmax biến ba điểm số thành ba xác suất cộng bằng 1. (b) Iris với hai đặc trưng cánh hoa: ba vùng quyết định ngăn cách bởi các đường thẳng (94,3% huấn luyện, 97,8% kiểm tra).

Một khung chung: gradient $(1/n)X^T(\mu - y)$

Mô hình	Trung bình μ	Phân phối của y
Hồi quy tuyến tính (½MSE)	μ = xw	Chuẩn (Gauss)
Logistic Regression	μ = σ(xw)	Bernoulli
Softmax Regression	μ = softmax(xW)	Phân loại nhiều lớp
Hồi quy Poisson (đếm sự kiện)	μ = e^(xw)	Poisson

Mô hình tuyến tính tổng quát: hiểu Logistic rồi thì học mô hình khác chỉ là đổi hàm μ và phân phối.

Mạng nơ-ron: xếp nhiều Logistic Regression

$$H = \sigma(XW_1),\ \tilde{H} = [1, H],\ p = \sigma(\tilde{H}w_2)$$

Một nơ-ron

Một Logistic Regression chính là một nơ-ron nhân tạo với kích hoạt sigmoid.

Lớp ra là Logistic

Chạy trên đặc trưng H mà lớp ẩn tự học ra, thay vì ta đoán x_1^2, x_1x_2, x_2^2 như ở mục 4.5.

W_1: (d+1)×m (mỗi cột là một nơ-ron ẩn); w_2: (m+1)×1.

Huấn luyện bằng lan truyền ngược

Lớp ra: y hệt Logistic

$\nabla_w_2 J = (1/n)\, \tilde{H}^T(p - y)$, chỉ thay X bằng $\tilde{H}$.

Lớp ẩn: quy tắc hàm hợp

$\nabla_W_1 J = (1/n)\, X^T[\, (p - y)v^T \odot H \odot (1 - H)\,]$, v là w_2 bỏ phần tử chệch.

Dùng $\sigma' = \sigma(1 - \sigma)$ (mục 2.3). Hàm kích hoạt phải khả vi: hàm dấu có đạo hàm 0 nên không truyền được gradient về lớp ẩn.

Mạng tự học XOR

3 nơ-ron ẩn: 10/10

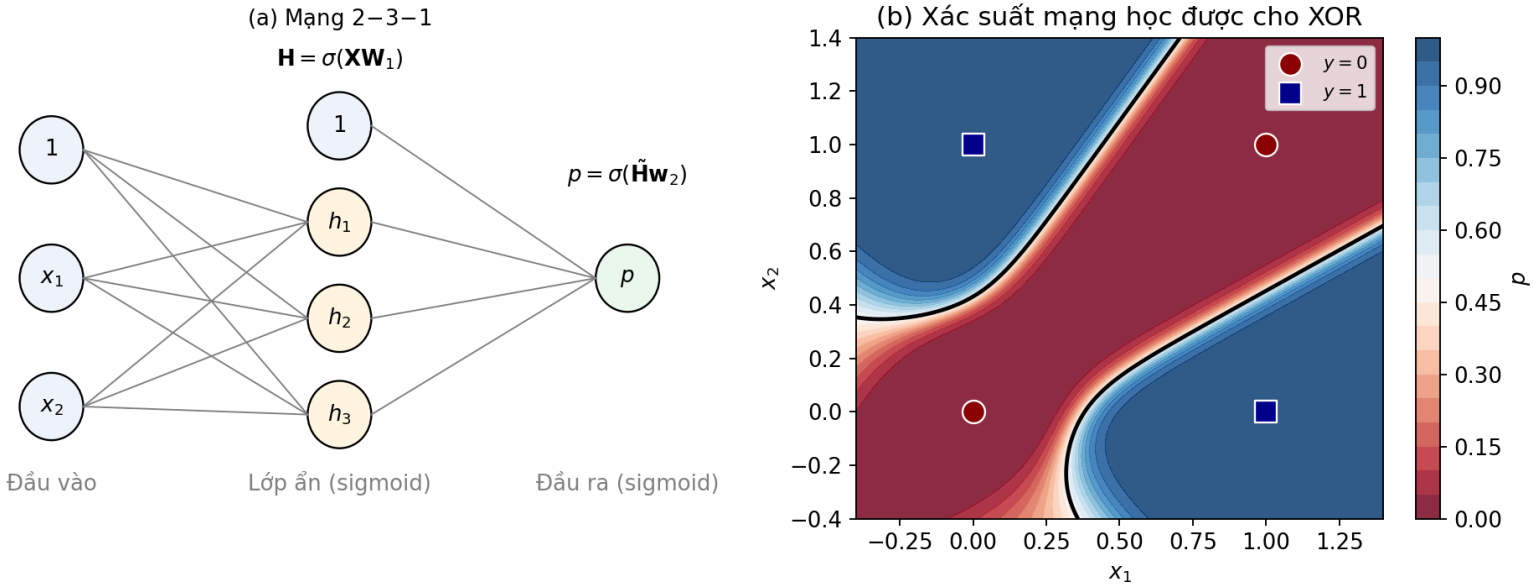
Học đúng XOR ở cả 10 lần khởi tạo ngẫu nhiên.

2 nơ-ron ẩn: 9/10

Một lần bị kẹt.

Xác suất thu được (0; 1; 0,999; 0,001) đúng nhãn XOR (0, 1, 1, 0), J cuối = 0,0005. Khác Logistic: hàm mất mát của mạng nhiều lớp không còn lồi.

Hình 23. Mạng 2-3-1 và bản đồ xác suất cho XOR



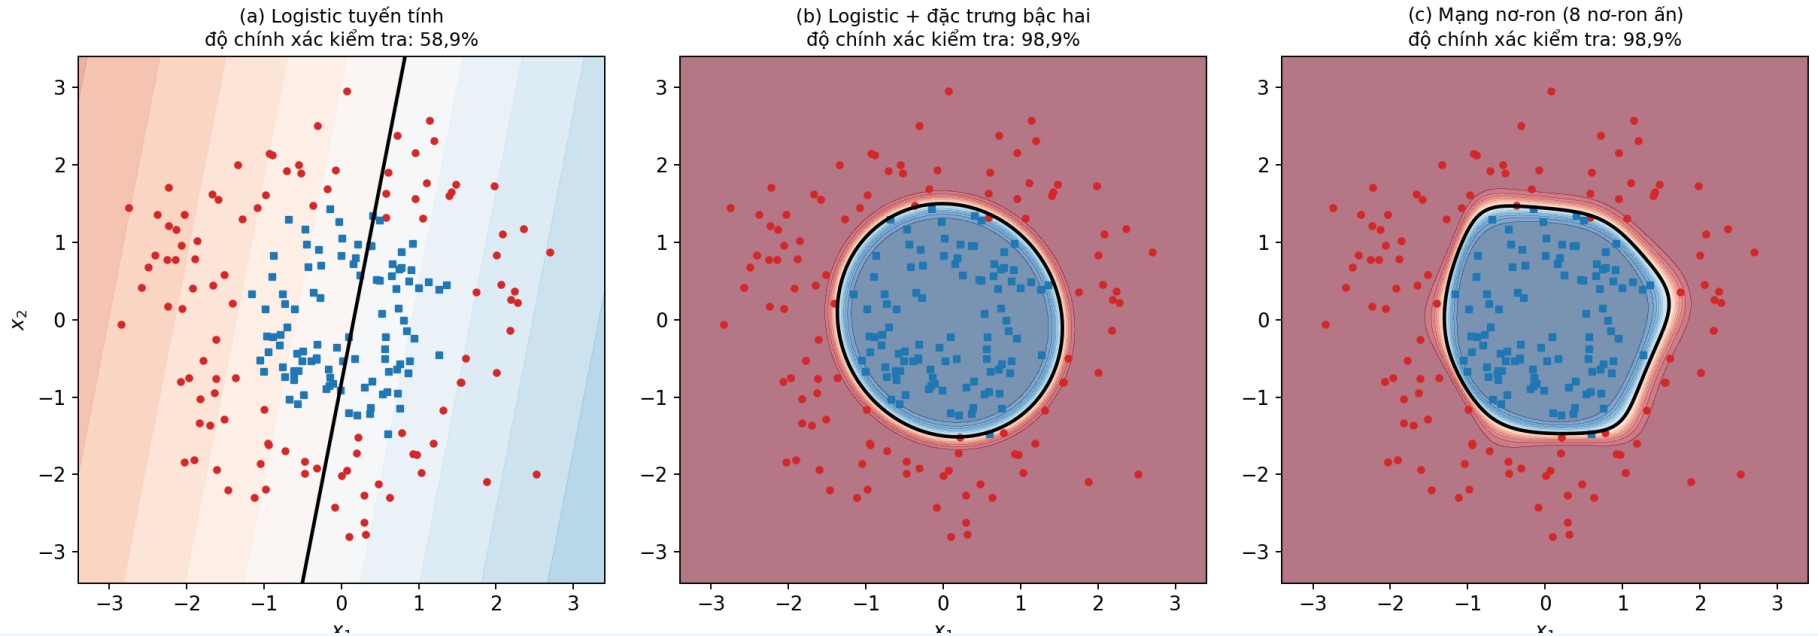
(a) Mỗi nơ-ron là một Logistic Regression. (b) Đường biên cong gồm hai nhánh: hai điểm lớp 1 trong dải xanh, hai điểm lớp 0 trong vùng đỏ.

Mạng học dữ liệu hình vòng tròn

Mô hình	Số đặc trưng vào	Acc. huấn luyện	Acc. kiểm tra
Logistic tuyến tính	2	51,0%	58,9%
Logistic + đặc trưng bậc hai (ta tự thêm)	5	99,0%	98,9%
Mạng 8 nơ-ron ẩn (tự học đặc trưng)	2	99,0%	98,9%

Số nơ-ron ẩn: 2 nơ-ron chỉ đạt 80% đến 86% (không đủ tạo biên khép kín); 4 nơ-ron: 97% đến 99%; 8 nơ-ron: 98% đến 99% (5 lần khởi tạo).

Hình 24. Dữ liệu hình vòng tròn



(a) Logistic tuyến tính chỉ có đường thẳng. (b) Đặc trưng bậc hai ta tự chọn. (c) Mạng nơ-ron tự học đặc trưng, biên gần như tròn.

Lộ trình học tiếp

Mô hình	Điểm khác so với bước trước
Hồi quy tuyến tính	Dự đoán số thực, mất mát MSE
Perceptron	Thêm hàm dấu để ra nhãn, mất mát max(0, −m)
Logistic Regression	Làm mềm hàm dấu thành sigmoid, cross-entropy, cho xác suất
Softmax Regression	Nhiều lớp: ma trận W, hàm softmax
Mạng nơ-ron nhiều lớp	Xếp nhiều Logistic, lan truyền ngược, tự học đặc trưng
Mạng sâu (CNN, RNN, Transformer…)	Cùng khung huấn luyện, đổi kiến trúc cho ảnh, chuỗi, văn bản

Tóm tắt và lời kết

Ý tưởng lớn

Mô hình hóa bằng xác suất; hợp lý cực đại sinh ra hàm mất mát; gradient dạng X^T(dự đoán − thực tế).

Cân bằng

Khớp dữ liệu và độ lớn tham số qua điều chuẩn hóa (L2, L1).

Quan hệ với Perceptron

Perceptron là giới hạn cứng của Logistic Regression; Logistic là phiên bản mềm, khả vi.

Mở rộng

Softmax cho nhiều lớp; xếp nhiều Logistic thành mạng nơ-ron, tự học đặc trưng.

Trung thực

Trên dữ liệu dễ, accuracy các mô hình tuyến tính gần nhau; lợi thế là xác suất và ổn định.

Bài tập A: tính tay (1/2)

A1. $p = 0{,}8$: tính odds và log-odds. Log-odds $= -2$ thì p bằng bao nhiêu?

A2. $X = (1{,}0;\ 1{,}1;\ 1{,}2)^T$ (cột bias và x), $y = (0,\ 0,\ 1)^T$. Từ $w = 0$, tính J, gradient và w sau một bước $\eta = 1$; tính lại J.

A3. Tung đồng xu 10 lần được 7 ngửa. Dùng $L(p) = p^7(1 - p)^3$ tìm p theo hợp lý cực đại.

A4. Tính softmax của $s = (1,\ 2,\ 3)$, so với $(0{,}5;\ 1{,}5;\ 2{,}5)$. Nhãn thật lớp 3 thì mất mát bao nhiêu?

Bài tập A: tính tay (2/2)

A5. Chứng minh Softmax với K = 2 trở về sigmoid $p_1 = \sigma(s_1 - s_0)$.

A6. w = 0,9 cho “số năm kinh nghiệm”. Odds ratio khi thêm 1 và 3 năm? Người có p = 0,2 thêm 1 năm thì p bằng bao nhiêu?

A7. Bỏ sót ca bệnh (FN) tốn gấp 5 lần báo động nhầm (FP): ngưỡng τ* bằng bao nhiêu?

A8. Tính (1/c)ln(1 + e^(−cm)) với c = 10, m = −1 và m = 1; so với max(0, −m).

Bài tập B (lập trình) và C (mở rộng)

Phần B

B1 Logistic từ đầu và kiểm tra gradient số. B2 So sánh batch, SGD, mini-batch. B3 $\|w\|$ theo λ với 6 sinh viên. B4 Đa cộng tuyến với nhiễu 0,05; 0,2; 0,5; 1. B5 ROC và AUC từ đầu. B6 Ung thư vú: Logistic và Perceptron, loại sai nào nguy hiểm hơn? B7 Softmax trên Iris.

Phần C

C1 So sánh L1 và L2 trên dữ liệu ung thư vú (đếm trọng số khác 0). C2 Mạng nơ-ron hai lớp, kiểm tra gradient, dữ liệu vòng tròn với 2, 4, 8 nơ-ron ẩn. C3 Dữ liệu mất cân bằng 95/5, so sánh có và không class_weight="balanced".

Làm B1 trước: các bài còn lại đều dùng lại hàm sigmoid, mất mát và gradient của B1.

Gợi ý đáp án A (1/2)

A1. odds = 0,8/0,2 = 4; log-odds = ln 4 ≈ 1,386. Log-odds −2: $p = 1/(1 + e^{2}) \approx 0{,}119$.

A2. $w = 0$: mọi $p = 0{,}5$, $J = \ln 2 \approx 0{,}6931$, $p - y = (0{,}5;\ 0{,}5;\ -0{,}5)^{T}$. $X^{T}(p - y) = (0{,}5;\ -0{,}5)^{T}$, gradient $\approx (0{,}1667;\ -0{,}1667)^{T}$. $w = (-0{,}1667;\ 0{,}1667)^{T}$, $s = (-0{,}1667;\ 0;\ 0{,}1667)^{T}$, $p \approx (0{,}4584;\ 0{,}5;\ 0{,}5416)^{T}$, $J \approx 0{,}6399 < 0{,}6931$.

A3. $\ln L = 7 \ln p + 3 \ln(1 - p)$; $7/p - 3/(1 - p) = 0 \Rightarrow p = 0{,}7$, đúng tỉ lệ quan sát.

A4. $p \approx (0{,}090;\ 0{,}245;\ 0{,}665)$, giống hệt vì hai vector hơn kém nhau hằng số 0,5. Nhãn lớp 3: $-\ln 0{,}665 \approx 0{,}408$.

Gợi ý đáp án A (2/2)

A5. $p_1 = e^{(s_1)}/(e^{(s_0)} + e^{(s_1)})$; chia tử và mẫu cho $e^{(s_1)}$: $p_1 = 1/(e^{(s_0 - s_1)} + 1) = \sigma(s_1 - s_0) = \sigma(x(w_1 - w_0))$.

A6. $e^{0,9} \approx 2,46$; $e^{2,7} \approx 14,88$ ($= 2,46^3$). $p = 0,2$: odds $0,25 \rightarrow 0,25 \times 2,46 \approx 0,615$, $p \approx 0,381$.

A7. $c_{FN} = 5$, $c_{FP} = 1$: $\tau^* = 1/6 \approx 0,167$, thấp hơn 0,5 vì bỏ sót nguy hiểm hơn.

A8. $m = -1$: $\approx 1,0000045$, sát $\max(0, 1) = 1$. $m = 1$: $\approx 4,5 \cdot 10^{-6}$, sát 0. Với c lớn, mất mát logistic gần như trùng mất mát Perceptron.

Kết quả tham khảo B và C

B6 (ung thư vú)

Logistic (C = 1): accuracy ≈ 95,3%, AUC ≈ 0,992, log-loss ≈ 0,107. Perceptron: ≈ 96,5%, AUC ≈ 0,992: chênh lệch trong dao động. FN nguy hiểm hơn: hạ τ xuống dưới 0,5 để tăng recall.

B7, C1, C2, C3

B7: J từ 1,0986 xuống ≈ 0,0634, test 100%. C1: L2 giữ 30 trọng số; L1 chỉ 7, 9, 11, 13 trọng số khác 0 ứng với C = 0,05; 0,1; 0,5; 1. C2: 2 nơ-ron ≈ 80% đến 86%; 4 và 8 nơ-ron ≈ 97% đến 99%. C3: class_weight tăng recall, giảm precision, AUC gần như không đổi.

B3: llwll giảm đơn điệu khi λ tăng (≈ 3,04; 2,05; 1,18). B5: AUC = 0,9534.