Softmax Regression · Mục 1

Từ Logistic Regression đến bài toán phân loại nhiều lớp

Vì sao một xác suất là chưa đủ khi có nhiều hơn hai kết quả?



Logistic Regression chỉ có một xác suất

Hai kết quả

Một con số p = P(y=1 | **x**). Lớp còn lại tự động là 1 − p. Vừa đủ.

Ba kết quả: rớt, đạt, giỏi

Cần ba xác suất p_0, p_1, p_2 không âm và cộng lại bằng 1. Một con số p không biểu diễn được.

Ba câu hỏi của mục này

1. Logistic Regression còn hạn chế gì khi có hơn hai lớp?
2. Bài toán nhiều lớp được mô tả ra sao, nhãn mã hóa thế nào?
3. Có những hướng giải nào, vì sao cần mô hình xác suất chung?

Gán nhãn 0, 1, 2 rồi hồi quy: vì sao không ổn?

Áp đặt thứ tự

0 < 1 < 2 ngầm nói lớp 1 nằm giữa lớp 0 và lớp 2. Với chữ số hay loại email, điều này vô nghĩa.

Áp đặt khoảng cách đều

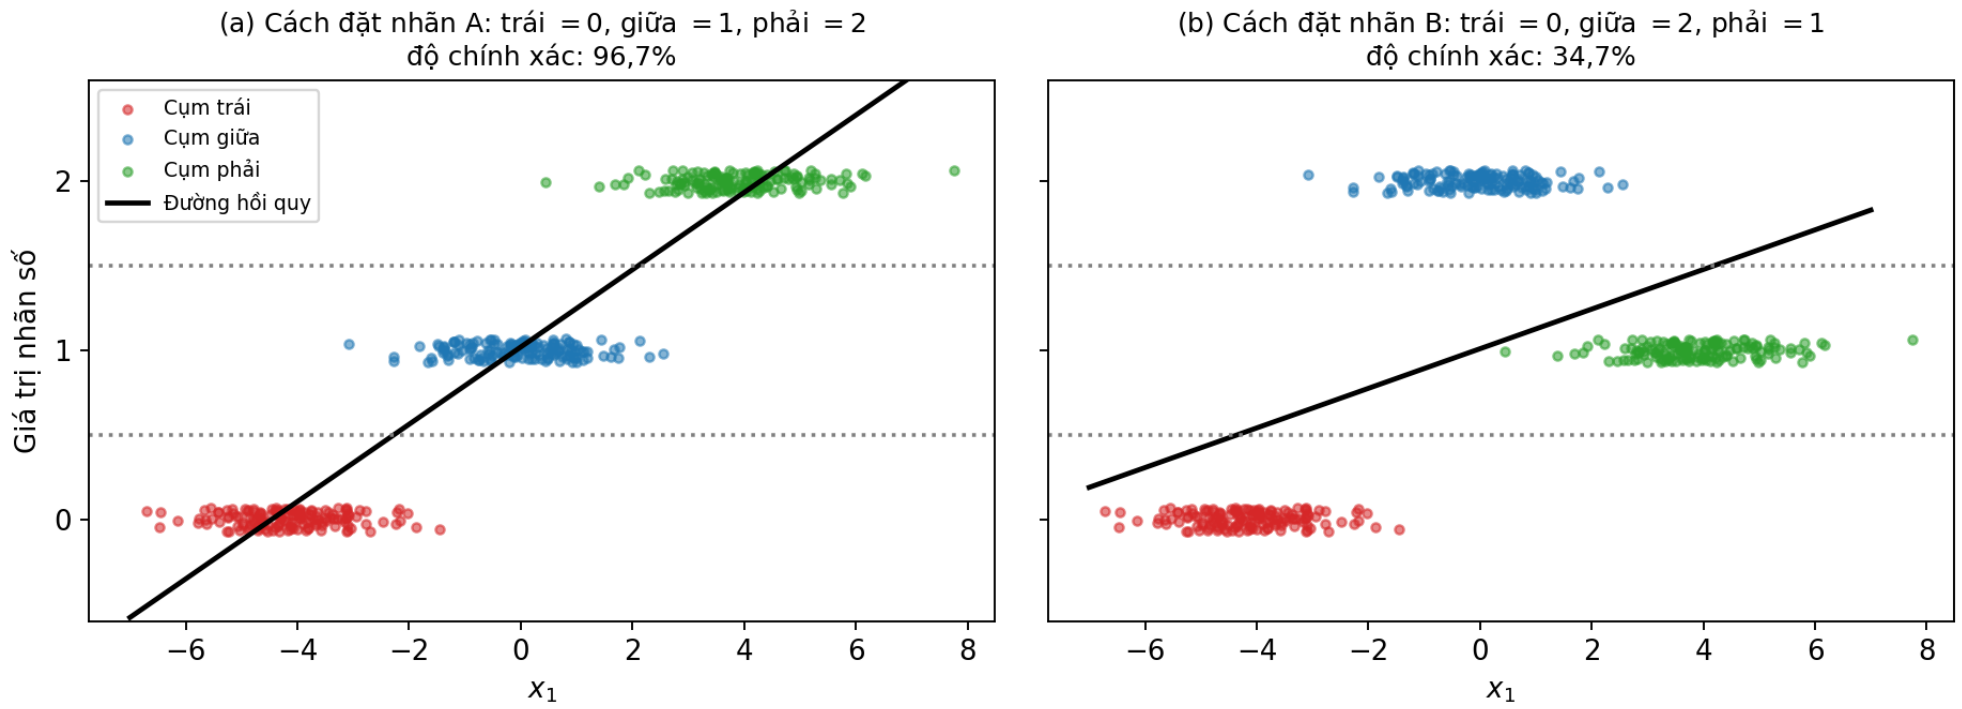
Nhầm 0 thành 2 bị coi nặng gấp đôi nhầm 0 thành 1. Nhầm 1 thành 9 đâu nặng gấp tám lần nhầm 1 thành 2.

Thí nghiệm: ba cụm trên trục x_1

Cách đặt nhãn	Trái	Giữa	Phải	Chính xác
A	0	1	2	96,7%
B	0	2	1	34,7%

Dữ liệu giống hệt, chỉ đổi tên lớp mà độ chính xác rơi từ 96,7% xuống 34,7%. Mô hình tốt phải bất biến khi đánh số lại các lớp.

Hình 1. Hồi quy tuyến tính trên nhãn dạng số



(a) Cách A: đường hồi quy đi qua đúng ba cụm. (b) Cách B: không có đường thẳng nào làm được, cụm giữa (nhãn 2) bị đoán sai hoàn toàn.

Bài toán K lớp và mã hóa one-hot

Mục tiêu

Với mỗi mẫu, ước lượng một phân phối trên K lớp:

$p_{ik} = P(y = k \mid \mathbf{x}_i)$, $p_{ik} \geq 0$, $\Sigma_k\, p_{ik} = 1$

Dự đoán: $\hat{y}_i = \text{argmax}_k\, p_{ik}$

One-hot với K = 3

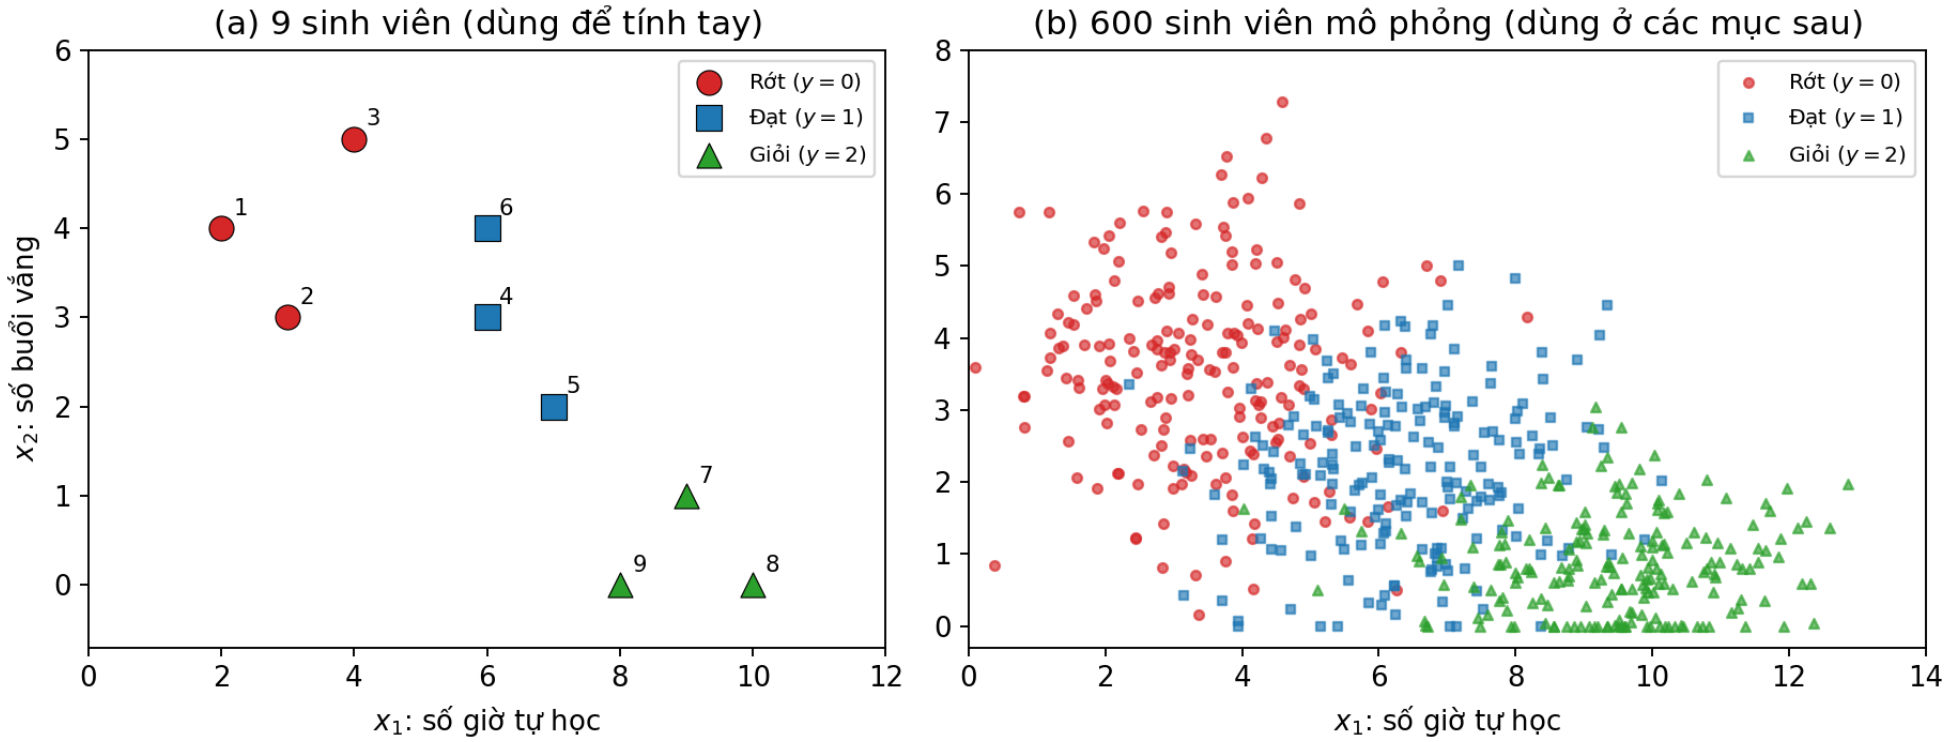
Kết quả	y	Vector one-hot
rớt	0	(1, 0, 0)
đạt	1	(0, 1, 0)
giỏi	2	(0, 0, 1)

Các lớp bình đẳng: mọi cặp vector cách nhau như nhau, không lớp nào "ở giữa".

Mỗi hàng của Y là một phân phối xác suất "mục tiêu", cùng kích thước n×K với ma trận dự đoán P.

K = 2: nhãn {0, 1} của Logistic Regression chính là one-hot rút gọn.

Hình 2. Dữ liệu ba mức kết quả học tập



(a) 9 sinh viên dùng để tính tay. (b) 600 sinh viên mô phỏng (200 mỗi lớp). Lớp "đạt" nằm giữa lớp "rớt" và lớp "giỏi".

Hướng 1: one-vs-rest, K bộ nhị phân độc lập

Bộ thứ k hỏi: "mẫu này thuộc lớp k hay lớp khác?" Nhãn nhị phân là cột k của Y. Kết quả trên dữ liệu 600 sinh viên:

Che khuất

Bộ "đạt chống phần còn lại" gần như không học được gì: trả về $p \approx 0{,}333$ cho mọi sinh viên, vì một đường thẳng không tách được lớp nằm giữa.

35,6%

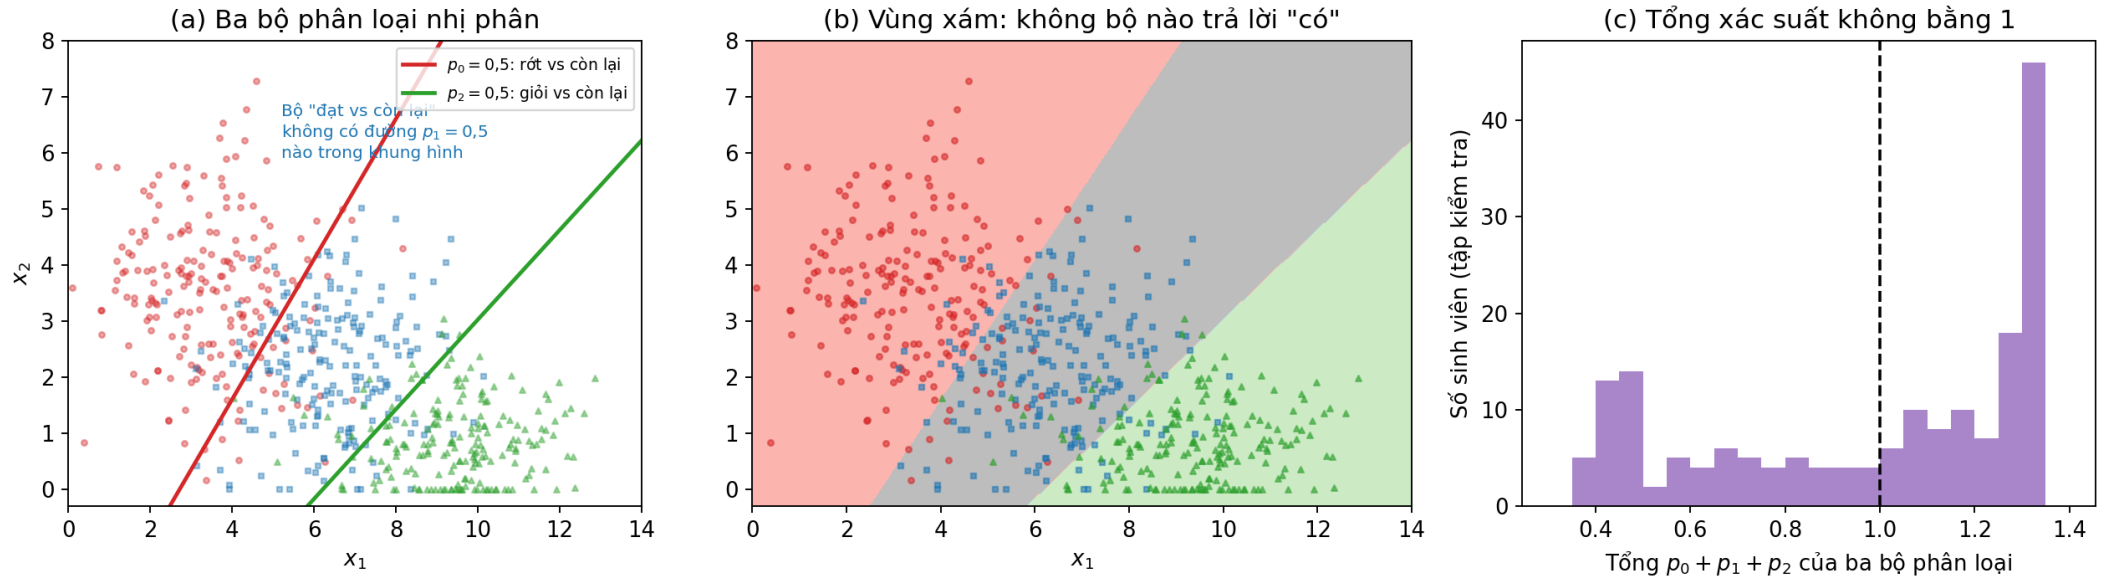
số mẫu kiểm tra mà cả ba bộ đều trả lời "không": vùng không bộ nào nhận.

0,357–1,349

khoảng dao động của $p_0 + p_1 + p_2$. Tổng không bằng 1 nên không phải phân phối xác suất.

Độ chính xác 83,9%, nhưng lớp "đạt" chỉ được nhận đúng **66,7%**: lớp ở giữa chịu thiệt nhiều nhất.

Hình 3. One-vs-rest trên 600 sinh viên



(a) Bộ "đạt chống phần còn lại" không có đường p = 0,5 đáng kể. (b) Vùng xám: không bộ nào trả lời "có". (c) Tổng ba xác suất dao động quanh 1.

Hướng 2: một mô hình xác suất chung

K điểm số $s_k = x \cdot w_k$ qua softmax:

$$p_k = e^{(s_k)} / \Sigma_j e^{(s_j)}$$

Các lớp cạnh tranh: xác suất một lớp tăng thì các lớp còn lại buộc phải giảm.

	One-vs-rest	Softmax
Tổng xác suất	không bằng 1	luôn bằng 1
Huấn luyện	riêng từng bộ	đồng thời
Lớp ở giữa	bị che khuất	được "kẹp" bởi hai ranh giới
Vùng không ai nhận	có	không
Nhận đúng lớp "đạt"	66,7%	80,0%

Khi K = 2, softmax trở về đúng Logistic Regression. Mục 2 sẽ xây dựng mô hình này.

Tóm tắt và câu hỏi kiểm tra nhanh

Điều cần nhớ

- Logistic Regression: một xác suất, chỉ cho hai lớp.
- Gán nhãn số rồi hồi quy áp đặt thứ tự và khoảng cách.
- Nhãn one-hot Y: các lớp bình đẳng, cùng kích thước với P.
- One-vs-rest: che khuất, vùng không ai nhận, tổng khác 1.
- Giải pháp: K điểm số + softmax, một phân phối xác suất thật.

Thử sức

1. K = 4, $\mathbf{y} = (2, 0, 3, 1)^T$. Viết ma trận one-hot Y. Tổng mỗi hàng, mỗi cột bằng bao nhiêu?
2. K = 10: one-vs-rest cần bao nhiêu mô hình? One-vs-one thì sao?
3. OvR cho $(p_0, p_1, p_2) = (0{,}62; 0{,}35; 0{,}41)$. Tính tổng và lớp dự đoán.

Softmax Regression · Mục 2

Mô hình Softmax Regression

K điểm số tuyến tính chạy song song, rồi softmax biến chúng thành một phân phối xác suất.



Ba câu hỏi của mục này

1. Quy trình

Mô hình nhận đầu vào, xử lý và đưa ra K xác suất như thế nào?

2. Vector và ma trận

Viết gọn bằng ma trận ra sao? Softmax có những tính chất gì?

3. Hình học

Vùng quyết định trông thế nào? Trọng số có ý nghĩa gì khi có nhiều cột tham số?

2.1. Ý tưởng: hội đồng K giám khảo

Mỗi lớp có một giám khảo chuyên trách chấm điểm theo tiêu chí riêng. Quy trình gồm bốn bước:

1. Nhận đặc trưng

Mô hình nhận $x_1, \ldots, x_d$ của một mẫu.

2. Chấm điểm

Giám khảo k tính điểm số tuyến tính $s_k = x \cdot w_k$, mỗi lớp một bộ trọng số riêng.

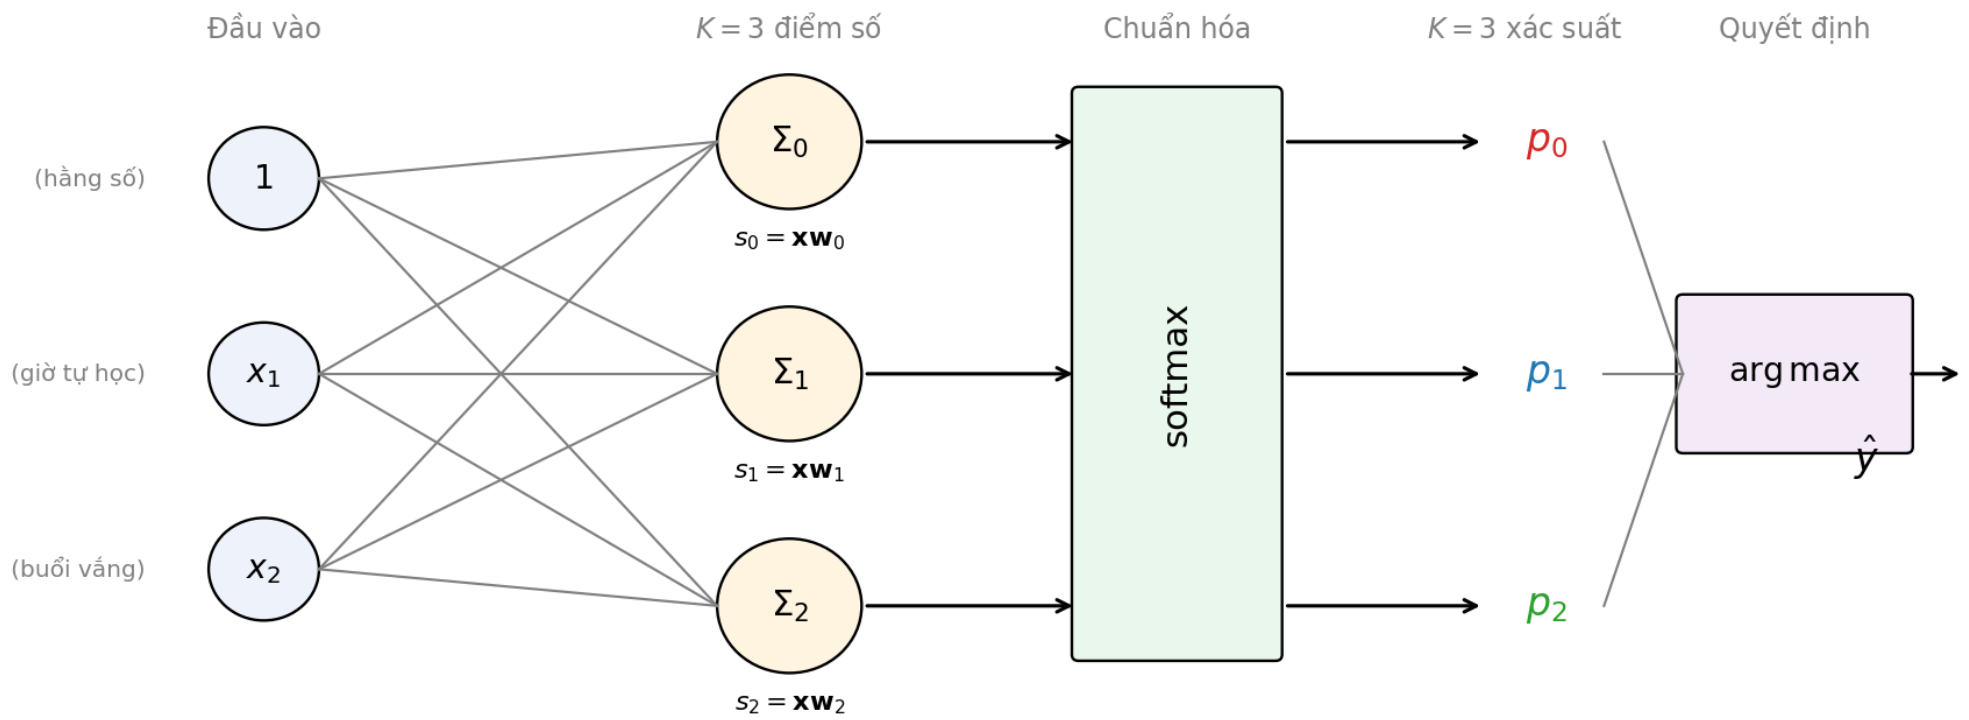
3. Quy đổi

Softmax chia 100% phiếu cho K lớp theo điểm số. Các giám khảo không chấm độc lập.

4. Quyết định

Lớp có xác suất lớn nhất được chọn: $\hat{y} = \text{argmax}_k\ p_k$.

Hình 4. Cấu trúc của Softmax Regression



Hai đặc trưng, ba lớp: mỗi đầu vào nối tới cả ba điểm số, softmax chuyển thành ba xác suất cộng lại bằng 1, argmax chọn lớp dự đoán.

Logistic Regression và Softmax Regression

	Logistic Regression	Softmax Regression
Số điểm số	1 điểm số $s = \mathbf{x} \cdot \mathbf{w}$	K điểm số $s_k = \mathbf{x} \cdot \mathbf{w}_k$
Hàm chuẩn hóa	Sigmoid $\sigma(s)$	Softmax trên cả K điểm số
Đầu ra	1 xác suất p (lớp còn lại là 1 − p)	K xác suất cộng lại bằng 1
Số tham số	d + 1	K(d + 1)
Quyết định	$\hat{y} = 1$ nếu $p \geq 0{,}5$	$\hat{y} = \text{argmax}_k\, p_k$

2.2. Điểm số của một lớp

$$s_k = w_{0k} + w_{1k}x_1 + \ldots + w_{dk}x_d = \mathbf{x}\cdot\mathbf{w}_k$$

w_{0k}: hệ số chệch

Điểm số "nền" mà lớp k nhận được khi mọi đặc trưng bằng 0.

w_{jk}: ủng hộ hay phản đối

Nếu $w_{jk} > 0$, tăng x_j làm điểm của lớp k tăng. Nếu $w_{jk} < 0$ thì làm giảm.

Gộp K điểm số bằng ma trận W

$\mathbf{W} = [\ \mathbf{w}_0\ \mathbf{w}_1\ \ldots\ \mathbf{w}_{K-1}\ ]$ kích thước $(d+1) \times K$

$\mathbf{S} = \mathbf{XW}$ $(n \times K)$, $s_{ik} = \mathbf{x}_i \cdot \mathbf{w}_k$

Cột k của **S** là vector điểm số $\mathbf{Xw}_k$ của "bài toán thứ k" quen thuộc. Vậy **S = XW** là K bộ chấm điểm chạy song song, chỉ cần một phép nhân ma trận.

Tổng số tham số: $K(d + 1)$. Với $d = 2$, $K = 3$ có 9 tham số, gấp ba Logistic Regression.

Ví dụ: chọn tay W cho ba mức kết quả

Ma trận W (3 × 3)

Hàng: hệ số chệch, giờ học, buổi vắng. Cột: rớt, đạt, giỏi.

	w_0	w_1	w_2
chệch	1,5	0	−6,5
x_1	−1	0	1
x_2	1	0	−1

Điểm số

$s_0 = 1{,}5 - x_1 + x_2$

$s_1 = 0$

$s_2 = -6{,}5 + x_1 - x_2$

Lớp rớt: điểm giảm theo giờ học, tăng theo buổi vắng. Lớp giỏi làm ngược lại. Lớp đạt có điểm cố định 0, đóng vai trò “mốc”.

2.3. Hàm softmax

$$p_k = e^{(s_k)} / \Sigma_j e^{(s_j)}, k = 0, ..., K-1$$

Bước 1: lấy mũ

$e^{(s_k)}$ biến điểm số bất kỳ thành số dương. Hàm mũ là hàm tăng.

Bước 2: chia cho tổng

Các số dương cộng lại bằng 1, thành một phân phối xác suất.

Tên "softmax": nếu "max cứng" gán 1 cho lớp thắng và 0 cho các lớp còn lại, thì softmax là phiên bản "mềm" của phép chọn đó.

Ví dụ tính softmax

Với K = 3 điểm số s = (0,5; 1,5; 2,5):

Lớp	s_k	$e^(s_k)$	p_k
0	0,5	1,6487	0,090
1	1,5	4,4817	0,245
2	2,5	12,1825	0,665
Tổng		18,3129	1

Lớp có điểm cao nhất nhận nhiều xác suất nhất, nhưng các lớp còn lại không bị gạt về 0: điểm thấp hơn chỉ làm xác suất nhỏ đi một cách mượt.

Giả thiết của Softmax Regression

$$\ln(p_k / p_l) = s_k - s_l = \mathbf{x}(\mathbf{w}_k - \mathbf{w}_l)$$

Log-odds giữa hai lớp bất kỳ là hàm tuyến tính của đặc trưng. Đây là mở rộng trực tiếp của giả thiết $\ln(p/(1-p)) = \mathbf{x}\cdot\mathbf{w}$ ở Logistic Regression.

Kiểm chứng: $\ln(0{,}665 / 0{,}245) \approx 1{,}0 = 2{,}5 - 1{,}5$

Các tính chất của softmax

Tính chất	Biểu thức	Giải thích
Phân phối xác suất	$0 < p_k < 1, \Sigma\, p_k = 1$	Tử dương, nhỏ hơn mẫu; tổng tử = mẫu
Đơn điệu	$s_k > s_l \Leftrightarrow p_k > p_l$	e^s tăng, mọi p cùng mẫu số
Cho dự đoán	$\text{argmax}\ p_k = \text{argmax}\ s_k$	Chỉ cần so điểm số
Bất biến khi dịch	$\text{softmax}(s + c) = \text{softmax}(s)$	Thừa số e^c triệt tiêu
Tỉ số xác suất	$p_k / p_l = e^{(s_k - s_l)}$	Mẫu số triệt tiêu
Liên hệ sigmoid	$K = 2$: $p_1 = \sigma(s_1 - s_0)$	Chứng minh ở slide sau

Bất biến khi dịch và tính toán ổn định

Chỉ phụ thuộc hiệu điểm số

$e^{(s_k+c)} / \Sigma_j e^{(s_j+c)} = e^c \cdot e^{(s_k)} / (e^c \cdot \Sigma_j e^{(s_j)}) = p_k$

Hệ quả: softmax chỉ phụ thuộc hiệu các điểm số, không phụ thuộc giá trị tuyệt đối. Điều này còn dẫn đến tính dư thừa tham số ở mục 2.5.

Tránh tràn số

Với s = (1000, 1001, 1002), e^{1000} vượt giới hạn số thực: tính trực tiếp cho kết quả nan.

Cách làm: trừ điểm số lớn nhất của từng hàng trước khi lấy mũ. Kết quả đúng: (0,090; 0,245; 0,665).

Độ lớn điểm số điều khiển độ tự tin

Nhân mọi điểm số s = (0,5; 1,5; 2,5) với hệ số c > 0 (không đổi thứ tự lớp):

Hệ số c	p_0	p_1	p_2
0,5	0,186	0,307	0,507
1	0,090	0,245	0,665
2	0,016	0,117	0,867
5	0,000	0,007	0,993

Khi $c \to \infty$, softmax tiến tới "max cứng". Độ lớn của W điều khiển độ tự tin của mô hình.

Khi K = 2, softmax trở thành sigmoid

$$p_1 = e^{s_1} / [e^{s_0} + e^{s_1}] = 1 / [1 + e^{-(s_1 - s_0)}] = \sigma(s_1 - s_0)$$

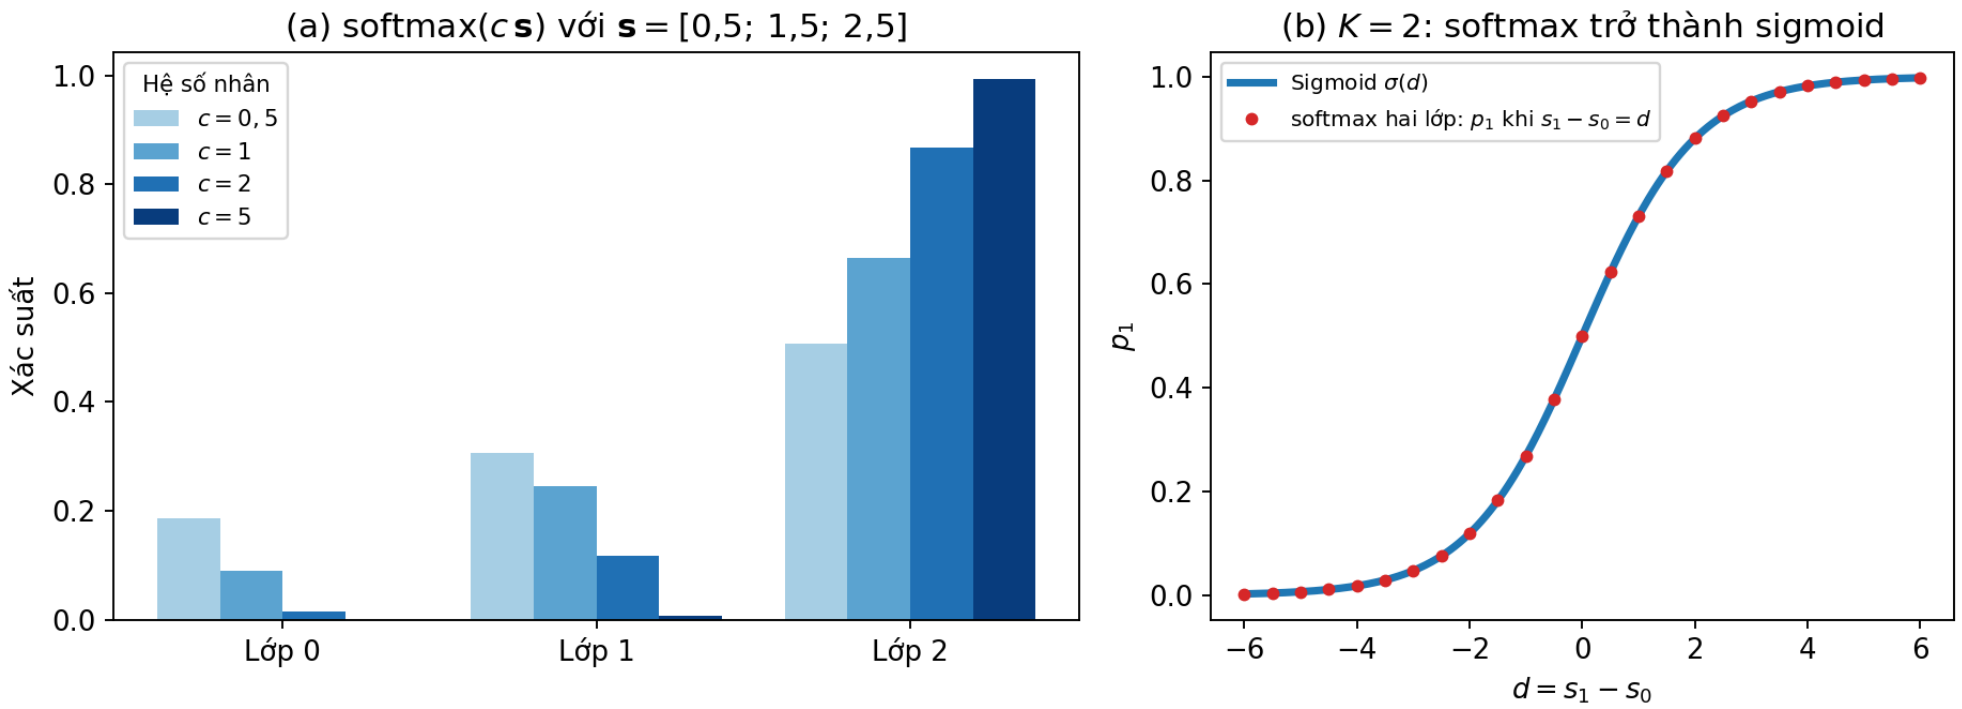
Đúng là Logistic Regression

Với vector tham số $\mathbf{w} = \mathbf{w}_1 - \mathbf{w}_0$ và $p_0 = 1 - p_1$. Softmax Regression bao hàm Logistic Regression.

Kiểm chứng bằng số

$s = (0{,}2; 1{,}7)$: softmax cho $p_1 = 0{,}8176$, đúng bằng $\sigma(1{,}7 - 0{,}2) = \sigma(1{,}5) = 0{,}8176$.

Hình 5. Độ lớn điểm số và trường hợp K = 2



(a) Hệ số nhân càng lớn thì xác suất càng dồn về lớp có điểm cao nhất. (b) Với K = 2, softmax chính là sigmoid của hiệu hai điểm số.

Đạo hàm của softmax

$$\partial p_k / \partial s_j = p_k(\mathbf{1}[k=j] - p_j)$$

k = j

$p_k(1 - p_k)$. Với K = 2 trở về $\sigma'(s) = \sigma(s)(1 - \sigma(s))$.

k ≠ j

$-p_k p_j$. Tăng điểm lớp j làm giảm xác suất lớp k.

Dạng ma trận Jacobian: $\text{diag}(p) - p^T p$. Mỗi hàng và mỗi cột cộng lại bằng 0, vì $\Sigma\, p_k = 1$ luôn đúng nên các xác suất tăng giảm bù trừ nhau. Đó là sự cạnh tranh giữa các lớp.

2.4. Biểu diễn vector và ma trận

Một mẫu

$s_i = x_i W$ (1 × K)

$p_i = \text{softmax}(s_i)$, $\hat{y}_i = \text{argmax}_k\, p_{ik}$

Toàn bộ n mẫu

S = XW, P = softmax(S) theo từng hàng

Mỗi hàng của P là một phân phối trên K lớp.

Đại lượng	X	W	S = XW	P	Y
Kích thước	n×(d+1)	(d+1)×K	n×K	n×K	n×K

Ví dụ từng bước cho sinh viên 6

Học 6 giờ, vắng 4 buổi: $\mathbf{x}_6 = (1, 6, 4)$, với W ở ví dụ trước.

$$\mathbf{s}_6 = \mathbf{x}_6 W = (-0{,}5;\ 0;\ -4{,}5)$$

$$\mathbf{p}_6 \approx (0{,}375;\ 0{,}618;\ 0{,}007) \Rightarrow \hat{y}_6 = 1\ (\text{đạt})$$

Dự đoán đúng với độ tin cậy vừa phải 61,8%: sinh viên này khá gần ranh giới lớp rớt (37,5%) vì học 6 giờ nhưng vắng tới 4 buổi.

Kết quả cho 9 sinh viên

SV	p_0	p_1	p_2	$\hat{y}$	y
1	0,971	0,029	0,000	0	0
2	0,817	0,182	0,000	0	0
3	0,924	0,076	0,000	0	0
4	0,178	0,798	0,024	1	1
5	0,024	0,798	0,178	1	1
6	0,375	0,618	0,007	1	1
7	0,000	0,182	0,817	2	2
8	0,000	0,029	0,971	2	2
9	0,000	0,182	0,817	2	2

Xác suất gán cho lớp thật

$$q_i = p_{i,y_i} = \sum_k y_{ik}\, p_{ik} \Leftrightarrow q = (Y \odot P)\cdot 1$$

Chọn đúng phần tử của P ở vị trí lớp thật nhờ ma trận one-hot Y. Với 9 sinh viên:

$q \approx (0{,}971;\ 0{,}817;\ 0{,}924;\ 0{,}798;\ 0{,}798;\ 0{,}618;\ 0{,}817;\ 0{,}971;\ 0{,}817)$

Tích các q_i

$\prod q_i \approx 0{,}187$: xác suất mô hình gán cho toàn bộ nhãn quan sát được.

Trung bình $-\ln q_i$

$\approx 0{,}186$. Càng gần 0 thì mô hình càng phù hợp. Đây là điểm xuất phát của hợp lý cực đại ở mục 3.

2.5. Vùng quyết định

Ranh giới lớp k và l: $s_k = s_l \Leftrightarrow x(w_k - w_l) = 0$

Vùng lớp k là giao của K − 1 nửa không gian $x(w_k - w_l) \geq 0$, nên là miền lồi. Với d = 2, ranh giới là đường thẳng.

Rớt | đạt

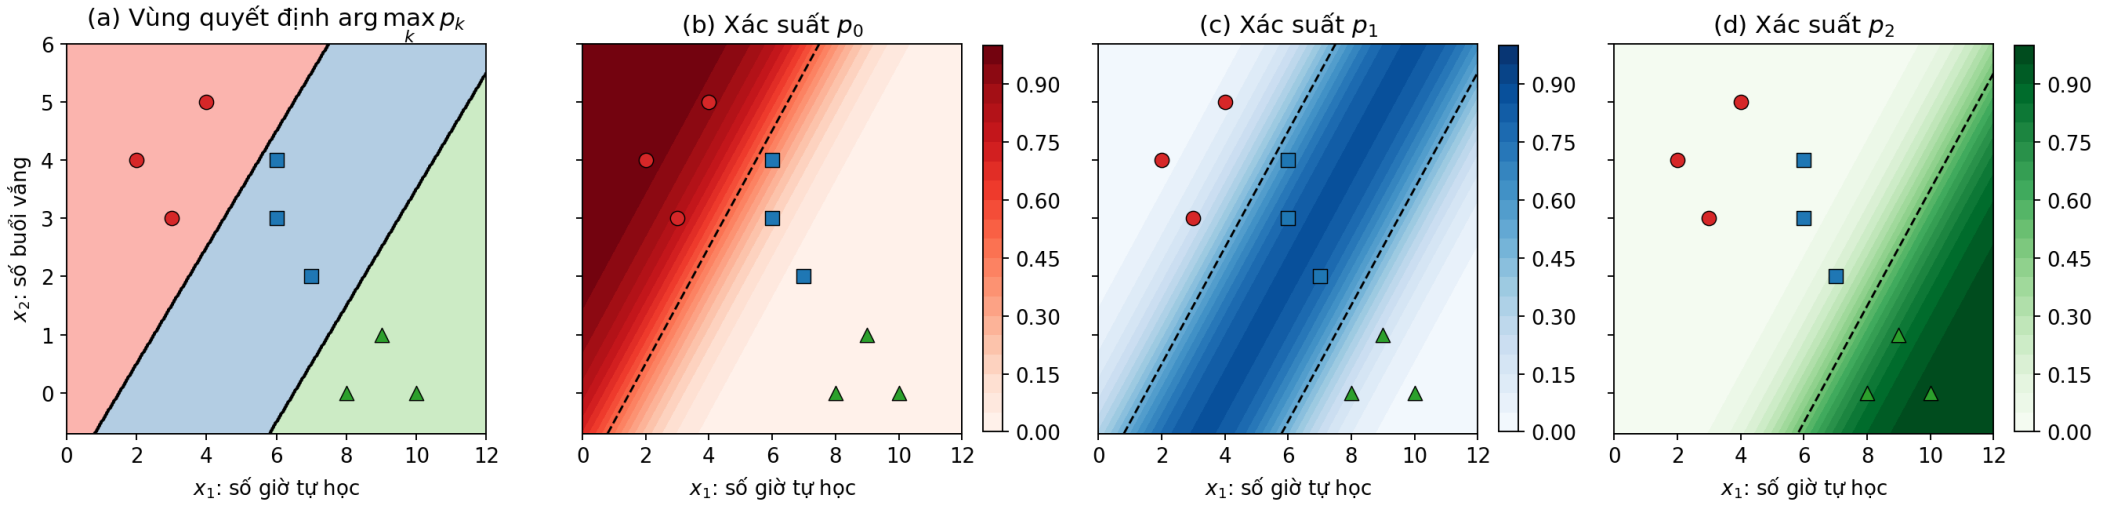
$s_0 = s_1 \Leftrightarrow x_1 - x_2 = 1{,}5$

Đạt | giỏi

$s_1 = s_2 \Leftrightarrow x_1 - x_2 = 6{,}5$

Lớp đạt là dải nằm giữa hai ranh giới, nên không bị che khuất như ở one-vs-rest.

Hình 6. Vùng quyết định và bản đồ xác suất



(a) Ba vùng quyết định ngăn cách bởi hai đường thẳng. (b), (c), (d) Bản đồ xác suất p_0, p_1, p_2; lớp đạt cao nhất ở dải giữa. Các điểm là 9 sinh viên.

Ý nghĩa của trọng số: odds ratio giữa hai lớp

x_j tăng 1 đơn vị ⇒ p_k/p_l được nhân với $e^{(w_{jk} - w_{jl})}$

Điều có ý nghĩa là hiệu giữa các trọng số của hai lớp, không phải từng trọng số riêng lẻ. Với W ở ví dụ:

Mỗi giờ học thêm

Nhân p_giỏi/p_đạt và p_đạt/p_rớt với $e \approx 2{,}718$.

Mỗi buổi vắng thêm

Nhân các tỉ số đó với $e^{-1} \approx 0{,}368$.

Kiểm chứng SV 6

p_giỏi/p_đạt = 0,0111 → học thêm 1 giờ: 0,0302 = 0,0111 × 2,718.

Tính dư thừa tham số

$W' = W + v1^T \Rightarrow \text{softmax}(XW') = \text{softmax}(XW)$

Cộng cùng vector v vào mọi cột: mọi điểm số của mẫu i bị dịch cùng $x_i v$. Hai ma trận khác nhau nhưng cùng một mô hình.

Chỉ K − 1 cột độc lập: (K−1)(d+1) tham số, ví dụ 6 thay vì 9. Với K = 2 chỉ còn d + 1, đúng bằng Logistic Regression.

Lớp tham chiếu: chọn $w_0 = 0$ thì $\ln(p_k/p_0) = x \cdot w_k$.

Chỉ các hiệu $w_k - w_l$ có ý nghĩa; một cột riêng lẻ thì không. Hệ quả: hàm mất mát không có nghiệm duy nhất, L2 sẽ chọn một nghiệm (mục 4.4).

Tóm tắt mục 2

Mô hình

K điểm số $s_k = \mathbf{x}\cdot\mathbf{w}_k$, W cỡ (d+1)×K, rồi softmax. **S = XW**, **P** = softmax(**S**). Softmax Regression = K hồi quy tuyến tính song song + softmax.

Softmax

Bất biến khi dịch, $p_k/p_l = e^{(s_k - s_l)}$, log-odds tuyến tính. K = 2 trở về sigmoid.

Hình học

Vùng mỗi lớp là giao của K − 1 nửa không gian, nên lồi. Lớp giữa được "kẹp" bởi hai ranh giới.

Trọng số

Ý nghĩa nằm ở hiệu $w_{jk} - w_{jl}$: nhân p_k/p_l với $e^{(w_{jk} - w_{jl})}$.

Dư thừa tham số

Cộng v vào mọi cột không đổi mô hình; chỉ (K−1)(d+1) tham số độc lập. Mất mát sẽ không có nghiệm duy nhất.

Câu hỏi kiểm tra nhanh (1/2)

1. Với **s** = (2, −1, 0,5), tính softmax. Lớp nào được dự đoán? Kiểm tra $\ln(p_0/p_2) = s_0 - s_2$.
2. Cộng 3 vào cả ba điểm số ở câu 1 thì các xác suất thay đổi thế nào? Giải thích.
3. K = 2, s = (1, 3): tính p_1 bằng softmax và bằng sigmoid. Vector w của Logistic Regression tính từ w_0, w_1 ra sao?
4. K = 4, d = 5: kích thước của W? Tổng số tham số và số tham số độc lập?

Câu hỏi kiểm tra nhanh (2/2)

1. d = 1, K = 3, $\mathbf{w}_0 = (0, 0)^T$, $\mathbf{w}_1 = (-1, 1)^T$, $\mathbf{w}_2 = (-3, 2)^T$. Tính xác suất tại x = 2. Điểm này nằm trên ranh giới của hai lớp nào?
2. Với W ở mục 2.2, học thêm 2 giờ (đặc trưng khác giữ nguyên) thì p_giỏi/p_đạt được nhân với bao nhiêu?
3. Chứng minh: cộng cùng vector v vào mọi cột của W thì P không đổi.
4. Vì sao one-vs-rest không "kẹp" được lớp ở giữa còn Softmax thì được? Mô tả vùng của một lớp trong từng mô hình.

Gợi ý đáp án (1/2)

1. $e^2 = 7{,}389$; $e^{-1} = 0{,}368$; e^0,5 = 1,649; tổng 9,406 ⇒ $\mathbf{p} \approx (0{,}786; 0{,}039; 0{,}175)$. Dự đoán lớp 0. $\ln(0{,}786/0{,}175) \approx 1{,}5 = 2 - 0{,}5$.
2. Không đổi: e^3 ở tử và mẫu triệt tiêu, softmax chỉ phụ thuộc hiệu các điểm số.
3. Softmax: $e^3/(e^1 + e^3) = 20{,}086/22{,}804 \approx 0{,}881$. Sigmoid: $\sigma(3 - 1) = \sigma(2) \approx 0{,}881$. $\mathbf{w} = \mathbf{w}_1 - \mathbf{w}_0$.
4. **W** cỡ 6 × 4; 24 tham số; độc lập: $(K-1)(d+1) = 3 \times 6 = 18$.

Gợi ý đáp án (2/2)

1. Tại x = 2: $\mathbf{s} = (0, 1, 1) \Rightarrow \mathbf{p} \approx (0{,}155; 0{,}422; 0{,}422)$. Nằm trên ranh giới lớp 1 và 2, vì $(\mathbf{w}_1 - \mathbf{w}_2) = (2, -1)$ và $2 - 1 \cdot 2 = 0$.
2. Nhân với $e^{(w_{12} - w_{11})} = e^1$ mỗi giờ, nên hai giờ nhân $e^2 \approx 7{,}389$.
3. $s'_{ik} = s_{ik} + \mathbf{x}_i\mathbf{v}$: mọi điểm số của mẫu i cộng cùng hằng số $c_i = \mathbf{x}_i\mathbf{v}$, nên $e^{(c_i)}$ triệt tiêu và $p'_{ik} = p_{ik}$.
4. One-vs-rest: vùng của lớp k là một nửa không gian, lớp giữa không thể là một nửa không gian. Softmax: vùng là giao của K − 1 nửa không gian, nên có thể là một dải giữa hai ranh giới.

Softmax Regression · Mục 3

Huấn luyện mô hình Softmax Regression

Hàm mất mát cross-entropy, gradient P − Y và thuật toán Gradient Descent.



Để máy tự tìm W từ dữ liệu

Mô hình + Hàm mất mát + Thuật toán tối ưu = Huấn luyện

Mô hình đã có ở mục 2. Mục này làm hai thành phần còn lại, trả lời ba câu hỏi:

1. Hàm mất mát

Đo sự phù hợp giữa K xác suất dự đoán và nhãn thật, có cơ sở xác suất ra sao?

2. Gradient

Gradient theo ma trận **W** là gì? Quy tắc cập nhật có còn gọn như Logistic Regression?

3. Thuật toán

Chạy ra sao? Tốc độ học, chuẩn hóa đặc trưng, cách chia dữ liệu ảnh hưởng thế nào?

3.1. Vì sao không dùng lại MSE?

$$l_i(\text{MSE}) = \|\mathbf{p}_i - \mathbf{y}_i\|^2 = \Sigma_k (p_{ik} - y_{ik})^2$$

Jacobian của softmax chứa các tích $p_k(1 - p_k)$ và $p_k p_j$, nên khi p gần một phân phối "chắc chắn" thì gradient gần 0.

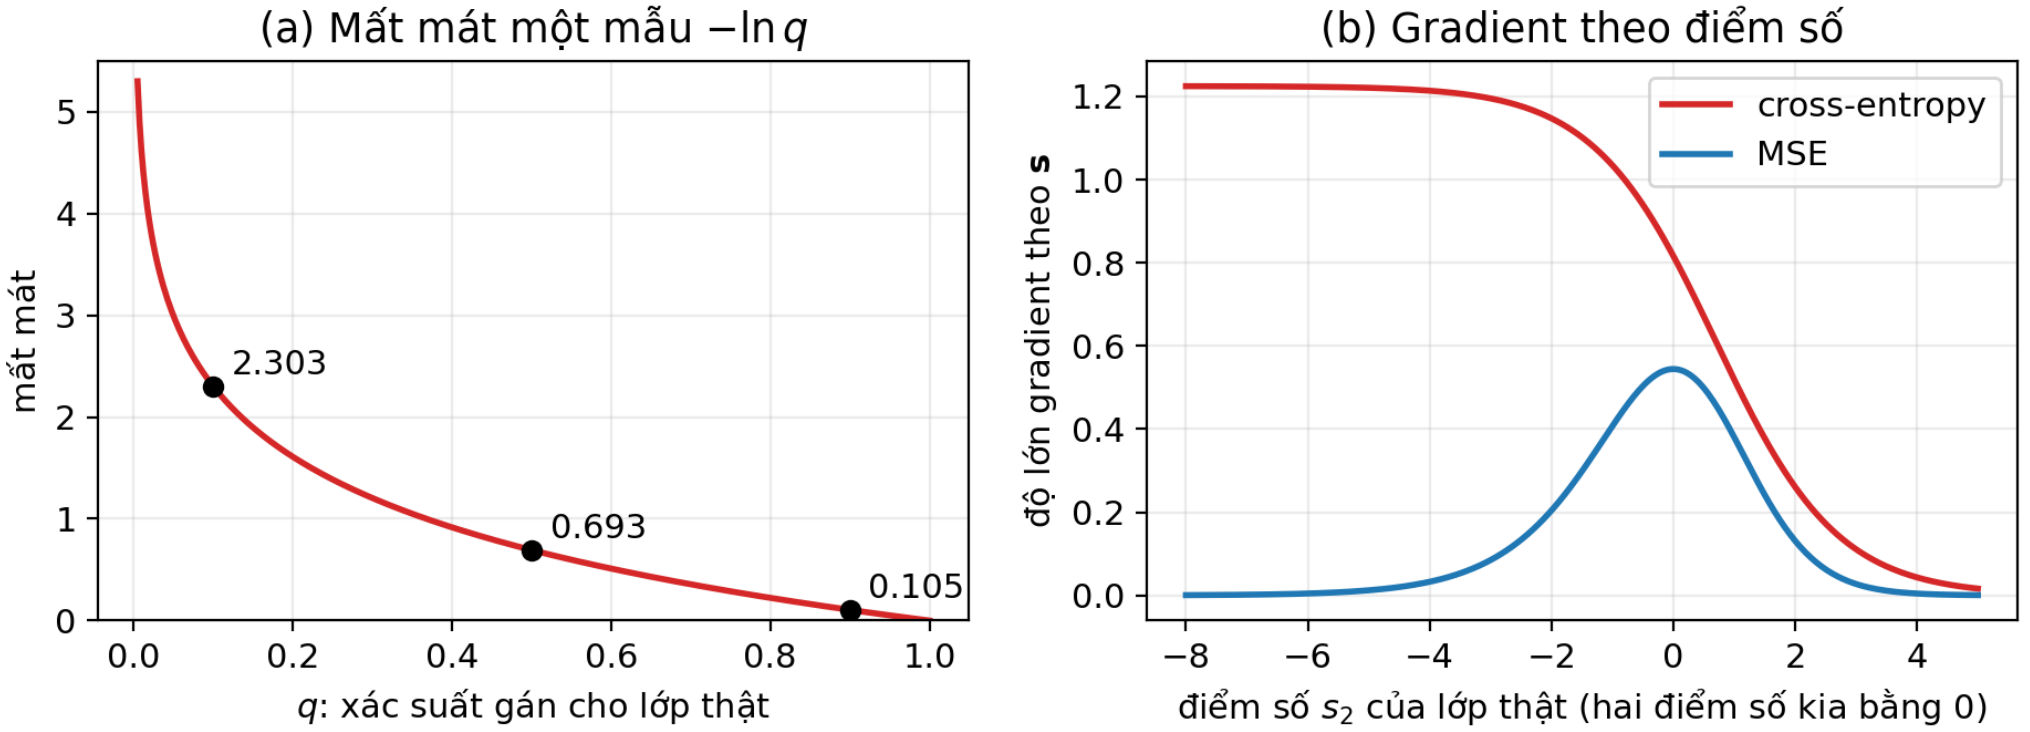
Ví dụ

Mẫu thuộc lớp 2, $\mathbf{y} = (0, 0, 1)$, nhưng điểm số $\mathbf{s} = (4, 0, -2)$ nên $\mathbf{p} \approx (0{,}980; 0{,}018; 0{,}002)$.

Hệ quả

$\|\mathbf{p} - \mathbf{y}\| \approx 1{,}398$ (sai rất nặng) nhưng gradient của MSE chỉ khoảng 0,056: gần như không học được từ mẫu sai nặng nhất.

Hình 7. Cross-entropy tránh được "gradient tắt"



(a) Mất mát một mẫu -ln q tiến tới vô cùng khi q → 0. (b) Mẫu lớp 2 có điểm số (0, 0, s_2): gradient cross-entropy lớn đúng khi mô hình sai nặng, còn gradient MSE tiến về 0.

Từ hai lớp lên K lớp

Hai lớp, viết đối xứng

$l_i = -y_i \ln p_i - (1 - y_i) \ln(1 - p_i) = -\Sigma_k\, y_{ik} \ln p_{ik}$, $k = 0, 1$

Dùng one-hot: hàng Y là $(1 - y_i, y_i)$, hàng P là $(1 - p_i, p_i)$. Không còn lớp nào "đặc biệt".

K lớp

$l_i = -\Sigma_k\, y_{ik} \ln p_{ik} = -\ln \mathbf{p_i c} = -\ln q_i$

y_i one-hot nên chỉ một số hạng khác 0, ứng với lớp thật c. q_i là xác suất mô hình gán cho lớp thật: $-\ln q$ là mức "ngạc nhiên".

Bảng quen thuộc: q = 0,99 → 0,010; q = 0,5 → 0,693; q = 0,01 → 4,605.

Hàm mất mát cross-entropy nhiều lớp

$$J(\mathbf{W}) = -(1/n)\,\Sigma_i\,\Sigma_k\, y_{ik} \ln p_{ik},\ \mathbf{P} = \text{softmax}(\mathbf{XW})$$

$$J(\mathbf{W}) = -(1/n)\cdot \mathbf{1}_n^T\,(\mathbf{Y} \odot \ln \mathbf{P})\,\mathbf{1}_K$$

$\odot$ là phép nhân từng phần tử, ln P lấy logarit từng phần tử. Mất mát chỉ phụ thuộc vào xác suất gán cho lớp thật.

Ba kiểm tra quen thuộc

K = 2

Trở về đúng cross-entropy nhị phân, vì $y_{i1} = y_i$ và $y_{i0} = 1 - y_i$.

W = 0

Mọi $p_{ik} = 1/K$, mỗi mẫu bị phạt ln K. Với K = 3: $J_0 = \ln 3 \approx 1{,}0986$. Dùng làm mốc kiểm tra cài đặt.

Ví dụ 9 sinh viên

W chọn tay ở mục 2.2 cho trung bình $-\ln q_i \approx 0{,}186 = J(\mathbf{W})$.

Sinh viên	1	2	3	4	5	6	7	8	9
q_i	0,971	0,817	0,924	0,798	0,798	0,618	0,817	0,971	0,817
$l_i = -\ln q_i$	0,030	0,202	0,079	0,226	0,226	0,481	0,202	0,030	0,202

Dạng log-sum-exp (dùng khi lập trình)

$$l_i = -s_i c + \ln \Sigma_j e^{(s_{ij})}$$

Vì $\ln p_{ik} = s_{ik} - \ln \Sigma_j e^{(s_{ij})}$. Khi cài đặt, trừ điểm số lớn nhất của hàng trước khi lấy mũ để không tràn số.

Nhờ dạng này không bao giờ phải tính ln 0, nên không cần np.clip như ở Logistic Regression.

3.2. Hợp lý cực đại cho phân phối nhiều lớp

Nhãn là biến phân phối loại

$q_i = P(\mathbf{y}_i \mid \mathbf{x}_i) = \Pi_k \, p_{ik}\hat{}(y_{ik})$

Tích chỉ còn một thừa số khác 1: p_ic của lớp thật. Với K = 2 trở về $p_i\hat{}y_i \, (1 - p_i)\hat{}(1-y_i)$.

Hàm hợp lý và log-hợp lý

$L(\mathbf{W}) = \Pi_i \, \Pi_k \, p_{ik}\hat{}(y_{ik})$

$\ln L(\mathbf{W}) = \Sigma_i \, \Sigma_k \, y_{ik} \ln p_{ik}$

$$\max L(\mathbf{W}) \Leftrightarrow \max \ln L(\mathbf{W}) \Leftrightarrow \min J(\mathbf{W}),\ J(\mathbf{W}) = -(1/n) \ln L(\mathbf{W})$$

Cross-entropy không phải lựa chọn tùy tiện: nó là âm log-hợp lý trung bình của mô hình phân phối loại.

So sánh vài bộ tham số trên 9 sinh viên

Bộ tham số	L(**W**)	ln L(**W**)	J(**W**)
W = 0 (mọi p = 1/3)	$\approx 5{,}1\cdot10^{-5}$	−9,888	1,099
$\mathbf{W}_{\text{tay}}$, bỏ số buổi vắng	$\approx 5{,}0\cdot10^{-4}$	−7,607	0,845
$\mathbf{W}_{\text{tay}}$, bỏ số giờ học	$\approx 4{,}1\cdot10^{-18}$	−40,04	4,449
$\mathbf{W}_{\text{tay}}$, đổi chỗ cột $\mathbf{w}_0$ và $\mathbf{w}_2$	$\approx 1{,}2\cdot10^{-26}$	−59,68	6,631
$\mathbf{W}_{\text{tay}}$	$\approx 0{,}187$	−1,676	0,186
$2 \cdot \mathbf{W}_{\text{tay}}$	$\approx 0{,}567$	−0,567	0,063

$\mathbf{W}_{\text{tay}}$ hợp lý hơn **W** = 0 khoảng 3700 lần. Đổi chỗ cột làm J tăng vọt. $2\cdot \mathbf{W}_{\text{tay}}$ có J nhỏ hơn vì 9 sinh viên phân loại đúng hoàn toàn (dữ liệu phân tách hoàn hảo, mục 4.4).

Mất mát không phụ thuộc cách đặt tên lớp

Hoán vị lớp

Hoán vị đồng thời các cột của **Y** và **W**: điểm số chỉ đổi vị trí, q_i không đổi, nên J không đổi.

Khác hồi quy trên nhãn số (96,7% hay 34,7% tùy cách đặt số ở mục 1.1).

Cộng v vào mọi cột

$J(\mathbf{W} + \mathbf{v}\mathbf{1}^T) = J(\mathbf{W})$ với mọi **v**.

J có những hướng "phẳng": nếu $\mathbf{W}^*$ là cực tiểu thì cả họ $\mathbf{W}^* + \mathbf{v}\mathbf{1}^T$ cũng là cực tiểu (sẽ phân tích ở mục 4.3).

3.3. Gradient của mất mát một mẫu

Chuỗi $\mathbf{W} \to s_{ij} \to p_{ik} \to l_i$, ba bước:

Bước 1

$\partial l_i / \partial p_{ik} = -y_{ik} / p_{ik}$

Bước 2

$\partial p_{ik} / \partial s_{ij} = p_{ik}(\mathbf{1}[k=j] - p_{ij})$. Cộng theo k, thừa số p_{ik} triệt tiêu mẫu số.

Bước 3

$s_{ij} = \mathbf{x}_i \mathbf{w}_j$ nên $\partial s_{ij} / \partial w_k = \mathbf{x}_i^T$ nếu j = k, bằng 0 nếu khác.

$\partial l_i / \partial s_i = \mathbf{p}_i - \mathbf{y}_i$, $\nabla_{\mathbf{W}} l_i = \mathbf{x}_i^T (\mathbf{p}_i - \mathbf{y}_i)$ cỡ $(d+1) \times K$

Thừa số $p(1-p)$ gây "gradient tắt" ở MSE đã bị triệt tiêu: gradient chỉ còn là sai số $\mathbf{p}_i - \mathbf{y}_i$.

Ví dụ gradient theo điểm số

Mẫu có **s** = (0,5; 1,5; 2,5), **p** ≈ (0,090; 0,245; 0,665), nhãn thật là lớp 1, y = (0, 1, 0):

$$l = -\ln 0{,}245 \approx 1{,}408,\ \mathbf{p} - \mathbf{y} \approx (0{,}090;\ -0{,}755;\ 0{,}665)$$

Phần tử âm duy nhất

Ở lớp đúng: tăng điểm số lớp 1 sẽ làm J giảm.

Hai phần tử dương

Tăng điểm số hai lớp kia làm J tăng. Lớp 2 đang bị gán 0,665 một cách sai nên có phần tử dương lớn nhất.

Gradient của hàm mất mát tổng

$$\nabla_{\mathbf{W}} J = (1/n) \Sigma_i \mathbf{x}_i^T(\mathbf{p}_i - \mathbf{y}_i) = (1/n)\, \mathbf{X}^T(\mathbf{P} - \mathbf{Y})$$

Kích thước

$\mathbf{X}^T$ cỡ (d+1)×n, $\mathbf{P} - \mathbf{Y}$ cỡ n×K, tích cỡ (d+1)×K khớp với $\mathbf{W}$.

Từng cột

$\nabla_{\mathbf{w}_k} J = (1/n)\, \mathbf{X}^T(\mathbf{p}_{:,k} - \mathbf{y}_{:,k})$: đúng gradient Logistic Regression của bài toán "lớp k hay không".

Khác ở chỗ $\mathbf{p}_{:,k}$ lấy từ softmax. Softmax là K bộ phân loại Logistic được gắn với nhau bằng mẫu số chung.

Quy tắc cập nhật: kéo và đẩy

$$\mathbf{W} \leftarrow \mathbf{W} - (\eta/n)\,\mathbf{X}^{\mathrm{T}}(\mathbf{P} - \mathbf{Y}) = \mathbf{W} + (\eta/n)\,\mathbf{X}^{\mathrm{T}}(\mathbf{Y} - \mathbf{P})$$

Lớp đúng ($y_{ik} = 1$)

Hệ số $1 - p_{ik} > 0$: cột w_k được kéo về phía $\mathbf{x}_i^{\mathrm{T}}$. Mô hình càng ít tin lớp đúng thì kéo càng mạnh.

Các lớp còn lại

Hệ số $-p_{ik} < 0$: cột w_k bị đẩy ra xa $\mathbf{x}_i^{\mathrm{T}}$. Lớp bị gán xác suất cao một cách sai bị đẩy mạnh nhất.

Mẫu đã đúng, chắc chắn

$\mathbf{p}_i \approx \mathbf{y}_i$ nên $\mathbf{p}_i - \mathbf{y}_i \approx \mathbf{0}$: gần như không đóng góp.

Phiên bản “mềm” của Perceptron nhiều lớp, đẩy mọi lớp sai theo trọng số p_{ik} và học cả từ mẫu đã đúng.

Tổng các cột của W không đổi

Vì sao

$(\mathbf{P} - \mathbf{Y})\mathbf{1}_K = 0$ vì mỗi hàng của **P** và **Y** cộng lại bằng 1. Suy ra $\nabla_{\mathbf{W}} J \cdot \mathbf{1}_K = 0$: mỗi hàng của gradient cộng lại bằng 0.

Phần "kéo" của lớp đúng bằng đúng tổng phần "đẩy" của các lớp còn lại. Khởi tạo $\mathbf{W} = \mathbf{0}$ thì $\Sigma_k \mathbf{w}_k = 0$ ở mọi bước.

So sánh quy tắc cập nhật

Mô hình	Cập nhật
Hồi quy tuyến tính	$\mathbf{w} \leftarrow \mathbf{w} - (2\eta/n)\, \mathbf{X}^T(\mathbf{X}\mathbf{w} - \mathbf{y})$
Logistic Regression	$\mathbf{w} \leftarrow \mathbf{w} - (\eta/n)\, \mathbf{X}^T(\sigma(\mathbf{X}\mathbf{w}) - \mathbf{y})$
Softmax Regression	$\mathbf{W} \leftarrow \mathbf{W} - (\eta/n)\, \mathbf{X}^T(\text{softmax}(\mathbf{X}\mathbf{W}) - \mathbf{Y})$

3.4. Vai trò của learning rate η

Đặc trưng đã chuẩn hóa, batch GD từ $\mathbf{W_0 = 0}$. J tối ưu ≈ 0,3730; $J_0 = \ln 3 \approx 1{,}0986$.

η	Sau 10 epoch	100 epoch	500 epoch	2000 epoch
0,01	1,061	0,846	0,608	0,464
0,1	0,843	0,528	0,406	0,375
0,5	0,600	0,405	0,374	0,373
1	0,520	0,383	0,373	0,373
2	0,455	0,375	0,373	0,373
5	0,394	0,373	0,373	0,373
10	0,408	0,405	0,405	0,405

Đọc bảng learning rate

η quá nhỏ (0,01)

J giảm rất chậm, sau 2000 epoch vẫn chưa tới mức tối ưu.

η vừa phải (0,5 đến 5)

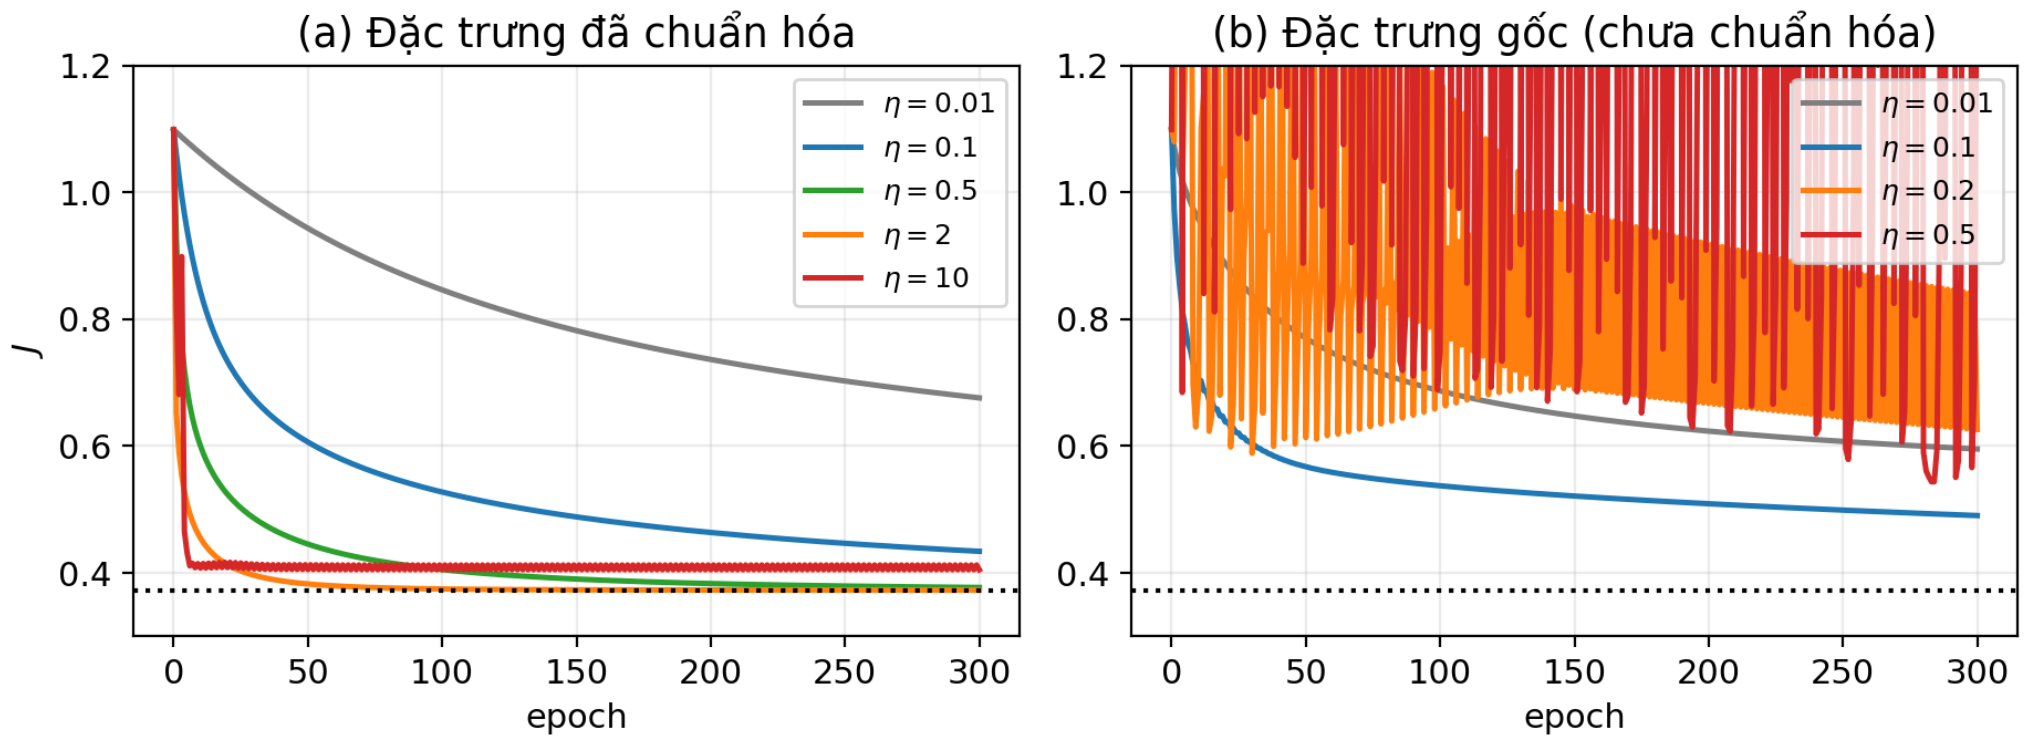
J giảm nhanh và hội tụ về ≈ 0,373.

η quá lớn (10)

Bước nhảy quá dài, **W** dao động; J dừng ở khoảng 0,405.

Cách nhận biết: vẽ J theo epoch. J tăng hoặc dao động mạnh thì giảm η; J giảm đều nhưng quá chậm thì tăng η.

Hình 8. Hàm mất mát J theo epoch với các η khác nhau



(a) Đặc trưng đã chuẩn hóa: η từ 0,5 đến 2 hội tụ nhanh, η = 0,01 chậm, η = 10 dao động. (b) Đặc trưng gốc: η phải nhỏ và hội tụ chậm hơn nhiều. Đường chấm là $J \approx 0{,}373$.

Vì sao cần chuẩn hóa đặc trưng

Thang đo lệch nhau (giờ học cỡ 0 đến hơn 10, buổi vắng 0 đến 6, cột 1) làm J thành thung lũng dài và hẹp. Điều kiện đủ để J giảm mỗi bước: $\eta < 4/\lambda_{max}$.

Đặc trưng	Giá trị riêng của $(1/n)\mathbf{X}^T\mathbf{X}$	Tỉ số lớn/nhỏ	$4/\lambda_{max}$
Gốc	0,069; 5,24; 53,5	khoảng 770	khoảng 0,075
Đã chuẩn hóa	0,46; 1,00; 1,54	khoảng 3,3	khoảng 2,6

η (đặc trưng gốc)	10 epoch	100 epoch	500 epoch	2000 epoch
0,001	1,073	0,958	0,771	0,624
0,01	0,957	0,687	0,568	0,509
0,1	0,706	0,537	0,465	0,400
0,5	4,912	0,750	0,706	0,889

Chuẩn hóa với $\eta = 0,5$ đạt 0,374 sau 500 epoch; đặc trưng gốc tốt nhất mới đạt 0,400 sau 2000 epoch.

Cách chuẩn hóa

$$z_{ij} = (x_{ij} - \mu_j) / \sigma_j,\ \mu_j = (1/n) \sum_i x_{ij},\ \sigma_j = \sqrt{((1/n) \sum_i (x_{ij} - \mu_j)^2)}$$

Không chuẩn hóa cột 1

Cột 1 là hằng số ($\sigma = 0$), đóng vai trò hệ số chệch.

Chỉ tính từ tập huấn luyện

Dùng đúng μ, σ đó cho tập kiểm tra. Nếu tính trên cả tập kiểm tra, thông tin của nó đã lọt vào huấn luyện.

Ví dụ: $\mu = (6{,}295; 2{,}394)$, $\sigma = (3{,}108; 1{,}685)$. Sinh viên học 10 giờ có $z_1 = (10 - 6{,}295)/3{,}108 \approx 1{,}192$.

3.5. Ba biến thể của Gradient Descent

Biến thể	Số mẫu mỗi lần cập nhật	Số lần cập nhật mỗi epoch
Batch GD	n (toàn bộ)	1
Stochastic GD (SGD)	1	n
Mini-batch GD	b (1 < b < n)	⌈n/b⌉

Một epoch là một lượt duyệt qua toàn bộ n mẫu. Với n = 420 và b = 32, mỗi epoch có ⌈420/32⌉ = 14 lần cập nhật (13 batch đủ 32 mẫu và một batch cuối 4 mẫu).

Batch

Hướng đi chính xác, đường cong mượt, nhưng chậm khi n lớn.

SGD

Mỗi bước rẻ, tiến nhanh, nhưng nhiễu và không hội tụ hẳn nếu η cố định.

Mini-batch

Dung hòa, tận dụng phép nhân ma trận. Phổ biến nhất.

Thuật toán Gradient Descent

Các bước

1. Khởi tạo $\mathbf{W} = \mathbf{0}$, cỡ $(d+1)\times K$.
2. Lặp $t = 1, \ldots, T_{max}$ (mỗi lần là một epoch):
3. Xáo trộn mẫu, chia thành các mini-batch.
4. Mỗi batch $\mathbf{B}$:
    1. $\mathbf{P_B} = \text{softmax}(\mathbf{X_B W})$;
    2. $\mathbf{G} = (1/b)\,\mathbf{X_B}^T(\mathbf{P_B} - \mathbf{Y_B})$;
    3. $\mathbf{W} \leftarrow \mathbf{W} - \eta\mathbf{G}$.
5. Nếu điều kiện dừng thỏa thì dừng.

Điều kiện dừng

- $\|\nabla_{\mathbf{W}} J\| < \varepsilon$ (chuẩn Frobenius).
- $J_t - J_{t-1}$ nhỏ hơn ngưỡng.
- Đạt số epoch tối đa T_{max} (luôn nên có).

Khởi tạo $\mathbf{W} = \mathbf{0}$ hợp lệ vì J lồi; các cột $\mathbf{w}_k$ vẫn phân hóa vì các cột của Y khác nhau. Với SGD và mini-batch, theo dõi J trên toàn bộ dữ liệu sau mỗi epoch.

3.6. Tính tay một vòng: bước 1 ($W_0 = 0$, $\eta = 0{,}1$)

Xác suất và mất mát

$\mathbf{W}_0 = \mathbf{0}$ nên $\mathbf{S} = \mathbf{0}$ và mọi $p_{ik} = 1/3$. $J(\mathbf{W}_0) = \ln 3 \approx 1{,}0986$.

$\mathbf{X}^T\mathbf{P}$ có mỗi cột là (3; 18,333; 7,333), vì bằng 1/3 tổng các cột của $\mathbf{X}$.

Gradient và cập nhật

Hàng chệch bằng 0 vì ba lớp cân bằng. Mỗi hàng của gradient cộng lại bằng 0.

$\mathbf{W}_1 \approx$ cột rớt (0; −0,1037; 0,0519), đạt (0; 0,0074; 0,0185), giỏi (0; 0,0963; −0,0704)

Dấu hợp lý: cột rớt có hệ số giờ học âm, buổi vắng dương; cột giỏi ngược lại. Mô hình bắt đầu học đúng chiều ta chọn tay ở mục 2.2.

Các bước tiếp theo của ví dụ tay

Bước t	J($\mathbf{W}_t$)	Đoán đúng
0	1,0986	–
1	0,9217	3 / 9
2	0,8159	
3	0,7429	
4	0,6872	
5	0,6437	
6	0,6082	9 / 9

Nhận xét 1

J giảm đều. Sau 6 bước 9/9 mẫu đúng dù J còn 0,608: xác suất chưa đủ chắc chắn nên thuật toán vẫn tiếp tục.

Nhận xét 2

Cả 9 mẫu đóng góp vào gradient ở mọi bước (khác Perceptron). Mỗi hàng của $\mathbf{W}_t$ cộng lại bằng 0.

3.7. Từ công thức sang Python (NumPy)

Ký hiệu toán	Trong mã Python
Ma trận đặc trưng: **X** (có cột 1)	Xb = them_bias(X)
Ma trận one-hot: **Y**	Y = one_hot(y, K)
S = XW	Xb @ W
P = softmax(**S**)	softmax(Xb @ W)
J(**W**)	mat_mat(Xb, Y, W)
Gradient: (1/n) $\mathbf{X}^T(\mathbf{P} - \mathbf{Y})$	Xb.T @ (P - Y) / n
Cập nhật: $\mathbf{W} \leftarrow \mathbf{W} - \eta\nabla\mathbf{J}$	W = W - eta * gradient(...)

So với Logistic Regression, mã chỉ khác ở hai chỗ: vector thành ma trận, sigmoid thành softmax.

Kiểm tra cài đặt trên 9 sinh viên

Khớp ví dụ tay

Sau 1, 2, 6 bước: J = 0,9217; 0,8159; 0,6082, đúng các $\mathbf{W}_1$, $\mathbf{W}_2$, $\mathbf{W}_6$ đã tính. J ban đầu = ln 3.

Đạo hàm số

So gradient giải tích với finite difference tại W ngẫu nhiên: sai khác tối đa $\approx 1{,}7 \cdot 10^{-10}$, xác nhận công thức $(1/n)\mathbf{X}^T(\mathbf{P} - \mathbf{Y})$.

```
def gradient(Xb, Y, W): P = softmax(Xb @ W); return Xb.T @ (P - Y) / len(Xb)
```

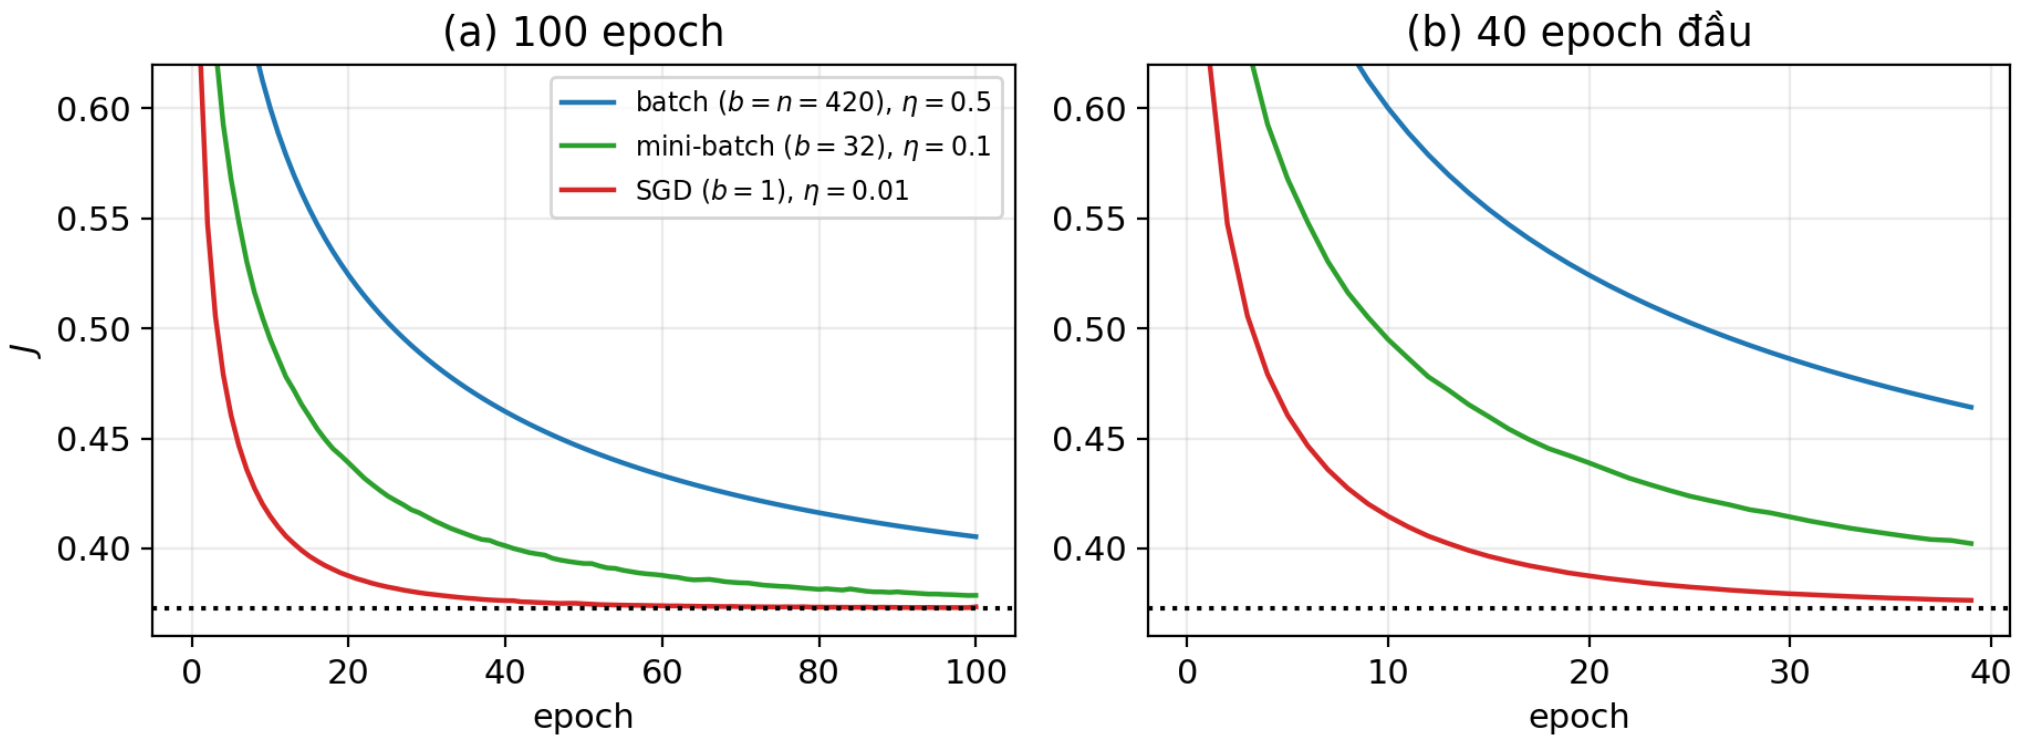
Huấn luyện trên 600 sinh viên

420 mẫu huấn luyện, 180 kiểm tra, đặc trưng chuẩn hóa, 200 epoch, J ban đầu = ln 3:

Biến thể	η	J cuối	Train	Test
Batch (b = 420)	0,5	0,3833	85,71%	85,00%
Mini-batch (b = 32)	0,1	0,3737	85,95%	85,56%
SGD (b = 1)	0,01	0,3730	85,95%	85,00%

Batch chưa hội tụ hẳn sau 200 epoch (cần khoảng 500), không phải "kém hơn". Chênh lệch 85,0% so với 85,6% chỉ là một mẫu trên 180.

Hình 9. J theo epoch của ba biến thể Gradient Descent



(a) 100 epoch; (b) 40 epoch đầu. Mini-batch và SGD thực hiện nhiều bước hơn mỗi epoch nên giảm nhanh hơn và dao động nhẹ; batch mượt nhưng chậm hơn. Đường chấm là $J \approx 0{,}373$.

Ma trận W sau huấn luyện (batch, 2000 epoch)

W (đặc trưng chuẩn hóa)

	rớt	đạt	giỏi
chệch	−1,29	1,80	−0,51
giờ học	−4,38	0,25	4,12
buổi vắng	1,37	−0,41	−0,96

$J = 0{,}373$; $\|\text{gradient}\| = 3{,}5 \cdot 10^{-5}$; tổng mỗi hàng của **W** bằng **0**.

Ma trận nhầm lẫn (kiểm tra)

thật \ đoán	0	1	2
0 (rớt)	49	11	0
1 (đạt)	9	48	3
2 (giỏi)	0	4	56

Chính xác 85,0%; lớp "đạt" nhận đúng 48/60 = 80,0%.

Giờ học tăng thì điểm lớp rớt giảm mạnh, lớp giỏi tăng mạnh, lớp đạt gần như không đổi: đúng trực giác. Chỉ hiệu $\mathbf{w}_2 - \mathbf{w}_0$ mới có ý nghĩa.

Tóm tắt mục 3

Hàm mất mát

MSE + softmax gây gradient tắt. Cross-entropy $J = -(1/n)\,\Sigma\, y_{ik} \ln p_{ik}$ là âm log-hợp lý trung bình; $J_0 = \ln K$; không phụ thuộc cách đặt tên lớp.

Gradient

$\partial l_i/\partial s_i = \mathbf{p}_i - \mathbf{y}_i$, $\nabla_{\mathbf{W}} J = (1/n)\,\mathbf{X}^{\mathrm{T}}(\mathbf{P} - \mathbf{Y})$. Kéo cột lớp đúng, đẩy các lớp còn lại; tổng các cột của **W** không đổi.

Siêu tham số

η quá nhỏ thì chậm, quá lớn thì dao động. Chuẩn hóa (μ, σ từ tập huấn luyện) cho phép η lớn hơn nhiều.

Biến thể

Batch chính xác nhưng chậm, SGD nhanh nhưng nhiễu, mini-batch dung hòa.

Kết quả

Tay: J = 1,0986 → 0,9217 → 0,8159. Mã NumPy khớp, gradient khớp đạo hàm số cỡ 10^{-10}; 600 sinh viên đạt 85,0% kiểm tra.

Câu hỏi kiểm tra nhanh (1/2)

1. K = 3, $\mathbf{p}$ = (0,2; 0,5; 0,3), nhãn thật lớp 2. Tính cross-entropy và gradient theo vector điểm số.
2. Hai mẫu độc lập có $q_1 = 0{,}8$ và $q_2 = 0{,}5$. Tính L, ln L và J (trung bình trên hai mẫu).
3. K = 10 và $\mathbf{W} = \mathbf{0}$: J bằng bao nhiêu? Độ chính xác trên tập cân bằng cỡ bao nhiêu?
4. d = 20, K = 10, n = 1000: kích thước $\mathbf{W}$ và ∇J? Số lần cập nhật mỗi epoch của batch, SGD, mini-batch b = 50?

Câu hỏi kiểm tra nhanh (2/2)

1. $\mathbf{x} = (1, 2, 1)$, nhãn lớp 1 ($K = 3$), $\mathbf{W} = \mathbf{0}$. Tính gradient $\mathbf{x}^{\mathrm{T}}(\mathbf{p} - \mathbf{y})$, một bước SGD với $\eta = 0{,}3$, rồi xác suất lớp 1 và mất mát mới.
2. Chứng minh $\nabla_{\mathbf{W}} J \cdot \mathbf{1}_K = 0$. Suy ra gì về tổng các cột của $\mathbf{W}$ khi khởi tạo $\mathbf{W} = \mathbf{0}$?
3. $\mu = 6{,}295$, $\sigma = 3{,}108$ (từ tập huấn luyện): chuẩn hóa sinh viên học 10 giờ. Vì sao không chuẩn hóa cột 1, và không tính μ, σ trên tập kiểm tra?
4. J tăng dần qua các epoch: có thể do nguyên nhân gì, cần làm gì?

Gợi ý đáp án (1/2)

1. $q = p_2 = 0{,}3$ nên $l = -\ln 0{,}3 \approx 1{,}204$. $p - y = (0{,}2; 0{,}5; -0{,}7)$, cộng lại bằng 0.
2. $L = 0{,}8 \times 0{,}5 = 0{,}4$; $\ln L \approx -0{,}916$; $J = -\ln L / 2 \approx 0{,}458$.
3. Mọi $p_k = 1/10$ nên $J = \ln 10 \approx 2{,}303$. Chọn lớp bất kỳ thì độ chính xác kỳ vọng 10%.
4. W và ∇J cỡ 21×10 (210 tham số). Batch: 1; SGD: 1000; mini-batch: $\lceil 1000/50 \rceil = 20$ lần mỗi epoch.

Gợi ý đáp án (2/2)

1. $p = (1/3, 1/3, 1/3)$, $p - y = (1/3, -2/3, 1/3)$. Sau một bước $s = (-0{,}6; 1{,}2; -0{,}6)$, $p \approx (0{,}124; 0{,}752; 0{,}124)$. Xác suất lớp 1 tăng từ 0,333 lên 0,752; mất mát giảm từ 1,099 xuống 0,286.
2. $(P - Y)1 = P1 - Y1 = 1 - 1 = 0$, nên W1_K không đổi qua các bước; khởi tạo $W = 0$ thì $\Sigma_k w_k = 0$ ở mọi bước.
3. $z = (10 - 6{,}295)/3{,}108 \approx 1{,}192$. Cột 1 là hằng số ($\sigma = 0$). Tính trên tập kiểm tra làm thông tin của nó lọt vào huấn luyện.
4. Thường do η quá lớn (giảm η, ví dụ chia 2 hoặc 10); hoặc chưa chuẩn hóa; hoặc lỗi gradient (kiểm tra bằng đạo hàm số và $J_0 = \ln K$). Với SGD, theo dõi J trên toàn bộ dữ liệu.

Softmax Regression · Mục 4

Phân tích cơ chế học của Softmax Regression

Mẫu sai tác động ra sao, nghiệm có duy nhất không, và mô hình tuyến tính không làm được gì?



Năm câu hỏi để hiểu cơ chế học

1. Mẫu sai

Cột nào của **W** bị kéo, cột nào bị đẩy, và mạnh đến mức nào?

2. Khởi tạo, η, thang đo

Chúng ảnh hưởng thế nào đến kết quả?

3. Hình dạng của J

J có lồi không? Kết quả có phải một ma trận **W** duy nhất?

4. Phân tách hoàn hảo

Điều gì xảy ra, và điều chuẩn hóa L2 giúp gì?

5. Giới hạn

Mô hình không làm được gì, khắc phục bằng cách nào?

Dữ liệu dùng lại: 600 sinh viên (420 huấn luyện, 180 kiểm tra), ma trận tối ưu **W*** ở mục 3.7, $J(\mathbf{W}^*) \approx 0{,}3730$.

4.1. Một mẫu đóng góp bao nhiêu vào gradient?

$$\|\nabla_W l_i\|_F = \|x_i\| \cdot \|p_i - y_i\|$$

$\nabla_W l_i = x_i^T(p_i - y_i)$ là tích ngoài (hạng một), nên chuẩn Frobenius bằng tích hai chuẩn:

$\|p_i - y_i\|$: mức sai của xác suất

Bằng 0 khi gán xác suất 1 cho lớp thật; không bao giờ vượt quá 2 (khi mọi xác suất dồn vào một lớp sai).

$\|x_i\|$: độ lớn đặc trưng

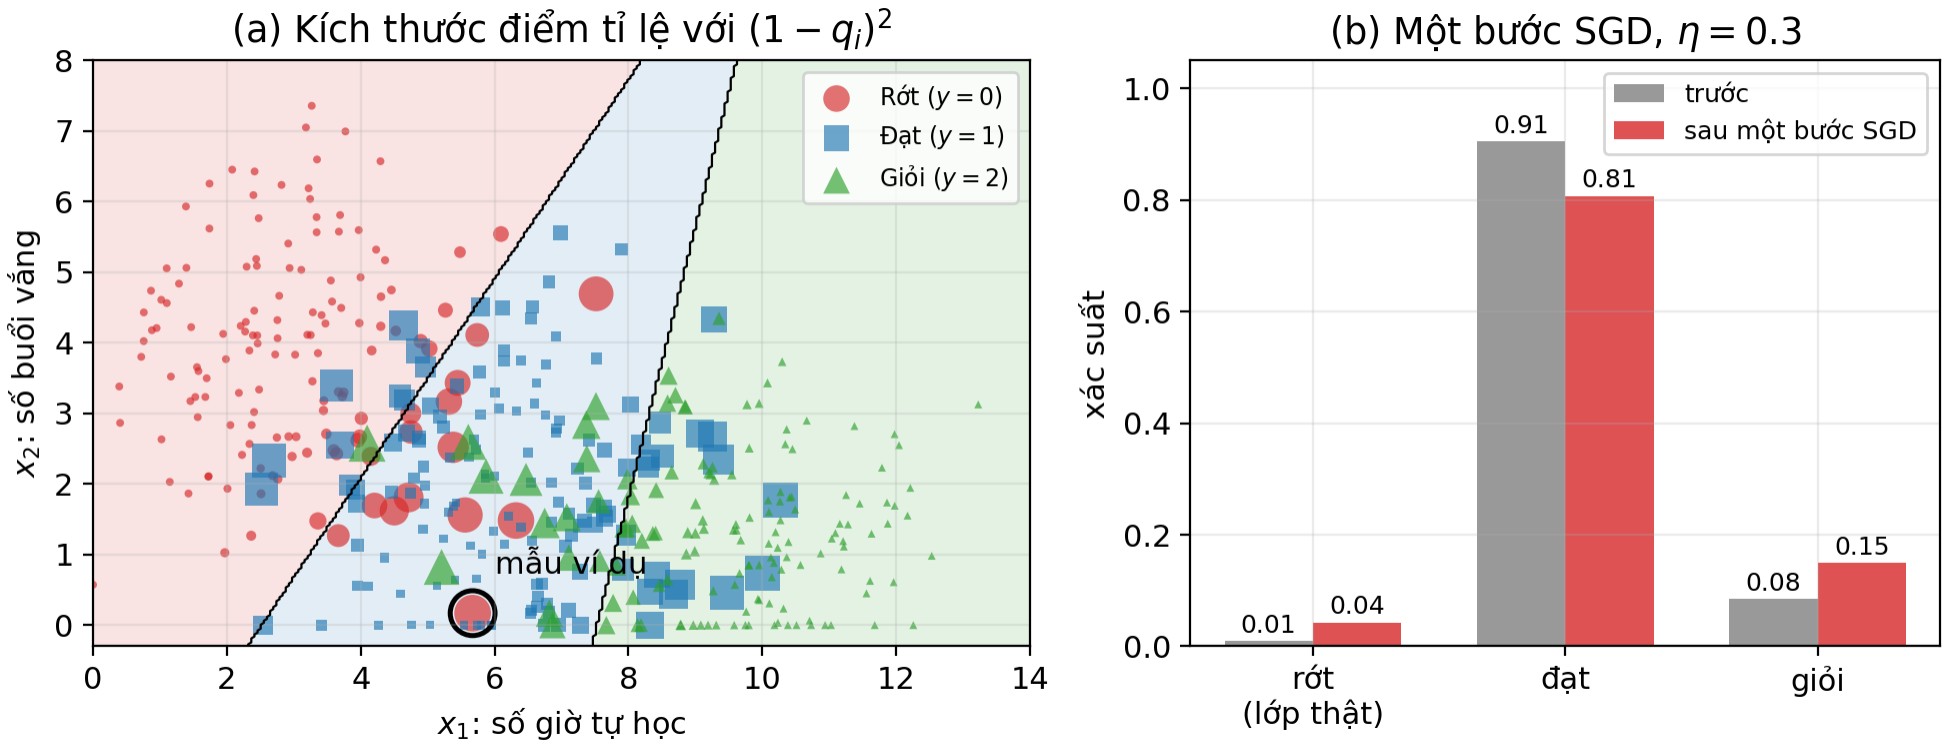
Mẫu nằm xa tâm dữ liệu sau chuẩn hóa thì kéo mạnh hơn.

Năm mẫu điển hình tại W*

Mẫu (x_1; x_2)	Lớp thật	p	‖p−y‖	‖x‖	‖∇l‖	Tình trạng
2,27; 4,16	rớt	0,992 0,008 0,000	0,012	1,94	0,023	Đúng, rất chắc
4,48; 2,59	đạt	0,451 0,544 0,005	0,641	1,16	0,746	Đúng nhưng sát biên
5,74; 4,11	rớt	0,381 0,602 0,017	0,863	1,44	1,242	Sai nhẹ, sát biên
5,67; 0,17	rớt	0,010 0,905 0,085	1,344	1,67	2,243	Sai nặng
10,00; 0,73	đạt	0,000 0,055 0,945	1,337	1,84	2,464	Sai nặng, xa tâm

58/420 mẫu bị đoán sai. Độ lớn gradient trung bình của nhóm sai là 1,423, gấp hơn 5 lần nhóm đúng (0,280).

Hình 10. Mức đóng góp và một bước SGD



(a) Kích thước điểm tỉ lệ với $1 - q_i^2$: các mẫu quanh đường biên và các mẫu sai ảnh hưởng nhất. (b) Xác suất của mẫu lớp rớt bị đoán thành đạt, trước và sau một bước SGD ($\eta = 0,3$).

Kéo lớp đúng, đẩy các lớp còn lại

Một bước SGD theo mẫu i, lớp thật c: $\mathbf{W}' = \mathbf{W} - \eta\, \mathbf{x}_i^T(\mathbf{p}_i - \mathbf{y}_i)$. Theo từng cột:

$$\mathbf{w}_c' = \mathbf{w}_c + \eta(1 - p_{ic})\, \mathbf{x}_i^T \text{ (kéo)};\quad \mathbf{w}_k' = \mathbf{w}_k - \eta\, p_{ik}\, \mathbf{x}_i^T \text{ (đẩy, } k \neq c)$$

$$s_i' = s_i + \eta\, \|\mathbf{x}_i\|^2\, (\mathbf{y}_i - \mathbf{p}_i)$$

Lớp đúng

Điểm tăng $\eta\|\mathbf{x}\|^2(1 - p_{ic})$, tỉ lệ với mức mô hình chưa tin lớp đúng.

Mỗi lớp sai

Điểm giảm $\eta\|\mathbf{x}\|^2 p_{ik}$: lớp đang "thắng sai" bị đẩy mạnh nhất.

Tổng thay đổi

$\Sigma_k(y_{ik} - p_{ik}) = 0$: độ tăng bằng tổng độ giảm.

Ví dụ một bước SGD (η = 0,3)

Mẫu (5,67; 0,17): lớp thật là rớt nhưng mô hình tin chắc là đạt. Sau chuẩn hóa $\mathbf{x} = (1; -0{,}2006; -1{,}3205)$, $\|\mathbf{x}\|^2 \approx 2{,}784$.

	rớt (đúng)	đạt	giỏi
s trước	−2,222	2,296	−0,073
p trước	0,010	0,905	0,085
Δs	+0,827	−0,756	−0,071
s sau	−1,396	1,540	−0,144
p sau	0,043	0,807	0,150

Mất mát giảm từ 4,618 xuống 3,149. Xác suất lớp giỏi vẫn tăng dù điểm giảm, vì lớp đạt giảm nhiều hơn. J toàn tập tăng 0,3730 → 0,3923: lý do SGD dao động quanh điểm tối ưu.

So với Perceptron nhiều lớp

	Perceptron nhiều lớp	Softmax Regression
Khi nào cập nhật	Chỉ khi mẫu sai	Mọi mẫu, theo $\mathbf{p}_i - \mathbf{y}_i$
Lớp đúng	Kéo cố định $\eta \cdot \mathbf{x}_i^T$	Kéo $\eta(1 - p_i c) \cdot \mathbf{x}_i^T$, đổi liên tục theo mức sai
Lớp sai	Đẩy đúng một cột (lớp bị chọn nhầm)	Đẩy mọi cột theo trọng số p_{ik}
Mẫu đúng nhưng chưa chắc	Bỏ qua	Tiếp tục cải thiện, đẩy mẫu xa các đường biên

4.2. Chuẩn hóa: số epoch để J cách J* không quá 0,001

η	Đặc trưng gốc	Đặc trưng đã chuẩn hóa
0,01	> 40000	24569
0,05	16341	4912
0,1	8170	2455
0,2	dao động	1227
0,5	dao động	490
1	dao động	244
2	dao động	121
5	dao động	45
10	dao động	dao động

Cùng η, chuẩn hóa nhanh hơn khoảng 3,3 lần và chịu được η lớn hơn nhiều. Cấu hình tốt nhất cần 45 epoch so với 8170 (khoảng 180 lần).

Chuyển ngược về thang đo gốc

Chuẩn hóa chỉ đổi cách đi đến nghiệm, không đổi mô hình. Cho điểm số không đổi, $1 \cdot z \cdot \mathbf{W}' = 1 \cdot x \cdot \mathbf{W}$:

$$w_{jk} = w'_{jk} / \sigma_j,\ w_{0k} = w'_{0k} - \sum_j \mu_j w_{jk}$$

W gốc	rớt	đạt	giỏi
chệch	5,633	1,876	−7,509
giờ học	−1,409	0,081	1,328
buổi vắng	0,813	−0,244	−0,569

Mỗi giờ học thêm làm điểm lớp rớt giảm 1,409 và điểm lớp giỏi tăng 1,328. Hai ma trận cho điểm số XW trùng nhau đến cỡ 10^{-15}.

Khởi tạo: P giống nhau, W khác nhau

Khởi tạo	$J(\mathbf{W}_0)$	J cuối	$\max\lvert \mathbf{P} - \mathbf{P}^* \rvert$	Hàng chệch của **W** cuối
0	1,099	0,373000	0	(−1,292; 1,804; −0,512)
W_{A0}	6,461	0,373000	$2 \cdot 10^{-15}$	(−0,959; 2,138; −0,178)
W_{B0}	0,718	0,373000	$6 \cdot 10^{-16}$	(−0,292; 2,804; 0,488)

Công thức

$\mathbf{W}_\infty = \mathbf{W}^*_{\text{tâm}} + \mathbf{v}_0\mathbf{1}^T$, với $\mathbf{v}_0 = \mathbf{W}_0\mathbf{1}/K$ là trung bình mỗi hàng của khởi tạo. $\mathbf{W}^*_{\text{tâm}}$ là nghiệm có các hàng cộng lại bằng 0.

Ý nghĩa

Khởi tạo chỉ ảnh hưởng số bước và thành phần "vô hình" $\mathbf{v}_0\mathbf{1}^T$, không ảnh hưởng mô hình. Khác Logistic Regression, W không duy nhất.

W = 0 không làm các cột giống nhau mãi: các cột của Y khác nhau nên mỗi cột nhận một gradient khác.

4.3. Ma trận Hessian

$$\mathbf{H}(\mathbf{W}) = (1/n)\,\Sigma_i\, \mathbf{A}_i \otimes \mathbf{x}_i^T\mathbf{x}_i,\ \mathbf{A}_i = \mathrm{diag}(\mathbf{p}_i) - \mathbf{p}_i^T\mathbf{p}_i$$

Các thành phần

$\mathbf{A}_i$ cỡ K×K là Jacobian của softmax; $\mathbf{x}_i^T\mathbf{x}_i$ cỡ (d+1)×(d+1). $\mathbf{H}$ cỡ (d+1)K × (d+1)K, ghép bằng tích Kronecker.

Kiểm tra K = 2

Với $\mathbf{w} = \mathbf{w}_1 - \mathbf{w}_0$, trở về Hessian $(1/n)\mathbf{X}^T\mathbf{S}\mathbf{X}$ của Logistic Regression, vì $\mathbf{A}_i$ có phần tử $p_i(1 - p_i)$.

J là hàm lồi

Lấy hướng $\mathbf{Z}$ bất kỳ cùng cỡ $\mathbf{W}$, đặt $\mathbf{u}_i = \mathbf{x}_i\mathbf{Z}$ (vector hàng 1×K):

$$\text{vec}(\mathbf{Z})^T H \, \text{vec}(\mathbf{Z}) = (1/n) \, \Sigma_i \left[\Sigma_k \, p_{ik} \, u_{ik}^2 - (\Sigma_k \, p_{ik} \, u_{ik})^2 \right] \geq 0$$

Phương sai

Biểu thức trong ngoặc là phương sai của u_{ik} khi chọn lớp k theo phân phối $\mathbf{p}_i$, nên không âm.

Hệ quả

H nửa xác định dương, J lồi: mọi cực tiểu địa phương là toàn cục, GD với η phù hợp hội tụ từ mọi khởi tạo.

Nhưng Hessian suy biến

Phương sai bằng 0 khi u_{ik} là hằng số theo k. Điều đó xảy ra với $\mathbf{Z} = \mathbf{v}\mathbf{1}^T$ (cộng cùng vector **v** vào mọi cột):

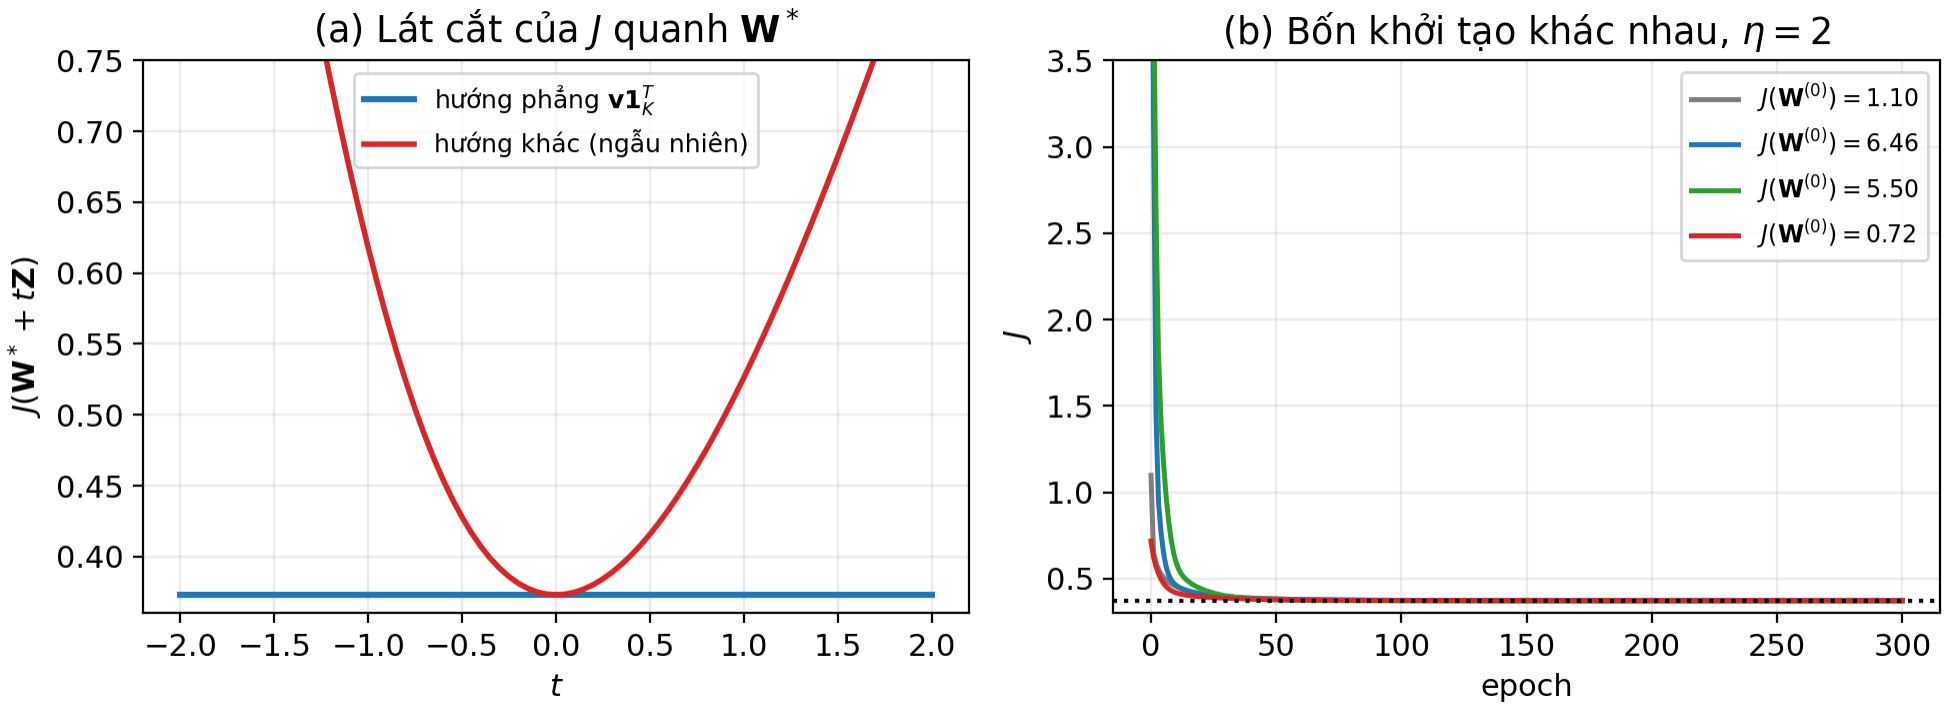
$$\mathbf{H}\,\mathrm{vec}(\mathbf{v}\mathbf{1}^T) = \mathbf{0} \text{ với mọi } \mathbf{v}\text{: } \dim\ker \mathbf{H} = d + 1,\ \mathrm{rank}\,\mathbf{H} = (K-1)(d+1)$$

Ví dụ d = 2, K = 3 tại **W***: 9 trị riêng là

0; 0; 0; 0,0058; 0,0135; 0,0295; 0,0738; 0,1333; 0,2286

Đúng d + 1 = 3 trị riêng bằng 0 (cỡ 10^{-17}) và (K − 1)(d + 1) = 6 trị riêng dương.

Hình 11. Thung lũng phẳng và nhiều khởi tạo



(a) Dọc hướng **v1**ᵀ, J không đổi (đường phẳng); dọc hướng ngẫu nhiên khác, J tăng dạng parabol. (b) GD từ bốn khởi tạo khác nhau (η = 2) đều hội tụ về J ≈ 0,373 dù W cuối khác nhau.

Hệ quả của Hessian suy biến

Thung lũng phẳng

W* + **v1**^{T} đều là cực tiểu, nên W không duy nhất. Nhưng P, J và dự đoán như nhau: về mô hình đó là một nghiệm.

GD không bị ảnh hưởng

Vì **∇J·1** = 0, gradient vuông góc với mọi hướng phẳng; thành phần đó bị "đóng băng" ở giá trị khởi tạo.

Đọc W theo hiệu cột

Trọng số −1,409 của cột rớt chỉ có nghĩa khi so với 0,081 (đạt) và 1,328 (giỏi).

Bỏ dư thừa

Cố định $w_0 = 0$, hoặc thêm L2, hoặc khởi tạo **W = 0**. Với $w_0 = 0$, Hessian thu gọn cỡ 6 có mọi trị riêng dương (0,0020 đến 0,2265).

Điều kiện tối ưu có ý nghĩa gì?

$$\Sigma_i (p_{ik} - y_{ik})\, \mathbf{x}_i = \mathbf{0} \text{ với mọi lớp } k$$

Thành phần cột 1

$(1/n)\,\Sigma_i\, p_{ik} = (1/n)\,\Sigma_i\, y_{ik}$: trung bình xác suất dự đoán của mỗi lớp bằng đúng tỉ lệ lớp. Ở đây cả hai bằng 140/420 = 0,3333.

Các thành phần còn lại

$\Sigma_i\, p_{ik}\, x_{ij} = \Sigma_i\, y_{ik}\, x_{ij}$. Với giờ học, cả hai vế cho (−149,28; −1,08; 150,36). Mô hình đã “khớp mô-men”.

Độ cong quyết định tốc độ và độ ổn định

Gần nghiệm, GD hội tụ khi $|1 - \eta\lambda| < 1$ với mọi trị riêng dương: $\eta < 2/\lambda_{max}$. Số điều kiện $\kappa = \lambda_{max}/\lambda_{min^+}$ đo độ "dài hẹp" của thung lũng.

	Đặc trưng gốc	Đã chuẩn hóa
λ_{max}	10,05	0,2286
λ_{min^+}	0,0021	0,0058
Số điều kiện κ	khoảng 4880	khoảng 39
Ngưỡng $2/\lambda_{max}$	khoảng 0,199	khoảng 8,75

Khớp thực nghiệm: $\eta = 0{,}1$ hội tụ, 0,2 dao động (gốc); $\eta = 5$ hội tụ, 10 dao động (chuẩn hóa). Chuẩn hóa giảm κ hơn 120 lần.

Logistic Regression và Softmax Regression

	Logistic Regression	Softmax Regression
Tham số	vector $\mathbf{w}$, d + 1 phần tử	ma trận $\mathbf{W}$, (d+1)×K
Hessian	$(1/n)\mathbf{X}^T\mathbf{S}\mathbf{X}$, xác định dương nếu $\mathbf{X}$ đủ hạng	$(1/n)\Sigma\mathbf{A}_i \otimes \mathbf{x}_i^T\mathbf{x}_i$, nửa xác định dương, suy biến
Tính lồi	Lồi	Lồi
Nghiệm	Duy nhất	$\mathbf{P}$ duy nhất; $\mathbf{W}$ xác định sai khác $\mathbf{v1}^T$
Theo khởi tạo	Không phụ thuộc	$\mathbf{P}$ không phụ thuộc; $\mathbf{W}$ phụ thuộc qua $\mathbf{v}_0$
Ổn định	$\eta < 2/\lambda max$	$\eta < 2/\lambda max$ (trên các trị riêng dương)

Nhiều hơn hai lớp không làm mất tính lồi, nhưng chuyển tính "duy nhất" từ W sang P: cái giá của dư thừa tham số.

4.4. Dữ liệu phân tách hoàn hảo

Lề của mẫu i: $m_i = s_{i,y_i} - \max_{j \neq y_i} s_{ij}$. Nếu $\mathbf{W}^\circ$ đúng mọi mẫu (mọi $m_i > 0$), nhân $\mathbf{W}^\circ$ với $c > 0$ nhân mọi lề với c:

$$l_i(c\mathbf{W}^\circ) \leq \ln(1 + (K-1)\, e^{(-c\, m_i)}) \to 0 \text{ khi } c \to \infty$$

$J \to 0$ nhưng không bằng 0

$l_i > 0$ với mọi c: không tồn tại cực tiểu hữu hạn. Muốn J nhỏ hơn thì $\mathbf{W}$ phải lớn hơn.

Tính lồi vẫn đúng

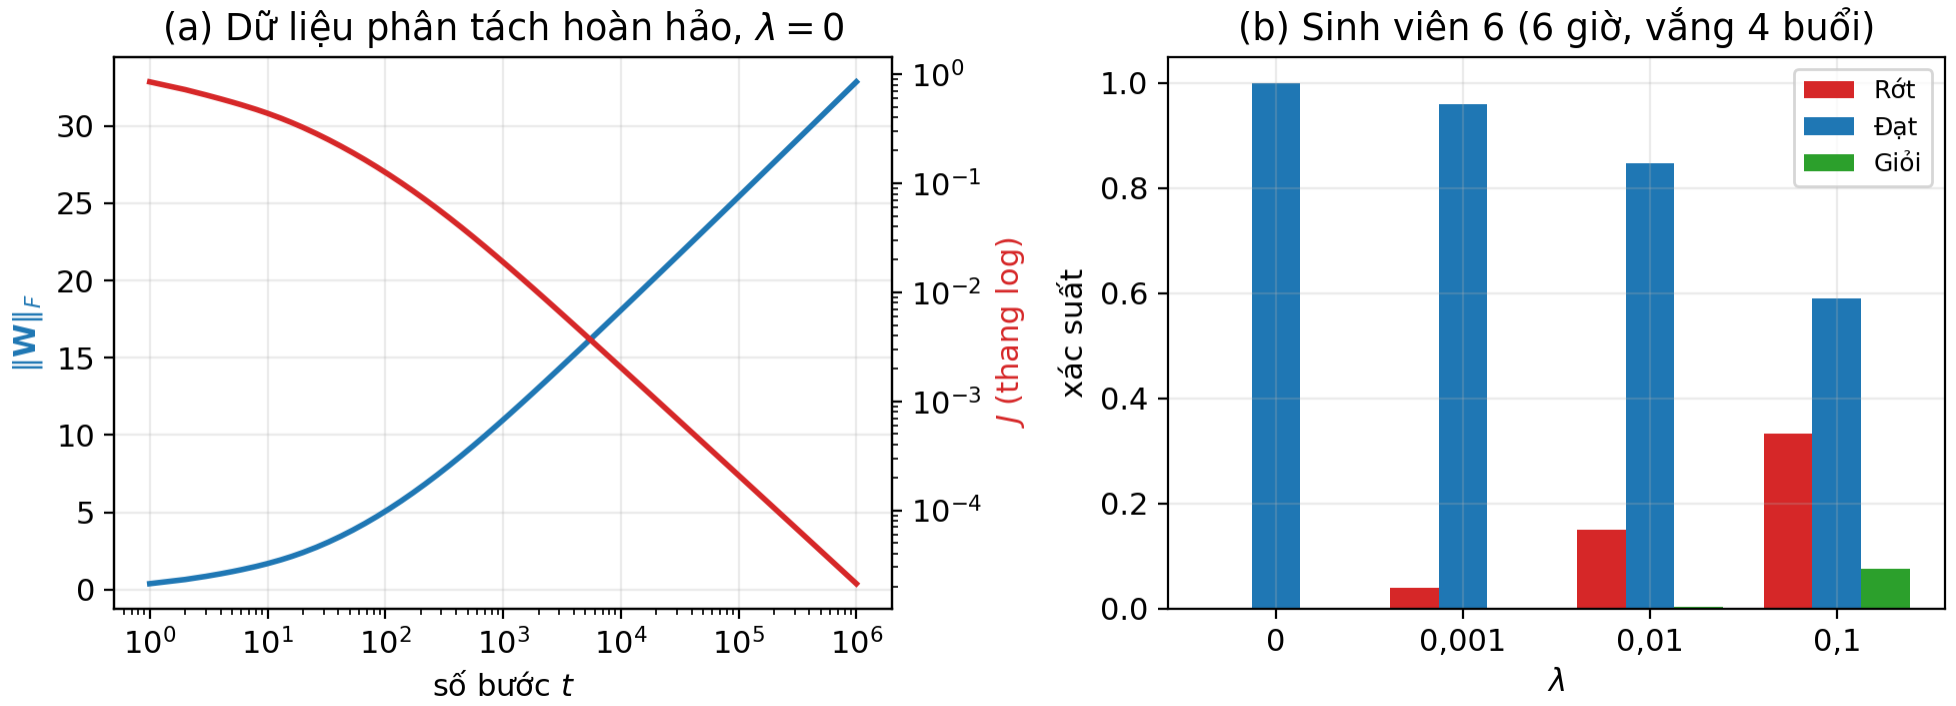
Chỉ là "đáy thung lũng" nằm ở vô cực. Dữ liệu 9 sinh viên là ví dụ.

Chạy GD lâu trên 9 sinh viên (η = 0,5)

Số bước t	$\|\mathbf{W}\|_F$	J	Lề nhỏ nhất
10	1,68	$4{,}4\cdot10^{-1}$	−0,128
100	5,06	$1{,}3\cdot10^{-1}$	1,056
1000	10,98	$1{,}9\cdot10^{-2}$	2,911
10^4	18,07	$2{,}0\cdot10^{-3}$	5,173
10^5	25,42	$2{,}1\cdot10^{-4}$	7,477

Từ bước 100 mọi mẫu đã đúng nhưng thuật toán không dừng: $\|\mathbf{W}\|_F$ tăng khoảng 7 đơn vị mỗi khi t nhân 10 (tăng cỡ log t), J giảm cỡ 1/t mà không bao giờ về 0.

Hình 12. Phân tách hoàn hảo và điều chuẩn hóa L2



(a) Với λ = 0, $\|\mathbf{W}\|_F$ (xanh, trục trái) tăng không ngừng theo log số bước, J (đỏ, trục phải) giảm mà không đạt 0. (b) Với L2, xác suất của sinh viên 6 dè dặt hơn khi λ tăng.

Hệ quả khi $W \to \infty$

Xác suất cực đoan

Softmax rất "nhọn": sinh viên 6 (sát ranh giới) được gán $p_đạt \approx 1{,}000$ sau 10^5 bước, trong khi ở ma trận chọn tay chỉ 0,618.

Không có điểm dừng tự nhiên

Chỉ dừng vì Tmax hoặc ε ta đặt. Dừng sớm vô hình trung là một dạng điều chuẩn hóa.

Phụ thuộc điều kiện dừng

Không có nghiệm hữu hạn để các bộ giải cùng hướng tới. Dễ gặp hơn khi nhiều đặc trưng hoặc thêm đa thức.

Điều chuẩn hóa L2 (weight decay)

$$J_\lambda(\mathbf{W}) = J(\mathbf{W}) + (\lambda/2)\|\tilde{\mathbf{W}}\|_F^2,\ \mathbf{W} \leftarrow (\mathbf{I} - \eta\lambda\mathbf{D}_0)\mathbf{W} - \eta\cdot(1/n)\mathbf{X}^T(\mathbf{P} - \mathbf{Y})$$

$\tilde{\mathbf{W}}$ là $\mathbf{W}$ bỏ hàng chệch; $\mathbf{D}_0 = \mathrm{diag}(0, 1, \ldots, 1)$. Mỗi bước, trọng số bị co một hệ số $1 - \eta\lambda$.

Nghiệm hữu hạn

J_λ vẫn lồi và có cực tiểu hữu hạn kể cả khi phân tách hoàn hảo.

Chọn nghiệm căn giữa

Phạt nhỏ nhất khi các cột có trung bình bằng 0, nên L2 khử phần lớn dư thừa. Hàng chệch không bị phạt.

Xác suất dè dặt

λ càng lớn, W càng nhỏ, xác suất càng bớt cực đoan.

L2 trên 9 sinh viên: xác suất sinh viên 6

λ	$\lVert\tilde{W}\rVert_F$	p (rớt, đạt, giỏi)
0	23,00 (vẫn tăng)	0,000 1,000 0,000
0,001	9,08	0,040 0,960 0,000
0,01	4,68	0,150 0,846 0,004
0,1	1,81	0,334 0,589 0,077

Với λ = 0,1, xác suất gần với ma trận chọn tay ở mục 2.2 (0,618 cho lớp đạt).

Đánh đổi khi chọn λ (600 sinh viên)

λ	$\|\tilde{W}\|_F$	Acc huấn luyện	Acc kiểm tra	Log-loss kiểm tra
0	6,26	86,2%	85,0%	0,354
0,001	5,61	86,2%	85,6%	0,358
0,01	3,66	85,7%	85,0%	0,407
0,1	1,54	82,4%	80,0%	0,591
1	0,43	74,1%	73,3%	0,884

λ rất nhỏ gần như không đổi gì; λ lớn làm mô hình bị “bó”, xác suất bị kéo về 1/3. Chọn λ trên tập kiểm định riêng (mục 5). scikit-learn dùng C, tương đương λ = 1/(Cn).

4.5. Vùng quyết định luôn lồi

$$R_k = \cap_{j \neq k} \{ x : x(w_k - w_j) \geq 0 \}$$

Giao của các nửa không gian là tập lồi. Nếu x_a, $x_b \in R_k$ thì mọi điểm trên đoạn nối cũng thuộc R_k. Mô hình không thể đúng khi một lớp không lồi:

Lớp bị bao quanh

Như một chiếc nhẫn quanh lớp khác.

Hai nhóm tách rời

Lớp khác nằm giữa, như hai phía của một dải.

Hình lưỡi liềm

Hoặc hình chữ "C".

Đây là phiên bản nhiều lớp của hạn chế "không giải được XOR". Dữ liệu sinh viên thuận lợi vì ba lớp là ba dải gần song song.

Ví dụ: ba vòng tròn đồng tâm

600 điểm, 200 mỗi lớp, bán kính 1, 3, 5 (có nhiễu). Lớp 1 là vòng bao quanh lớp 0 nên không lồi.

Kết quả tuyến tính

Accuracy huấn luyện 36,2%, kiểm tra 35,0% (ngẫu nhiên là 33,3%). $J = 1{,}0964$ chỉ thấp hơn $\ln 3 = 1{,}0986$; $\|\mathbf{W}\|_F \approx 0{,}11$.

Vì sao

Các lớp đều có tâm ở gốc nên trung bình x_1, x_2 mỗi lớp bằng 0: gradient tại $\mathbf{W} = \mathbf{0}$ gần như bằng 0. Mô hình gán $p \approx 1/3$ ở mọi điểm.

Giống bộ dữ liệu XOR ở bài Logistic Regression: không có hướng tuyến tính nào cải thiện được J.

Giải pháp: thêm đặc trưng đa thức

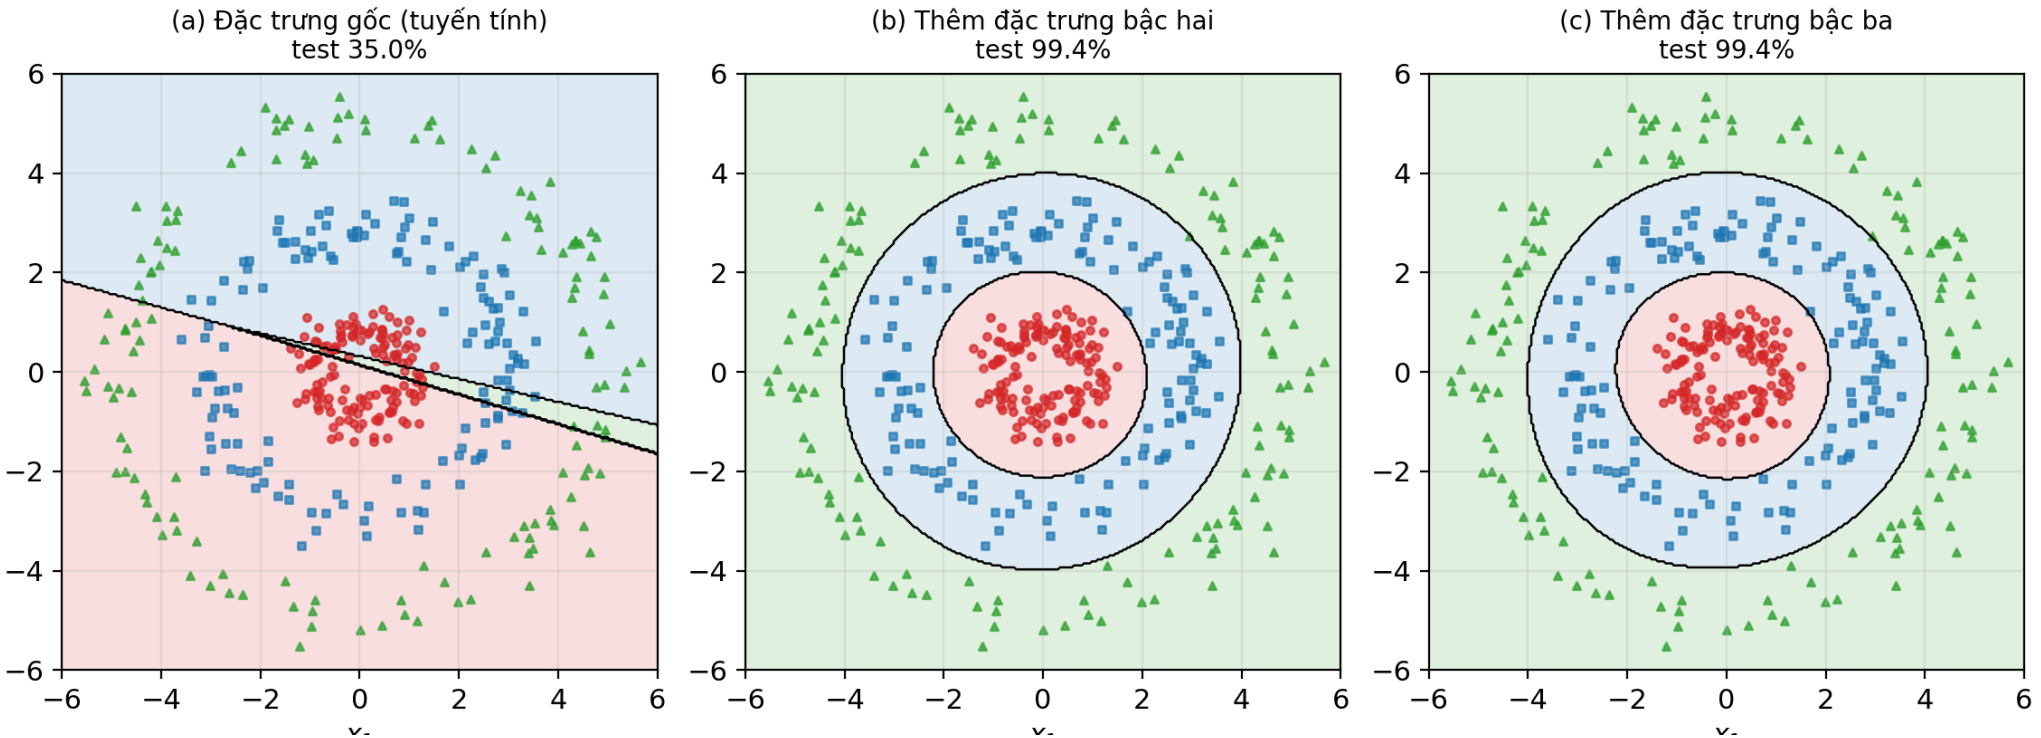
Mô hình chỉ cần tuyến tính theo tham số, không cần tuyến tính theo dữ liệu gốc. Với bậc 2:

$$\varphi(x) = (x_1, x_2, x_1^2, x_1x_2, x_2^2)$$

$$s_k = w_{0k} + w_{1k}x_1 + w_{2k}x_2 + w_{3k}x_1^2 + w_{4k}x_1x_2 + w_{5k}x_2^2$$

Mọi công thức ở mục 3 giữ nguyên, chỉ thay **X** bằng ma trận đặc trưng mới (rồi chuẩn hóa). Biên $s_k = s_j$ là đường conic; với dữ liệu vòng tròn, hiệu điểm số chỉ phụ thuộc $r^2 = x_1^2 + x_2^2$, nên biên là các đường tròn đồng tâm.

Hình 13. Ba vòng tròn đồng tâm: đặc trưng gốc và đa thức



(a) Đặc trưng gốc: $\mathbf{W} \approx \mathbf{0}$, vùng quyết định gần như một đường thẳng. (b) Thêm bậc 2: hai đường biên là hai đường tròn. (c) Bậc 3: gần như không đổi. Cả ba dùng $\lambda = 10^{-3}$.

Kết quả và cái giá của đặc trưng đa thức

Mô hình	Số tham số	J	Acc huấn luyện	Acc kiểm tra	$\|\tilde{W}\|_F$
Tuyến tính	9	1,0964	36,2%	35,0%	0,11
Bậc 2, $\lambda = 0$	18	0,0085	100,0%	99,4%	22,12
Bậc 2, $\lambda = 10^{-3}$	18	0,0543	99,8%	99,4%	11,15
Bậc 3, $\lambda = 10^{-3}$	30	0,0538	100,0%	99,4%	11,13

Nhận xét

Chỉ thêm 3 đặc trưng, accuracy nhảy từ 35,0% lên 99,4%. Bậc 3 không hơn bậc 2 vì biên thật là đường tròn. Với $\lambda = 0$, $\|\tilde{W}\|$ gấp đôi: L2 giữ trọng số không phình ra.

Cái giá

Số đặc trưng mới $C(d+k, k) - 1$ và tham số $K \cdot C(d+k, k)$. Ví dụ $d = 10$, $K = 10$, bậc 3: 285 đặc trưng, 2860 tham số. Cần L2 và chuẩn hóa; lối thoát là mạng nơ-ron (mục 6.3).

Tóm tắt mục 4

Mẫu sai

Đóng góp $\|\mathbf{x}\|\cdot\|\mathbf{p}-\mathbf{y}\|$ (với $\|\mathbf{p}-\mathbf{y}\| < 2$). Một bước SGD: lớp đúng tăng theo $1 - p_c$, lớp sai giảm theo p_k, tổng bằng 0. "Mềm" hơn Perceptron.

Khởi tạo, η, thang đo

Mọi khởi tạo cho cùng **J** và **P**; $\mathbf{W}_\infty = \mathbf{W}^*_{\text{tâm}} + v_0 1^T$. Chuẩn hóa: 45 epoch so với 8170.

Lồi nhưng suy biến

H nửa xác định dương, có d + 1 trị riêng 0. **W** không duy nhất dù **P** duy nhất. Ổn định khi $\eta < 2/\lambda_{max}$; κ giảm từ 4880 xuống 39.

Phân tách hoàn hảo

$J \to 0$ khi $\|\mathbf{W}\| \to \infty$, xác suất cực đoan. L2 cho nghiệm hữu hạn, các cột trung bình 0; λ quá lớn thì khớp kém.

Giới hạn tuyến tính

Vùng quyết định luôn lồi: ba vòng tròn chỉ đạt 35,0%. Đặc trưng đa thức: 99,4% với 18 tham số, nhưng số tham số tăng rất nhanh.

Câu hỏi kiểm tra nhanh (1/2)

1. K = 3, $\mathbf{p}$ = (0,1; 0,7; 0,2), lớp thật là lớp 0, $\|\mathbf{x}\|^2 = 10$. Một bước SGD với $\eta = 0{,}05$: tính Δs từng lớp và xác suất mới (biết $s = \ln p$).
2. Hai mẫu cùng $\|x\|$, lớp thật là lớp 1: A có $\mathbf{p}$ = (0,05; 0,90; 0,05), B có $\mathbf{p}$ = (0,5; 0,4; 0,1). Gradient mẫu nào lớn hơn, bao nhiêu lần?
3. Chứng minh $\|\mathbf{p} - \mathbf{y}\| < 2$ với y one-hot và mọi $p_k > 0$.
4. d = 5, K = 4, $\mathbf{X}$ đủ hạng. Hessian cỡ bao nhiêu, hạng bao nhiêu, bao nhiêu trị riêng bằng 0?

Câu hỏi kiểm tra nhanh (2/2)

1. Từ **W = 0**, hàng chệch của nghiệm là (−2; 0; 2). Chạy lại từ khởi tạo có hàng chệch (1; 2; 6), các hàng khác bằng 0: hàng chệch mới là gì? Xác suất có đổi không?
2. K = 3, mẫu đúng có lề m = 2 với cả hai lớp sai. Tính mất mát khi nhân W với c = 1, 2, 3. Giải thích vì sao GD không dừng khi dữ liệu phân tách hoàn hảo.
3. L2 với $\eta = 0{,}5$, $\lambda = 0{,}1$: một đặc trưng có gradient dữ liệu bằng 0 thì sau 10 bước còn bao nhiêu phần trọng số? Vì sao không phạt hàng chệch?
4. d = 3, thêm đa thức bậc tối đa 2, K = 4: bao nhiêu đặc trưng mới và tham số? Vì sao Softmax tuyến tính không phân loại được ba vòng tròn đồng tâm?

Gợi ý đáp án (1/2)

1. $\Delta \mathbf{s} = 0{,}5 \cdot (0{,}9; -0{,}7; -0{,}2) = (0{,}45; -0{,}35; -0{,}10)$. $\mathbf{p}' \propto (0{,}1e^{0{,}45}; 0{,}7e^{-0{,}35}; 0{,}2e^{-0{,}10}) \Rightarrow \mathbf{p}' \approx (0{,}189; 0{,}594; 0{,}218)$. Xác suất lớp đúng tăng $0{,}1 \to 0{,}189$; mất mát $2{,}303 \to 1{,}668$; tổng Δs bằng 0.
2. $\|\mathbf{p} - \mathbf{y}\|$: A $\approx 0{,}122$; B $\approx 0{,}787$. Gradient B lớn hơn A khoảng 6,4 lần.
3. $\|\mathbf{p} - \mathbf{y}\|^2 = (1 - p_c)^2 + \Sigma_{k \neq c} p_k^2 < 2(1 - p_c)^2 < 2$, vì $\Sigma_{k \neq c} p_k = 1 - p_c$ và các $p_k > 0$.
4. **H** cỡ 24×24, hạng $(K - 1)(d + 1) = 18$, có $d + 1 = 6$ trị riêng bằng 0.

Gợi ý đáp án (2/2)

1. $\mathbf{v}_0 = (1 + 2 + 6)/3 = 3$ ở hàng chệch, nên hàng chệch mới $(-2; 0; 2) + 3 = (1; 3; 5)$. Xác suất không đổi: cộng cùng hằng số vào mọi điểm số không đổi softmax.
2. lc = ln(1 + 2e^(−2c)): 0,240; 0,036; 0,0049. Giảm khi c tăng nhưng không bao giờ bằng 0, nên gradient luôn khác 0 và $\|\mathbf{W}\|$ tiếp tục tăng.
3. Mỗi bước nhân $1 - \eta\lambda = 0{,}95$; sau 10 bước còn $0{,}95^{10} \approx 0{,}599$, khoảng 60%. Hàng chệch chỉ dịch điểm số, không ảnh hưởng độ dốc hay độ phức tạp; phạt nó kéo xác suất về bằng nhau một cách không cần thiết.
4. 9 đặc trưng mới (3 bậc một + 6 bậc hai), 4 × 10 = 40 tham số. Vùng quyết định tuyến tính phải lồi nhưng vòng giữa là hình vành khuyên; thêm vào đó đối xứng quay làm $\mathbf{W} \approx 0$.

Softmax Regression · Mục 5

Đánh giá và trực quan hóa mô hình

Mô hình tốt đến đâu? Từ đường cong học, ma trận nhầm lẫn K×K đến chất lượng của chính các xác suất.



Mục này gồm năm phần

5.1 Quan sát

Đường cong học, vùng quyết định và bản đồ xác suất.

5.2 Huấn luyện và kiểm tra

So hai tập, nhận diện học thuộc (overfitting).

5.3 Theo từng lớp

Ma trận K×K, precision, recall, F1, trung bình macro, micro, weighted; quyết định theo chi phí.

5.4 Chất lượng xác suất

Log-loss, điểm Brier, top-k, hiệu chuẩn, AUC one-vs-rest.

5.5 scikit-learn

So sánh với one-vs-rest, chọn siêu tham số bằng kiểm định chéo.

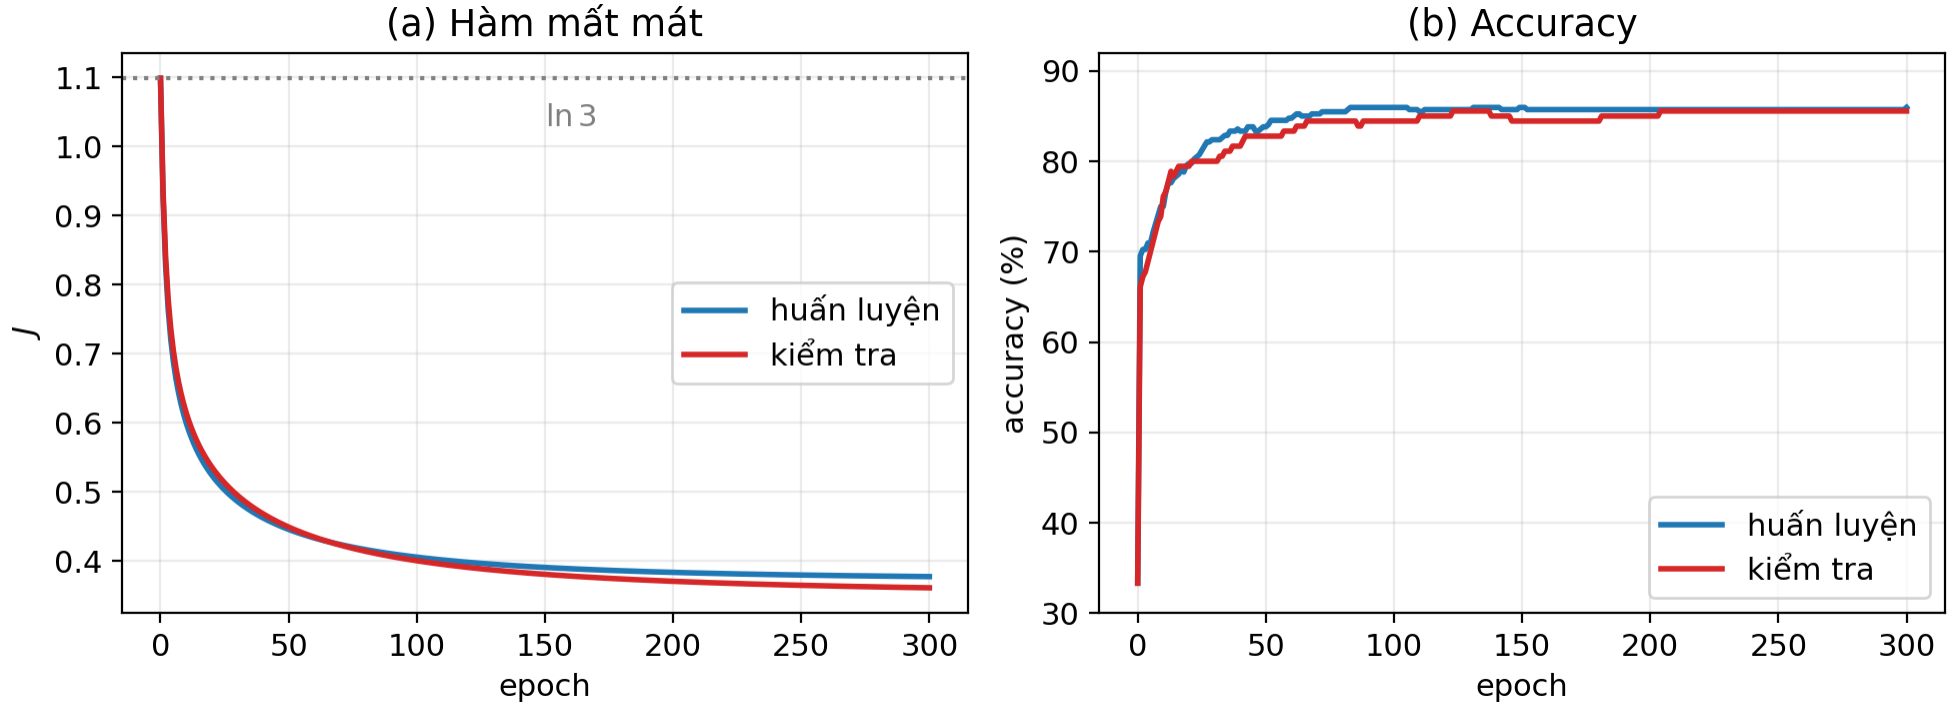
Dữ liệu: 600 sinh viên (420 huấn luyện, 180 kiểm tra, mỗi lớp 60 mẫu kiểm tra); mô hình batch GD, $\eta = 0{,}5$, 2000 epoch, đặc trưng chuẩn hóa, $J(\mathbf{W}^*) = 0{,}3730$.

5.1. Đường cong học

Vẽ J và accuracy theo epoch trên cả hai tập. Tập kiểm tra chỉ để theo dõi, không dùng để cập nhật W.

Epoch	J train	J test	Acc train	Acc test
0	1,0986	1,0986	0,3333	0,3333
10	0,6001	0,6147	0,7500	0,7611
50	0,4455	0,4489	0,8381	0,8278
300	0,3772	0,3610	0,8595	0,8556
2000	0,3730	0,3536	0,8619	0,8500

Hình 14. Đường cong học trên dữ liệu 600 sinh viên



(a) J trên tập huấn luyện và kiểm tra giảm từ ln 3 rồi ổn định. (b) Accuracy tăng vọt trong khoảng 50 epoch đầu rồi gần như đi ngang.

Ba nhận xét từ đường cong học

Epoch 0

W = 0 nên p_{ik} = 1/3 và J = ln 3. Accuracy bằng đúng 1/3: argmax trả lớp có chỉ số nhỏ nhất (rớt), và mỗi tập có đúng một phần ba mẫu thuộc lớp rớt.

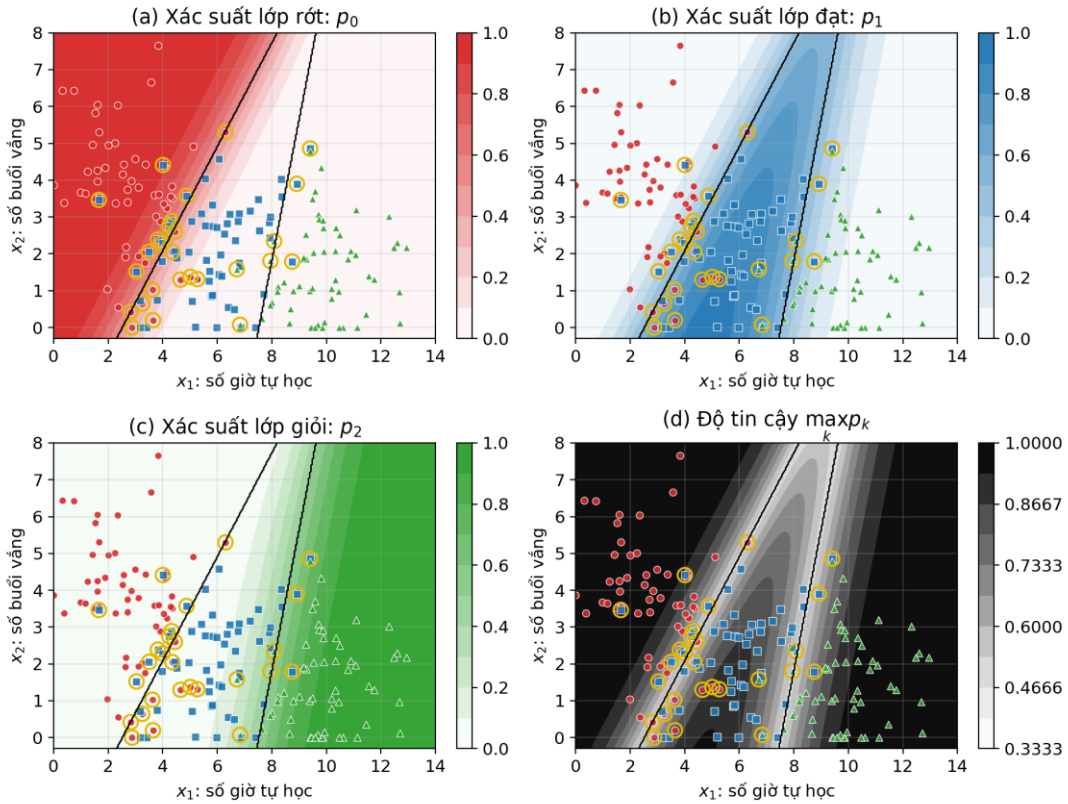
J test < J train

0,354 so với 0,373: tập kiểm tra tình cờ dễ hơn một chút. Đừng đọc quá nhiều từ chênh lệch nhỏ giữa hai tập.

Accuracy bão hòa sớm

Sau epoch 300 accuracy kiểm tra 85,6% → 85,0% (một mẫu) trong khi J vẫn giảm: J cho thấy chất lượng xác suất tiếp tục cải thiện, accuracy thì không.

Hình 15. Bản đồ xác suất trên mặt phẳng đặc trưng



(a), (b), (c): xác suất lớp rớt, đạt, giỏi (màu càng đậm càng cao).

(d): độ tin cậy $\max_k p_k$ (càng tối càng chắc chắn).

Đường liền: biên quyết định, nơi hai lớp cao nhất có xác suất bằng nhau.

Điểm to: 180 mẫu kiểm tra; vòng vàng: 27 mẫu bị đoán sai.

Đọc bản đồ xác suất

Biên thẳng, vùng lồi

Hai đường biên gần song song vì số giờ học x_1 là yếu tố chi phối.

Dải chưa chắc chắn

Đường đồng mức $p_k/p_j = r$ cách biên ln $r/\|\mathbf{w}_k - \mathbf{w}_j\|$. Để đạt 9:1: cách biên rớt/đạt ln 9/1,825 ≈ 1,20 đơn vị; đạt/giỏi ln 9/1,288 ≈ 1,71 đơn vị.

Lớp đạt khó nhất

p_1 chỉ cao trong một dải hẹp; hai bên là hai biên mà mô hình phải chọn giữa đạt và lớp kia.

Dải giữa rớt và đạt hẹp hơn dải giữa đạt và giỏi vì $\|\mathbf{w}_0 - \mathbf{w}_1\|$ lớn hơn nên điểm số đổi nhanh hơn khi rời biên.

Các lỗi nằm ở đâu? (27 lỗi trên 180 mẫu kiểm tra)

18 lỗi

độ tin cậy < 0,7: nằm trong dải chưa chắc chắn quanh biên.

6 lỗi

độ tin cậy từ 0,7 đến 0,9.

3 lỗi sai chắc chắn

độ tin cậy ≥ 0,9. Ví dụ (1,65; 3,46) lớp đạt, p ≈ (0,993; 0,007; 0,000), mất mát 4,95.

Nhóm	Đóng góp vào tổng mất mát (63,64)
27 mẫu sai (15% số mẫu)	58,2%
3 lỗi sai chắc chắn (1,7% số mẫu)	khoảng 16,2%
Riêng mẫu (1,65; 3,46)	7,8%

Trong 72 mẫu có độ tin cậy ≥ 0,9 chỉ 3 mẫu sai (4,2%); trong 42 mẫu < 0,7 có 18 mẫu sai (43%). Độ tin cậy là tín hiệu để xem lại bằng tay.

5.2. Đánh giá trên tập huấn luyện và kiểm tra

Tập kiểm tra bị giấu trong suốt huấn luyện, chỉ dùng ở cuối. Với dữ liệu thật nên chia phân tầng để mỗi lớp có tỉ lệ tương tự ở cả hai tập.

Chỉ số	Huấn luyện (n = 420)	Kiểm tra (n = 180)
Log-loss J	0,3730	0,3536
Accuracy	86,2%	85,0%
Điểm Brier	0,2173	0,2106
AUC one-vs-rest	0,956	0,961

Hai tập gần nhau nên không học thuộc. Sai số chuẩn của accuracy: $\sqrt{(0{,}85 \cdot 0{,}15/180)} \approx 0{,}027$, tức ±2,7 điểm phần trăm.

Ma trận nhầm lẫn trên hai tập

Huấn luyện

thật \ đoán	rớt	đạt	giỏi
rớt	126	14	0
đạt	10	112	18
giỏi	1	15	124

Kiểm tra

thật \ đoán	rớt	đạt	giỏi
rớt	49	11	0
đạt	9	48	3
giỏi	0	4	56

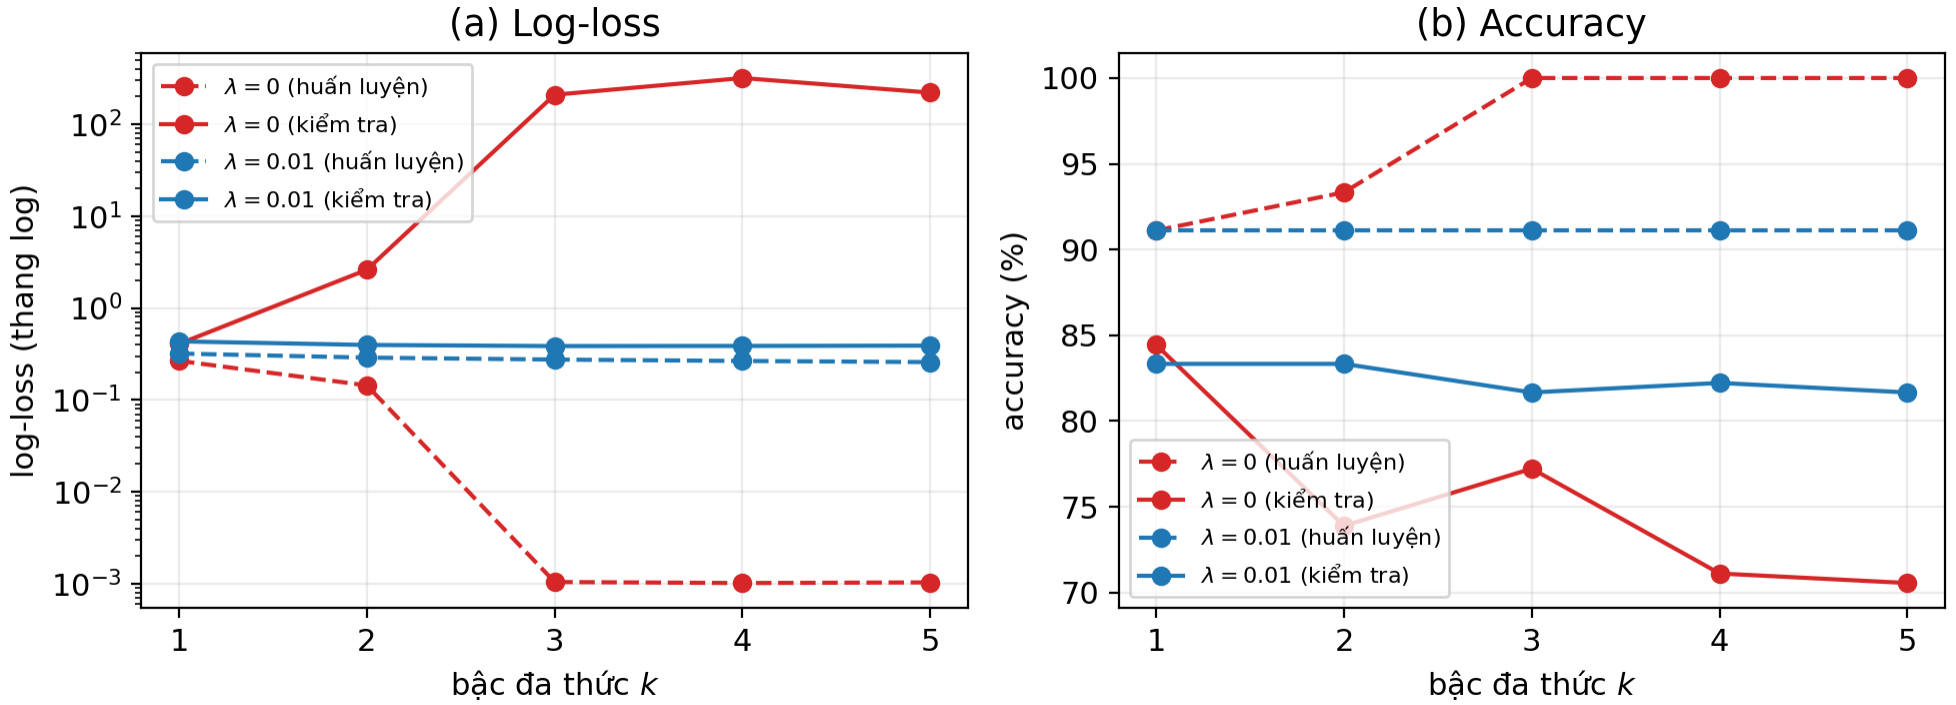
Cả hai có cùng dạng: lỗi tập trung ở ô kề đường chéo (rớt–đạt, đạt–giỏi), gần như không nhầm rớt với giỏi.

Học thuộc: 45 mẫu huấn luyện, đa thức bậc k

Bậc	λ	Tham số	J train	J test	Acc train	Acc test
1	0	9	0,265	0,407	0,911	0,844
1	0,01	9	0,318	0,434	0,911	0,833
2	0	18	0,143	2,609	0,933	0,739
2	0,01	18	0,287	0,396	0,911	0,833
3	0	30	0,000	209,778	1,000	0,772
3	0,01	30	0,274	0,385	1,000	0,817
5	0	63	0,000	221,082	1,000	0,706
5	0,01	63	0,257	0,390	0,911	0,817

Giá trị 209,8 phụ thuộc giới hạn 300 vòng lặp của L-BFGS; điều cần nhớ là bậc độ lớn.

Hình 16. Log-loss và accuracy khi tăng bậc đa thức



(a) Log-loss (thang log), (b) accuracy trên tập huấn luyện (nét đứt) và kiểm tra (nét liền). Không điều chuẩn hóa (đỏ): log-loss kiểm tra tăng vọt. Có L2, λ = 0,01 (xanh): ổn định ở mọi bậc.

Dấu hiệu của overfitting

Học thuộc

Với $k \geq 3$, $\lambda = 0$: accuracy huấn luyện 100%, J huấn luyện ≈ 0, nhưng accuracy kiểm tra giảm từ 84,4% xuống 70,6% ($k = 5$). **W** phình ra, xác suất cực đoan (mục 4.4).

Log-loss nhạy hơn

Ở $k = 2$: accuracy giảm 9 điểm, log-loss kiểm tra tăng 6,6 lần (0,396 → 2,609). Khoảng cách J test − J train lớn là dấu hiệu rõ rệt.

L2 giữ ổn định

Log-loss kiểm tra 0,385 đến 0,434 ở mọi bậc, đổi lại J huấn luyện cao hơn.

Lưu ý: ở đây dùng tập kiểm tra chỉ để minh họa. Trong thực tế chọn bậc và λ trên tập kiểm định riêng hoặc kiểm định chéo (mục 5.5).

5.3. Ma trận nhầm lẫn K × K

C_{ij} là số mẫu có lớp thật i bị đoán là lớp j (hàng = thật, cột = dự đoán). Có K(K − 1) = 6 loại nhầm lẫn, thay vì hai loại FP và FN.

$$\text{Accuracy} = \text{tr}(\mathbf{C})/n = (49 + 48 + 56)/180 = 0{,}850$$

Cách đọc

Rớt bị nhầm thành đạt 11 lần; đạt bị nhầm thành rớt 9 lần và thành giỏi 3 lần; giỏi bị nhầm thành đạt 4 lần.

Nhầm lẫn theo thứ bậc

Không có sinh viên rớt nào bị đoán là giỏi và ngược lại: chỉ các lớp kề nhau mới bị lẫn, đúng hình học của bài toán.

Precision, recall, F1 theo từng lớp

Xét từng lớp k như bài toán "lớp k hay không" (ý tưởng one-vs-rest):

$TP_k = C_{kk}$, $FN_k = \Sigma_{j \neq k} C_{kj}$ (phần còn lại của hàng k), $FP_k = \Sigma_{i \neq k} C_{ik}$ (phần còn lại của cột k)

$Precision_k = C_{kk}$ / tổng cột k

Trong các mẫu được đoán là lớp k, bao nhiêu thật sự thuộc lớp k.

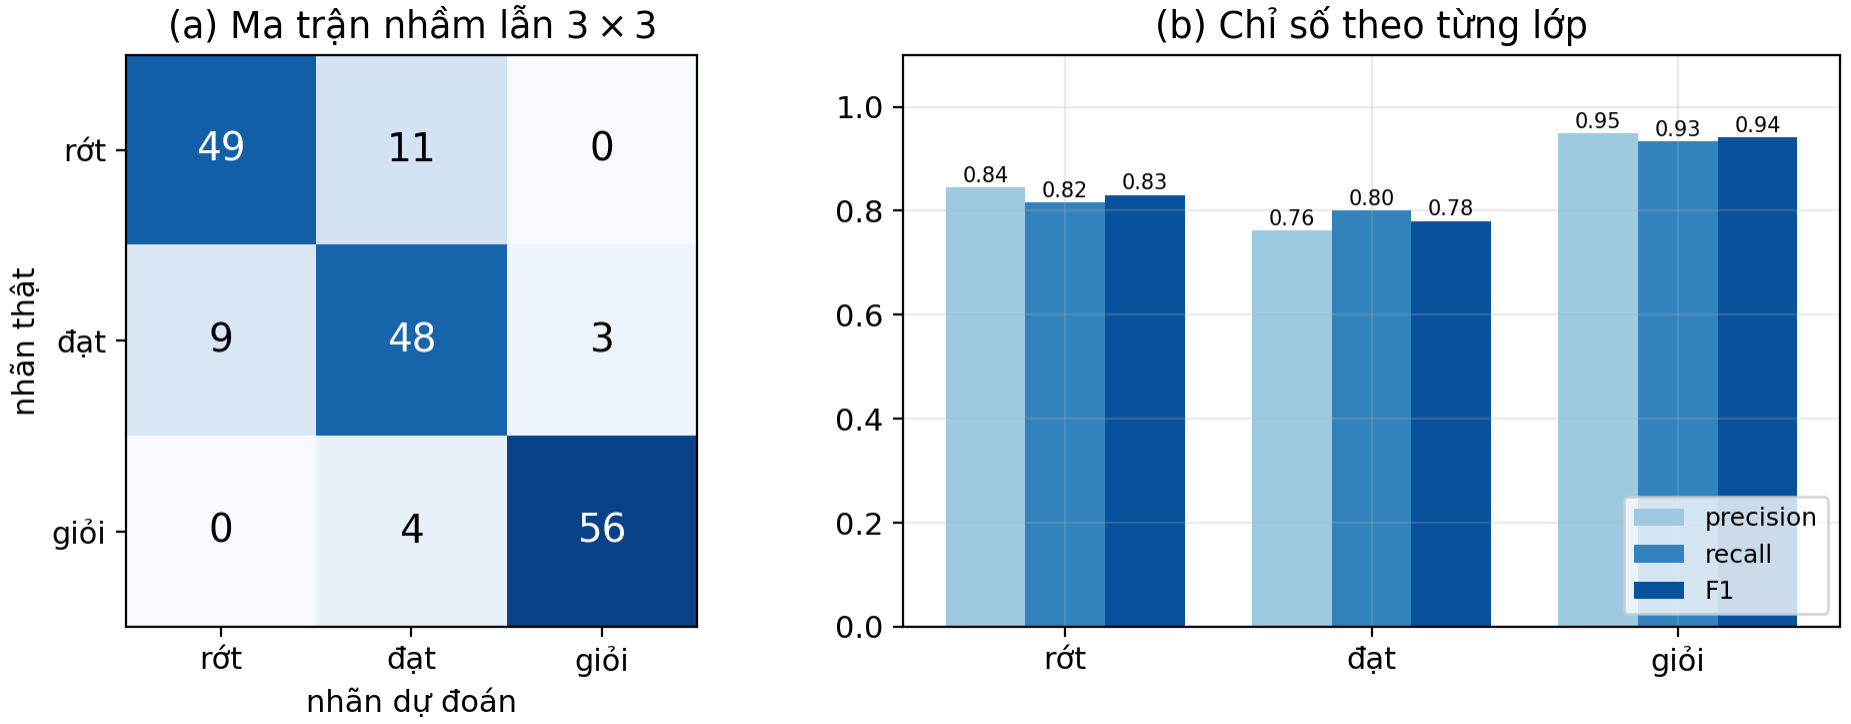
$Recall_k = C_{kk}$ / tổng hàng k

Trong các mẫu thật sự thuộc lớp k, mô hình tìm ra bao nhiêu.

$F1_k = 2TP / (2TP + FP + FN)$

Trung bình điều hòa của precision và recall.

Hình 17. Ma trận nhầm lẫn và các chỉ số theo từng lớp



(a) Ma trận nhầm lẫn 3×3 trên tập kiểm tra: lỗi chỉ xảy ra giữa các lớp kề nhau. (b) Precision, recall, F1 theo từng lớp: lớp giỏi cao nhất, lớp đạt (nằm giữa) thấp nhất.

Chỉ số theo lớp trên tập kiểm tra

Lớp	TP	FP	FN	Precision	Recall	F1	Support
Rớt	49	9	11	49/58 = 0,845	49/60 = 0,817	0,831	60
Đạt	48	15	12	48/63 = 0,762	48/60 = 0,800	0,780	60
Giỏi	56	3	4	56/59 = 0,949	56/60 = 0,933	0,941	60

Lớp giỏi cao nhất vì nằm ở rìa dữ liệu. Lớp đạt thấp nhất (F1 = 0,780): nằm giữa nên lẫn với cả hai lớp kề.

Ba cách lấy trung bình

Macro

Trung bình đơn giản theo lớp, mỗi lớp trọng số như nhau; nhạy với lớp hiếm.

Weighted

Trung bình có trọng số theo support n_k; bám theo các lớp lớn.

Micro

Gộp TP, FP, FN của mọi lớp rồi tính. Với một nhãn mỗi mẫu: micro-precision = micro-recall = micro-F1 = accuracy.

Trên tập kiểm tra	Precision	Recall	F1
Macro	0,852	0,850	0,851
Weighted	0,852	0,850	0,851
Micro	0,850	0,850	0,850

Macro và weighted trùng nhau vì ba lớp cân bằng (n_k = 60).

Khi lớp lệch: macro khác hẳn accuracy

Ví dụ giả định n = 160, lớp giỏi hiếm (10 mẫu). C = [[90, 5, 5], [10, 30, 10], [2, 3, 5]], accuracy = 125/160 = 0,781.

Lớp	Precision	Recall	F1	Support
Rớt	0,882	0,900	0,891	100
Đạt	0,789	0,600	0,682	50
Giỏi	0,250	0,500	0,333	10
Macro F1			0,635	
Weighted F1			0,791	
Micro F1 (= accuracy)			0,781	

Macro-F1 thấp hơn nhiều vì lớp giỏi chỉ chiếm 6% mẫu nhưng đóng góp 1/3 vào macro. Nếu mọi lớp quan trọng như nhau, nhìn macro; tốt nhất luôn xem cả bảng theo lớp.

Quyết định theo ma trận chi phí

Với K lớp, c_{kj} là chi phí khi lớp thật k bị đoán là j ($c_{kk} = 0$). Chi phí kỳ vọng khi đoán j là $\Sigma_k\, p_k\, c_{kj}$:

$$\hat{y} = \operatorname{argmin}_j \Sigma_k\, p_k\, c_{kj} = \operatorname{argmin}_j \mathbf{p}\cdot\mathbf{c}_j$$

Mọi sai lầm như nhau

$c_{kj} = 1$ thì chi phí kỳ vọng là $1 - p_j$: trở về $\hat{y} = \operatorname{argmax}_j p_j$. K = 2 cho ngưỡng $\tau^* = c_{FP}/(c_{FP} + c_{FN})$.

Ví dụ: bỏ sót sinh viên rớt tốn gấp 3

c = [[0, 3, 3], [1, 0, 1], [1, 1, 0]]. Với **p** = (0,2; 0,5; 0,3): **p·c** = (0,8; 0,9; 1,1), chọn “rớt” dù xác suất chỉ 0,2; argmax chọn “đạt”.

Kết quả quyết định theo chi phí

Ma trận nhầm lẫn mới

thật \ đoán	rớt	đạt	giỏi
rớt	56	4	0
đạt	18	39	3
giỏi	0	4	56

Đánh đổi

	argmax	theo chi phí
Recall rớt	81,7%	93,3%
Tổng chi phí	49	37
Accuracy	85,0%	83,9%

Đổi lại, nhiều sinh viên đạt bị báo nhầm là rớt (18 thay vì 9). Quy tắc này chỉ tối ưu khi xác suất được hiệu chuẩn tốt, và ma trận chi phí phải do bài toán quy định trước, không chọn bằng cách thử trên tập kiểm tra.

5.4. Log-loss đa lớp và điểm Brier

$$\text{Log-loss} = -(1/n)\,\Sigma_i \ln q_i,\ \text{Brier} = (1/n)\,\Sigma_i \|\mathbf{p}_i - \mathbf{y}_i\|^2$$

Chỉ số (tập kiểm tra)	Softmax	Mô hình hằng
Log-loss	0,3536	ln 3 = 1,0986
Điểm Brier	0,2106	2/3 ≈ 0,6667

e^(−0,3536) ≈ 0,702: trung bình nhân của xác suất gán cho lớp thật là khoảng 0,70, so với 0,33 nếu đoán mò. Brier nằm trong [0, 2], càng nhỏ càng tốt.

Top-k accuracy

Mẫu đúng ở top-k nếu lớp thật nằm trong k lớp có xác suất cao nhất

k	1	2	3
Top-k accuracy (kiểm tra)	85,0%	100%	100%

Hữu ích khi K lớn và "gợi ý vài lớp" là chấp nhận được. Với K = 3, top-2 = 100% cho biết lớp thật không bao giờ bị đẩy xuống hạng cuối: một khía cạnh của nhận xét "chỉ nhầm giữa các lớp kề nhau".

Hiệu chuẩn theo độ tin cậy

Chia mẫu theo độ tin cậy $\max_k p_k$, so độ tin cậy trung bình với tỉ lệ đúng thực tế:

Nhóm $\max_k p_k$	Số mẫu	Tin cậy TB	Tỉ lệ đúng
[0,333; 0,5)	1	0,498	0,000
[0,5; 0,6)	21	0,553	0,571
[0,6; 0,7)	20	0,655	0,600
[0,7; 0,8)	30	0,765	0,933
[0,8; 0,9)	36	0,854	0,889
[0,9; 1]	72	0,968	0,958

ECE = Σ (n_b/n)·|acc_b − conf_b| = 0,050. Độ tin cậy trung bình (0,826) hơi thấp hơn accuracy (0,850): mô hình hơi dè dặt, không quá tự tin. Nhiều nhóm chỉ 20 đến 36 mẫu nên các số rất nhiễu.

AUC theo kiểu one-vs-rest

Coi p_k là điểm số của bộ phân loại "lớp k hay không". AUC_k là xác suất một mẫu thuộc lớp k có p_k cao hơn một mẫu không thuộc lớp k (mỗi lớp có 60 × 120 = 7200 cặp).

Lớp	Rớt	Đạt	Giỏi	Macro
AUC	0,969	0,920	0,993	0,961

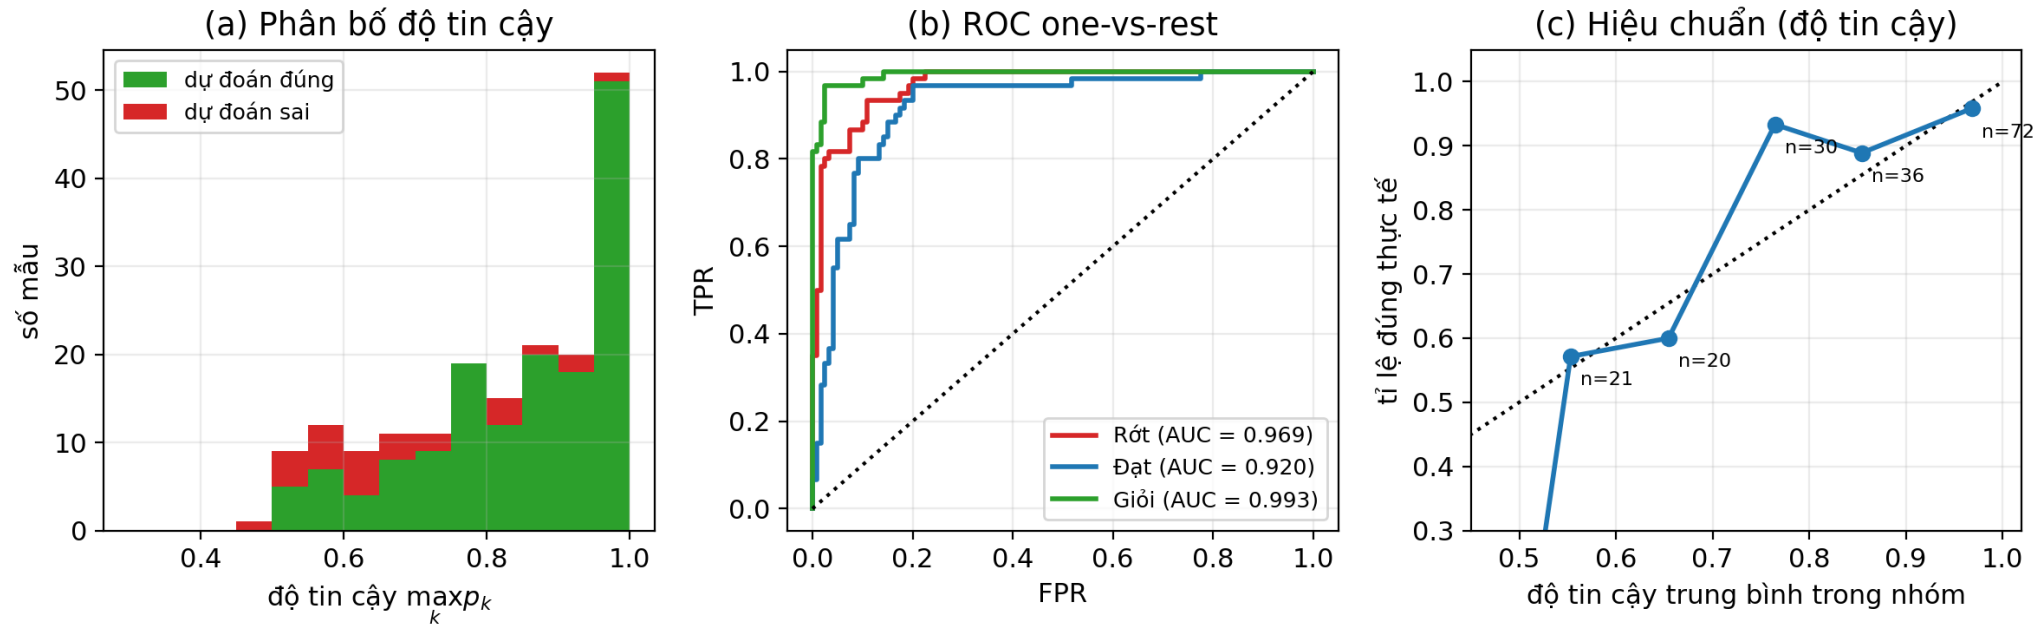
Lớp đạt thấp nhất

p_1 phải phân biệt đạt với cả rớt lẫn giỏi (hai phía khác nhau), nên xếp hạng khó hơn.

AUC không đo hiệu chuẩn

Chỉ phụ thuộc thứ tự: thay p bằng p^2 (giữ thứ tự) thì AUC không đổi dù xác suất bị méo.

Hình 18. Độ tin cậy, ROC và hiệu chuẩn



(a) Phân bố độ tin cậy, tách theo dự đoán đúng (xanh) và sai (đỏ): lỗi dồn về vùng thấp. (b) ROC one-vs-rest từng lớp (đạt thấp nhất). (c) Biểu đồ hiệu chuẩn: các điểm gần đường chéo.

Khi nào dùng chỉ số nào?

Câu hỏi	Chỉ số phù hợp
Tỉ lệ nhãn đúng (lớp cân bằng, mọi sai như nhau)	Accuracy
Lớp lệch hoặc tầm quan trọng khác nhau	Ma trận nhầm lẫn, precision/recall/F1 từng lớp, macro-F1
Lớp thật có nằm trong vài ứng viên đầu không	Top-k accuracy
Xếp hạng từng lớp, không phụ thuộc ngưỡng	ROC và AUC one-vs-rest
Chất lượng của chính xác suất	Log-loss, điểm Brier, hiệu chuẩn (ECE)
Các loại sai có chi phí khác nhau	Ma trận chi phí, $\text{argmin}_j\, p \cdot c_j$
So sánh cấu hình khi huấn luyện	Log-loss (nhạy hơn accuracy)

5.5. LogisticRegression của scikit-learn

Khi có hơn hai lớp, thư viện dùng cross-entropy nhiều lớp với softmax: chính là Softmax Regression.

C và λ

Mục tiêu: $C \cdot \Sigma l_i + \frac{1}{2}\|\tilde{W}\|^2_F$, tương đương $\lambda = 1/(Cn)$. C nhỏ thì điều chuẩn hóa mạnh; mặc định C = 1 ($\lambda = 1/420 \approx 0{,}0024$).

Tham số

coef_ cỡ K×d (mỗi hàng một lớp), intercept_ độ dài K. W = vstack([intercept_, coef_.T]); không cần thêm cột 1.

Phương thức

predict_proba → P; decision_function → S = XW; predict → lớp có điểm cao nhất.

Hệ số khớp mô hình tự cài đặt sau khi đổi về thang gốc; xác suất lệch tối đa 0,00035 (ta dừng sau 2000 epoch). Các hàng của hệ số cũng cộng lại bằng 0 (5,6324 + 1,8761 − 7,5085 = 0).

So sánh Softmax và one-vs-rest

Mô hình	Acc train	Acc test	Log-loss test	AUC OvR
Softmax, tự cài đặt	86,2%	85,0%	0,3536	0,9606
Softmax, sklearn ($C = 10^{10}$)	86,2%	85,0%	0,3536	0,9606
Softmax, sklearn ($C = 1$)	86,2%	85,6%	0,3541	0,9607
One-vs-rest, sklearn	83,3%	80,6%	0,4772	0,9337

Cài đặt đúng

Tự cài đặt và sklearn trùng nhau đến chữ số thập phân thứ tư.

Softmax hơn rõ rệt

Accuracy cao hơn 4,4 điểm, log-loss thấp hơn, AUC cao hơn: K bộ nhị phân độc lập yếu với lớp đạt ở giữa và xác suất không cộng lại bằng 1.

Chọn siêu tham số bằng kiểm định chéo 5 lần

Không chọn theo tập kiểm tra. Chia tập huấn luyện thành 5 phần; chuẩn hóa nằm trong pipeline để tránh rò rỉ thông tin.

C	Bậc 1: CV acc	Bậc 1: CV log-loss	Bậc 2: CV acc	Bậc 2: CV log-loss
0,001	0,7095	0,9938	0,7667	0,9276
0,01	0,7762	0,7144	0,8262	0,6242
0,1	0,8381	0,4791	0,8452	0,4300
1	0,8524	0,3963	0,8452	0,3876
10	0,8548	0,3932	0,8381	0,3915
100	0,8524	0,3944	0,8381	0,3936

Đọc kết quả kiểm định chéo

C quá nhỏ (0,001)

Điều chuẩn hóa quá mạnh, mô hình bị bó (underfit): accuracy 71 đến 77%, log-loss gần ln 3.

C ≥ 1

Kết quả gần như không đổi: 2 đặc trưng và 420 mẫu nên không có nguy cơ overfit.

Bậc 2 không đáng kể

Log-loss tốt nhất 0,3876 chỉ thấp hơn 0,0056 so với bậc 1 (0,3932), nhỏ hơn dao động giữa các lần chia (±0,03). Ưu tiên mô hình đơn giản: bậc 1, C = 10.

Đánh giá một lần trên tập kiểm tra	Accuracy	Log-loss
Bậc 1, C = 10	0,8500	0,3543
Bậc 2, C = 1	0,8444	0,3564

Lời khuyên thực hành

1. Chuẩn hóa đặc trưng bên trong pipeline.
2. Chọn siêu tham số (C, bậc đa thức) bằng kiểm định chéo trên tập huấn luyện, nên dựa vào log-loss.
3. Báo cáo một lần trên tập kiểm tra: ma trận K×K, precision/recall/F1 từng lớp (macro-F1 nếu lệch), log-loss, AUC; không chỉ accuracy.
4. Nếu các loại sai có hậu quả khác nhau, quyết định bằng ma trận chi phí trên xác suất đã kiểm tra hiệu chuẩn.
5. So với one-vs-rest khi nghi ngờ lợi ích của mô hình xác suất chung.

Tóm tắt mục 5

Quan sát

J giảm từ ln 3 xuống 0,37; accuracy bão hòa sớm hơn J. Bản đồ xác suất: vùng lồi, hai biên thẳng, dải chưa chắc chắn rộng ln 9/$\|w_k - w_j\|$. 18/27 lỗi có độ tin cậy < 0,7.

Huấn luyện và kiểm tra

Hai tập gần nhau (85,0%, ±2,7 điểm) nên không overfit. Với ít dữ liệu và nhiều đặc trưng, log-loss kiểm tra tăng vọt khi $\lambda = 0$; L2 giữ ổn định.

Theo từng lớp

Precision chia cột, recall chia hàng. Macro, weighted, micro (= accuracy). Lớp đạt có F1 thấp nhất (0,780). Chi phí: $\text{argmin}_j\, p \cdot c_j$.

Chất lượng xác suất

Log-loss 0,354 (so với 1,099), Brier 0,211 (so với 0,667), top-2 = 100%, ECE = 0,050, AUC OvR 0,969; 0,920; 0,993 (macro 0,961).

scikit-learn

Khớp mã tự cài đặt (sai số $3 \cdot 10^{-4}$); $\lambda = 1/(Cn)$. Softmax hơn one-vs-rest (85,0% so với 80,6%). Chọn siêu tham số bằng kiểm định chéo; tập kiểm tra dùng một lần.

Câu hỏi kiểm tra nhanh (1/2)

1. Vì sao ở epoch 0 ($W = 0$), $J = \ln 3$ và accuracy bằng 1/3 trên tập có ba lớp cân bằng?
2. $C = [[50, 5, 5], [10, 30, 10], [0, 5, 35]]$: tính accuracy, precision, recall, F1 từng lớp, rồi macro-F1, weighted-F1, micro-F1.
3. Bộ phân loại ba lớp luôn đoán lớp 0 trên tập có 95% mẫu lớp 0 và 2,5% mỗi lớp còn lại: accuracy và macro-recall? Điều này nói gì về việc chọn chỉ số?
4. $p = (0{,}5; 0{,}3; 0{,}2)$, lớp thật là lớp 1: đúng ở top-k nhỏ nhất bằng bao nhiêu? Tính $-\ln q$ và $\|p - y\|^2$.

Câu hỏi kiểm tra nhanh (2/2)

1. Với c = [[0, 3, 3], [1, 0, 1], [1, 1, 0]], quyết định theo chi phí cho p = (0,4; 0,35; 0,25) là lớp nào? Khi nào khác argmax?
2. Nhóm [0,7; 0,8) có 30 mẫu, tin cậy TB 0,765, tỉ lệ đúng 0,933, n = 180: đóng góp vào ECE? Vì sao không kết luận mô hình "dè dặt" chỉ từ nhóm này?
3. AUC đạt = 0,9197 với 60 mẫu dương, 120 mẫu âm: khoảng bao nhiêu cặp xếp đúng? Vì sao AUC lớp này thấp hơn hai lớp kia?
4. C = 1, n = 420: λ = ? intercept_ cỡ 3, coef_ cỡ 3×2: W cỡ bao nhiêu và dựng thế nào? Vì sao StandardScaler phải nằm trong pipeline khi kiểm định chéo?

Gợi ý đáp án (1/2)

1. $W = 0$ nên mọi điểm số bằng 0, $p_{ik} = 1/3$, mỗi mẫu bị phạt $-\ln(1/3) = \ln 3$. Argmax trả lớp 0 cho mọi mẫu nên chỉ mẫu thật sự lớp 0 được đoán đúng: 1/3.
2. $n = 150$, đường chéo 115 nên accuracy $\approx 0{,}767$. Precision: 0,833; 0,750; 0,700. Recall: 0,833; 0,600; 0,875. F1: 0,833; 0,667; 0,778. Macro-F1 = 0,759; weighted-F1 $\approx 0{,}763$; micro-F1 $\approx 0{,}767$.
3. Accuracy = 95%; macro-recall $= (1 + 0 + 0)/3 \approx 0{,}333$. Accuracy cao nhưng vô dụng với hai lớp hiếm: khi lớp lệch cần ma trận nhầm lẫn, chỉ số theo lớp và macro.
4. Lớp thật có $p = 0{,}3$, đứng thứ hai: đúng ở top-2. $-\ln 0{,}3 \approx 1{,}204$; $\|p - y\|^2 = 0{,}25 + 0{,}49 + 0{,}04 = 0{,}78$.

Gợi ý đáp án (2/2)

1. Chi phí kỳ vọng: rớt 0,60; đạt 1,45; giỏi 1,55: chọn rớt, trùng argmax. Khác nhau khi có lớp chi phí nhầm cao, ví dụ p = (0,2; 0,5; 0,3): argmax chọn đạt, theo chi phí chọn rớt.
2. $(30/180)\cdot|0{,}933 - 0{,}765| \approx 0{,}028$ trên tổng ECE 0,050. Nhóm chỉ 30 mẫu (sai số chuẩn $\approx 0{,}046$) và nhóm [0,6; 0,7) cho chiều ngược lại (đúng 0,600 < tin cậy 0,655): cần nhìn cả bảng.
3. $0{,}9197 \times 7200 \approx 6622$ cặp. Lớp đạt nằm giữa nên p_1 phải phân biệt đạt với hai lớp ở hai phía, còn p_0 chỉ phân biệt rớt với phần ở một phía.
4. $\lambda = 1/(1\cdot 420) \approx 0{,}0024$. W cỡ 3×3: W = np.vstack([clf.intercept_, clf.coef_.T]). Chuẩn hóa trong pipeline để mỗi lần chia chỉ tính μ, σ từ phần huấn luyện; nếu không, thông tin phần kiểm định rò rỉ và điểm CV lạc quan.

Softmax Regression · Mục 6

Tổng kết và mở rộng

Khi nào dùng Softmax, nó liên hệ thế nào với Logistic Regression và one-vs-rest, và bước tiếp theo là mạng nơ-ron.



Năm mục đã đi qua

Mục	Câu hỏi chính	Kết quả cần nhớ
1	Vì sao Logistic Regression chưa đủ khi K > 2?	Nhãn số phụ thuộc cách đánh số; one-vs-rest cho xác suất không cộng lại bằng 1; cần mô hình chung với nhãn one-hot Y
2	Mô hình là gì?	$\mathbf{S} = \mathbf{XW}$, $\mathbf{P} = \text{softmax}(\mathbf{S})$; K = 2 trở về sigmoid; vùng lồi; **W** dư thừa tham số
3	Huấn luyện thế nào?	$J = -(1/n)\,\Sigma \ln q_i$; $\nabla \mathbf{J} = (1/n)\mathbf{X}^T(\mathbf{P} - \mathbf{Y})$; $J_0 = \ln K$
4	Mô hình học ra sao?	Kéo lớp đúng, đẩy lớp sai theo p_{ik}; J lồi nhưng Hessian suy biến; phân tách hoàn hảo cần L2
5	Mô hình tốt đến đâu?	Ma trận K×K, F1 theo lớp, log-loss, hiệu chuẩn, AUC; 85,0% kiểm tra, log-loss 0,354

6.1. Ưu điểm của Softmax Regression (1/2)

Xác suất cho mọi lớp, tổng bằng 1

Đầu ra p_i là phân phối thật sự: dùng được log-loss, Brier, hiệu chuẩn và quyết định theo chi phí.

Học chung K lớp

Các cột w_k cạnh tranh qua mẫu số chung nên lớp ở giữa vẫn học tốt: 85,0% so với 80,6% của one-vs-rest.

Cơ sở xác suất rõ ràng

Cross-entropy là âm log-hợp lý của phân phối loại; không phụ thuộc cách đặt tên lớp.

Bài toán tối ưu lồi

Mọi cực tiểu địa phương là toàn cục; GD hội tụ từ mọi khởi tạo; ma trận P cuối là duy nhất.

6.1. Ưu điểm của Softmax Regression (2/2)

Gradient gọn, dễ cài đặt

$(1/n)\mathbf{X}^T(\mathbf{P} - \mathbf{Y})$ cùng dạng hồi quy tuyến tính và Logistic; vài chục dòng NumPy. Chi phí mỗi epoch O(ndK).

Có thể diễn giải

Hiệu hai cột trọng số cho biết ảnh hưởng của từng đặc trưng lên tỉ lệ giữa hai lớp.

Nền tảng cho mô hình sâu

Softmax là lớp đầu ra chuẩn của mạng nơ-ron phân loại nhiều lớp (mục 6.3).

Diễn giải trọng số bằng odds giữa hai lớp

$p_k/p_l = e^{(s_k - s_l)}$: tăng x_j một đơn vị nhân odds lớp k so với lớp l với $e^{(w_{jk} - w_{jl})}$. Với W gốc ở mục 4.2:

Thay đổi	Đạt : rớt	Giỏi : đạt	Giỏi : rớt
Thêm 1 giờ tự học (x_1)	$e^{1,489} \approx 4,43$	$e^{1,246} \approx 3,48$	$e^{2,735} \approx 15,4$
Thêm 1 buổi vắng (x_2)	$e^{-1,056} \approx 0,348$	$e^{-0,325} \approx 0,722$	$e^{-1,381} \approx 0,251$

Kiểm chứng: học 6 giờ, vắng 2 buổi có $p \approx (0,041; 0,890; 0,069)$, odds đạt:rớt $\approx 21,5$; học 7 giờ thì $p \approx (0,008; 0,781; 0,211)$, odds $\approx 95,5 = 21,5 \times 4,43$.

Mỗi hệ số chỉ có nghĩa khi so hai lớp với nhau (hệ quả của dư thừa tham số).

Hạn chế và cách khắc phục (1/2)

Hạn chế	Nguyên nhân	Hướng khắc phục
Vùng quyết định luôn lồi, biên thẳng	Điểm số tuyến tính theo đặc trưng	Đặc trưng đa thức, tương tác; mạng nơ-ron
Nghiệm **W** không duy nhất	Bất biến khi cộng $\mathbf{v1}^T$; Hessian suy biến	Khởi tạo 0; lớp tham chiếu; L2
$\mathbf{W} \to \infty$ khi phân tách hoàn hảo	$J \to 0$ nhưng không đạt	L2; dừng sớm; thêm dữ liệu
Nhạy với thang đo đặc trưng	Số điều kiện Hessian lớn	Chuẩn hóa bằng thống kê tập huấn luyện

Hạn chế và cách khắc phục (2/2)

Hạn chế	Nguyên nhân	Hướng khắc phục
Ngoại lai, nhãn nhiễu kéo mạnh	Gradient $\propto \|\mathbf{x}_i\| \cdot \|\mathbf{p}_i - \mathbf{y}_i\|$	L2; làm sạch dữ liệu; mất mát bền vững hơn
Lớp mất cân bằng	Cross-entropy trung bình ưu tiên lớp đông	Trọng số lớp, lấy mẫu lại, macro-F1
Chi phí tăng theo K	(d+1)K tham số; softmax trên cả K lớp	Softmax phân cấp, lấy mẫu lớp âm
Lớp loại trừ nhau, độc lập với phương án khác	Công thức softmax	K sigmoid độc lập (đa nhãn); nested logit

Giả định 1: mỗi mẫu có đúng một nhãn

$\Sigma_k p_k = 1$: tăng xác suất một lớp thì các lớp còn lại giảm

Softmax: các lớp loại trừ nhau

Phù hợp khi mỗi mẫu thuộc đúng một lớp (chữ số, rớt/đạt/giỏi).

Đa nhãn: dùng K sigmoid độc lập

Ví dụ gắn nhiều thẻ cho một bài báo: mỗi nhãn một cross-entropy nhị phân, tổng xác suất không cần bằng 1. Đây là chỗ one-vs-rest phù hợp.

Giả định 2: độc lập với phương án không liên quan (IIA)

$p_k/p_l = e^{(s_k - s_l)}$ chỉ phụ thuộc điểm số của hai lớp đó. Với s = (1, 2, 3): **p** ≈ (0,090; 0,245; 0,665), $p_1/p_0 = e \approx 2{,}72$. Bỏ lớp thứ ba: **p** ≈ (0,269; 0,731), tỉ lệ vẫn bằng e.

Ví dụ ô tô và xe buýt

Ô tô và xe buýt đỏ có xác suất 1/2 mỗi loại. Thêm xe buýt xanh giống hệt xe buýt đỏ.

Thực tế

Người dùng chia đôi phần xe buýt: (1/2, 1/4, 1/4).

Softmax dự đoán

Giữ tỉ lệ ô tô : xe buýt đỏ = 1 nên cho (1/3, 1/3, 1/3): không thực tế.

6.2. Logistic, one-vs-rest và Softmax

	Logistic	One-vs-rest	Softmax
Số lớp	2	$K \geq 2$	$K \geq 2$
Tham số	vector $\mathbf{w}$	K vector $\mathbf{w}_k$, huấn luyện riêng	ma trận $\mathbf{W}$, huấn luyện chung
Biến đổi	sigmoid $\sigma(s)$	sigmoid cho từng k	softmax trên cả $\mathbf{s}$
Đầu ra	$P(y = 1)$	K xác suất độc lập, $\Sigma \neq 1$	phân phối, $\Sigma = 1$
Mất mát	cross-entropy nhị phân	K cross-entropy nhị phân	cross-entropy nhiều lớp
Gradient	$(1/n)\mathbf{X}^T(\sigma - y)$	cột k như Logistic	$(1/n)\mathbf{X}^T(\mathbf{P} - \mathbf{Y})$
Nghiệm	$\mathbf{w}$ duy nhất	mỗi $\mathbf{w}_k$ duy nhất	$\mathbf{P}$ duy nhất, $\mathbf{W}$ sai khác $\mathbf{v1}^T$
Đa nhãn	không	có	không

K = 2: Softmax chính là Logistic Regression

Hai cột đối nhau

$\nabla_{\mathbf{w}_1} J = (1/n)\mathbf{X}^T(\mathbf{p}_{:,1} - \mathbf{y}_{:,1})$ và $\nabla_{\mathbf{w}_0} J = -\nabla_{\mathbf{w}_1} J$, vì $\mathbf{p}_{:,0} - \mathbf{y}_{:,0} = -(p_{:,1} - y_{:,1})$.

$\mathbf{w}_1 \leftarrow \mathbf{w}_1 - \eta\nabla$; $\mathbf{w}_0 \leftarrow \mathbf{w}_0 + \eta\nabla$

Hiệu hai cột

$\mathbf{w}_1 - \mathbf{w}_0 \leftarrow \mathbf{w}_1 - \mathbf{w}_0 - 2\eta\nabla_{\mathbf{w}_1} J$

Đặt $\mathbf{w} = \mathbf{w}_1 - \mathbf{w}_0$: đúng một bước GD của Logistic Regression với tốc độ học 2η.

Khởi tạo từ 0 thì $\mathbf{w}_1 = -\mathbf{w}_0 = \mathbf{w}/2$ ở mọi bước. Logistic chỉ là trường hợp đặc biệt, gọn hơn: một trong hai cột là dư thừa.

Kiểm chứng bằng số (lớp rớt và giỏi)

Softmax K = 2 với $\eta = 0{,}5$ và Logistic với $\eta = 1{,}0$, cùng 300 bước, đặc trưng chuẩn hóa:

	$w_1 - w_0$ (softmax)	w (logistic, η gấp đôi)
Giá trị	(0,2941; 4,7815; −1,6007)	(0,2941; 4,7815; −1,6007)

max |khác biệt| ≈ $8{,}9 \cdot 10^{-16}$

Trùng nhau đến sai số làm tròn số học: hai quá trình huấn luyện cho cùng quỹ đạo của $w_1 - w_0$.

One-vs-rest và Softmax trên 600 sinh viên

Ba bộ phân loại độc lập

Bộ	k = 0 (rớt)	k = 1 (đạt)	k = 2 (giỏi)
J	0,154	0,609	0,221

Bộ "đạt" có J = 0,609, chỉ thấp hơn ln 2 ≈ 0,693 một chút: gần như không học được vì không đường thẳng nào tách đạt khỏi cả rớt lẫn giỏi.

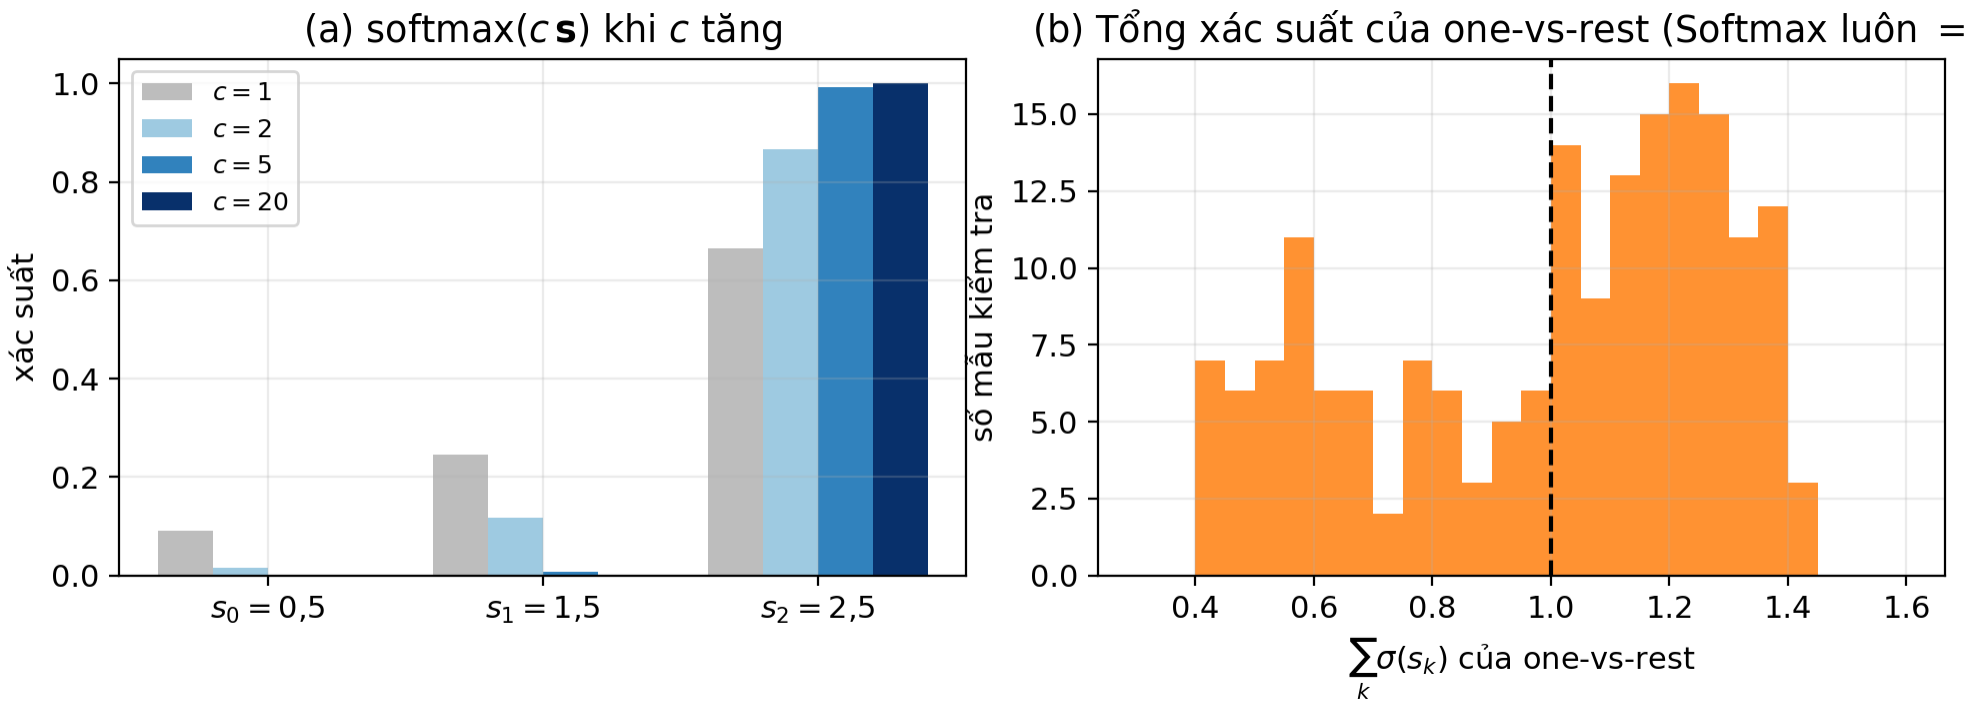
Xác suất không cộng lại bằng 1

Tổng nằm từ 0,41 đến 1,44; 60,6% mẫu kiểm tra có tổng ngoài [0,8; 1,2].

48 mẫu (26,7%) không bộ nào cho xác suất ≥ 0,5; 3 mẫu có nhiều hơn một bộ "nhận".

Softmax chỉ cần so sánh điểm số của đạt với từng lớp kề, không cần tách đạt khỏi cả hai.

Hình 19. “Nhiệt độ” của softmax và tổng xác suất one-vs-rest



(a) Softmax với hệ số c: khi c tăng, xác suất dồn vào lớp có điểm số lớn nhất (s = 0,5; 1,5; 2,5). (b) Tổng xác suất của one-vs-rest trên tập kiểm tra rất khác 1; tổng của Softmax luôn bằng 1.

Softmax tốt hơn ở mọi chỉ số

Kiểm tra (180 mẫu)	One-vs-rest	Softmax
Accuracy	80,6%	85,0%
Macro-F1	0,798	0,851
Log-loss	0,477	0,354
AUC one-vs-rest	0,934	0,961

One-vs-rest vẫn có chỗ đứng: dùng cho đa nhãn, huấn luyện song song K bộ, thay bộ nhị phân bằng loại khác (như SVM), và tránh giả định IIA. Khi các lớp loại trừ nhau và cần xác suất đúng nghĩa, Softmax là lựa chọn mặc định.

Perceptron nhiều lớp là giới hạn “cứng” của Softmax

$$(1/c)\cdot l_i(c\cdot s_i) \to \max_j s_{ij} - s_i, y_i \text{ khi } c \to \infty$$

c là nghịch đảo nhiệt độ. Giới hạn chính là mất mát của Perceptron nhiều lớp. Ví dụ s = (0,5; 1,5; 2,5), lớp thật là lớp 1:

c	**p = softmax(c·s)**	**l_i / c**
1	0,090 0,245 0,665	1,408
2	0,016 0,117 0,867	1,072
5	0,000 0,007 0,993	1,001
20	0,000 0,000 1,000	1,000
$\to \infty$	one-hot của lớp 2	2,5 - 1,5 = 1

c → 0: phân phối đều. Hệ số c xuất hiện trong nhiều kỹ thuật học sâu (nhiệt độ).

6.3. Softmax là mạng nơ-ron không có lớp ẩn

Mạng một lớp ẩn gồm m nơ-ron, để mô hình tự học đặc trưng thay vì ta tự đoán đa thức:

$$\mathbf{H} = \tanh(\tilde{\mathbf{X}}\mathbf{W}_1),\ \mathbf{S} = \tilde{\mathbf{H}}\mathbf{W}_2,\ \mathbf{P} = \mathrm{softmax}(\mathbf{S})$$

Lớp ra = Softmax Regression

P = softmax($\tilde{\mathbf{H}}\mathbf{W}_2$) chạy trên đặc trưng **H** do mạng học. Bỏ lớp ẩn (**H** = **X**) thì trở về mục 2.

Kích thước và tham số

$\mathbf{W}_1$ cỡ (d+1)×m, $\mathbf{W}_2$ cỡ (m+1)×K; tổng (d+1)m + (m+1)K. Mất mát vẫn là cross-entropy.

Lan truyền ngược: phần lớn công thức đã có

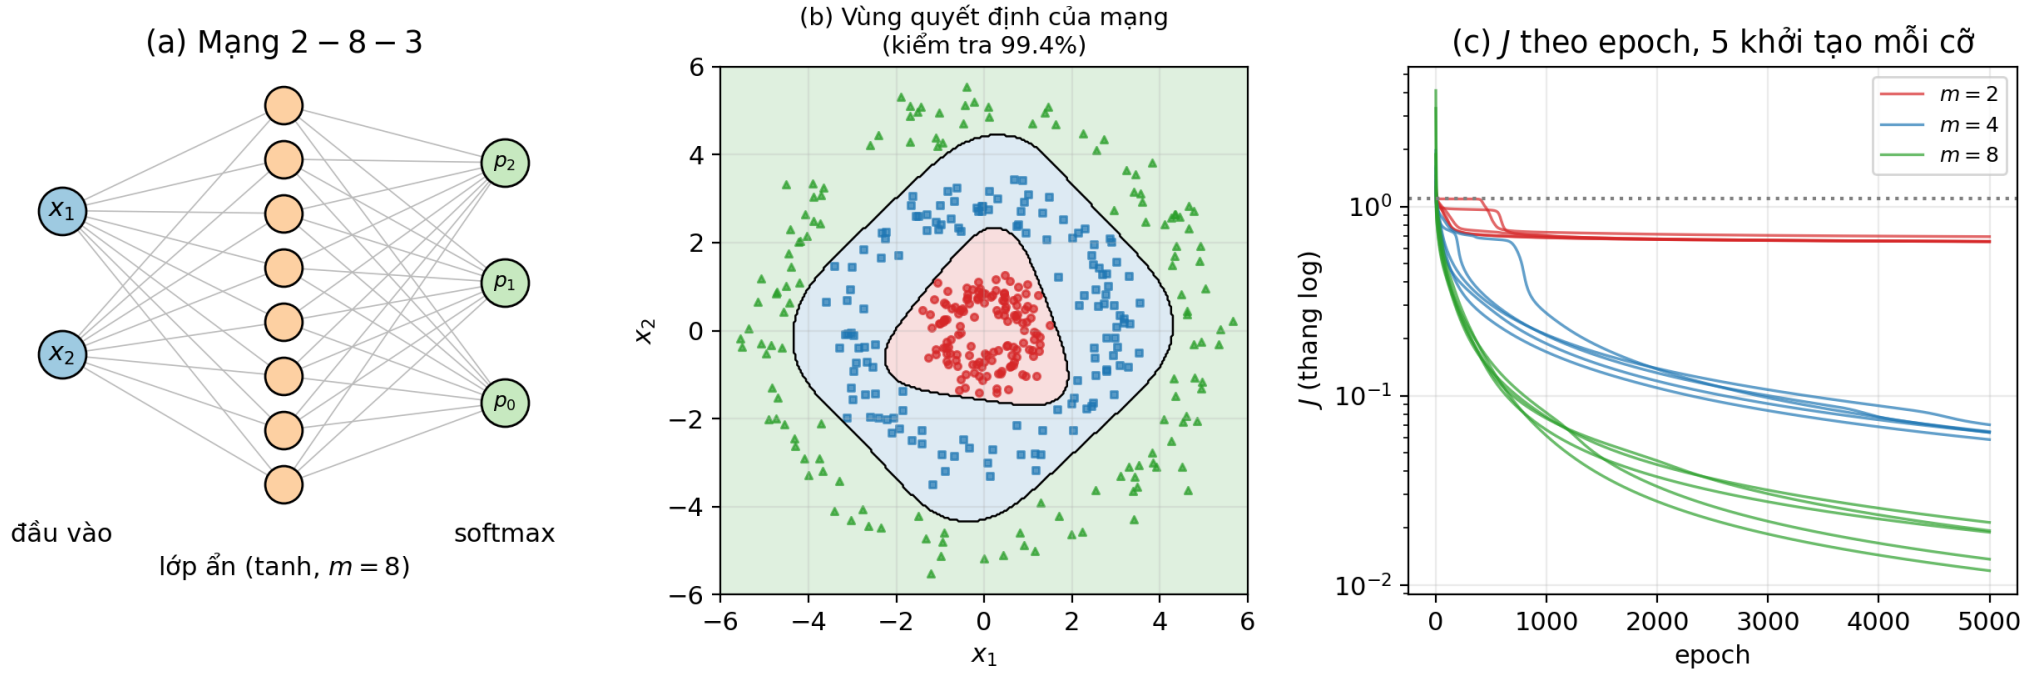
$$D_2 = \partial J/\partial S = (1/n)(P - Y),\ \nabla_{W_2} J = \tilde{\mathbf{H}}^{T} D_2$$

$$D_1 = (D_2 V^{T}) \odot (1 - H \odot H),\ \nabla_\{W_1\} J = \tilde{X}^{T} D_1$$

V là W_2 bỏ hàng chệch; $\tanh'(z) = 1 - \tanh^2(z)$. Kiểm tra cỡ: D_2 n×K, V^{T} K×m nên D_1 n×m, $\nabla_\{W_1\} J$ cỡ (d+1)×m.

Nhận ra P − Y là sai số ở lớp ra chính là bước đầu tiên của lan truyền ngược trong mọi mạng phân loại nhiều lớp.

Hình 20. Mạng nơ-ron trên ba vòng tròn đồng tâm



(a) Mạng 2-8-3: lớp ra softmax là Softmax Regression trên đặc trưng ẩn. (b) Vùng quyết định cong do mạng tự học. (c) J theo epoch (thang log) với 5 khởi tạo cho mỗi cỡ lớp ẩn m; đường chấm là ln 3.

Kết quả trên ba vòng tròn (kiểm tra 180 điểm)

Mô hình	Đặc trưng	Tham số	Accuracy kiểm tra
Softmax Regression	x_1, x_2	9	35,0%
Softmax + đa thức bậc 2 (tự chọn)	5 đặc trưng	18	99,4%
Mạng 2-2-3	x_1, x_2	15	62,8% đến 70,0%
Mạng 2-4-3	x_1, x_2	27	96,1% đến 98,9%
Mạng 2-8-3	x_1, x_2	51	96,1% đến 99,4%

Gradient lan truyền ngược khớp đạo hàm số cỡ 10^{-10}. Mạng m = 8 chỉ nhận hai đặc trưng gốc mà vẫn đạt tới 99,4%, tương đương mô hình đa thức ta tự chọn.

Mạng khác Softmax Regression ở đâu?

Cỡ lớp ẩn quan trọng

m = 2 quá ít để tạo vùng lồng nhau cho ba lớp: J dừng ở $\approx 0{,}65$. m = 4 và 8 giảm J xuống 0,06 và 0,02.

J không còn lồi

Với $m \geq 4$, các khởi tạo cho J cuối và accuracy khác nhau (96,1% đến 99,4% với m = 8), khác Softmax Regression.

Cần khởi tạo ngẫu nhiên

$W_1 = W_2 = 0$ thì H = 0, V = 0 nên $\nabla_{W_1} J = 0$: nơ-ron ẩn không học (J đứng ở ln 3, accuracy 33,3%). Khởi tạo giống nhau thì các nơ-ron luôn giống nhau.

Học sâu: cùng công thức, nhiều lớp hơn

- Softmax là lớp đầu ra chuẩn: điểm số lớp cuối gọi là logits; gradient lớp ra vẫn là P − Y (chia n).
- Điều chuẩn hóa L2 gọi là weight decay: $W \leftarrow (1 - \eta\lambda)W - \eta\nabla J$. Ngoài ra còn dừng sớm, dropout.
- Mini-batch SGD và biến thể (momentum, Adam) là cách huấn luyện chuẩn, vì dữ liệu lớn và J không lồi.
- Hàm kích hoạt ReLU, $\varphi(z) = \max(0, z)$, giúp mạng sâu huấn luyện ổn định hơn tanh.
- Chuẩn hóa đầu vào, ma trận nhầm lẫn, log-loss, hiệu chuẩn giữ nguyên vai trò. Mạng sâu thường quá tự tin: chia logits cho một nhiệt độ để hiệu chuẩn lại.

Một “mạch” chung của các mô hình đã học

Mô hình	Điểm số	Đầu ra	Mất mát	Gradient theo điểm số
Hồi quy tuyến tính	$\mathbf{Xw}$	chính điểm số	bình phương sai số	$\propto \hat{y} - y$
Logistic Regression	$\mathbf{Xw}$	$\sigma(s)$	cross-entropy nhị phân	$\sigma(s) - y$
Softmax Regression	$\mathbf{XW}$	softmax($\mathbf{s}$)	cross-entropy nhiều lớp	$\mathbf{P - Y}$
Mạng nơ-ron (đầu ra softmax)	$\mathbf{\tilde{H}W}_L$, $\mathbf{H}$ do mạng học	softmax($\mathbf{s}$)	cross-entropy nhiều lớp	$\mathbf{P - Y}$, rồi lan truyền ngược

Ba mô hình đầu thuộc họ mô hình tuyến tính tổng quát, gradient chung dạng $\mathbf{X}^T$(dự đoán − thực tế). Mạng nơ-ron mở rộng họ này bằng cách để đặc trưng được học ra.

Tổng kết mục 6

Khi nào dùng

Các lớp loại trừ nhau và cần xác suất đúng nghĩa: Softmax là mặc định. Đa nhãn: K sigmoid. Chú ý IIA, mất cân bằng, ngoại lai.

Quan hệ giữa các mô hình

K = 2 là Logistic (tốc độ học 2η). One-vs-rest cho $\Sigma \neq 1$ và kém hơn Softmax (80,6% so với 85,0%). $c \to \infty$ cho Perceptron nhiều lớp.

Hướng đi tiếp

Softmax là lớp ra của mạng nơ-ron: gradient **P − Y**, lan truyền ngược, khởi tạo ngẫu nhiên, J không còn lồi.

Diễn giải: tăng x_j một đơn vị nhân p_k/p_l với $e^{(w_{jk} - w_{jl})}$; chỉ hiệu hai cột có ý nghĩa.

6.4. Bài tập A: tính tay và lý thuyết (1/2)

1. A1. $s = (2, 0, -1)$, lớp thật là lớp 2: tính p, mất mát cross-entropy và gradient $p - y$.
2. A2. $X = [[1, 0], [1, 2]]$ (cột đầu là chệch), $y = (0, 2)$, $K = 3$, $W_0 = 0$: tính Y, $J(W_0)$, ∇J, W_1 với $\eta = 1$ và $J(W_1)$.
3. A3. Chứng minh Softmax $K = 2$ tương đương Logistic với $w = w_1 - w_0$; quỹ đạo $w_1 - w_0$ trùng Logistic có tốc độ học 2η.
4. A4. $W^* = [[1, -1, 0], [2, 0, -2]]$; cộng $v1^T$ với $v = (1, 3)^T$ được W'. Với $x = (1, 1)$, so điểm số và xác suất. Điều này nói gì về tính duy nhất?

6.4. Bài tập A: tính tay và lý thuyết (2/2)

1. A5. Dùng W gốc ở mục 6.1: hệ số nhân odds giỏi:đạt khi thêm một buổi vắng; odds đạt:rớt khi thêm 2 giờ học.
2. A6. s = (1, 2, 3): tính p và p_1/p_0; bỏ lớp thứ ba và tính lại. Rút ra gì về IIA? Ví dụ ô tô và hai xe buýt?
3. A7. Tính softmax(c·s) với s = (1, 2, 3), c = 1 và c = 2. Điều gì xảy ra khi $c \to 0$ và $c \to \infty$?
4. A8. Mạng d = 4, m = 10, K = 3: số tham số, cỡ $\nabla_{W_1}J$ và $\nabla_{W_2}J$; so với Softmax Regression. Nếu $W_1 = 0$ và $W_2 = 0$ thì sao?

Bài tập B: lập trình (1/2)

1. B1. Cài đặt Softmax từ đầu bằng NumPy; huấn luyện trên Iris (chia 70/30 phân tầng, $\eta = 0{,}5$, 2000 epoch). Kiểm tra gradient bằng đạo hàm số, in J đầu (kỳ vọng ln 3), so với LogisticRegression.
2. B2. Tính Hessian tại W* của B1: trị riêng, số trị riêng bằng 0, hạng. So với d + 1 và (K − 1)(d + 1).
3. B3. Trên 9 sinh viên, cài L2 và huấn luyện với $\lambda \in \{0; 0{,}001; 0{,}01; 0{,}1\}$ ($\eta = 0{,}5$, 10^5 bước): in $\|W\|_F$ và xác suất sinh viên 6 theo λ.
4. B4. Tái hiện mục 5 trên 600 sinh viên: ma trận nhầm lẫn, precision/recall/F1 và macro-F1, log-loss, ECE, AUC. Tự cài rồi đối chiếu classification_report, roc_auc_score.

Bài tập B: lập trình (2/2) và C: mở rộng

1. B5. load_digits (64 đặc trưng, 10 lớp), pipeline StandardScaler + LogisticRegression(C = 1): accuracy, macro-F1, log-loss, top-3, AUC; cặp lớp nhầm nhiều nhất.
2. B6. So Softmax với OneVsRestClassifier trên cùng dữ liệu B5 theo accuracy, macro-F1, log-loss.
3. B7. Huấn luyện ở $\eta \in \{0{,}01; 0{,}1; 0{,}5; 2; 10\}$ trên đặc trưng chuẩn hóa và gốc; ghi số epoch để J cách $J^* \leq 0{,}001$. Đối chiếu bảng mục 4.2 và ngưỡng $2/\lambda max$.
4. C1. Cài mạng một lớp ẩn softmax; kiểm tra gradient; m = 2, 4, 8 trên ba vòng tròn (5 khởi tạo). Vì sao m = 2 không đủ? C2. Vì sao mạng không học khi $W_1 = W_2 = 0$?
5. C3. Làm lệch dữ liệu (14 mẫu lớp giỏi), so class_weight = None và "balanced" (accuracy, macro-F1, recall giỏi). C4. Gắn thẻ đa nhãn: softmax hay K sigmoid? Viết mất mát và gradient.

Gợi ý đáp án A (1/2)

1. A1. $e^2 = 7{,}389$; $e^0 = 1$; $e^{-1} = 0{,}368$; tổng 8,757 $\Rightarrow p \approx (0{,}844; 0{,}114; 0{,}042)$. Mất mát $-\ln 0{,}042 \approx 3{,}170$; $p - y \approx (0{,}844; 0{,}114; -0{,}958)$, tổng bằng 0.
2. A2. $J(W_0) = \ln 3 \approx 1{,}0986$. $\nabla J = (1/2)X^T(P - Y) = [[-1/6, 1/3, -1/6], [1/3, 1/3, -2/3]]$. $W_1 = -\nabla J$. Điểm số: $s_1 = (1/6, -1/3, 1/6)$, $s_2 = (-1/2, -1, 3/2) \Rightarrow p_1 \approx (0{,}384; 0{,}233; 0{,}384)$, $p_2 \approx (0{,}111; 0{,}067; 0{,}821)$; $J(W_1) \approx 0{,}577$.
3. A3. $p_1 = \sigma(x(w_1 - w_0))$; $\nabla_{w_0}J = -\nabla_{w_1}J$ nên $(w_1 - w_0)' = w_1 - w_0 - 2\eta\nabla_{w_1}J$, đúng GD Logistic với tốc độ học 2η.
4. A4. $s^* = (3, -1, -2)$, $s' = (7, 3, 2) = s^* + 4$ (vì $xv = 4$): cùng $p \approx (0{,}976; 0{,}018; 0{,}007)$. W' cũng tối ưu: W không duy nhất, chỉ P duy nhất.

Gợi ý đáp án A (2/2)

1. A5. Giỏi:đạt khi thêm một buổi vắng nhân $e^{(-0,569 - (-0,244))} = e^{(-0,325)} \approx 0,722$. Đạt:rớt khi thêm 2 giờ nhân $4,43^2 = e^{2,978} \approx 19,6$.
2. A6. $p \approx (0,090; 0,245; 0,665)$, $p_1/p_0 = e \approx 2,718$. Bỏ lớp thứ ba: $p \approx (0,269; 0,731)$, tỉ lệ vẫn e: tính IIA. Thêm xe buýt xanh cùng điểm số, mô hình cho (1/3, 1/3, 1/3), thực tế (1/2, 1/4, 1/4).
3. A7. $c = 1$: (0,090; 0,245; 0,665). $c = 2$: (0,016; 0,117; 0,867). $c \to 0$: phân phối đều; $c \to \infty$: one-hot của lớp có điểm cao nhất, và $l_i/c \to \max_j s_{ij} - s_{i,y_i}$.
4. A8. $(d+1)m + (m+1)K = 5 \cdot 10 + 11 \cdot 3 = 83$ tham số, so với $(d+1)K = 15$. $\nabla_{W_1} J$ cỡ 5×10, $\nabla_{W_2} J$ cỡ 11×3. Nếu $W_1 = W_2 = 0$ thì $H = 0$, $V = 0$ nên W_1 không bao giờ cập nhật: mạng suy biến thành mô hình chỉ có hệ số chệch.

Gợi ý đáp án B (kết quả tham khảo)

1. B1. J đầu = ln 3 = 1,0986; J cuối ≈ 0,0634; accuracy huấn luyện ≈ 97,1% (105 mẫu), kiểm tra 100% (45 mẫu); gradient khớp đạo hàm số cỡ 10^{-10}.
2. B2. Iris: H cỡ 15×15, có d + 1 = 5 trị riêng bằng 0 (cỡ 10^{-17}), hạng (K − 1)(d + 1) = 10; cần phân biệt "bằng 0" với "rất nhỏ nhưng dương" (cỡ 10^{-4}).
3. B3. $\|W\|_F \approx 23{,}0$ (vẫn tăng), 9,08, 4,68, 1,81; xác suất sinh viên 6 từ (0; 1; 0) đến (0,334; 0,589; 0,077).
4. B4. F1 theo lớp 0,831; 0,780; 0,941, macro-F1 0,851, log-loss 0,3536, ECE 0,050, AUC 0,969; 0,920; 0,993 (macro 0,961).
5. B5, B6. digits: accuracy ≈ 97,2%, macro-F1 ≈ 0,972, log-loss ≈ 0,102, top-3 = 100%, AUC ≈ 0,999; nhầm nhiều nhất 8 → 1 (khoảng 3 mẫu). One-vs-rest: 96,9%, 0,969, log-loss ≈ 0,138: kém hơn, khác biệt rõ nhất ở log-loss.
6. B7. Chuẩn hóa: 24569 ($\eta = 0{,}01$), 2455 (0,1), 490 (0,5), 121 (2) epoch; $\eta = 10$ dao động quanh 0,405. Gốc: 16341 (0,05), 8170 (0,1); $\eta \geq 0{,}2$ dao động; khớp ngưỡng 8,75 và 0,199.

Gợi ý đáp án C

1. C1. m = 2: accuracy 62,8% đến 70,0%, $J \approx 0{,}65$; m = 4: 96,1% đến 98,9%; m = 8: 96,1% đến 99,4%. Hai nơ-ron ẩn chỉ tạo hai đường cong, không đủ cho cả hình tròn giữa lẫn vành khuyên.
2. C2. $W_1 = W_2 = 0$: W_1 không cập nhật, J đứng ở ln 3, accuracy 1/3. Khởi tạo hằng số khác 0: các nơ-ron ẩn giống hệt nhau, nhận cùng gradient nên luôn giống nhau (đối xứng không bị phá): mạng như chỉ có một nơ-ron ẩn.
3. C3. Không trọng số: accuracy 75,0%, macro-F1 0,753, recall giỏi 56,7%. “balanced”: 82,2%, 0,825, recall giỏi 83,3% (precision giỏi giảm từ 1,00 xuống 0,94). $J_w = -(1/n) \Sigma w_\{y_i\} \ln q_i$, với w_k tỉ lệ nghịch với số mẫu lớp k nên lớp hiếm đóng góp nhiều hơn.
4. C4. Dùng K sigmoid độc lập (một mẫu có thể có nhiều thẻ): $J = -(1/n) \Sigma_i \Sigma_k [t_{ik} \ln \sigma(s_{ik}) + (1 - t_{ik}) \ln(1 - \sigma(s_{ik}))]$, gradient theo điểm số $\sigma(s_{ik}) - t_{ik}$. Đây là gợi ý suy ra từ các mục 6.1 và 6.2, tài liệu không có đáp án sẵn.